MASTER THESIS XIDIAN UNIVERSITY

西安电子科技大学

硕士学位论文

数据中心磁盘故障预测模型研究

作者姓名 杨冲昊

学校导师姓名、职称 王 平 教授

企业导师姓名、职称 王定健 高工

申请学位类别 工程硕士

中国知网 https://www.cnki.net

学校代码 10701　　学　号 1601120482
分 类 号 TN918　　密　级 公开

西安电子科技大学

硕士学位论文

数据中心磁盘故障预测模型研究

作者姓名：杨冲昊

领　　域：电子与通信工程

学位类别：工程硕士

学校导师姓名、职称：王 平 教授

企业导师姓名、职称：王定健 高工

学　　院：通信工程学院

提交日期：2019 年 4 月

中国知网 https://www.cnki.net

Research on Data Center Disk Failure Prediction Model

A thesis submitted to

XIDIAN UNIVERSITY

in partial fulfillment of the requirements

for the degree of Master

in Electronics and Communications Engineering

By

Yang Chonghao

Supervisor: Wang Ping Title: Professor

Supervisor: Wang Dingjian Title: Senior Engineer

April 2019

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

摘要

随着大数据时代的到来，海量数据的存储逐渐由客户端转移到了云端并存储在企业数据中心里，一旦数据中心发生故障，将会给企业带来巨大的损失。而如今现代数据中心的数据存储依旧以磁盘存储占主导地位，因此磁盘故障的维护是如今运维人员的主要工作之一。如何高效的利用现有资源根据磁盘数据对未来可能发生的磁盘故障进行预测，并及时备份数据更换磁盘来提高现代数据中心存储系统的可靠性已成为数据中心的研究热点之一。然而，当前数据中心磁盘故障预测研究中仍存在着不足之处，目前主要采用的磁盘故障预测建模方法均是以分类问题进行处理，只能预测出磁盘未来是否会发生故障，而且当前磁盘故障预测问题的研究精度也不够高，同时磁盘故障预测模型的有效预测时间也比较短，运维和相关工作人员无法及时根据磁盘预测的结果将磁盘进行备份和处理。

针对上述问题，本文提出一种磁盘故障预测模型，该模型分为基于卷积神经网络的磁盘故障检测模型和融合 LSTM 神经网络和 fbprophet 算法的 SMART 数据预测模型，该模型可以准确预测出未来 30 天的磁盘故障情况。主要内容如下：

(1) 磁盘故障检测模型利用卷积神经网络具有分别计算、利用局部处理数据、权值共享，使其可以在输入数据保持高维度的同时自动有效的提取出数据有用特征并进行计算，最终达到分类目的的特点。利用多个卷积层和池化层对磁盘信息进行特征提取，得到能够检测出磁盘是否故障与当前磁盘信息之间的关系，从而检测出当前磁盘是否存在故障的结果。

(2) SMART 数据预测模型利用 LSTM 神经网络解决长时间依赖问题与 fbprophet 算法对时间序列数据周期性和节假日特点拟合效果较好的特点，将两个模型融合来提高磁盘 SMART 数据的预测精度。将模型融合的 SMART 数据预测模型输出结果输入到磁盘故障检测模型中，建立能确定未来具体发生故障时间的磁盘故障预测模型。实验证明该模型可以准确预测出磁盘未来 30 天的故障信息。

本文工作为未来磁盘故障预测系统的设计和实现提供了一定参考。

关键词： 数据中心， 磁盘故障预测， SMART， CNN， LSTM 神经网络， fbprophet 算法, 模型融合

中国知网 https://www.cnki.net

ABSTRACT

With the advent of the era of big data, the storage of massive data is gradually transferred from the client to the cloud and stored in the enterprise data center. Once the data center fails, it will bring a lot of losses to the enterprise. Nowadays, data storage in modern data centers still dominates disk storage, so the maintenance of disk failure is one of the main tasks of today's operation and maintenance personnel. How to effectively use existing resources to predict future disk failures based on disk data, and timely backup data replacement disks to improve the reliability of modern data center storage systems has become one of the research hotspots of data centers. However, there are still some shortcomings in the current data center disk failure prediction research. At present, the main disk failure prediction modeling methods are processed by classification problems, which can only predict whether the disk will fail in the future, and the current disk failure. The research accuracy of the prediction problem is not high enough, and the effective prediction time of the disk failure prediction model is also short. The operation and maintenance and related personnel cannot timely back up and process the disk according to the results predicted by the disk.

Aiming at the above problems, this thesis proposes a disk failure prediction model, which is divided into a disk failure detection model based on convolutional neural network and a SMART data prediction model based on LSTM neural network and fbprophet algorithm, which can accurately predict the next 30 days. Disk failure condition. The main contents are as follows:

(1) Disk failure detection model uses convolutional neural network to calculate and utilize local processing data and weight sharing, so that it can automatically and effectively extract useful features of data while calculating high-dimensional input data and calculate it. Characteristics of the purpose of the classification. Feature extraction is performed on the disk information by using multiple convolution layers and a pooling layer to obtain a result of detecting whether the disk is broken and the current disk information, thereby detecting whether the current disk is broken.

(2) SMART data prediction model uses LSTM neural network to solve the problem that

中国知网 https://www.cnki.net

long-term dependence problem and fbprophet algorithm have better fitting effect on periodic and holiday features of time series data. The two models are combined to improve the prediction accuracy of disk SMART data. The model data fusion model SMART data output model is input into the disk failure detection model to establish a disk failure prediction model that can determine the specific failure time in the future. Experiments show that the model can accurately predict the failure information of the disk in the next 30 days.

This thesis provides a reference for the design and implementation of future disk failure prediction systems.

Keywords: datacenter, disk failure prediction, SMART, CNN, LSTM, fbprophet, model fusion

中国知网 https://www.cnki.net

插图索引

图 2.1 故障预测技术原理图 9
图 2.2 利用核函数将线性不可分数据转到高维线性可分空间 10
图 2.3 3 层 BP 神经网络 11
图 2.4 LeNet-5 卷积神经网络结构图 12
图 2.5 卷积神经网络池化层池化方法 13
图 2.6 循环神经网络结构 (a) 循环神经网络示意图 (b) 循环神经网络展开 14
图 2.7 LSTM 神经网络结构图 15
图 2.8 时间序列数据存在变点时的情况 18
图 2.9 分段线性函数图 18
图 3.1 磁盘故障检测方案的整体流程 21
图 3.2 磁盘故障检测模型设计 24
图 3.3 ReLu 函数 25
图 3.4 磁盘故障检测模型训练流程 26
图 3.5 不同检测模型的 AUC 值对比 31
图 3.6 不同检测模型的 ROC 曲线对比 31
图 4.1 磁盘故障预测模型整体设计 33
图 4.2 SMART 数据预测模型整体设计思路 37
图 4.3 基于 LSTM 神经网络的 SMART 数据预测模型设计方案 38
图 4.4 磁盘 SMART 数据预测模型训练流程 43
图 4.5 不同循环层数 *SSE* 对比 46
图 4.6 预测 14 天结果 LSTM 神经网络不同循环层数校正决定系数对比 46
图 4.7 不同模型 14 天和 30 天预测结果 *SSE* 对比 48
图 4.8 不同算法 14 天和 30 天预测结果的校正决定系数对比 48
图 4.9 融合模型与其他模型 30 天预测结果 *SSE* 对比 49
图 4.10 融合模型与其他模型 30 天预测结果的校正决定系数对比 50
图 4.11 磁盘故障预测模型与其他模型 14 天磁盘故障预测结果 ROC 曲线对比 51
图 4.12 磁盘故障预测模型与其他模型 30 天故障预测结果 ROC 曲线对比 52
图 4.13 不同模型 14 天和 30 天故障预测 AUC 对比 52

中国知网 https://www.cnki.net

表格索引

表 2.1 磁盘 SMART 属性示意表 8
表 3.1 实验运行环境 28
表 3.2 部分磁盘 SMART 数据缩放后结果 29
表 3.3 磁盘故障检测可能出现的结果 29
表 3.4 磁盘故障检测模型性能评估标准 30
表 3.5 不同模型磁盘故障检测性能对比 30
表 4.1 磁盘 SMART 属性信息增益值 44
表 4.2 表经过预处理以后磁盘 SMART 属性值 44
表 4.3 LSTM 神经网络不同循环层数预测性能对比 46
表 4.4 不同模型 14 天 SMART 数据预测结果 47
表 4.5 不同模型 30 天 SMART 数据预测结果 47
表 4.6 融合模型与其他算法 30 天 SMART 数据预测性能对比 49
表 4.7 不同算法下 14 天磁盘故障预测性能比较 50
表 4.8 不同算法下 30 天磁盘故障预测模型性能比较 51

中国知网 https://www.cnki.net

符号对照表

符号	符号名称
$\triangle t_l$	预测时间
$\triangle t_w$	预测时间下限
$\triangle t_p$	故障发生时间范围
$\triangle t_d$	预测所使用的已有时间
x_j^k	k 层卷积的 j 维特征平面
M_j	输入特征平面集合
w_{ij}^k	卷积核
b_j^k	偏置量
S_t	t 时刻隐含层输出
x_t	t 时刻隐含层输入
o_t	输出层输入
R_t	剩余项
ε_t	误差项
γ	趋势项参数
β	季节项参数
$X_{\max}$	磁盘特征最大值
$X_{\min}$	磁盘特征最小值
J	卷积层输入矩阵
θ_t	损失函数参数值
$H_A(X)$	信息熵
σ	Sigmoid 函数
R^2	决定系数
R_a^2	校正决定系数

中国知网 https://www.cnki.net

缩略语对照表

缩略语	英文全称	中文对照
SMART	Self-Monitoring Analysis and Reporting	自我检测分析报告
GB	Gigabyte	吉字节
TB	Terabyte	太字节
EB	Exabyte	艾字节
ZB	Zettabyte	泽字节
PB	Petabytes	拍字节
SVM	Support Vector Machine	支持向量机
NB	Naive Bayes Classifier	朴素贝叶斯
RNN	Recurrent Neural Network	循环神经网络
CNN	Convolutional Neural Networks	卷积神经网络
LSTM	Long Short-Term Memory	长短期记忆网络
SSD	Solid State Drive	固态驱动器
GPU	Graphics Processing Unit	图形处理器
PCA	PrincipalComponents Analysis	主成分分析
TP	True Positive	真阳性
TN	True Negative	真阴性
FP	False Positive	假阳性
FN	False Negative	假阴性
TPR	True Positive Rate	真正例率
FPR	False Positive Rate	假正例率
FAR	False Accept Rate	错误接受比例
FDR	false discovery rate	错误发现率
ROC	receiver operating characteristic curve	接收器操作特性
AUC	Area Under Curve	ROC 曲线下面积
SSE	the sum of squares due to error	和方差

中国知网 https://www.cnki.net

目录

摘要 I
ABSTRACT III
插图索引 V
表格索引 VII
符号对照表 IX
缩略语对照表 XI
第一章 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 2
1.3 论文主要研究内容 4
1.4 论文结构与具体安排 5
第二章 SMART 技术及故障预测算法 7
2.1 SMART 技术 7
2.1.1 工作原理 7
2.1.2 属性介绍 8
2.2 故障预测技术 9
2.3 支持向量机 10
2.4 深度学习算法 10
2.4.1 BP 神经网络 10
2.4.2 卷积神经网络 11
2.4.3 循环神经网络 13
2.4.4 LSTM 神经网络 15
2.5 fbprophet 算法 17
2.6 模型融合 19
2.7 本章小结 20
第三章 基于卷积神经网络的磁盘故障检测模型 21
3.1 方案的整体流程 21
3.2 数据预处理 22
3.2.1 数据清洗 22
3.2.2 缺失值处理 22
3.2.3 样本采样 22

中国知网 https://www.cnki.net

3.3 磁盘故障检测模型 23
3.3.1 模型设计 24
3.3.2 模型训练与测试 25
3.4 实验及结果分析 27
3.4.1 实验运行环境 27
3.4.2 实验数据集 28
3.4.3 性能判定指标 29
3.4.4 不同模型性能对比 30
3.4.5 结果分析 31
3.5 本章小结 32
第四章 基于模型融合的磁盘故障预测模型 33
4.1 方案的整体流程 33
4.2 数据预处理 34
4.2.1 特征选择 34
4.2.2 主成分分析 35
4.3 SMART 数据预测模型 36
4.3.1 基于 LSTM 神经网络的 SMART 数据预测模型 37
4.3.2 基于 fbprophet 算法的 SMART 数据预测模型 39
4.3.3 模型融合 41
4.3.4 训练与测试策略 42
4.4 SMART 数据预测模型实验 43
4.4.1 实验结果 45
4.4.2 融合结果 48
4.5 磁盘故障预测模型实验 50
4.6 实验结果分析 52
4.7 本章小结 53
第五章 总结与展望 55
5.1 本文主要研究成果和创新点 55
5.2 对未来工作的展望 56
参考文献 57
致谢 63
作者简介 65

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

如今随着大数据时代到来海量数据的涌入，全世界的数据级别已经从TB(1024GB=1TB)跃升到PB(1024TB=1TB)、EB(1024PB=1EB)乃至ZB(1024EB=1ZB)级别[1]。全球的数据总量也在以每年50%的速度快速增长，照着这个速度下去，再过20年全球的数据总量将会比现在多增加1000倍[59]。随着近几年云计算技术的活跃发展，个人电脑和终端的数据存储也逐渐由线下转变为云端存储从而使得这些设备转变为数据访问入口，而这些云端数据主要存储在企业的数据中心里[2]。因此近些年数据中心存储的数据量占总数据量的比例正在飞速上升，仓储式数据中心结构也逐渐普遍被企业所接受[2]。因此数据的可靠性变得越来越重要，数据可靠性逐渐成为企业和数据中心最为关注的问题之一[65]-[71]-[72]。

然而近几年国内外各大互联网公司数据中心频频出现故障代表着可靠性问题仍不容乐观。2012年12月24日圣诞节平安夜后，亚马逊AWS位于美国东部地区的数据中心发生了故障，其弹性负载均衡服务(Elastic Load Balancing Service)发生了中断，导致Netflix和Heroku等网站受到影响[3]。此外2010年1月、2011年4月22日、2012年10月22日亚马逊AWS均出现过不同程度的服务器大面积宕机，在2011年4月22日发生的亚马逊的云数据中心服务器瘫痪被认为是亚马逊公司历史上发生的最为严重的云计算安全事件之一[3]。美国的微软公司在2010年9月的几周时间里发生了至少三次的数据托管服务中断，这一事件是美国的微软公司首次出现了重大的云计算服务故障事件[3]。2016年1月28日，Github全球服务中断导致所有托管在上面的开源项目无法访问，该故障持续了6个多小时。而近几年国内也频繁发生数据中心故障的新闻，其中北京亦庄数据中心由于停电原因导致某村镇银行和多家金融机构托管在该机房的所有的设备宕机7个小时，导致服务器全部中断。2017年6月17日，新浪微博几乎全平台瘫痪，故障持续约一个小时。而在微博还没有从数据中心瘫痪事件走出的时候，2017年6月19日饿了么点餐也出现了问题，由于饿了么平台机房故障，导致饿了么平台宕机。2018年7月20日，腾讯云出现问题，前沿数控近千万元级的平台数据全部丢失，这一故障的发生导致了一家刚起步的创业公司直接破产。而就在事情发生的一个多月之前，阿里云也发生过同类事件，导致了国内半个互联网瘫痪等等。由此可见，数据中心一旦发生故障，给企业和用户带来的损失是致命的。在2005年4月美国TIA工程技术委员会对数据中心进行了分类提出了按照数据中心故障发生的时间长短将故障分为4个级别[4]：T1级别允许的年平均故障发生时间为28.8小

中国知网 https://www.cnki.net

时；T2 级别允许的年平均故障发生时间为 22 小时；T3 级别允许的年平均故障发生时间为 1.6 小时；T4 级别允许的年平均故障发生时间为 0.4 小时。级别越高的数据中心对业务故障中断的要求越短，这个十几年前提出的分类方法显然已经不适合当前数据中心的要求。如今数据中心对于业务故障中断到回复要求的时间能力要求更高，很多互联网公司的数据中心要求全年无故障运行，而一旦出现了影响正常业务的服务中断，相应的运维负责人就会受到严重的处分和惩罚。如今的数据中心故障事件都按秒来计算企业损失。对于数据中心来说，时间就是金钱，每一秒的数据中心故障导致的服务中断都会带来巨大的损失，而数据中心的磁盘故障占据了数据中心所有设备故障事件的 71.1%[5],[73]。一旦磁盘发生故障，会给数据中心带来巨大的损失。虽然近几年固态硬盘(SSD)的应用逐渐普及，但是由于其高昂的成本，企业数据中心的存储仍以硬盘存储占主导地位，但是研究表明 SSD 也容易出现故障[1]。随着存储容量和磁盘数量的增加，数据丢失事件时有发生，磁盘故障事件不仅成为可能，而且经常会发生在数据中心。因此数据中心的数据保护如今是运维人员的一个主要问题之一。早在 2008 年 Google 就报告说，每次他们在 48000 个磁盘上连续执行 6 小时时长的 PB 级操作时，磁盘就会发生故障[6]。

在数据中心发生相关故障的影响下(由于物理条件的影响)[60]进一步加剧了数据丢失的风险。而能够避免磁盘故障发生的一个有效办法就是可以通过技术准确的预测出即将发生的磁盘故障事件，因此可以将磁盘数据备份到健康磁盘中避免故障的发生。基于以上我们提出了数据中心的磁盘故障预测模型，该模型主要以磁盘 SMART 数据为主要出发点，基于目前主流的预测检测算法进行建模，使数据中心在磁盘发生故障之前可以及时告知运维人员进行更换，从而大大的减少数据中心磁盘故障的发生次数，减小企业的损失。

1.2 国内外研究现状

有效保证数据中心存储的可靠性和安全性一直以来都是数据中心运维人员最为关心的方面。近些年来，故障预测技术得到了越来越多人的研究，当前国内外已存在大量的研究成果和较为完善的磁盘故障预测解决方案[55]。本小节主要介绍国内外磁盘故障预测技术的主流方法和已取得的主要成果。

现如今预测技术早已被应用在天气、股票分析、房价分析等多种行业中[52]，而针对数据中心磁盘故障预测技术最早可以追溯到上个世纪。早在 1994 年以来，各大磁盘开发商就已经开发了自我监控技术来达到磁盘故障提前预知的目的，以便用户提前备份数据[7]。自我检测和报告技术(SMART)系统主要在用户正常使用、正常操作以及离线测试期间收集磁盘相关属性来设置故障预测标志阈值[6],[8]。磁盘 SMART 特征标

中国知网 https://www.cnki.net

识是操作系统和第三方软件读取的信号，用于警告用户即将发生的驱动器故障。磁盘SMART 技术主要依靠提供的有关原始磁盘运行状况信息和阈值算法，即当有任何属性超过了预定义的值时，该算法会触发磁盘的 SMART 标记从而达到预测故障的效果。然而这种方法的局限性也显而易见，如果保守地设置阈值以避免错误警报将会牺牲预测故障的准确性[8],[63]。这种方法一般可以接受的误报率为 0.1%，然而对于当前在磁盘驱动器中所使用的磁盘 SMART 算法，磁盘制造商的故障预测率只能达到3%~10%[6],[7]。由于仅仅对磁盘 SMART 统计数据进行阈值处理无法得到预期的预测精度，因此运维人员开始使用各种不同的机器学习模型和其他措施来尝试提高磁盘故障预测的准确性[53]-[57]-[58]。

为了提高磁盘故障预测的准确性，Hamerly 和 Elkan 在 2001 年使用了基于贝叶斯的磁盘 SMART 故障预测建模方法，他们对 1936 年磁盘驱动器数据集进行了测试，实现了朴素贝叶斯分类，该方法的故障预测率为 55%，FAR(错误率)为 1%[9]。在 2002 年由 Hughes 等人使用 Wilcoxon 秩和检验来构建磁盘故障预测模型，这个模型提出了两种不同的策略：多变量测试和 ORing 单属性测试[6]。他们的模型在 3744 个驱动器上进行了测试，该故障预测率达到了 60%，FAR 为 0.5%。2003 年 Murray 等人比较了 SVM、无监督聚类、秩和检验和反向排列检验等模型的性能[10]，在随后的工作中他们开发出多实例朴素贝叶斯(mi-NB)的方法，他们测试出在 369 个磁盘驱动器的数据集中，在对于某些数据集的磁盘 SMART 属性建立的模型中，秩和检验的性能要优于 SVM(支持向量机)(0%的错误检测率下，故障预测率为 28.1%[11])。当使用所有数据集时，SVM 以 0%的 FAR 与 50.6%的故障预测率达到了最优性能。早期的磁盘故障预测方法由于其故障预测率只达到了 50%因此预测效果不好，无法将其应用到实际的操作中，我们分析其磁盘故障预测率过低的主要原因是由于数据集过小，并且其使用的 SMART 数据标准不具有普遍性，同时早期的磁盘 SMART 属性与现在属性差异较大测量准确性较低，而且目前在进行预测建模时仅仅将磁盘故障预测作为简单的分类问题来处理没有考虑到磁盘数据的时序性。

2008 年来自罗格斯大学的熊辉教授团队与 IBM 合作在 IBM 的 BlueGene 集群上使用了来自专用日志系统的磁盘数据做了磁盘故障预测系统[12]，该研究主要使用了三种预测技术(RIPPER 分类器、支持向量机和最近邻分类)，首先使用 RIPPER 分类器和支持向量机这两种标准分类工具来根据系统日志训练出故障预测模型然后与基于最近邻预测器的故障预测方法做了对比，结果发现最近邻预测器的性能更加优秀，但是由于该团队使用的 IBM 的 BlueGene 集群上的系统日志数据集由于过于专业化而无法公开使用。

Featherstun 和 Fulp 在 2010 年使用了系统日志事件而不是磁盘的 SMART 属性来建模，并使用了 SVM 来挖掘系统日志消息来进行磁盘故障预测[12]，他们达到了 80%

中国知网 https://www.cnki.net

的故障预测率。2013 年南开大学计算机与控制工程学院的王刚、朱炳鹏等人在前馈神经网络基础上应用反向传播学习来训练磁盘 SMART 属性，并在 FAR 相当低的情况下实现了 95%的故障预测率[14],[75]。2016 年张旭等人提出了根据健康度评估磁盘的预测模型，该模型使用了健康度来评估磁盘的剩余寿命从而将磁盘剩余寿命分为六个等级。该模型主要使用单层 RNN(循环神经网络)在标记时间序列样本以后，在时间点之前的最后 N 个连续样本的输出中采用了投票算法，从而最终估计磁盘设备的健康水平，该模型的准确度 FDR 为 97.71%，FAR 为 0.06%[15],[16]。该模型是迄今为止预测性能最好的磁盘故障预测系统也是使用 SMART 做的预测模型，该模型预测性能好是由于 RNN 模型可以很好的直接处理固有的时间依赖性，但是由于 RNN 的梯度消失问题严重对于长期依赖问题没有办法处理，因此该模型只能处理短时间的磁盘故障问题。2017 年 Lima 和 Fernando Dione dos Santos 等人使用 LSTM 神经网络进行磁盘剩余寿命的预测，可以预测出未来一年的磁盘故障情况，但是该模型的预测精度不高[17]。2017 年 4 月，杭州电子科技大学的兰云龙提出了利用磁盘健康度进行磁盘故障评估模型，该模型提出了基于欧式距离的磁盘健康度并利用 LSTM 神经网络进行磁盘健康度的预测从而得到磁盘故障情况，该模型可以预测更远的磁盘故障[81]。2018 年张建国等人提出了基于分层扰动的磁盘健康度预测模型，该模型可以精确的预测出磁盘驱动器未来 5 天和 15 天的故障情况[80]。

1.3 论文主要研究内容

综上所述，虽然目前基于磁盘 SMART 信息的故障预测技术研究已经取得了很好的进展，但是在磁盘故障预测领域仍存在很多问题，主要问题有：

1．目前针对磁盘故障的预测建模的主要方案都是将磁盘故障预测问题当做故障分类问题处理，即通过预测未来是否发生故障的研究来确定磁盘是否发生故障，仅仅给出了故障预警情况就算完成了预测功能，但是对于磁盘什么时候会发生故障并没有做深入研究；

2．目前的研究对于磁盘故障预测的预测时间没有明显的提升，磁盘故障预测的有效时间较短，即长期依赖问题没有很好地解决[66]；

3．目前所有的磁盘故障预测模型的研究都基于一个算法来解决问题，磁盘的故障预测模型性能均不太理想，且在磁盘故障模型的建立时存在一定的过拟合情况，并没有考虑到利用融合不同算法的特点来进一步提高磁盘故障预测模型的预测性能。

针对以上问题，本文提出了一种磁盘故障预测模型，该模型使用了基于卷积神经网络的磁盘故障检测模型和融合了 LSTM 和 fbprophe 算法的 SMART 数据预测模型，本文的主要研究内容如下：

中国知网 https://www.cnki.net

1．本文详细研究磁盘故障预测问题的发展背景和国内外研究现状，学习几种常用的深度学习模型，然后将磁盘故障预测问题分为 SMART 数据预测模型和磁盘故障检测模型两部分，解决预测出磁盘故障的前提下确定具体磁盘故障发生的时间问题；

2．本文使用真实企业级磁盘数据集，并根据数据集情况使用数据清洗、缺失值处理、样本采样、特征选择、主成分分析等处理方法进行磁盘数据集预处理，使处理后的磁盘数据集可以直接输入到模型中进行处理；

3．本文利用卷积神经网络具有分别计算，利用局部处理数据、权值共享使其可以在输入数据保持高维度的同时自动有效的提取出数据有用特征并进行计算，从而达到识别或分类目的的特点，设计基于卷积神经网络的磁盘故障检测模型，该模型利用带有是否故障标签的磁盘数据集，根据输入磁盘的 SMART 数据检测出当前磁盘的故障情况；

4．本文设计融合 LSTM 神经网络和 fbprophet 算法的 SMART 数据预测模型，该模型利用 LSTM 神经网络对长期依赖问题的处理和 fbprophet 算法对时间序列预测问题突变点和周期性特征的处理的优势，从而根据当前 SMART 数据预测未来 30 天 SMART 数据，将 SMART 数据的时序性得到有效地利用；

5．本文将基于融合模型的磁盘故障预测模型与循环神经网络和支持向量机算法的磁盘故障预测模型性能进行对比来证明本文提出的模型的可行性。

1.4 论文结构与具体安排

本文的结构主要分为五个部分，各章节内容安排如下：

第 1 章为绪论部分，主要介绍了数据中心磁盘故障预测问题研究的提出背景和研究意义，接下来介绍了磁盘故障预测问题相关领域近几年国内外研究现状并针对当前研究现状进行简单分析的同时指出了在当前磁盘故障预测研究中所存在的一些问题，最后简述了论文的结构和具体安排；

第 2 章介绍了本文主要涉及的相关背景知识，首先介绍了磁盘 SMART 数据的工作原理和属性组成，接下来介绍了故障预测的定义和相关知识，然后简单介绍了本文所涉及的对比算法，包括支持向量机、BP 神经网络和循环神经网络，再详细介绍了预测模型所使用的几种算法，包括卷积神经网络、LSTM 神经网络和 fbprophet 算法并在最后介绍了模型融合的方法；

第 3 章首先介绍了磁盘故障检测模型的设计思路，然后介绍了针对磁盘故障检测模型的数据集预处理方法，接下来针对基于卷积神经网络的磁盘故障检测模型介绍了模型的具体设计，最后通过实验建立基于卷积神经网络的磁盘故障检测模型并通过与支持向量机和 BP 神经网络的故障检测模型性能对比说明该磁盘故障检测模型的可行

中国知网 https://www.cnki.net

性；

第 4 章提出了一种基于模型融合的磁盘故障预测模型，首先介绍了磁盘故障预测模型的整体设计方案，然后介绍了针对 SMART 数据预测模型的数据集预处理方法，接下来利用 LSTM 神经网络对长时间依赖的问题和 fbprophet 算法对时间序列突变性和周期性问题处理较好的优势提出了 SMART 数据预测模型，并将两种模型进行了融合，然后通过实验将两种算法和融合模型的预测性能进行对比，最后将 SMART 数据预测模型与磁盘故障检测模型结合得出了基于模型融合的磁盘故障预测模型，并通过与基于循环神经网络与支持向量机的故障预测模型的性能对比说明了该模型的可行性；

第 5 章针对本文所得出的研究成果和创新点进行了总结，并对下一步的研究工作进行展望。

中国知网 https://www.cnki.net

第二章 SMART 技术及故障预测算法

本章从磁盘 SMART 技术的工作原理和主要属性介绍入手，简单介绍了磁盘故障预测技术的原理，说明了磁盘故障预测技术的可行性，并给出了几种本文涉及到的机器学习和深度学习算法，其中简单介绍了支持向量机、BP 神经网络和循环神经网络的原理，详细介绍了卷积神经网络和 LSTM 神经网络的原理，接着介绍了 fbprophet 算法的原理，最后介绍了模型融合的思想和主要实现方法。

2.1 SMART 技术

磁盘 SMART 技术又叫做磁盘自我检测分析和报告技术，全称为“Self-Monitoring Analysis and Reporting Technology”[18],[64]，是一种硬盘状态自动检测技术与磁盘预警系统和磁盘属性规范。该技术通过在磁盘硬件内的检测指令对磁盘的硬件性能如磁盘磁头飞行高度、磁盘盘片转速、磁盘温度、马达旋转时间等数据的运行状况进行实时监控和记录并与磁盘厂商出厂时所设置的阈值进行比较，一旦监控属性超过预设值时将会触发主机的监控软件向维护人员发出告警来提醒运维人员进行维护和修复，依靠此方法在磁盘发生故障之前保障硬盘的数据安全问题降低不必要的损失。目前大部分硬盘生产厂商均配备了该项技术。

2.1.1 工作原理

磁盘 SMART 技术最早在 1994 年由 Compaq 公司提出并与 IBM、希捷、富士通、昆腾等磁盘厂商参与修正，在该技术中融合了当时 Compaq 公司的 IntelliSafe 诊断技术和 IBM 的 PFA 检测技术[19]。该技术主要负责监控和测量磁盘的关键参数来评估磁盘当前状态是否安全，并将评估结果和相关指标传入操作系统或用户的进程中。当时该项技术得到了磁盘生产厂商的一致认可并在 1995 年由各大磁盘生产厂商的支持下将磁盘 SMART 的标准规则加入了 ATA 行业标准[20]。

磁盘的 SMART 信息由厂商保存在硬盘的系统保留区中，这个区域位于磁盘物理面的最开始的几十个物理磁道中并由各自厂商在内部写入相关的 SMART 数据管理程序。此外除了 SMART 信息表单，该管理程序还包括了格式化工具、加密解密工具、自我监控工具和自我修复工具等。该检测软件通过“SMART Return Status”命令对磁盘 SMART 信息进行读取并不允许进行修改。

磁盘厂商所提供的 SMART 技术主要以磁盘 SMART 信息为基准，厂商提供两个信息“超出阈值”和“未超出阈值”。根据磁盘 SMART 技术要求，如果该磁盘在运

中国知网 https://www.cnki.net

行时的磁盘相关信息超出了厂家在出厂时所设置的阈值即“超出阈值”，则会被判定为该磁盘发生故障。但是事实上超过阈值指的是磁盘的当前状态暂时超负荷运作其状态可能会在未来发生故障，而不是发生故障。如果只是短时间超负荷运作则磁盘大概率不会发生故障，而当前系统无法读取到磁盘的扇区数据也可能只是由于当前磁盘在其正常运行时创建了一个不可读的扇区所导致。事实证明，仅仅依靠 SMART 技术的阈值法来判定磁盘是否故障是不可取的。

目前磁盘故障预测技术所采用的数据集大多数都使用了磁盘 SMART 数据。而不同的厂商所使用的 SMART 数据中属性值略微不同，除了当前常用的一些属性以外，有些厂商还会提供一些独有的属性以供参考。这些属性大多包含了三个属性，分别为 SMART 原始值、标准化值和临界值。原始值为通过磁盘 SMART 技术所采集到的初始值，比如原始读取错误率、磁盘旋转时间、温度等等。标准化值为原始值经过磁盘厂商内置的算法计算后所得到的标准化值，该值将所有属性统一缩放到了[0,255]之间，目前的磁盘 SMART 技术所提供的阈值告警算法均为基于标准化值来进行比较的结果。临界值为目前该磁盘属性的标准值所达到过的最差状态。

2.1.2 属性介绍

由于利用磁盘 SMART 属性的阈值法的局限性，导致了基于此种方法的磁盘故障预测率仅仅能达到 3%~10%，远远无法满足企业使用的要求，因此运维人员将研究重点放在了 SMART 属性值上。一般来说磁盘的 SMART 属性值分为两种，即磁盘环境属性和磁盘的读写属性。磁盘环境属性主要指磁盘在运行过程中的环境状态，如温度(Temperature)、通电时间(Power on Hours)、磁盘旋转时间(Spin Up Time)等；磁盘的读写属性主要指磁盘在读写数据时的自身属性，如原始读取错误率(Raw Read Error Rate)、重新分配的扇区数(Reallocated Sectors Count)、寻求错误率(Seek Error Rate)等。

表2.1 磁盘 SMART 属性示意表

磁盘 SMART 属性	磁盘 SMART 属性值
Smart_1_normalized	120
Smart_1_raw	2346048
Smart_2_normalized	134
Smart_2_raw	101
Smart_3_normalized	91
Smart_3_raw	0

由于一个磁盘的 SMART 属性过多，这里我们仅罗列其中的一部分属性及属性值

中国知网 https://www.cnki.net

作介绍。本文在做磁盘预测模型的训练之前首先将所有的磁盘 SMART 属性做了特征提取和降维工作。部分磁盘 SMART 数据及相关意义如表 2.1 所示。

由表 2.1 可以看出，左侧为磁盘 SMART 相关参数属性，右侧为对应的属性值。这里 serial_number 为数据中心对应的磁盘编号，Model 为磁盘型号，Capacity 为磁盘容量值，然后是该磁盘的 SMART 属性以及对应值。这里每项 SMART 属性都对应了标准值和初始值两项内容。

2.2 故障预测技术

故障预测技术为在故障发生之前预测故障并采用相应的预防策略来避免故障或者通过准备应对即将发生的故障从而缩短故障修复时间的技术，是进一步提高可用性的有效方法。近几年来，预防性维护技术已成为系统可靠性研究中企业运维人员和相关研究人员日益重视的领域之一[56],[75]。

故障预测问题与故障检测不同，故障检测指利用当前的系统情况检测出已经存在的故障问题，而故障预测问题的研究主要是为了避免系统故障的发生。因此在这种情况下需要有效地主动预测出故障，故障预测的有效时间与系统可靠性紧密相关[78]。故障预测目标是根据当前的系统状态预测出未来时刻系统可能会出现的状况。因此，目前故障预测的焦点主要为在线故障预测[75]。

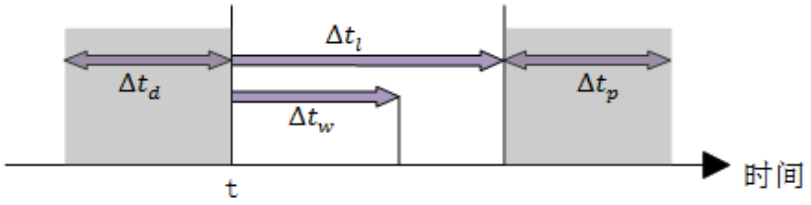


图2.1 故障预测技术原理图[21]

如图 2.1，对于即将发生故障的系统进行在线预测，在 t 时刻对系统进行预测，若预测出 $t+\Delta t_l$ 时间系统故障信息，则这段时间被称为预测领先时间。Δt_l 允许的时间下限为 Δt_w，即执行故障处理操作所需要的最短时间。另一方面，如果 Δt_p 的值过大，导致故障发生的时间范围过大而故障预测的结果没有任何实用意义。由于在线故障预测技术考虑到了系统的当前状态，因此在故障预测建模时，需要使用当前时刻之前的系统状态数据这段时间为 Δt_d。

故障预测技术作为系统发生故障之前主动进行处理的一项工作，一般情况下需要与发生故障的根本原因即故障诊断相结合以便确定未来发生故障的原因。但是磁盘故障预测技术为检测出磁盘故障问题从而直接将磁盘信息进行备份从而做到磁盘故障的提前处理，因此这里我们不进行磁盘故障诊断的说明。

中国知网 https://www.cnki.net

2.3 支持向量机

支持向量机[12](Support Vector Machine, SVM)最早在 1963 年被提出，是一种在数据分类领域最常用的方法之一。支持向量机在解决二元分类问题时，主要通过构造一个可以将两类样本点距离最近值分离的同时与这些点保持最远的最优超平面，从而将数据集进行切割达到分类效果的方法。

针对线性不可分问题，支持向量机提出了核函数的思想，即将线性不可分的数据集从低维度的特征空间映射到线性可分的高维度特征空间，从而使数据集变为线性可分。图 2.2 为利用核函数方法将线性不可分数据集映射到线性可分的高维空间。

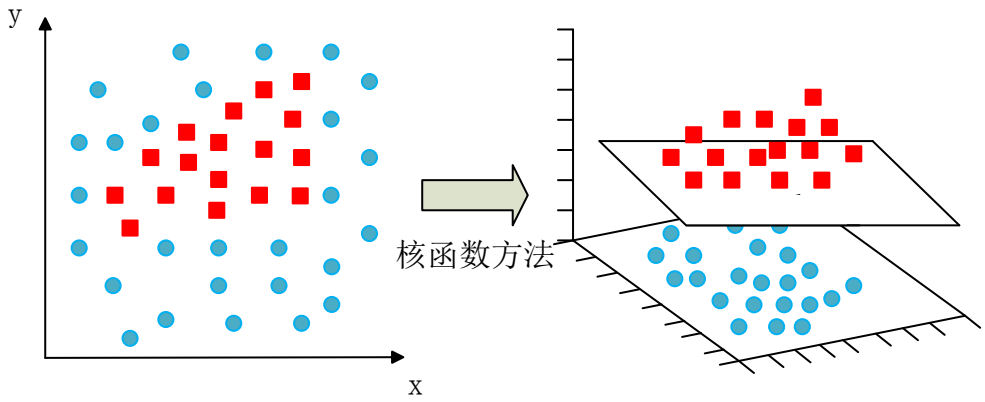


图2.2 利用核函数将线性不可分数据转到高维线性可分空间

2.4 深度学习算法

深度学习是近些年来发展较快的一种技术，在如今的大数据时代，深度学习已经广泛的应用于各个领域。在本节我们主要介绍基于分类和回归问题常用的几个深度学习模型：BP 神经网络、卷积神经网络模型，循环神经网络模型以及 LSTM 神经网络模型。

2.4.1 BP 神经网络

BP 神经网络[74](Back Propagation Neural Nework)最早在 1986 年被提出，它由大量的处理单元之间进行互联形成，用来模拟人大脑的结构和功能。BP 神经网络的结构由大量的神经元之间进行互联形成，每个神经元代表了一种输出，该输出为激励函数。每对神经元之间的连接表示信号通过该连接时的权重，在计算过程中主要利用梯度下降法使每次输出值和期望值的均方误差最小逐渐逼近目标值。

BP 神经网络模型的建立主要分为前向传递和反向传播两个过程。一般前向传递

中国知网 https://www.cnki.net

过程主要为建立模型的过程，反向传播过程为模型的训练调参过程。如图 2.3 为典型的 3 层 BP 神经网络结构。

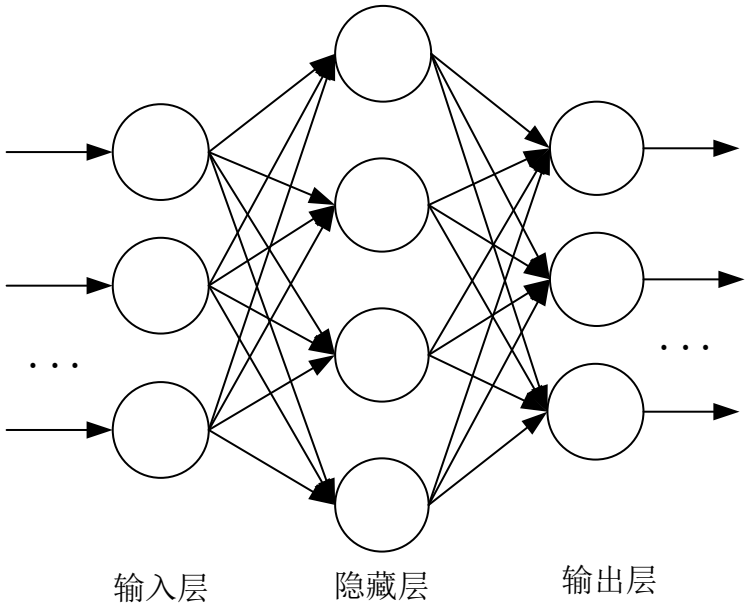


图2.3 3 层 BP 神经网络

2.4.2 卷积神经网络

卷积神经网络(Convolutional Neural Networks,CNN)是一种包含卷积类计算并且具有多层深度结构的前馈神经网络，是深度学习中极其具有代表性的网络结构之一[29]。卷积神经网络由于其局部感受、权值共享和对空间的亚采样的特点被科研工作者和企业广泛应用于语音分析、图像识别和自然语言处理等多个领域之中。卷积神经网络由于其卷积层的特殊结构使得该算法在保持数据局部信息的同时做特征提取从而大大的减少计算的复杂度。如图 2.4 为 1998 年 Yann LeCun 及其合作者构建的 LeNet-5 卷积神经网络并在手写数字的识别问题中取得了很好的效果[22]。

卷积神经网络通常分为三层即输入层、隐含层和输出层[29],[30]。卷积神经网络的输入层为神经网络处理数据之前的网络，可以用来处理高维数据。常见的，若一维卷积神经网络的输入层用来接收一维数组或二维数组，一般该一维数组用来表示时间或频谱的亚采样，而二维数组一般包含多个通道；同理二维卷积神经网络的输入层用来接收二维数组或者三维数组；三维卷积神经网络的输入层用来接收四维数组。一般由于卷积神经网络经常被用在计算机图像处理领域，因此在将其应用在图像领域时一般假设了三维输入数据，即平面上的二维像素点和 RGB 通道[29]。这里我们所处理的数据集为一维的磁盘特征数据，因此在输入层主要使用一维卷积神经网络。卷积神经网络与其他神经网络算法类似使用梯度下降法进行训练学习，因此卷积神经网络的输入数据特征处理前需要进行标准化。将输入数据特征进行标准化后有利于提升整个神经

中国知网 https://www.cnki.net

网络的学习效率。

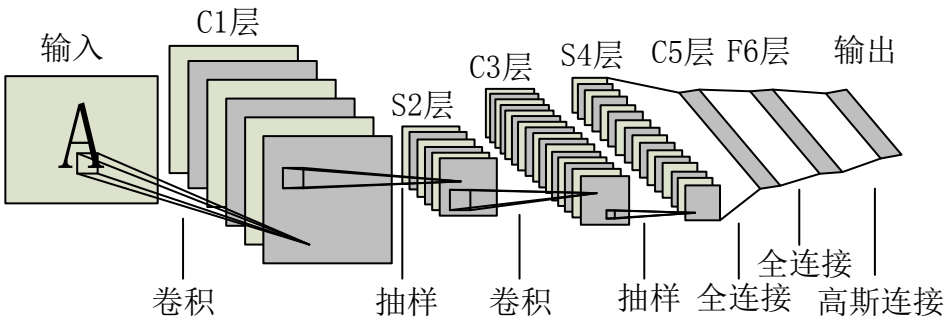


图2.4 LeNet-5 卷积神经网络结构图[22]

卷积神经网络的隐含层主要包括卷积层(Convolutional Layer)、池化层(Pooling Layer)和全连接层(Fully Connected Layer)，这三层神经网络层为卷积神经网络的核心，因此我们在这里将这三种网络进行重点介绍：

卷积神经网络中卷积层的主要作用是对输入数据进行特征提取，卷积层的结构类似于一个前馈神经网络的神经元。卷积层中的每一个神经元都与前一层神经元中位置相近的多个神经元相连接并利用此结构来进行局部感知。卷积核在模型学习时会通过局部感知输入特征，在每个神经元范围内对输入数据特征做矩阵运算并叠加偏置量来进行局部信息综合，从而得到全局数据信息特征。

卷积层的计算公式为[29],[30]：

$$x_j^k = f(\sum_{i \in M_j} x_i^{k-1} \bullet W_{ij}^k + b_j^k) \tag{2-1}$$

这里 x_j^k 是第 k 层卷积层中的 j 维特征平面， M_j 是输入数据特征的平面集合， w_{ij}^k 表示从第 $k-1$ 层卷积层到 k 层所产生的特征值，又被称为卷积核。卷积核通常有四个维度表示，第一维表示为输出特征的平面个数。第二维表示为输入层的特征平面个数，其余两层分别为局部感知中单个神经元的感知域大小。 b_j^k 为对应的偏置量，该数值为 k 维向量， k 为对应输出特征的平面数。 $f(\bullet)$ 是激活函数。

卷积神经网络中的池化层作用主要是在卷积层将输入数据进行特征提取后，输出的特征将传递到池化层，池化层的作用主要是通过对原始数据特征按照卷积核和池化区域扫描后进行池化，一般通过平均池化法(取区域平均值)或最大池化法(取区域最大值)的方法将数据进行特征选择和信息过滤，从而极大地减少了下一层所需要的参数特征数量的同时也可以在一定程度上减少过拟合[29]。如图 2.5 所示。

卷积神经网络全连接层的作用与神经网络中隐含层作用相同，全连接层通常搭建

中国知网 https://www.cnki.net

在卷积神经网络的最后。全连接层进行的核心计算为矩阵相乘以后经过激活函数产生对应的非线性特征，其对应的输入输出公式为[22]-[29]-[30]

$$y = f(W \bullet x + b) \tag{2-2}$$

这里 x 和 y 分别为对应的输入特征向量和输出特征向量，W 为权值矩阵，b 为偏置量，$f(\bullet)$ 为激活函数。

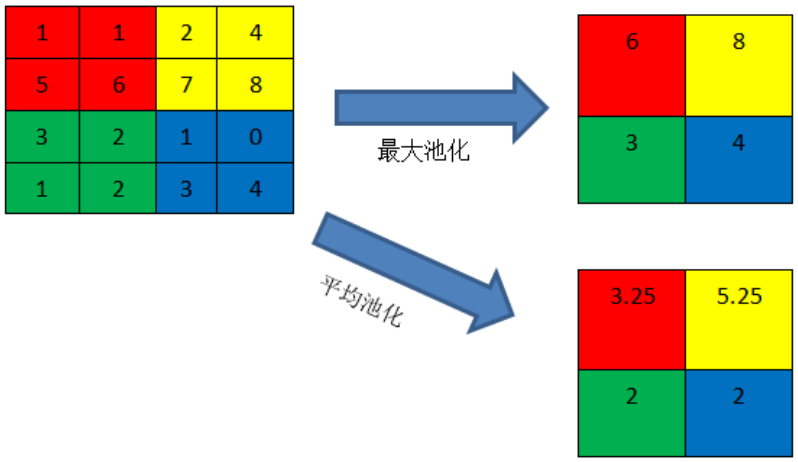


图2.5 卷积神经网络池化层池化方法

卷积神经网络的输出层一般紧接着全连接层，因此输出层的结构和工作原理与传统的前馈神经网络的输出层大致相同，对于分类问题，一般输出层使用逻辑函数或归一化指数函数来输出分类标签从而完成最后的分类问题。

2.4.3 循环神经网络

循环神经网络(Recurrent Neural Network,RNN)是近几年发展较快的另一种十分常用的深度学习模型。循环神经网络主要是为了处理时间序列数据而被设计出来的[20]。由于在传统的神经网络中，输入层到隐含层和隐含层到输出层之间前后两层的节点之间是用全连接的方式来传递数据的，但是在每层内的节点之间是无连接的。因此这种设计导致了其在处理当输入数据存在前后时序关系的问题时变得十分困难。

循环神经网络在处理时间序列问题时由于其结构在处理 t 时刻时可以将该时刻隐含层的信息传递给下一时刻的隐含层，从而有效利用了 t 时刻的信息在下一层使用，因此循环神经网络具有很好的时序性。目前循环神经网络被大量用在自然语言识别和翻译领域，该算法为时间序列问题的处理提供了有效的解决方案[20]。图 2.6(a)为典型的循环神经网络结构：

中国知网 https://www.cnki.net

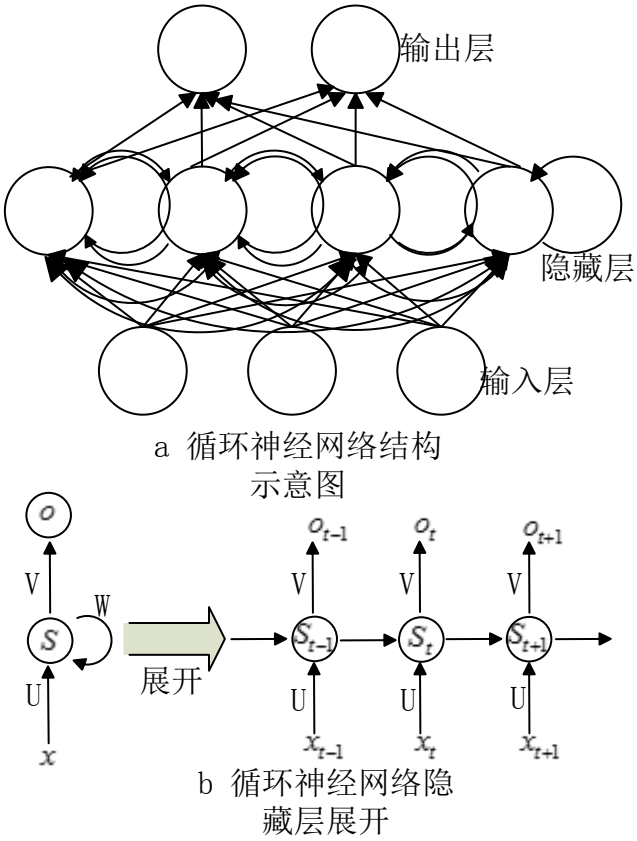


图2.6 循环神经网络结构 (a) 循环神经网络示意图 (b) 循环神经网络展开[24]

循环神经网络同样具有三层结构，即输入层、隐含层和输出层。其中输入层和输出层与人工神经网络相同，主要为输入时间序列。循环神经网络的隐含层为在一般人工神经网络隐含层的基础上增加了一个走向自己的链接，使其内部形成循环网络并进行了相互链接，从而使其隐含层的输入不但包括了输入层的输出，而且还包括了上一时刻的隐含层的输出，从而充分的利用了时间序列数据的时序性。但是并不是所有的历史数据均可以直接作用于下一时刻，同人工神经网络，当层数逐渐加深时会出现梯度消失问题。一般情况下，循环神经网络的影响层数小于 7 层[22]。

图 2.6(b)为将循环神经网络中的一个隐含节点展开后的内部结构。这里 x_t 为 t 时刻的输入层到隐含层的输入， s_t 表示 t 时刻隐含层的输出到隐含层的输出， o_t 为隐含层信息传递到输出层的输出，U 表示从输入层信息传递到隐含层的权值矩阵，V 为隐含层到输出层的权值矩阵，W 为隐含层节点的权值矩阵。在该结构中，有两条单方向流动的信息流。一条信息流是输入单元信息流动到隐含层单元最后再到输出单元的信息；另外一条信息流则是从上一时刻的隐含层单元保留的信息传递到下一时刻的隐含层单元的信息。

中国知网 https://www.cnki.net

2.4.4 LSTM 神经网络

LSTM(Long Short-Term Memory)神经网络被称为长短期记忆神经网络，最初是由 Hochreiter 和 Schmidhuber 提出并用于解决在长(深度)时间序列上反向传播时与基于梯度学习方法相关的问题[25],[67]。LSTM 神经网络是一种改进的循环神经网络，与大多数循环神经网络一样，LSTM 神经网络主要依靠一个神经元来传递上一时刻的历史信息，并通过存储单元和门控机制来实现从而增强传统的循环神经网络使其允许控制在存储单元中保存或记录内容以及新输入的信息如何贡献于该存储单元中已有的内容的功能。LSTM 神经网络的隐含层循环节主要由四个部分所组成，分别为输入门(input gate)、遗忘门(forget gate)、神经元状态(neural status)、输出门(output gate)[25],[67]。如图 2.7 所示。

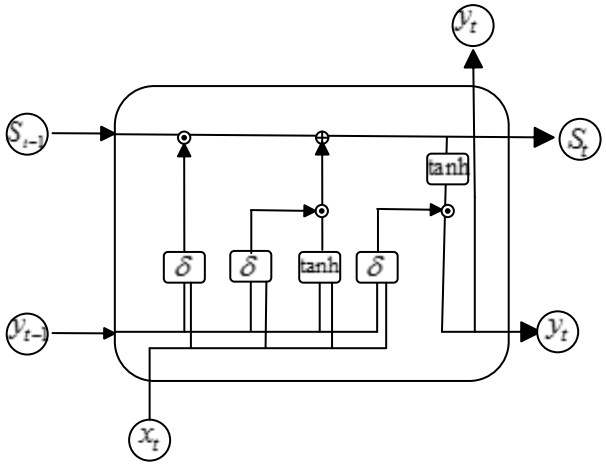


图2.7 LSTM 神经网络结构图[25],[67]

当前时刻的数据信息由该网络的 x_t 处输入，前一刻时间的历史信息矩阵作为该网络的神经元状态由 s_{t-1} 出输入，在当前时刻之前的信息经过遗忘门处理以后，剩余的信息将于输入门处理的数据信息相合并，合并后的数据组成了新的历史信息作为当前时刻的记忆信息，最后由历史信息与经过输入门处理后的输入信息进行矩阵乘法运算从而得到了当前时刻的输出信息，然后将处理过的历史信息矩阵继续传递给下一时刻的神经元。经过神经元之间的传递使得历史信息在经过门之间传递后可以将历史信息进行筛选并将筛选后的信息继续向下一层传递，从而减少了无用的信息噪声对于最终预测结果的干扰，最终有效的缓解了循环神经网络所存在的梯度消失问题。

LSTM 神经网络中的输入门作用为主要将该循环周期内的时间序列信息是否存储到神经元状态中，输入门的输入主要为当前时刻的时间序列信息 x_t 和上一时刻的神经元状态 s_{t-1}，输入门的公式为：

中国知网 https://www.cnki.net

$$i=\sigma(W_2[x_t,y_{t-1}]+b_2) \tag{2-3}$$

$$h=\tanh(W_3[x_t,y_{t-1}]+b_3) \tag{2-4}$$

这里i表示输入门，h为当前状态，b表示偏置项，W为权重矩阵，$\sigma(\bullet)$为Sigmoid函数，其输出值介于[0,1]之间。然后通过矩阵乘法运算将时间序列的当前状态与历史状态进行合并，从而求出新的神经元状态S_t，新神经元状态的输入有四项，分别为上一时刻的神经元状态S_{t-1}，遗忘门的输出结果，输入门的输出结果和当前状态的输出结果。

$$S_t=S_{t-1}\bullet f+i\bullet h \tag{2-5}$$

这里f为LSTM神经网络遗忘门，遗忘门主要作用是确定是否将上一个周期的时间序列信息从历史信息记录中去除掉，遗忘门的输入项有两项，分别为当前时刻的时间序列信息x_t和上一时刻的神经元状态S_{t-1}。

$$f=\sigma(W_1[S_{t-1},x_t]+b_1) \tag{2-6}$$

这里Sigmoid函数作用为过滤信息，0表示完全遗忘历史信息，1表示完全记录历史信息，神经元状态用来传递时间序列的历史信息。LSTM神经网络的输出门作用为决定将神经元状态的一部分信息进行输出，然后将输出值传递到下一个神经元中。输出门输入为两项分别为当前时刻的时间序列信息x_t和上一时刻的神经元状态S_{t-1}，输出门输出为：

$$o=\sigma(W_4[y_{t-1},x_t]+b_4) \tag{2-7}$$

最终将当前时刻的时间序列信息通过tanh处理后得到一个[-1,1]之间的值，然后与输出门的输出值o相乘从而得到一个循环层的最终输出值。

$$y_t=o\bullet\tanh(S_t) \tag{2-8}$$

由此可见，LSTM神经网络通过增加了神经元状态并经过遗忘门决策神经元状态的保存量从而长时间的保存了时间序列信号的历史信息，缓解了梯度消失问题，解决了长期依赖性问题。

中国知网 https://www.cnki.net

2.5 fbprophet 算法

fbprophet 算法是 facebook 公司在 2017 年开源的一个时间序列预测的算法，该算法利用基于时间序列的分解和机器学习的拟合从而得到进行预测时间序列的效果[26],[27]。fbprophet 算法具有可以处理时间序列所存在的一些异常值情况，还能够几乎全自动的预测时间序列的未来走势，并且还考虑了时间序列预测所关注的季节性效应和节假日效应，有效地处理了时间序列分析中突变点和周期性特征，解决了时间序列预测的关键性问题。

fbprophet 算法基于时间序列分析领域的时间序列分解(Decomposition of Time Series)并做了改进，时间序列分解将一个时间序列 y_t 分解为季节项 S_t，趋势项 T,剩余项 R_t，即对所有 $t \geq 0$，都有

$$y_t = S_t + T_t + R_t \tag{2-9}$$

fbprophet 算法基于此增加了节假日效应，从而得出时间序列 y_t 表达式为：

$$y_t = g(t) + s(t) + h(t) + \varepsilon_t \tag{2-10}$$

这里 $g(t)$ 为趋势项，表示时间序列在非周期上的变化趋势；$s(t)$ 为周期项(季节项)，$h(t)$ 为节假日项，ε_t 为误差项。fbprophet 算法为通过拟合这几项并将其累加起来从而得到了时间序列的预测值。

fbprophet 的趋势项中基于两种函数，一种为逻辑回归函数(logistic function)，另一种为分段线性函数(piecewise linear function)。基于逻辑回归函数的表达式并增加参数将原式改为

$$f(x) = \frac{C}{(1 + e^{-k(x-m)})} \tag{2-11}$$

这里 C 为时间序列的最大渐进值，k 为增长率，m 为中点，当 $C=1$，$k=1$，$m=0$ 时，该表达式为 Sigmoid 函数。fbprophet 算法考虑到时间序列数据中 $f(x)$ 的参数不可能为常数，因此将这三个参数变为随时间 t 变化的函数即 $C = C(t), k = k(t), m = m(t)$。除此之外，由于时间序列中曲线会存在周期变化规律存在变点，如图 2.8 所示。

时间序列趋势时间段的线段边界表示为：

中国知网 https://www.cnki.net

$$\gamma_j = (s_j - m - \sum_{l<j}\gamma_l)\bullet(1-\frac{k+\sum_{l<j}\sigma_l}{k+\sum_{l\le j}\sigma_l}) \tag{2-12}$$

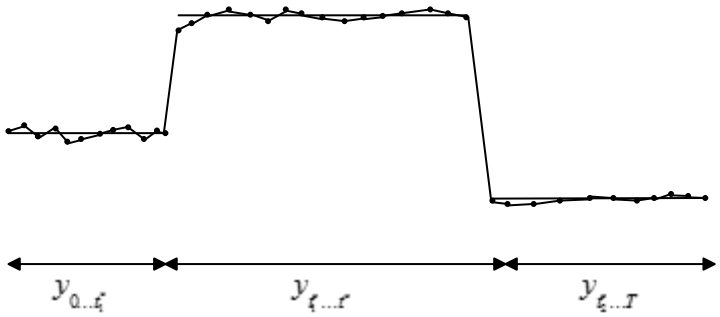


图2.8 时间序列数据存在变点时的情况[26][27]

最终得分段的逻辑回归增长模型为：

$$g(t)=\frac{C(t)}{1+\exp(-k+a(t)^T\sigma)\bullet(t-(m+a(t)^T\gamma))} \tag{2-13}$$

若趋势项基于分段线性函数时，由线性函数特点可知分段线性函数为在每个子区间内，函数均为线性函数，但是在整个区间内函数并不是线性的，如图 2.9 所示。

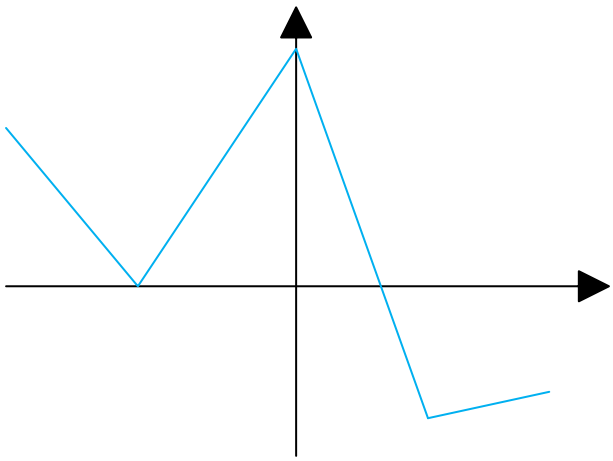


图2.9 分段线性函数图[27]

由此可得基于分段线性函数的趋势项模型为：

$$g(t)=(k+a(t)\sigma)\bullet t+(m+a(t)^T\gamma) \tag{2-14}$$

中国知网 https://www.cnki.net

这里 $\gamma=(\gamma_1,\cdots,\gamma_s)^T$， $\gamma_j=-s_j\sigma_j$。

fbprophet 算法中使用傅里叶级数来模拟时间序列的周期性，假设 P 为时间序列的周期，则它的傅里叶级数形式为：

$$s(t)=\sum_{n=1}^{N}a_n\cos(\frac{2\pi nt}{P})+b_n\sin(\frac{2\pi nt}{P}) \tag{2-15}$$

fbprophet 算法中时间序列的季节性表示为

$$s(t)=X(t)\beta \tag{2-16}$$

这里 $\beta=(a_1,b_1,\cdots,a_N,b_N)^T$， $X(t)=[\cos(\frac{2\pi 1t}{P}),\cdots,\cos(\frac{2\pi nt}{P}))]$。

fbprophet 算法中节假日项表示为

$$h(t)=Z(t)k=\sum_{i=1}^{L}k_i\bullet 1_{\{t\in D_i\}} \tag{2-17}$$

这里 $Z(t)=(1_{\{t\in D_1\}},\cdots,1_{\{t\in D_L\}})$， $k=(k_1,\cdots,k_L)^T$,并且 $k\sim Normal(0,v^2)$,v 表示节假日趋势。最终得由 fbprophet 算法拟合出的时间序列预测值为

$$y_t=g(t)+s(t)+h(t)+\varepsilon_t \tag{2-18}$$

2.6 模型融合

模型融合最早是在 kaggle 等机器学习算法大赛中常用的一个方法，使用模型融合通常可以在各种不同的机器学习任务中使得其最终结果可以获得提升[28]。模型融合即我们在做数据分析问题中综合考虑不同训练模型的特点，并将它们的输出结果融合到一起作为最终输出的方法。常用的模型融合方法主要有从输出的结果中进行融合、stacking 融合和 blending 融合[28]。

从输出的结果中进行融合方法主要有多数表决融合、加权表决融合、对结果取平均等方法。多数表决融合一般用于分类问题中的具体方法，通过把多数训练模型的结果进行多数表决，最终结果选取投票数多的结果从而提高判定率的方法。加权表决融合在多数表决融合默认所有的模型权重都是一样的基础上提出，这里认为每个模型最

中国知网 https://www.cnki.net

终输出的效果不一样从而赋予不同的权值从而得到更合理的输出效果。对结果取平均的融合方法是当前很多机器学习问题上比较常用的一个方法，通过对结果取均值可以减少过拟合现象从而提升模型的性能。

stacking 融合的基本思想是对于模型首先用一些基分类器进行分类，然后再使用另外一个分类区对结果进行整合。由于第二阶段的模型是以第一阶段的模型的预测值作为特征的，因此 stacking 融合的模型可以在特征空间上获得更加多的信息。stacking 由于其自动化的大型继承策略可以通过添加正则项从而有效的对抗过拟合并且不需要进行过多的调参和特征选择是目前提升机器学习效果最好的方法但是其构造非常复杂。

blending 融合的思想与 stacking 融合的思想大致相同，blending 融合思想是直接将 10%的结果再留出集上继续进行训练，用不相交的数据集训练出不同的结果后直接将输出值进行平均。blending 融合比 stacking 简单，避开了信息泄露问题。而缺点在于使用的数据过少，可能会产生过拟合。

2.7 本章小结

本章节首先介绍了磁盘 SMART 的技术原理及其相关的属性特征，然后介绍了故障预测技术的原理，随后分别介绍了神经网络中常用的三个神经网络模型，并详细卷积神经网络、循环神经网络和 LSTM 神经网络的原理，接下来介绍了 facebook 开源的时间序列预测算法 fbprophet 的工作原理，最后介绍了模型融合方法的思想和主流的模型融合方法，为后文提供了有力的理论依据。

中国知网 https://www.cnki.net

第三章　基于卷积神经网络的磁盘故障检测模型

磁盘 SMART 技术通过阈值算法和告警策略实现了磁盘故障的提前告知功能，但是依靠 SMART 技术进行的磁盘故障预测精度低，因此运维和相关研究人员着手使用机器学习算法进行磁盘故障预测[62]。由于磁盘 SMART 数据特征太多使得磁盘故障预测模型存在过于复杂、无法将磁盘信息发掘充分且预测精度不高等问题。卷积神经网络利用多个卷积核分别计算有效地利用局部处理数据、权值共享，使其可以在输入数据保持高维度的同时自动有效的提取出数据有用特征并进行计算，从而达到识别或分类的目的。本章基于卷积神经网络可以对高维数据信息特征深度挖掘，有效提取磁盘的 SMART 数据特征等特点，对磁盘数据集进行预处理得到检测模型所需的数据特征，研究卷积神经网络算法的磁盘故障检测模型，并与其他常用的分类模型进行性能比较。

3.1 方案的整体流程

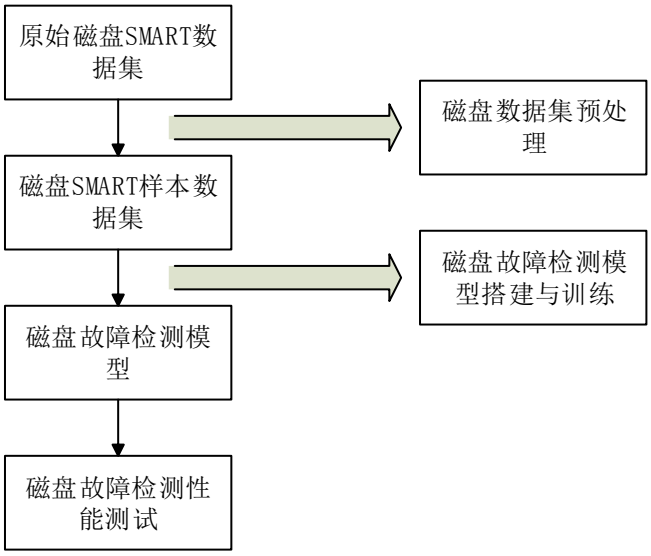


图3.1 磁盘故障检测方案的整体流程

图 3.1 是针对磁盘故障检测方案的整体流程介绍，首先从磁盘数据集出发，使用磁盘厂商提供的带有当前磁盘是否存在故障标签的磁盘 SMART 数据作为输入数据，利用卷积神经网络来建立当前输入数据与磁盘是否存在故障的关系，并使用磁盘训练数据集将数据样本进行训练得到磁盘故障检测模型，利用磁盘故障检测模型对当前磁盘状态进行检测从而达到根据磁盘的 SMART 数据检测出磁盘是否存在故障的目的。

中国知网 https://www.cnki.net

3.2 数据预处理

磁盘数据集为一个巨大的数据文件，由于磁盘数据集存在样本不平衡状况并且每个磁盘数据特征的格式和取值范围差距较大[61]。这种形式的磁盘数据无法直接使用卷积神经网络进行磁盘故障检测模型的构造，因此在进行磁盘故障检测模型的建立之前需要对磁盘数据进行预处理[69]。磁盘的数据预处理主要包括三个步骤：清洗磁盘数据以保留重要信息，缺失磁盘数据处理，以及对整个磁盘数据进行样本采样。

3.2.1 数据清洗

磁盘数据清洗主要工作是将磁盘数据集中与磁盘故障检测的无关的数据项进行清洗。磁盘数据集中含有磁盘编号、磁盘容量、SMART 等数据，但是绝大多数数据对于磁盘故障检测均不包含关键意义，因此直接将这些数据筛选后删去。这里我们只保留磁盘的 SMART 信息和当前磁盘是否故障标签。

由于数据集中每项磁盘 SMART 数据均含有原始值和标准化值两种，这里我们使用磁盘的标准化值来进行模型的构建。

经过磁盘数据清洗后，我们将磁盘数据集中保留了磁盘故障检测需要的属性即磁盘相关 SMART 属性和当前磁盘是否存在故障的标签。

3.2.2 缺失值处理

由于磁盘数据集并没有记录所有的磁盘 SMART 特征信息，同时磁盘生产厂商的不同可能会出现不同的磁盘设备型号导致存在不同的属性，因此数据集中个别样本的特征值会有明显的数值缺失。而且故障磁盘的数据集和良好磁盘的数据集样本会存在极度不平衡，一般良好的磁盘数量会远远超过故障的磁盘数量。

因此我们在缺失的数据值填补中尽量保留所有的故障磁盘样本，将故障磁盘的缺失属性数据用该磁盘前一天数据和后一天数据的平均值来代替，而对于良好的磁盘缺失特征超过1/3时则视为该样本数据无效并将该项磁盘数据直接删除掉，否则同样利用前一天数据和后一天数据的均值来代替该项磁盘数据缺失样本属性。

3.2.3 样本采样

将磁盘数据进行清洗和磁盘个别属性缺失值处理以后，磁盘数据集保留了磁盘 SMART 特征信息和当前磁盘是否存在故障的标签。由于磁盘数据具有极度不平衡的特点，如果训练样本极度不平衡则会导致模型在训练时侧重于训练样本数目较多的类别从而导致模型的训练效果不好，因此我们在磁盘故障检测模型的搭建和训练之前还需要将不平衡的训练样本集进行处理。

首先，在将不平衡样本集进行处理之前需要将磁盘 SMART 数据进行规范化处理，

中国知网 https://www.cnki.net

将磁盘数据规范化主要方式是将具有不同量纲的磁盘 SMART 数据的经过处理后按照一定比例来进行缩放，使得每项磁盘 SMART 特征数值均落在同一区间，从而减小磁盘数据因素对故障检测模型的影响。考虑到磁盘 SMART 数据的特点，这里我们将数据统一缩放到(-1,1)区间内。具体缩放策略如下：

$$Y = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \bullet 2 - 1 \tag{3-1}$$

这里 $X_{\max}$ 为该项磁盘特征的最大值， $X_{\min}$ 为该项磁盘特征的最小值， X 为该项特征的具体数值， Y 为缩放后的结果数值。

在将 SMART 数据缩放到同一区间后，我们开始将磁盘数据集进行样本不均衡处理。常用的数据集样本不均衡处理方法有数据重采样、类别均衡采样、样本数据合成、代价敏感方法。样本重采样主要包括数据的上采样和下采样，由样本数量较少的一方采样，即通过对数据量小的类别进行随机采样从而扩充数据量，但是这个过程可能会采到大量的重复样本，这种采样方式为样本的上采样。由样本数量较多的一方采样，即通过对数据量大的类别进行随机采样从而缩小数据量，但是这个过程有可能会丢弃一部分样本特征；类别均衡采样指按照样本类别分组，每个类别生成一个样本列表，先随机选择一个或几个类别然后从对应的样本列表中选择随机样本，但是这个过程在处理海量数据时可能由于特征选取和分类过多导致过程十分繁琐；样本数据合成通过算法对少数特征进行样本数量合成从而扩充数据量，这种方法可能会导致得到样本分类效果和真实情况相比有较大的偏差；代价敏感方法为通过增加损失函数改变类别权重的方法达到样本平衡的目的这种方法从算法层面平衡样本而样本数量本身并不会发生改变。

这里我们将磁盘训练样本集进行下采样，将整个磁盘数据训练集按照良好磁盘数据集与故障磁盘数据集为 10:1 的比例将故障标签为良好的磁盘特征进行随机采样，而故障磁盘数据集则保持不变。经过数据集样本采样以后，我们得到了良好磁盘数据与故障磁盘数据比例相对平衡的磁盘数据集，接下来我们将利用预处理完成的数据集来构造磁盘故障检测模型。

3.3 磁盘故障检测模型

在完成数据预处理以后，我们开始搭建基于卷积神经网络的磁盘故障检测模型并进行训练。磁盘故障检测模型模型整体结构如图 3.2 所示，首先将带有故障标签的磁盘 SMART 数据输入到卷积神经网络中，利用卷积神经网络使用多个卷积核分别计算有效地利用局部处理数据、权值共享，使其可以在输入的磁盘 SMART 数据保持高维

中国知网 https://www.cnki.net

度的同时自动有效的提取出磁盘数据的有用特征，然后输出为磁盘是否故障信息。进行磁盘故障检测的卷积神经网络主要分为三个部分，即卷积神经网络的卷积层、池化层和全连接层。由于根据磁盘 SMART 数据做故障分类与传统的图像和文本分类问题不同[29],[30]，因此我们在进行模型构建时对原始模型进行了改进，下面我们针对这几个网络层分别进行说明。

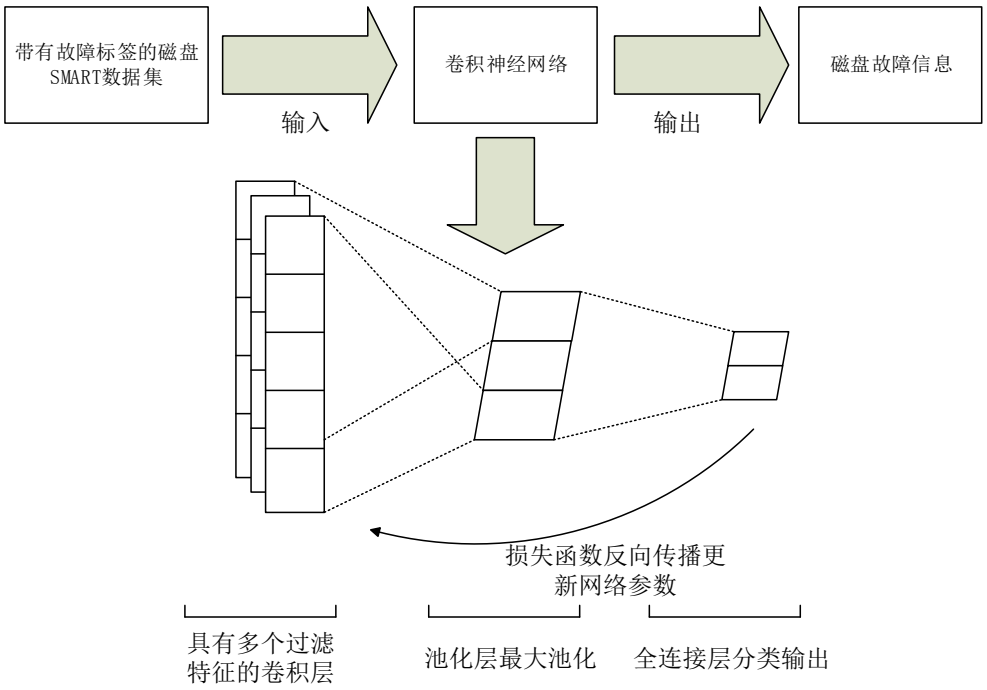


图3.2 磁盘故障检测模型设计

3.3.1 模型设计

基于卷积神经网络的磁盘故障检测模型设计主要为卷积神经网络的设计，将磁盘 SMART 数据输入卷积神经网络以后首先是卷积层，这里由于磁盘数据分类特点与图像领域不同，磁盘数据为时间序列，我们在这里使用一维卷积窗，输入数据为一个磁盘一天的数据。由于磁盘数据特点使得输入的长度远远大于文本分类问题的输入长度，因此这里我们使用多个卷积层与池化层使得模型可以尽可能多的提取到磁盘中的信息。具体模型中卷积层与池化层的层数和卷积窗的长度等参数的取值取决于磁盘 SMART 数据的长度。针对磁盘故障检测模型设计的卷积神经网络包含两个卷积层和池化层。第一层卷积层包含了 32 个卷积窗，池化层的池化窗的长宽为 3，第二层卷积层包含了 16 个卷积窗，池化层的池化窗的长宽为 3，横纵方向的滑动步长均为 2。卷积层和池化层后为全连接层，第一层全连接层包含 64 个神经元，第二层全连接层为输出层。

对于卷积层中的输入矩阵 J，矩阵行为磁盘特征，列为磁盘数据。因此该故障检

中国知网 https://www.cnki.net

测模型中的卷积层输出为

$$C = f(\sum_i w_i j_i + b) \tag{3-2}$$

这里 $f(\bullet)$ 为激励函数，采用 ReLU(The Rectified Linear Unit/修正线性单元)函数，它具有求梯度简单，收敛快的特点，图像如图 3.3 所示。

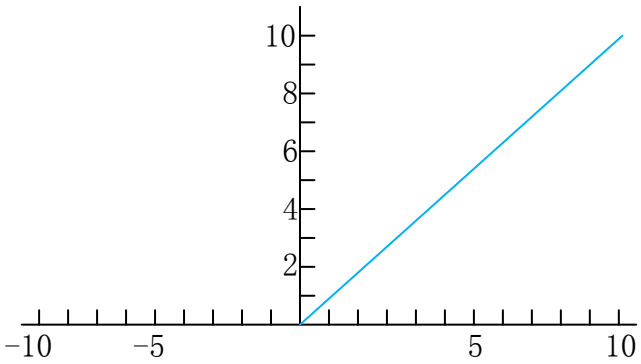


图3.3 ReLU 函数

对于磁盘故障检测模型中的池化层，我们使用 Max pooling 方法提取磁盘数据信息特征，即使用最大值作为输出矩阵相应元素的值。

对于磁盘故障检测模型中的全连接层，在磁盘数据经过两个卷积层与池化层的处理完成之后，我们就能够得到磁盘输入序列中所包含的重要信息特征，然后再通过全连接层将这些磁盘数据特征进行处理后就可以得出对产生磁盘数据系统的当前状态进行判断的模型从而确定该磁盘当前状态是否存在故障的概率。全连接层输出为：

$$y = f(wx + b) \tag{3-3}$$

这里 x 为最后一层池化层的输出结果，$f(\bullet)$ 为激活函数，我们采用 Sigmoid 函数，将输出映射到[0,1]之间，其计算公式为：

$$f(x) = \frac{1}{1+e^{-x}} \tag{3-4}$$

3.3.2 模型训练与测试

磁盘故障检测模型的训练和测试流程如图 3.4 所示。

中国知网 https://www.cnki.net

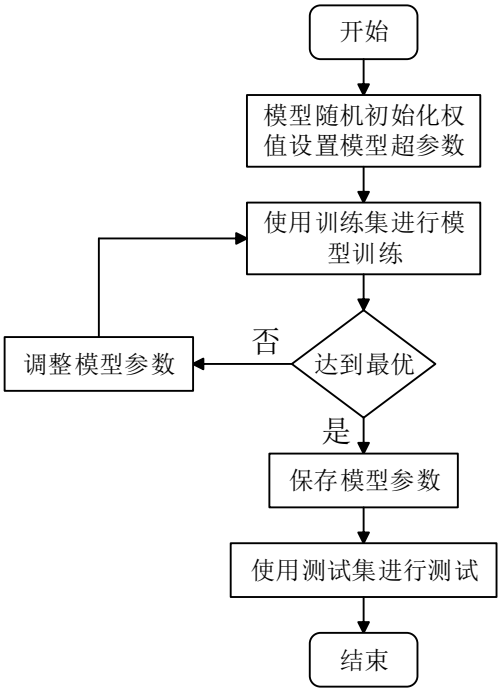


图3.4 磁盘故障检测模型训练流程

首先将整个系统的超参数进行随机初始化。这里我们将使用的磁盘数据集按照6:1:3 的比例划分为磁盘数据训练集、磁盘数据验证集和磁盘数据测试集，即将整个磁盘数据集 60%的数据样本作为磁盘故障检测的训练集来建立故障检测模型中检测模型的关系，10%的数据集样本作为磁盘故障检测模型训练过程中超参数调整的验证集，最后 30%的数据集样本作为磁盘故障检测模型训练完成后的测试集进行模型的性能测试。然后将划分好的训练集数据输入磁盘故障检测模型中进行模型训练，模型训练完成后得到的磁盘故障检测模型再利用验证集将数据集输入到模型中利用验证集来测试模型的性能，直到磁盘故障检测模型达到符合的评价指标以后训练结束，然后将训练完成的检测模型中的参数进行保存。最后再将测试集数据输入到训练好的故障检测模型中得到磁盘故障输出结果并与真实数据的故障情况进行对比。

在反向传播中，我们使用 adam 算法(自适应矩估计算法)来计算损失函数对每项参数的梯度来将模型参数进行更新[32][33]。首先将磁盘故障检测模型输入矩阵的梯度进行一阶和二阶矩估计，得到 x_t 和 y_t：

$$x_t = a_1 x_{t-1} + (1-a_1) g_t \tag{3-5}$$

$$y_t = a_2 y_{t-2} + (1-a_2) g_t^2 \tag{3-6}$$

中国知网 https://www.cnki.net

然后对 x_t 和 y_t 进行校正得：

$$x_t = \frac{x_t}{1-a_1^t} \tag{3-7}$$

$$y_t = \frac{y_t}{1-a_2^t} \tag{3-8}$$

最后计算磁盘故障检测模型参数的更新值，从而计算出更新后的参数 θ_t 的值：

$$\theta_t = \theta_{t-1}\left| -\frac{\eta x_t}{\sqrt{y_t+\varepsilon}} \right. \tag{3-9}$$

在磁盘故障检测模型的测试阶段，我们不需要修改模型每层的权值参数，所以在模型测试时只需要进行前向计算。检测模型的前向计算只需要依次计算出每层的输出值，最终得到从全连接层的输出值即为测试样本是否存在故障的概率。这里我们将输出值根据不同检测阈值设置进行对比来选择最佳阈值作为最终故障检测器判定标准。

3.4 实验及结果分析

在完成磁盘数据集预处理和故障检测模型搭建后，接下来我们开始进行磁盘故障检测实验。实验目的主要为了训练卷积神经网络的模型的超参数，同时选取基于不同算法的磁盘故障检测模型与基于卷积神经网络的磁盘故障检测模型性能进行对比。

3.4.1 实验运行环境

本次实验我们所使用的计算机相关参数以及运行环境配置如表 3.1。由于深度学习在进行反向传播时需要占用大量的资源，因此该模型的训练过程均在 GPU 上进行。本实验所使用的 GPU 型号为 NVIDIA GeForce GTX1060。模型建立时使用 Anaconda 开发环境并使用 Tensorflow 库，CUDA 版本为 9.0，编程开发语言为 Python3.4.1。

中国知网 https://www.cnki.net

表3.1 实验运行环境

实验参数	使用参数
处理器	AMD 瑞龙 1700(r7) 8 核 3.0GHz
运行内存	DDR4 32G(16*2) 3000 频
显卡	NVIDIA GeForce GTX1060
物理内存	1TB
操作系统	Windows10
CUDA[39]	CUDA9.0
编程语言	Python3.4.1
开发框架[70]	TensorFlow1.9.0

3.4.2 实验数据集

为了评估我们所提出的磁盘故障检测方法的实用性，这里我们使用 Backblaze 公司所提供的开源磁盘数据集[35]。该磁盘数据集主要包括了 2018 年 1 月 1 日至 2018 年 12 月 31 日一年时间所观察的 92348 个磁盘驱动器每天的相关数据。这些观察所记录的磁盘数据主要包括了每个磁盘设备有关的序列号、磁盘型号、磁盘容量、当前磁盘是否发生故障信息和 90 项磁盘 SMART 属性信息。根据磁盘数据集的特征，如果某磁盘设备停止工作或磁盘的第 5、187、188、197、198 项磁盘 SMART 信息检测失败，则该磁盘被标记为故障磁盘，该数据集大多数磁盘的 SMART 属性并不完全进行提取记录，该数据集对于没有进行提取的磁盘 SMART 属性记为空白。

对于磁盘数据集的预处理部分，首先将磁盘数据进行数据清洗，主要保留磁盘的故障标签和 SMART 信息。磁盘 SMART 数据清洗后部分示意如下。

原始数据为：

1.data

2.serial_number

3.model

4.capacity_bytes

5.failure

6.smart_1_normalized

7.smart_1_row

……

经过数据清洗后，磁盘信息变为：

中国知网 https://www.cnki.net

1.failure

2.smart_1_normalized

3.smart_2_normalized

……

然后将磁盘数据集进行缺失值处理，对于缺失值填补将故障标签的磁盘数据前一天和后一天的 SMART 数据做均值处理，最后进行样本采样。样本采样的数据缩放结果如表 3.2 所示。

表3.2 部分磁盘 SMART 数据缩放后结果

SMART 数据	缩放前数值	缩放后数值	该特征均值
Smart_01	120	-0.159420	99.756599
Smart_02	134	-0.247312	135.821525
Smart_03	91	-0.905882	98.955631
Smart_05	100	-0.375566	102.3143142

3.4.3 性能判定指标

磁盘故障检测的目标是在给定输入状态后使磁盘故障检测模型的输出结果可以尽可能准确的检测出磁盘当前状态的故障情况。由二元分类问题的结果可知，磁盘故障检测模型的当前输入一般有四种结果：假设输入为正类(磁盘正常)，如果检测器检测结果为正，则结果为真阳性(TP)。如果检测器检测结果为负(磁盘故障)，则结果为假阴性(FN)。假设输入为负类，如果检测器检测结果为正，则结果是假阳性(FP)。如果检测器检测结果为负，则为真阴性(TN)。表 3.3 为磁盘故障检测可能出现的结果。

表3.3 磁盘故障检测可能出现的结果

检测值 / 真实值	正	负
正	TP	FN
负	FP	TN

如表 3.4 所示，对于二分类问题，使用准确度、精确度、召回率和 ROC 曲线来说明磁盘故障检测模型的性能好坏，FPR 与 TPR 曲线为接收器操作特性(ROC)曲线，ROC 曲线下面积为 AUC 用来评估分类器的性能[34]，ROC 曲线的对角线为 FPR=TPR，当磁盘故障检测的 ROC 曲线在对角线上方时，该检测模型才有意义。理想情况下，

中国知网 https://www.cnki.net

曲线的 TPR=1，FPR=0 时，该磁盘故障检测模型的性能最好。AUC 为 ROC 曲线下面积，当该值越接近 1，表示该磁盘故障检测模型的性能越好。

表3.4 磁盘故障检测模型性能评估标准

准确度	$\frac{TP+TN}{TP+FP+FN+TN}$
精确度	$\frac{TP}{TP+FP}$
召回率(TPR)	$\frac{TP}{TP+FN}$
误报率(FPR)	$\frac{FP}{FP+TN}$

3.4.4 不同模型性能对比

接下来将基于卷积神经网络的磁盘故障检测模型与基于支持向量机(SVM)的磁盘故障检测模型[12]和基于 BP 神经网络的磁盘故障检测模型[74]针对准确度、精确度、召回率(表 3.5 所示)、ROC 曲线(图 3.6 所示)和 AUC 值(图 3.5 所示)等性能进行对比，ROC 曲线主要将磁盘故障检测模型阈值分别取 0.25、0.3、0.4、0.5、0.65、0.75、0.85、0.9 时的情况进行对比。

表3.5 不同模型磁盘故障检测性能对比

评价指标 / 训练模型	准确度	精确度	召回率	误报率
卷积神经网络	0.73493	0.82936	0.86317	0.08224
支持向量机	0.72613	0.76613	0.83801	0.07611
BP 神经网络	0.71290	0.81225	0.77462	0.09304

由 ROC 曲线下面积计算可得卷积神经网络 AUC=0.86，支持向量机 AUC=0.81，BP 神经网络 AUC=0.78，由图 3.5 可知，基于卷积神经网络的 AUC 值要大于基于支持向量机和 BP 神经网络的 AUC 值；由图 3.6ROC 曲线对比可知，基于卷积神经网络的检测性能要优于基于支持向量机和 BP 神经网络的检测性能。综上，基于卷积神经网络的磁盘故障检测模型在所有指标上都要优于基于支持向量机的故障检测模型和基于 BP 神经网络的磁盘故障检测模型。

中国知网 https://www.cnki.net

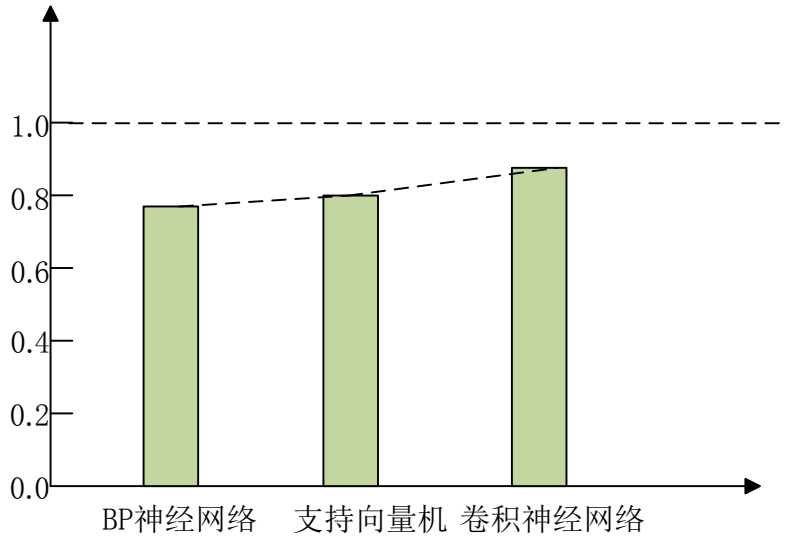


图3.5 不同检测模型 AUC 值对比

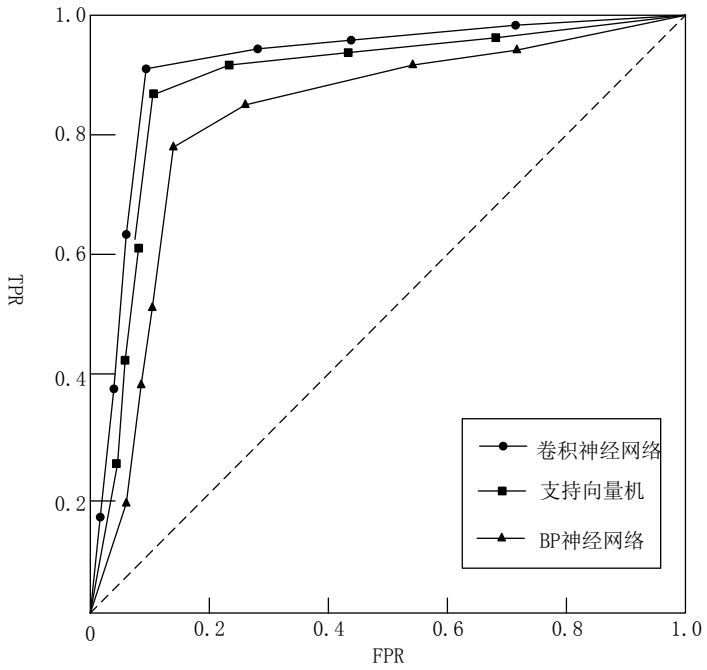


图3.6 不同检测模型的 ROC 曲线对比

3.4.5 结果分析

从不同算法的磁盘故障检测模型的性能对比可以看出，基于卷积神经网络的磁盘故障检测算法性能最优，其分类性能要高于基于支持向量机和 BP 神经网络算法的磁盘故障检测模型，这是由于卷积神经网络有效地利用局部处理数据、权值共享，使其将输入的磁盘数据保持高维度的同时自动有效的提取出磁盘数据的有用特征并进行计算，避免了检测结果的过拟合现象。因此基于卷积神经网络的磁盘故障检测模型是可行的。

中国知网 https://www.cnki.net

3.5 本章小结

本章主要针对磁盘故障预测系统的磁盘故障检测模型部分做了研究，我们针对磁盘数据集的特点提出了基于卷积神经网络的磁盘故障检测模型，其依靠卷积神经网络，通过对磁盘数据与当前磁盘是否存在故障的标签的分析和训练。使该模型在只需要提供相关磁盘信息的前提下可以直接判断出当前磁盘是否出现故障问题。本章节还介绍了磁盘数据的预处理，磁盘数据的采样规则，然后对磁盘故障检测模型的构成进行了详述，包括算法实现和结构设计，然后将磁盘故障检测模型进行了训练与测试并针对不同参数和与传统故障检测模型算法进行了对比实验。实验结果证明基于卷积神经网络的磁盘故障检测模型对于磁盘故障分类问题的处理性能更优。

中国知网 https://www.cnki.net

第四章　基于模型融合的磁盘故障预测模型

第三章分析了基于卷积神经网络磁盘故障检测性能，这是针对已知的磁盘数据根据当前状态判定磁盘是否发生故障的策略。随着对磁盘故障预测研究分析发现，目前的算法只能预测磁盘未来是否发生故障，无法预测出磁盘发生故障的具体时间，并且预测时间较短。运维和相关领域研究人员无法准确的根据预测结果进行进一步的处理导致算法的实用性下降，因而预测磁盘未来故障具体发生的时间尤为重要[33]-[34]-[35]。本章研究并分析磁盘数据的时序性，基于 LSTM 神经网络对长时间问题处理和 fbprophet 算法对突变点和周期性问题处理的优势，根据过去 SMART 数据预测未来 SMART 数据，并将结果进行融合来提高磁盘时间序列预测精度，再使用磁盘故障检测算法判断未来磁盘是否发生故障，最后与其他常用的磁盘故障预测模型进行性能比较。

4.1 方案的整体流程

磁盘故障预测模型的具体实现思路如图 4.1 所示。

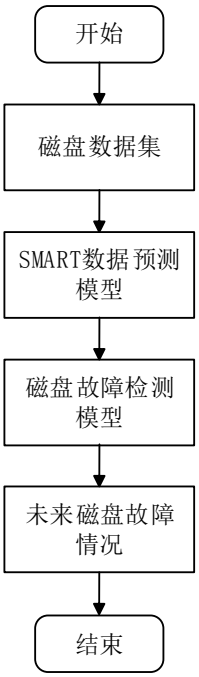


图4.1 磁盘故障预测模型整体设计

首先将磁盘数据集进行预处理，然后将处理后的 SMART 数据输入到 SMART 数据预测模型中，输出结果为未来时间的 SMART 数据，最后将未来时间的数据再输入

中国知网 https://www.cnki.net

到磁盘故障检测模型中，输出即为对应未来时间的磁盘是否故障的结果，从而得到可以预测出未来具体时间发生故障的磁盘故障预测模型。接下来我们介绍磁盘数据集预处理的过程。

4.2 数据预处理

本章的磁盘数据预处理方法与第 3 章的磁盘数据预处理方法步骤大致相同，主要区别在于将磁盘数据集进行数据清洗和缺失值处理后，增加了 SMART 数据的特征选择、主成分分析的步骤。由于 SMART 数据预测模型利用磁盘数据集的时序性用过去的 SMART 数据预测未来的 SMART 数据，不需要判断磁盘的故障信息，因此磁盘数据集数据清洗步骤中除了保留 SMART 信息以外还保留了磁盘数据集的时间戳和每个磁盘编号，去除掉了当前磁盘是否故障的标签；SMART 数据的缺失值处理方法和磁盘样本采样方法与第 3 章的 SMART 数据的缺失值处理方法和磁盘样本采样方法相同，因此不再进行描述，磁盘数据预处理主要详细说明 SMART 数据的特征选择方法和主成分分析方法。

4.2.1 特征选择

磁盘数据预处理主要为了清洗掉与磁盘数据预测模型的构建无关的特征，因此这里我们清洗掉了当前磁盘是否故障标签、磁盘容量，保留了磁盘状态收集的时间戳、磁盘编号和 SMART 数据；接下来针对清洗后磁盘数据集中的缺失值进行处理，我们保持与第 3 章相同的缺失值处理方法。在将磁盘数据集数据进行数据清洗以后，保留磁盘状态对于磁盘数据提取的时间戳、磁盘编号和 SMART 数据。由于磁盘的 SMART 属性高达一两百条，其中包含的大量 SMART 数据特征均具有强相关性，如果直接进行磁盘数据预测不仅工作量大而且不利于 SMART 数据预测。因此我们需要先对 SMART 数据进行特征选择，即需要将 SMART 数据中一些不相关的数据进行筛选。这里使用信息熵和信息增益的方法进行处理。

信息熵的概念最早是由统计热力学引入的，信息熵的概念是由香农提出，它用于随机变量的不确定性度量[40]。

$$H(X)=-\sum_{x\in X}P(x)\log P(x) \tag{4-1}$$

信息熵[41]是用来减少随机并且不确定性的属性（不确定属性的减少）。利用 $\log(1/P)$ 来衡量不确定性。P 为某件事发生的概率，越大说明这件事的不确定性越小。信息熵的公式其实就是 $\log(1/P)$ 的期望，即表示 P 不确定性的期望，信息熵值越大，

中国知网 https://www.cnki.net

说明 P 的不确定性越大。为了在 SMART 数据中选出可以表示磁盘当前特性的状态特征，我们用信息熵来判断所选 SMART 属性的信息量。这里用 X 表示磁盘数据，$P(x)$ 表示第 x 项属性在数据集中出现的概率。将磁盘数据 X 按照每个 SMART 属性进行划分,则每个属性的信息熵为：

$$H_A(X)=\sum_{j=1}^{n}\frac{|X_j|}{|X|}H(X_j) \tag{4-2}$$

信息增益是用来表示单个选择特征的指标，信息增益越大，则这个特征的选择性越好，信息增益的公式表示为：

$$G(A)=H(X)-H_A(X) \tag{4-3}$$

根据特征选择算法，将信息增益较大的磁盘 SMART 数据取出作为一项特征。这里我们保留 SMART 数据中信息增益较大的数据作为特征。

4.2.2 主成分分析

在将磁盘数据集进行了特征选择后我们去除了一部分信息增益较小的 SMART 特征项，但是由于经过磁盘特征选择处理以后的 SMART 数据仍属于高维数据且具有一定的相关性，因此为了磁盘数据处理方便，再将剩下 SMART 数据做主成分分析即将 SMART 数据做数据降维处理。

数据降维是针对一组数据集中的数据具有高维度特征时在经过处理后可以减少数据集维度的一种常用的数据预处理方法。通过数据集降维可以使数据集中高维度的数据只保留下来最重要的一些特征，从而去除掉一些不重要的特征和噪声，进一步提升数据处理速度的一种方法。

主成分分析法 PCA(Principal Component Analysis)是一种最广泛的数据降维方法[42]。通过数据降维的方法，可以将 SMART 数据从高维度进一步降维，从而留下少量的不相关特征，有利于进行 SMART 数据预测建模[43]-[44]。

首先将 SMART 数据进行规范化处理，考虑到 SMART 数据的特点，这里我们仍旧将磁盘数据统一缩放到(-1,1)区间内。具体磁盘数据的压缩方法与第三章的数据压缩方法相同，这里不再进行描述。

在将 SMART 数据进行了缩放后我们开始构建磁盘样本特征的协方差矩阵，首先先构造磁盘样本的特征矩阵[44]：

中国知网 https://www.cnki.net

$$X=\begin{bmatrix}(x^{(1)})^T\\ \vdots\\ (x^{(m)})^T\end{bmatrix}=\begin{pmatrix}x_1^{(1)} & \cdots & x_n^{(1)}\\ \vdots & \ddots & \vdots\\ x_1^{(m)} & \cdots & x_n^{(m)}\end{pmatrix} \tag{4-4}$$

这里 m 为磁盘的所有样本特征， n 为磁盘数量，所以有：

$$\mathrm{cov}=\frac{1}{m}X^T\bullet X \tag{4-5}$$

由此公式算出 SMART 样本数据的协方差矩阵的特征值和特征向量后得降维矩阵：

$$U=[u^{(1)}\cdots u^{(n)}] \tag{4-6}$$

这里U 为协方差矩阵的所有特征向量，每一列都是一个特征向量，按照特征值大小由大到小进行排序。

SMART 数据的降维矩阵U 中的特征值选择靠前的特征向量进行还原特征。至此，经过 SMART 数据预处理后磁盘数据集主要由三部分组成：磁盘数据状态时间戳、磁盘编号和去相关以后的 SMART 属性。

4.3 SMART 数据预测模型

针对 SMART 数据数据预测模型，我们使用磁盘厂商提供的磁盘 SMART 数据作为输入数据，利用融合了 LSTM 神经网络和 fbprophet 算法的模型建立根据当前输入的 SMART 数据预测未来时间 SMART 数据的模型。

SMART 数据预测模型的整体方案如图 4.2 所示，首先通过对原始磁盘数据集进行预处理和磁盘样本数据采样得到训练集数据、验证集数据和测试集数据，处理后的每个训练集数据包含了基于时间序列的当前 SMART 数据特征、未来 SMART 数据特征，然后利用基于时间序列的相关数据预测算法将训练集的 SMART 数据的当前数据和未来数据关系建立对应的时间序列预测模型，并利用验证集数据进行模型验证使预测模型性能达到最优，将测试集数据输入到训练好的 SMART 数据预测模型中得到 SMART 数据的预测结果并将 SMART 数据预测结果进行性能对比。

中国知网 https://www.cnki.net

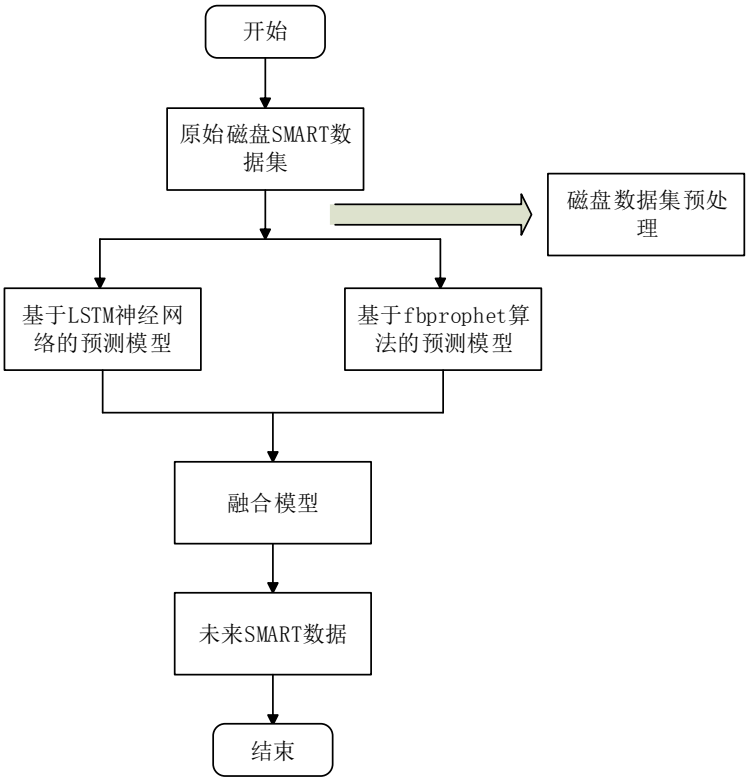


图4.2 SMART 数据预测模型整体设计思路

4.3.1 基于 LSTM 神经网络的 SMART 数据预测模型

图 4.3 为基于 LSTM 神经网络 SMART 数据预测模型设计方案，LSTM 神经网络是一种基于循环神经网络的改进模型。循环神经网络在传统神经网络的基础上，解决了预测模型每一次计算只会关注当前时刻处理而不关心上一刻的处理对当前时间节点的影响的问题，但是循环神经网络无法解决长时间预测问题。因此我们使用基于 LSTM 神经网络进行 SMART 数据预测，首先搭建基于 LSTM 神经网络的 SMART 数据预测模型。由于磁盘数据集在经过磁盘数据预处理和降维去相关以后得到的 SMART 数据特征之间均不相关，针对此特点，我们将 LSTM 神经网络进行了改进，这里分别使用 LSTM 神经网络对磁盘每一项 SMART 特征进行预测建模[45],[46]。

基于 LSTM 神经网络的 SMART 数据预测模型的循环结构主要分为三个门(遗忘门、输入门、输出门)与一个记忆单元，整个基于 LSTM 神经网络的磁盘数据预测模型分为前向计算和反向传播过程。SMART 数据预测模型的前向计算主要依靠三个门来控制[17],[47]。遗忘门决定在每个循环状态中磁盘 SMART 数据需要丢弃什么信息，遗忘门输出为：

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \tag{4-7}$$

这里h_{t-1}为上一个神经元的输出即上一个时间点的该项磁盘 SMART 数据特征信

中国知网 https://www.cnki.net

息，x_t为当前神经元的输入即当前时刻的磁盘 SMART 数据特征信息，σ为 Sigmoid 函数。通过 Sigmoid 函数输出为介于[0,1]的值从而可以确定是否将上个周期的磁盘 SMART 数据信息从历史记录中删除。

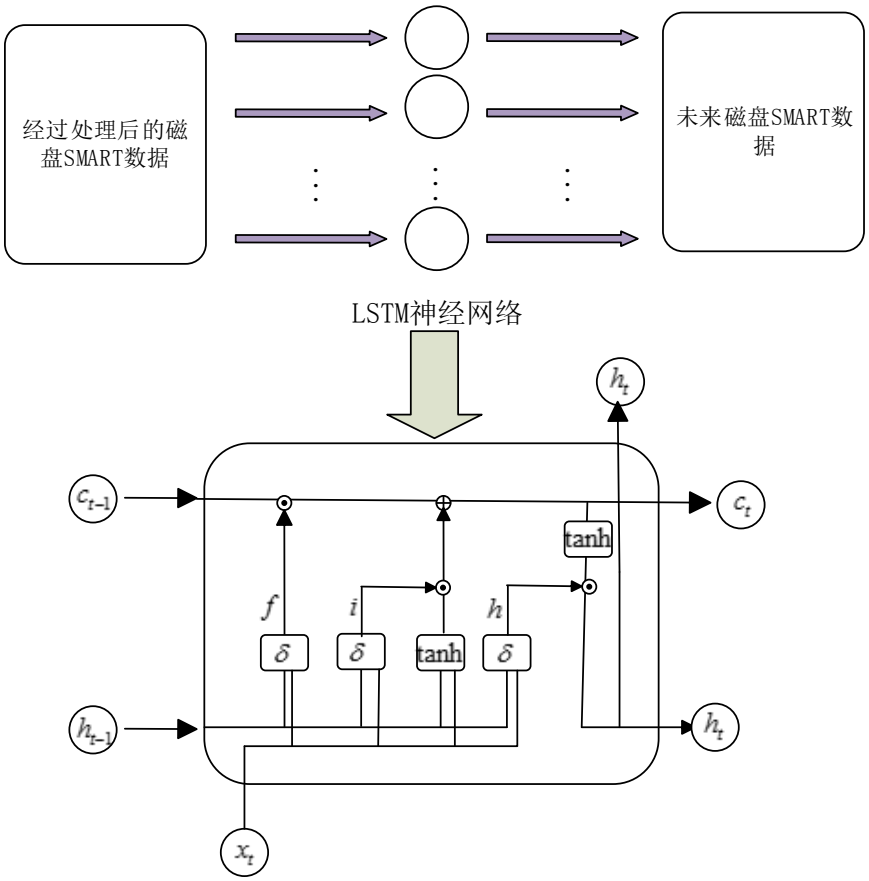


图4.3 基于 LSTM 神经网络 SMART 数据预测模型设计方案

输入门决定我们在每个循环状态层需要加入多少 SMART 信息到神经元中，SMART 数据预测模型的输入门公式为：

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \tag{4-8}$$

i_t函数效果与遗忘门相同，主要用来决定最终当前时刻是否将当前循环状态的 SMART 信息存储到神经元状态中，此时输入为当前时刻的 SMART 信息与上一时刻的神经元输出。然后我们将神经元状态通过 tanh 进行处理得到备选的用来更新 SMART 信息的内容:

$$\tilde{C}_t = \tanh(W_c \bullet [h_{t-1}, x_t] + b_t) \tag{4-9}$$

中国知网 https://www.cnki.net

再通过矩阵运算将过去的 SMART 信息状态C_{t-1}与遗忘门相乘从而去除掉我们这里需要去除的 SMART 状态信息。然后加上$i_t \bullet \tilde{C}_t$作为新的 SMART 磁盘信息状态。

$$C_t = f_t \bullet C_{t-1} + i_t \bullet \tilde{C}_t \tag{4-10}$$

输出门用来确定输出 SMART 状态信息并将此刻的输出值传递到下一个神经元中，这个值基于当前神经元的状态。这里我们的输入值为当前t时刻 SMART 信息x_t和磁盘上一时刻状态h_{t-1}。

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \tag{4-11}$$

最后将当前 SMART 信息状态通过 tanh 处理并得到一个[-1,1]之间的值，并和o_t相乘得到一个循环层的最终输出[46]-[47]-[48]。

$$h_t = o_t \bullet \tanh(C_t) \tag{4-12}$$

这个过程我们通过增加神经元状态的方式，长距离保持了 SMART 数据特征，缓解了梯度消失的问题从而可以预测更远时间的 SMART 数据。

基于 LSTM 神经网络的 SMART 数据预测模型的反向传播过程与循环神经网络的反向传播过程相同，这里主要分为反向计算每个磁盘数据预测单元的误差项值和根据误差项计算每个单元权重的梯度值。LSTM 神经网络误差项的反向传播主要包括了沿时间t的反向传播，即为从当前时刻计算每个时刻的误差项和将误差项向每层输出的上一层传播。

4.3.2 基于 fbprophet 算法的 SMART 数据预测模型

fbprophet 算法是 facebook 公司开源的一个时间序列预测的算法，fbprophet 是基于时间序列分解和机器学习的拟合提出的[26]-[27]。该算法基于时间序列的分解(Decomposition of Time Series)做了改进。在预测时间序列时添加了季节项、趋势项、剩余项来解决传统时间序列预测的突变问题从而增加模型的预测效果，由于磁盘的 SMART 数据具有时间序列性质，考虑到其他时间序列预测模型对季节性和趋势性预测不够准确，我们在此采用 fbprophet 算法进行 SMART 数据预测建模。由于处理后的 SMART 数据之间不具有相关性，因此我们直接使用 fbprophet 算法对处理后的 SMART 数据分别进行数据预测建模。

基于 fbprophet 算法的 SMART 数据预测模型主要由四部分组成，分别为趋势项、

中国知网 https://www.cnki.net

季节性项、假期项和误差项。fbprophet 算法通过拟合这几项最后将其累加起来从而得到时间序列的预测值，这样可以很好的解决时间序列预测问题出中的周期性变化和突变性[26]。

该 fbprophet 算法的趋势项中主要依赖两个函数进行拟合，一个是基于逻辑回归函数(logistic function)的，另一个是基于分段线性函数(piecewise linear function)的。这里我们采用逻辑回归函数进行 SMART 数据特征的趋势项拟合，逻辑回归表达式为[26]：

$$f(x)=\frac{C}{(1+e^{-k(x-m)})} \tag{4-13}$$

C 为 SMART 数据预测的最大渐进值，k 表示该预测的增长率，m 表示预测的中点，但是这里考虑到对于 SMART 数据特征参数 C，k，m 不可能都是常数，因此这里我们将三个参数替换为基于时间 t 变化的函数，即 $C=C(t),k=k(t),m=m(t)$。

考虑到 SMART 数据特征不会一直保持不变，在某些时间点有可能会发生潜在的周期性变化，这时候我们在 SMART 数据预测模型的函数中加入变点 S。这里基于 SMART 数据的前百分之 80 的趋势初始化设置变点数 $S=40$。并且变点的位置在时间戳 s_j，$1\le j\le 25$ 上。然后根据变点位置可以得到 SMART 数据预测模型增长率的变化。结合逻辑回归函数得到 SMART 数据预测模型趋势项分段的逻辑回归增长模型：

$$g(t)=\frac{C(t)}{1+\exp(-k+a(t)^T\sigma)\bullet(t-(m+a(t)^T\gamma))} \tag{4-14}$$

这里 $a(t)$ 表示指示函数即磁盘数据在变点的变化情况即 $a_j(t)=\begin{cases}1,t\ge s_j\\0,\text{其他}\end{cases}$，$\sigma$ 表示在变点 s_j 上发生的增长率变化量，K 表示增长率，γ 表示 SMART 预测模型的边界 $\gamma_j=(s_j-m-\sum_{t<j}\gamma_t)\bullet(1-\frac{k+\sum_{t<j}\sigma_t}{k+\sum_{t\le j}\sigma_t})$，$C(t)$ 为容量，这里我们取容量为常数 100。

对于季节性趋势的拟合这里我们用傅里叶级数来拟合 SMART 数据的周期性特征。$s(t)$ 的傅里叶级数形式为：

$$s(t)=\sum_{n=1}^{N}a_n\cos(\frac{2\pi nt}{P})+b_n\sin(\frac{2\pi nt}{P}) \tag{4-15}$$

这里 P 为磁盘数据的周期，取 $P=7$，即初始化 SMART 时间序列数据以周为周

中国知网 https://www.cnki.net

期，对于 $P=7$ 而言取 $N=3$。因此 SMART 数据的时间序列季节项为[27]：

$$s(t)=X(t)\beta \tag{4-16}$$

这里 $\beta=(a_1,b_1,\cdots,a_N,b_N)^T$， $X(t)=[\cos(\frac{2\pi(1)t}{7}),\cdots,\cos(\frac{2\pi(3)t}{7}))]$，将 β 初始化为 $\beta\sim N(0,1)$。

对于 SMART 数据预测模型的节假日效应拟合为磁盘的使用存在由于节假日等情况出现磁盘爆发式使用而导致 SMART 时间序列数据出现突变情况，该模型函数表示为[26]

$$h(t)=Z(t)k=\sum_{i=1}^{L}k_i\bullet 1_{\{t\in D_i\}} \tag{4-17}$$

这里 $k\sim N(0,v^2)$，这里 v 取默认值 $v=10$。误差项为 ε 默认服从正态分布。因此得最终基于 fbprophet 算法的 SMART 数据预测模型函数表达式为[26]：

$$y_t=g(t)+s(t)+h(t)+\varepsilon \tag{4-18}$$

根据此模型的函数表达式我们可以将 SMART 数据时间序列对未来的 SMART 数据进行预测。

4.3.3 模型融合

为了使磁盘故障预测模型的性能更优，将基于 LSTM 神经网络和基于 fbprophet 算法的 SMART 数据预测模型进行模型融合，将融合后的结果再进行磁盘故障检测。

考虑到基于 LSTM 神经网络可以预测更远的 SMART 数据，基于 fbprophet 算法对 SMART 时间序列的突变点和周期性问题可以很好的解决的特点，我们采用加权融合的方法将两个预测模型的输出结果进行融合。这里使用线性回归的方式来设置模型的权重[68]。

$$Y=(1-w)Y_1+wY_2 \tag{4-19}$$

这里 w 为模型的权重，Y 为真实值，Y_1 为基于 LSTM 数据预测结果，Y_2 为基于 fbprophet 的数据预测结果。

中国知网 https://www.cnki.net

4.3.4 训练与测试策略

SMART 数据预测模型训练与测试的主要工作为将两个预测模型分别进行训练与测试。这里将磁盘数据集按照 6:1:3 的比例将数据集划分为磁盘预测模型训练集、磁盘预测模型验证集和磁盘预测模型测试集。模型训练集主要负责模型各参数的训练，模型验证集为在训练过程中将不同参数结果利用验证集进行对比从而将该模型的需要训练的参数进行确定，最后将 SMART 数据预测模型利用测试集数据进行结果测试。

基于LSTM神经网络的SMART数据预测模型的训练方式与传统循环神经网络训练方式相同，需要训练的参数主要有：输入门的权重矩阵和偏置项，遗忘门的权重矩阵和偏置项，计算单元状态的权重矩阵和偏置项，输出门的权重矩阵和偏置项[17]。由于权重矩阵W由两个矩阵拼接而成，且这两部分矩阵在反向传播中均使用不同公式，因此我们将权重矩阵在训练的部分描述为两个矩阵。

定义当前t时刻的误差项：$\sigma_t = \dfrac{\partial E}{\partial h_t}$，从而得出上一时刻的误差项为[17]：

$$\sigma_{t-1}^T = \sigma_t^T \frac{\partial h_t}{\partial h_{t-1}} \tag{4-20}$$

因此将 LSTM 神经网络的误差项向前传递可得：

$$\sigma_k^T = \prod_{j=k}^{t-1} \sigma_{o,j}^T W_{oh} + \sigma_{f,j}^T W_{fh} + \sigma_{i,j}^T W_{ih} + \sigma_{\tilde{C},j}^T W_{ch} \tag{4-21}$$

最后得SMART数据预测模型中误差项对LSTM神经网络中各个门的梯度表达式为[17],[45]

$$\sigma_o^t = \sigma^t \tanh C_t \tag{4-22}$$

$$\sigma_i^t = \sigma^t o_t h \frac{\partial \tanh(C)}{\partial C} \tag{4-23}$$

$$\sigma_f^t = \sigma^t C_{t-1} \frac{\partial \tanh(C)}{\partial C} \tag{4-24}$$

$$\sigma_h^t = \sigma^t oi \frac{\partial \tanh(C)}{\partial C} \tag{4-25}$$

中国知网 https://www.cnki.net

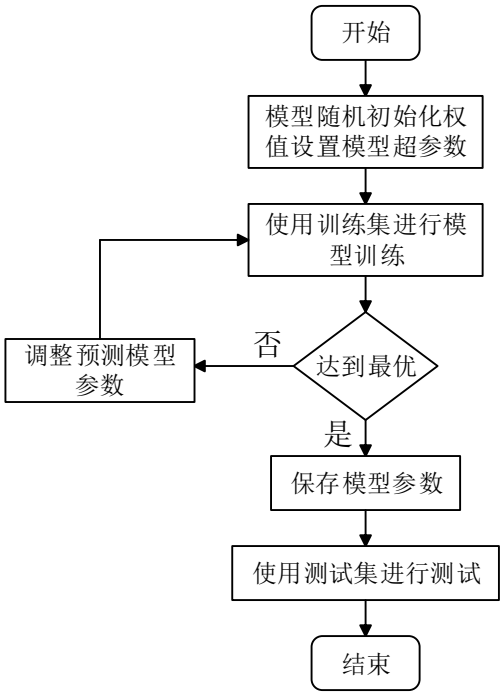


图4.4 SMART 数据预测模型训练流程

基于 fbprophet 算法的 SMART 数据预测模型的训练过程主要需要训练的 SMART 数据预测函数表达式的参数有：变点数，即预测模型的变点；变点变化率即在变点处的变化率；逻辑函数容量值；季节性，即预测模型的周期变化规律；节假日效应，即预测模型的突变情况。将 SMART 数据时间序列的每项特征输入到 fbprophet 时间序列预测模型中经过训练得到预测模型并根据模型预测未来的 SMART 数据值。

由以上公式更新磁盘数据预测模型的所有相关参数然后开始训练 SMART 数据预测模型，将训练完成后的预测模型性能在验证集中进行模型验证，直到当前 SMART 数据预测模型的性能达到最优，最终得出基于 LSTM 神经网络型与基于 fbprophet 算法的 SMART 数据预测模型。具体模型训练过程如图 4.4 所示。

4.4 SMART 数据预测模型实验

完成对磁盘数据集预处理和 SMART 数据预测模型的搭建以后，接下来将进行 SMART 数据预测模型的实验。

实验采用第 3 章所使用的磁盘数据集，这里主要根据磁盘 1 年的 SMART 信息进行建模，首先根据数据预处理方法将 SMART 数据集进行预处理。

对于磁盘数据进行特征选择结果，我们取前 17 项 SMART 数据作为特征，具体结果如表 4.1 所示。

完成 SMART 数据集的特征选择以后，再将处理后的数据进行主成分分析，这里取前 12 项特征作为主成分分析后的结果，如表 4.2 所示。

中国知网 https://www.cnki.net

表4.1 磁盘 SMART 属性信息增益值

磁盘 SMART 特征属性	信息增益
Raw Read Error Rate	0.0423
Spin Up Time	0．0364
Reallocated Sectors Count	0.0310
Seek Error Rate	0.0302
Power on Hours	0.0297
Reported Uncorrectable Errors	0.0277
High Fly Writes	0.0274
Temperature Celsius	0.0271
Hardware ECC Recovered	0.0251
Current Pending Sector Count	0.0249
Raw Reallocated Sectors Count	0.0248
Spin Retry Count	0.0200
Uncorrectable Sector Count	0.0198
Command Timeout	0.0182
Calibration Retry Count	0.0165
Flying Height	0.0130
Write Error Rate	0.0096

表4.2 经过预处理以后磁盘 SMART 属性值

Data	磁盘	Smart_01	Smart_03	Smart_05	Smart_07	Smart_09
20180101	00001	0.483871	-0.037037	1.000000	0.317073	0.789474
20180101	00002	0.322581	0.555556	1.000000	0.487805	0.578947
20180101	00003	0.290323	0.259259	-1.000000	0.317073	0.894737

完成 SMART 数据集预处理后,将结果输入到基于 LSTM 神经网络和 fbprophet 算法的 SMART 数据预测模型中建立基于这两种算法的 SMART 数据预测模型，然后将实验结果与基于 RNN 循环神经网络的 SMART 数据预测模型结果进行对比。这里我们使用的实验环境与第 3 章磁盘故障检测模型实验所使用的实验环境相同，具体我们在这里不再赘述。基于 fbprophet 算法的 SMART 数据预测模型的实现我们直接使用 facebook 网站上开源的 fbprophet 算法。然后将基于 LSTM 神经网络与基于 fbprophet

中国知网 https://www.cnki.net

算法的 SMART 数据预测结果融合并进行性能结果分析。

实验主要根据未来 14 天和未来 30 天的 SMART 数据预测结果将模型性能进行对比和总结。

4.4.1 实验结果

首先将基于 LSTM 神经网络的 SMART 数据预测模型针对不同循环层数的预测性能进行对比。

在磁盘故障检测模型中，评价磁盘故障检测模型的性能主要使用准确度、精确度、召回率和 ROC 曲线来评价磁盘故障检测模型性能的好坏，这里使用的 SMART 数据预测模型为回归模型，回归模型主要使用误差平方和(SSE)、决定系数(R-Square)和校正决定系数(R_a^2)来作为 SMART 数据预测模型性能的主要评价指标。这里我们使用 Y_p 表示模型输出的预测结果，使用 Y_a 表示数据的真实结果，使用 Y_m 表示该项 SMART 特征的均值。误差平方和(SSE)计算的是拟合数据与原始数据对应点的误差的平方和，计算表达式如下：

$$SSE = \sum (Y_p - Y_\mathrm{a})^2 \tag{4-26}$$

误差平方和表示磁盘原始 SMART 数据与真实数据对应点的误差平方和，该值越接近 0 表示模型的拟合性能越好。决定系数 R-Square 的表达式：

$$R^2 = 1 - \frac{\sum (Y_a - Y_p)^2}{\sum (Y_a - Y_m)^2} \tag{4-27}$$

这里 R 表示相关系数，R-Square 的理论取值范围为[–∞,1]，由于实际操作中一般会取值拟合效果较好的模型来评价性能，因此该参数的正常取值范围在[0,1]。这里 R^2 越接近 1，表明该数据预测模型的变量对预测参数 Y 的解释能力越好，这个模型的性能也就越好； R^2 越接近 0，表明该预测模型的性能越差。一般情况下 R^2 大于 0.4 即表示该预测模型的拟合程度较好。由于决定系数 R^2 会随着样本数的增加而增加，因此这里再用校正决定系数进行模型性能的评估，校正决定系数表达式如下：

$$R_a^2 = 1 - \frac{(1-R^2)(n-1)}{n-p-1} \tag{4-28}$$

这里 n 为样本数量， p 为特征数量，该参数抵消了样本数量对于相关系数的影响。

中国知网 https://www.cnki.net

针对不同循环层数预测性能 14 天结果如表 4.3 所示。图 4.5 与图 4.6 为 LSTM 神经网络不同循环层数误差平方和与校正决定系数对比。

表4.3 LSTM 神经网络不同循环层数预测性能对比

LSTM 循环层数	误差平方和 SSE	决定系数 R^2	校正决定系数 R_a^2
5	0.1304	0.5713	0.5669
7	0.0822	0.6322	0.6337
10	0.0671	0.6911	0.7111
12	0.0670	0.6919	0.7349
15	0.0670	0.6927	0.7342

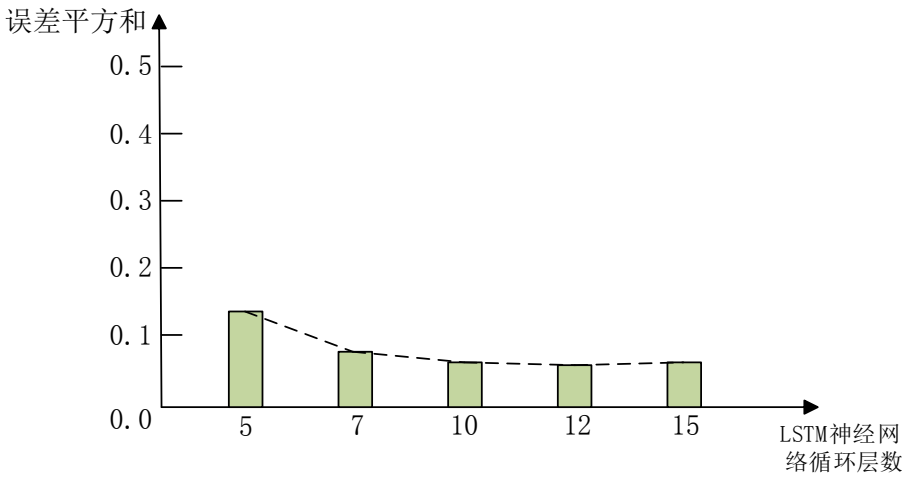


图4.5 不同循环层数 SSE 对比

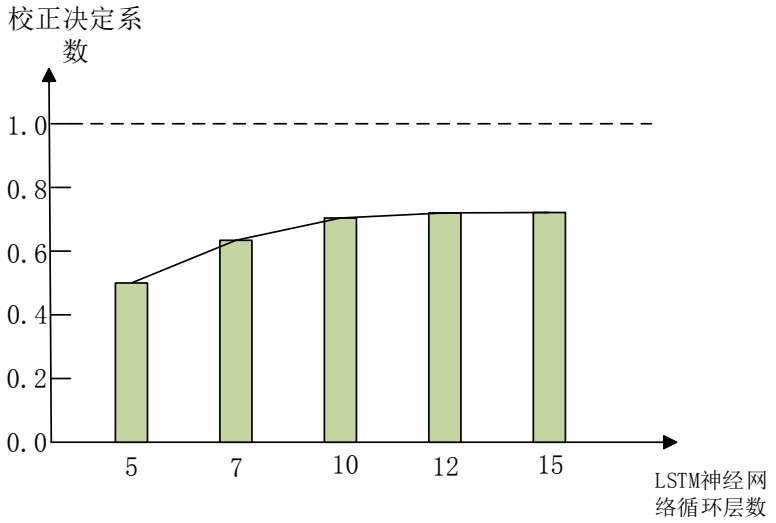


图4.6 预测 14 天结果 LSTM 神经网络不同循环层数校正决定系数对比

中国知网 https://www.cnki.net

观察图 4.5 可知，针对不同循环层数 LSTM 神经网络随着循环层数增加 *SSE* 值逐渐减小，当循环层数达到 10 层时 *SSE* 的变化逐渐趋于稳定。观察图 4.6 可知，校正决定系数值随着循环神经网络层数的增加而增加，当层数超过 10 层时，校正决定系数值趋于稳定。由此可以断定 LSTM 神经网络的循环层数对预测效果的影响随着 LSTM 神经网络的层数加深，磁盘故障预测效果有着明显的提升，但是当 LSTM 神经网络的层数超过 10 以后，预测效果变化逐渐减弱，我们推测出这可能是由于训练时产生的误差原因所引起的。因此在后续的实验当中，我们固定 LSTM 神经网络网络的层数为 10。

将基于 LSTM 神经网络与基于 fbprophet 算法的 SMART 数据预测模型针对 SMART 数据 14 天和 30 天结果进行预测，SMART 数据预测结果如表 4.4、表 4.5。图 4.7 和图 4.8 为不同模型 14 天和 30 天预测结果的误差平方和和校正决定系数对比图。

表4.4 不同模型 14 天 SMART 数据预测结果

磁盘数据预测模型	误差平方和 *SSE*	决定系数 R^2	校正决定系数 R_a^2
RNN 循环神经网络	0.0833	0.544	0.6741
LSTM 神经网络	0.0671	0.6911	0.7111
fbprophet 算法	0.0455	0.7302	0.7464

表4.5 不同模型 30 天 SMART 数据预测结果

磁盘数据预测模型	误差平方和 *SSE*	决定系数 R^2	校正决定系数 R_a^2
RNN 循环神经网络	0.3798	0.3031	0.2713
LSTM 神经网络	0.1077	0.5772	0.5631
fbprophet 算法	0.2013	0.4221	0.4551

由图 4.7 可知，当预测 14 天数据时，基于循环神经网络的 *SSE* 值比基于 LSTM 神经网络和 fbprophet 算法的高，其中 fbprophet 算法的 *SSE* 值最小。当预测 30 天数据时，基于循环神经网络的 *SSE* 值远远大于基于 LSTM 神经网络和 fbprophet 算法的值，基于 LSTM 神经网络的 *SSE* 值最小；由图 4.8 可知，当预测 14 天数据时三种模型的校正决定系数值相差不大，当预测 30 天数据时，基于 LSTM 神经网络和 fbprophet 算法的校正决定系数值远大于循环神经网络的校正决定系数值，其中基于 LSTM 神经网络的校正决定系数值最大，因此基于 LSTM 神经网络和基于 fbprophet 算法的 SMART 数据预测模型对 SMART 时间序列的拟合程度较好，可以有效的预测出未来

中国知网 https://www.cnki.net

14 天和 30 天的 SMART 数据，其中基于 LSTM 神经网络的 SMART 数据预测模型对于 30 天数据预测结果更接近真实数据，通过对比基于 fbprophet 算法的数据预测模型发现，该模型在预测精度上略低于基于 LSTM 神经网络算法的预测模型，我们猜测 fbprophet 算法在突变点和周期性规律的预测效果更好。因此可以使用这两种方法进行融合模型的搭建。

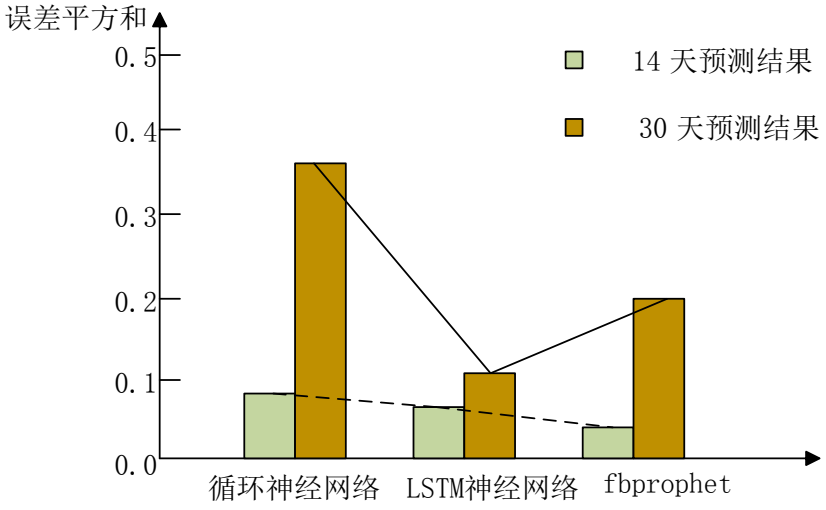


图4.7 不同模型 14 天和 30 天预测结果 *SSE* 对比

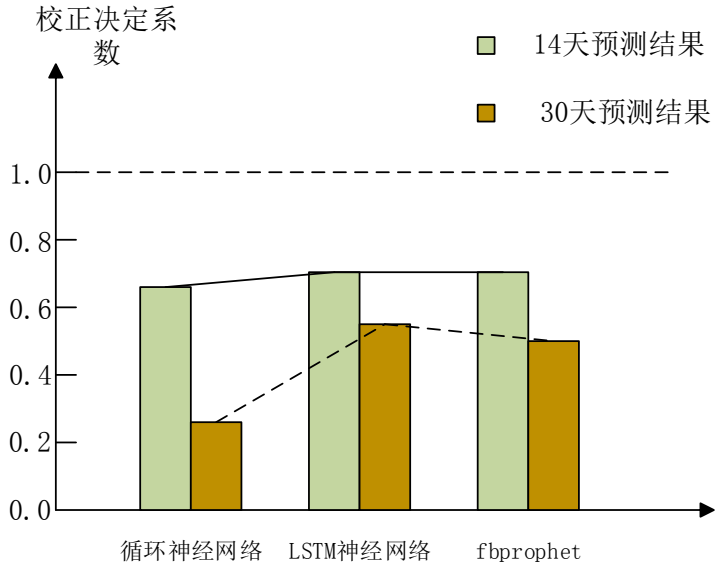


图4.8 不同算法 14 天和 30 天预测结果的校正决定系数对比

4.4.2 融合结果

我们直接将基于 LSTM 神经网络与基于 fbprophet 算法的 SMART 数据预测模型针对磁盘 14 天和 30 天的预测结果进行融合，融合后部分 SMART 数据参数 30 天预

中国知网 https://www.cnki.net

测结果如下。

2018.4.1	01306	0.064516	1.000000	1.000000
0.534585	0.155898	1.000000	1.000000	-0.424571
-0.065069	1.000000	-0.989957	-1.000000	

由融合结果可以看出，基于融合模型的预测结果与磁盘的 SMART 数据相比还是具有相似性的，然后针对 30 天的 SMART 预测结果将融合模型、基于 LSTM 神经网络和基于 fbprophet 算法的性能进行对比，对比结果如表 4.6、图 4.9、图 4.10 所示。

观察图 4.9 可知，基于模型融合的 30 天预测结果 *SSE* 值小于基于 LSTM 神经网络和 fbprophet 算法的 *SSE* 值；观察图 4.10 可知，基于模型融合的 30 天预测结果校正决定系数值要大于基于 LSTM 神经网络和 fbprophet 算法的校正决定系数值，因此由 30 天预测结果的误差平方和和校正决定系数对比可以看出基于融合模型的 SMART 数据预测方法对于 30 天的长时间预测 SMART 数据结果性能要优于 fbprophet 算法与 LSTM 神经网络。

表4.6 融合模型与其他算法 30 天 SMART 数据预测性能对比

磁盘数据预测模型	误差平方和 *SSE*	决定系数 R^2	校正决定系数 R_a^2
基于 LSTM 神经网络	0.1327	0.5272	0.5231
基于 fbprophet 算法	0.2013	0.4021	0.4551
融合模型	0.1029	0.5791	0.5830

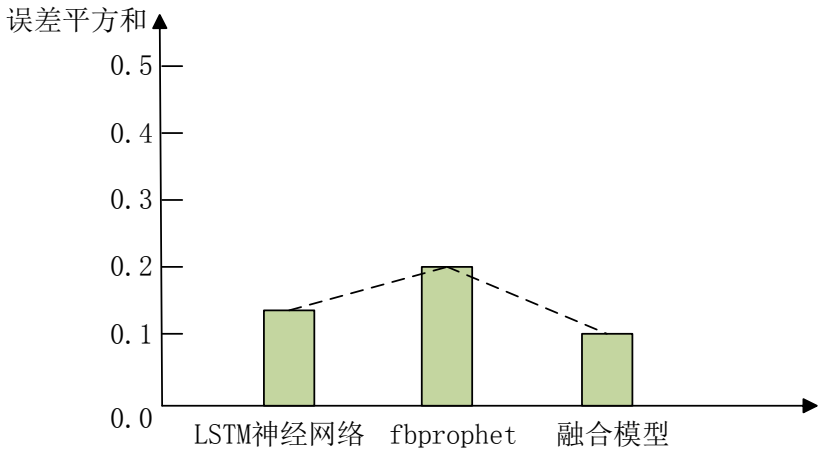


图4.9 融合模型与其他模型 30 天预测结果 *SSE* 对比

中国知网 https://www.cnki.net

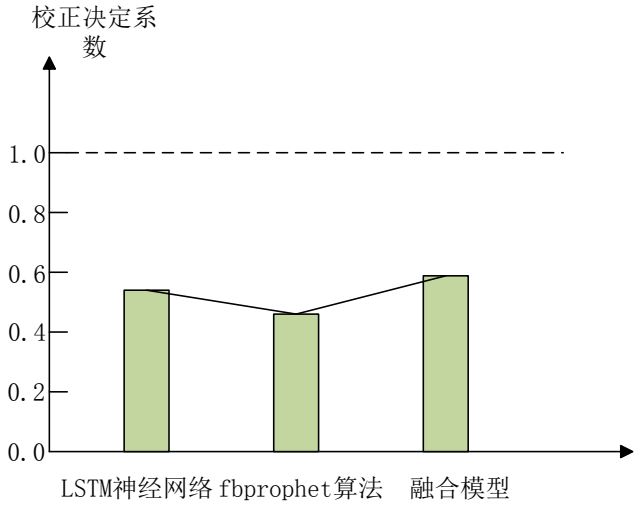


图 4.10 融合模型与其他模型 30 天预测结果校正决定系数对比

4.5 磁盘故障预测模型实验

在我们完成对 SMART 数据预测模型的实验后，接下来进行磁盘故障预测模型的实验，该模型首先使用融合模型预测出未来 14 天和 30 天的 SMART 数据，然后将未来 SMART 数据输入到磁盘故障检测模型中，从而检测出未来 14 天和 30 天的磁盘故障情况。实验完成后，将基于融合模型的磁盘故障预测模型与基于支持向量机的磁盘故障预测模型[12],[51]和基于 RNN 循环神经网络的磁盘故障预测模型[49],[79]进行性能对比，这里用来评价磁盘故障预测性能的指标与上一章相同，主要使用代表判断磁盘故障预测结果好坏的准确度、精确度、召回率、误报率、ROC 曲线和 AUC 值。

磁盘故障预测模型预测 14 天情况时，基于融合模型的 AUC=0.88，基于循环神经网络的 AUC=0.86，基于支持向量机的 AUC=0.79；磁盘故障预测模型预测 30 天情况时，基于融合模型的 AUC=0.81，基于循环神经网络的 AUC=0.63，基于支持向量机的 AUC=0.59，实验对比结果如表 4.7、表 4.8、图 4.11、图 4.12、图 4.13 所示。

表4.7 不同算法下 14 天磁盘故障预测性能比较

评价指标 / 训练模型	准确度	精确度	召回率	误报率
融合模型	0.83414	0.88096	0.87325	0.06311
循环神经网络	0.80147	0.83634	0.87363	0.07642
支持向量机	0.78095	0.79439	0.83710	0.07229

观察图 4.11 可知，当预测磁盘 14 天故障状况时基于融合模型的 ROC 曲线性能

中国知网 https://www.cnki.net

略优于基于循环神经网络和支持向量机的 ROC 曲线性能，但是相差不大；观察图 4.12 可知，当预测磁盘 30 天故障状况时基于融合模型的 ROC 曲线性能要远远优于基于循环神经网络和支持向量机的 ROC 曲线性能；观察图 4.13 可知，当预测磁盘 14 天故障状况时，基于模型融合的 AUC 值略大于基于循环神经网络和支持向量机的 AUC 值，当预测磁盘 30 天故障状况时，基于模型融合的 AUC 值远高于基于循环神经网络和支持向量机的 AUC 值。因此可以得出，基于模型融合的磁盘故障检测模型在预测 14 天磁盘故障信息时，预测性能和基于循环神经网络和支持向量机的性能相差不大，但是在预测 30 天磁盘故障信息时，预测性能要远远高于基于循环神经网络和支持向量机的预测性能。

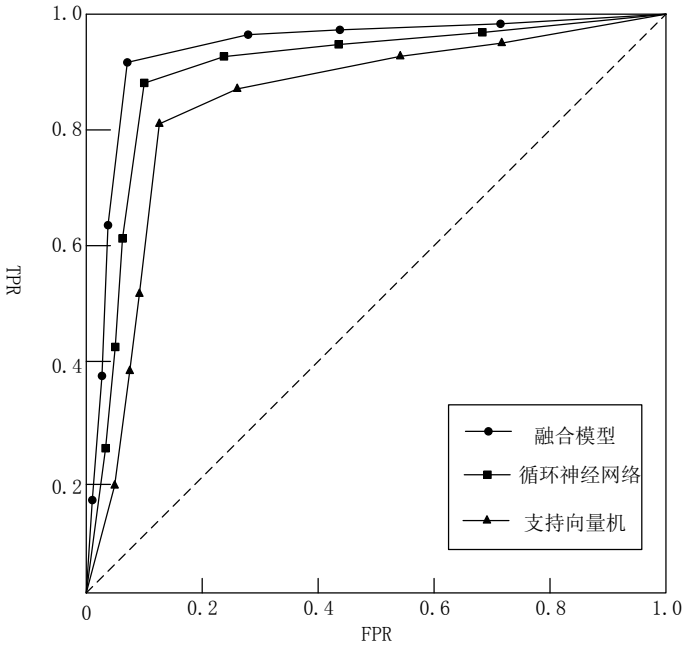


图 4.11 磁盘故障预测模型与其他模型 14 天磁盘故障预测结果 ROC 曲线对比

表4.8 不同算法下 30 天磁盘故障预测模型性能比较

评价指标 / 训练模型	准确度	精确度	召回率	误报率
融合模型	0.71451	0.80728	0.79314	0.07122
循环神经网络	0.33742	0.47135	0.42131	0.21349
支持向量机	0.42310	0.42271	0.46903	0.42373

中国知网 https://www.cnki.net

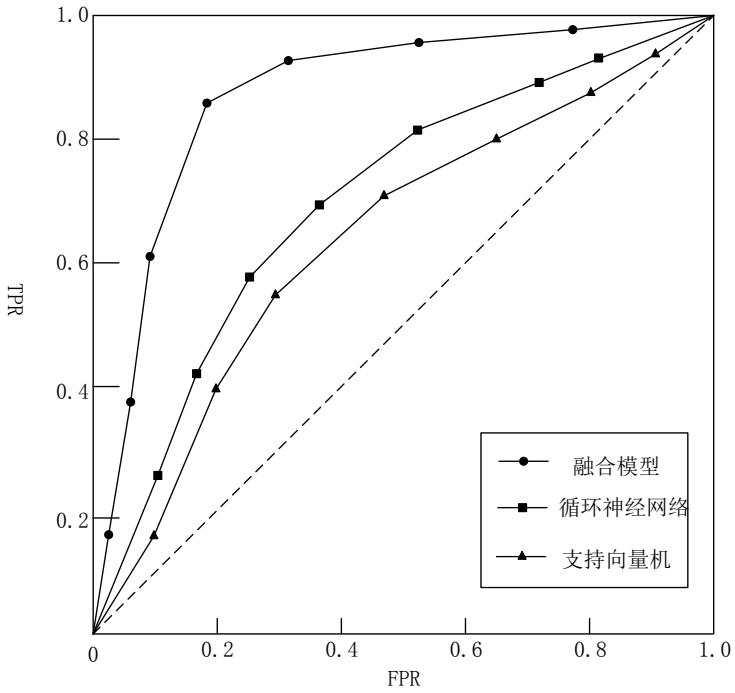


图 4.12 磁盘故障预测模型与其他模型 30 天故障预测结果 ROC 曲线对比

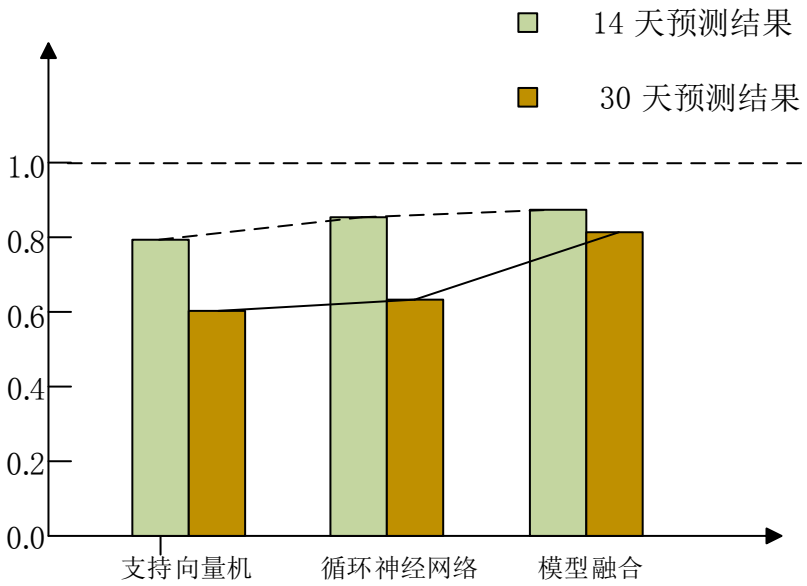


图 4.13 不同模型 14 天和 30 天故障预测 AUC 对比

4.6 实验结果分析

通过以上实验结果可以得出，本章所提出的磁盘故障预测模型是可行的，即通过当前的 SMART 数据特征在一定范围内预测出未来的 SMART 数据，然后根据磁盘故障检测模型检测出未来时间的磁盘是否发生故障，最终得到磁盘会发生故障的确定时间。

中国知网 https://www.cnki.net

通过对比 SMART 数据预测模型，我们发现融合后的 SMART 数据预测模型在预测精度上要高于基于 LSTM 神经网络和 fbprophet 算法的 SMART 数据预测模型。

通过对比磁盘故障预测模型可以发现，在进行 14 天磁盘故障预测时，本文所提出的磁盘故障预测模型与基于支持向量机和基于循环神经网络的磁盘故障预测模型的性能差距不大，但是在进行 30 天长时间磁盘故障预测时，本文提出的磁盘故障预测模型性能要远远优于基于支持向量机和基于循环神经网络的磁盘故障预测模型的性能。因此本文所提出的磁盘故障预测模型在对未来磁盘故障的预测模型是可行的。但是在目前的预测模型性能对比可以看出磁盘数据预测的整体预测性能仍需要继续提升，我们分析其中的原因有以下几点：

1．由于此次磁盘数据集为真实企业级硬盘数据，使用场景限制于固定的场景因此预测出的数据具有一定的局限性。虽然磁盘数据集内容很多，通过数据预处理和采样后的数据特征比较突出，但是我们 SMART 数据预测模型中使用的基于 LSTM 神经网络与 fbprophet 算法依赖的参数较多，现有数据总信息量仍不足以训练出一个足够好的 SMART 数据预测模型。

2．SMART 数据预测模型中基于 LSTM 神经网络与基于 fbprophet 算法的 SMART 数据预测模型在训练集中将训练样本学习的过好，导致把训练样本自身的特点当做很多有潜在样本都会具有的一般性质，导致模型的泛化性能下降即存在相对严重的过拟合现象，虽然经过添加误差项惩罚项、交叉验证法和模型融合使得其过拟合状况有所下降，但在预测磁盘长时间 SMART 数据时效果仍有待提高。

3．SMART 数据预测模型所使用的神经网络的复杂性较高，因此在现有有限的磁盘数据资源下，难以获得理论最优超参数设置，现有的预测方法仍旧不能发挥其最好的性能。

4．磁盘故障预测模型中基于卷积神经网络的磁盘故障检测部分的检测性能仍需要改善，利用已知的磁盘数据得到的检测结果仍不够准确。

4.7 本章小结

本章主要针对磁盘故障预测模型进行了详细说明，首先详细描述了磁盘故障预测模型的整体方案，接下来将磁盘数据集进行预处理。预处理以后，将符合输入格式的 SMART 数据进行预测模型的建模：根据磁盘的数据特征分别提出了基于 LSTM 神经网络和 fbprophet 算法的 SMART 数据预测模型，并最终根据 SMART 数据预测模型的各自特点将两个模型进行了模型融合从而得到了最终磁盘故障预测模型的 SMART 数据预测部分。然后将 SMART 数据预测模型与磁盘故障检测模型相结合得到了磁盘故障预测模型并根据提供的磁盘数据集将磁盘故障预测模型进行了磁盘故障预测实

中国知网 https://www.cnki.net

验。通过实验结果证明了本文所提出的的磁盘故障预测模型在进行长时间磁盘故障预测时性能要远远优于其他磁盘故障预测性能，并且可以准确的预测出 30 天磁盘故障情况。最后，我们还根据模型的特点对磁盘故障预测模型目前存在的问题和原因进行了进一步的分析。

中国知网 https://www.cnki.net

第五章 总结与展望

如今数据中心在企业中扮演着越来越重要的角色，然而随着数据存储量的几何式增长，数据中心存储设备的可靠性已经成为当前运维人员最关注的问题之一。如果不能有效地管理数据存储系统，提前对将要发生的磁盘故障问题进行预测并对数据及时备份处理，则会给企业和用户带来不可估量的损失。

目前针对磁盘故障预测国内外已经有了一定的研究，但是仍存在一些问题：首先，针对磁盘故障的预测建模主要方案是将磁盘故障预测问题作为二分类问题处理，只能根据磁盘数据预测出未来是否发生故障，但是无法有效的预测出故障发生的时间；其次，当前的大多数磁盘故障预测模型的故障预测有效时间较短，大多数故障预测模型无法在有效的时间内将磁盘问题进行备份处理；最后，当前的磁盘故障预测模型的研究大都基于单一的一个算法来进行建模，因此存在一定程度的过拟合情况，模型性能有待进一步提高。本文针对这些问题提出了一种磁盘故障预测模型，该模型分为磁盘故障检测和 SMART 数据预测两个部分，并通过实验和对比验证了本文提出的磁盘故障预测模型的可行性和有效性。下面我们对本文主要的研究成果和创新点进行了总结和反思，并对以后的研究工作进行了展望。

5.1 本文主要研究成果和创新点

本文主要针对数据中心磁盘故障预测问题的发展背景和当前主要存在的关键问题进行了研究和分析后提出了数据中心磁盘故障预测模型。

首先给出了 SMART 技术的工作原理和故障预测技术的定义，并对磁盘故障预测系统所使用的相关算法进行了介绍；

其次针对卷积神经网络的特点介绍了磁盘故障预测系统中基于卷积神经网络的磁盘故障检测方法的设计，然后介绍了针对该模型的磁盘数据集预处理方法，并将该模型通过与其他基于支持向量机和 BP 神经网络的磁盘故障检测模型的对比将检测性能进行了分析；

接下来介绍了磁盘故障预测模型的设计方案，然后针对 SMART 数据预测模型介绍了数据集的预处理方法，针对 SMART 数据预测模型的介绍，首先分别介绍了基于 LSTM 神经网络和 fbprophet 算法的 SMART 数据预测模型，然后利用两个模型预测的特点将预测结果进行融合，并通过对比实验得出融合模型可以比较准确预测出磁盘 SMART 未来 30 天数据的结果，最后将磁盘故障检测模型与 SMART 数据预测模型结合得到本文提出的磁盘故障预测模型，并将该磁盘故障预测模型与基于循环神经网络

中国知网 https://www.cnki.net

和基于支持向量机的磁盘故障预测模型的预测性能进行了对比来证明本文提出的模型在预测 30 天磁盘故障时性能更好。

本文的主要创新点包括以下几个方面：

1．本文针对磁盘故障预测问题提出了将磁盘故障预测模型分为 SMART 数据预测模型和磁盘故障检测模型两部分，从而可以准确预测出磁盘未来 30 天的故障情况，有利于相关工作人员及时针对问题进行处理；

2．本文针对 SMART 数据预测精度和预测时间距离的问题，提出了融合 LSTM 神经网络和 fbprophet 算法的 SMART 数据预测模型，该模型可以准确预测出未来 30 天的 SMART 数据信息，提高了 SMART 数据预测的精度和预测时间的距离；

3．本文针对磁盘故障检测问题，提出了基于卷积神经网络的磁盘故障检测模型，利用卷积神经网络局部处理、权值共享的特点根据当前磁盘的数据特征准确的检测出磁盘的故障情况，并且性能要优于基于支持向量机和 BP 神经网络的磁盘故障检测模型。

5.2 对未来工作的展望

本文针对数据中心存储设备磁盘的故障预测问题进行了分析和研究，数据中心磁盘故障预测问题近几年来一直是企业和相关研究人员比较重视的问题。随着问题研究的深入，通过在磁盘故障预测模型的设计和实验虽然解决了当前研究领域的一些不足和存在的问题，但是在研究过程中仍存在一些不完善的地方。对此我们将存在的问题进行了总结，未来我们将针对这些问题在以下几个方面进行进一步的研究：

1．本文所提出的磁盘故障预测模型虽然取得了较为理想的结果，但是在对预测模型的训练过程中，训练时间过长，一次模型的建立需要长达几十个小时，因此未来研究工作可以针对性能的提升将模型进行进一步优化，优化模型的训练时间；

2．本文针对磁盘故障预测模型所使用的数据集为 Backblaze 公司提供的磁盘数据信息，存在数据集的单一性，故需要进一步证明该磁盘故障预测模型对于其他磁盘数据集的普适性。这要求我们在未来的研究过程中引入大量的磁盘数据集来验证该模型的实用性；

3．本文提出的磁盘故障预测模型为实验仿真阶段，即根据已有的数据集进行建模，因此未来研究工作可以将磁盘故障预测模型应用在数据中心实际运行过程中，设计一套从数据收集到磁盘故障预测再到运维人员告警的完整系统来证明该模型的实用价值。

中国知网 https://www.cnki.net

参考文献

[1] Google: http://research.google.com/pubs/pub44830.html.

[2] Luiz André Barroso,Jimmy Clidaras,Urs Hölzl:The Datacenter as a Computer[M]. MORGAN&CLAYPOOL PUBLISHERS; 2013(7). 6~7.

[3] 盘点十大云计算安全事故[J]. 中国信息安全, 2013(5), 56~59.

[4] 徐珣, 印骏. 数据中心设计标准 TIA-942 解读[J]. 建筑电气, 2009, 28(11): 17-19.

[5] Vishwanath K V, Nagappan N. Characterizing Cloud Computing Hardware Reliability[C]// Proceedings of the 1st ACM Symposium on Cloud Computing, SoCC 2010, Indianapolis, Indiana, USA, June 10-11, 2010. ACM, 2010:193-204

[6] Hughes G F, Murray J F, Kreutz-Delgado K, et al. Improved disk-drive failure warnings[J]. IEEE Transactions on Reliability, 2002, 51(3): 350-357.

[7] SMART. wiki:https://en.wikipedia.org/wiki/SMART.

[8] Hamerly G, Elkan C. Bayesian approaches to failure prediction for disk drives[C]// Icml. 2001.

[9] Murray J F, Hughes G F, Kreutz-Delgado K. Hard drive failure prediction using non-parametric statistical methods[C]// Proceedings of ICANN/ICONIP. 2003.

[10] Murray J F, Hughes G F, Kreutz-Delgado K. Machine Learning Methods for Predicting Failures in Hard Drives: A Multiple-Instance Application[J]. Journal of Machine Learning Research, 2005, 6(1):783-816.

[11] Liang Y, Zhang Y, Sivasubramaniam A, et al. BlueGene/L Failure Analysis and Prediction Models.[C]// International Conference on Dependable Systems & Networks. IEEE Computer Society, 2006.

[12] Featherstun R W, Fulp E W. Using syslog message sequences for predicting disk failures[C]// Proceedings of the 24th international conference on Large installation system administration. USENIX Association, 2010.

[13] Zhu B, Wang G, Liu X, et al. Proactive drive failure prediction for large scale storage systems[C]// 2013 IEEE 29th Symposium on Mass Storage Systems and Technologies (MSST). IEEE, 2013.

[14] Xu C, Wang G, Liu X G, et al. Health Status Assessment and Failure Prediction for Hard Drives with Recurrent Neural Networks[J]. IEEE Transactions on Computers, 2016, 65(11):1-1.

[15] Chaves I C, Paula M R P D, Leite L G M , et al. BaNHFaP: A Bayesian Network Based Failure Prediction Approach for Hard Disk Drives[C]// 2016 5th Brazilian Conference on Intelligent Systems (BRACIS). IEEE, 2016:427-432.

中国知网 https://www.cnki.net

[16] Lima F D D S, Amaral G M R, Leite L G D M, et al. [IEEE 2017 Brazilian Conference on Intelligent Systems (BRACIS) - Uberlandia (2017.10.2-2017.10.5)] 2017 Brazilian Conference on Intelligent Systems (BRACIS) - Predicting Failures in Hard Drives with LSTM Networks[C]// Brazilian Conference on Intelligent Systems. IEEE Computer Society, 2017: 222-227.

[17] 郭群. 磁盘阵列数据安全预警技术研究[J]. 计算机时代, 2013(10): 4-5.

[18] 程川. RAID 系统箱体管理的设计与实现[D]. 华中科技大学, 2007.

[19] Mozer M C . A Focused Backpropagation Algorithm for Temporal Pattern Recognition[M]// Backpropagation. L. Erlbaum Associates Inc. 1995.

[20] Salfner F, Lenk M, Malek M. A survey of online failure prediction methods[J]. ACM Computing Surveys, 2010, 42(3): 1-42.

[21] Lecun Y L, Bottou L, Bengio Y, et al. Gradient-Based Learning Applied to Document Recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[22] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504-507.

[23] Graves A, Mohamed A R, Hinton G. Speech Recognition with Deep Recurrent Neural Networks[C]// 2013 IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2013.

[24] Hochreiter S, Schmidhuber, Jürgen. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[25] Taylor S J, Letham B. Forecasting at Scale[J]. The American Statistician, 2017: 0-0.

[26] Github: https://github.com/facebook/prophet.

[27] Mlwave: https://mlwave.com/kaggle-ensembling-guide/.

[28] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]. International Conference on Learning Representations(ICLR), 2015.

[29] Vieira J P A, Moura R S. [IEEE 2017 XLIII Latin American Computer Conference (CLEI) - Córdoba, Argentina (2017.9.4-2017.9.8)] 2017 XLIII Latin American Computer Conference (CLEI) - An analysis of convolutional neural networks for sentence classification[C]// Computer Conference. IEEE, 2017: 1-5.

[30] Kim Y. Convolutional neural networks for sentence classification[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing(EMNLP), 2014: 1746-1751.

[31] Kingma D P, Ba J. Adam: A method for stochastic optimization[C]. International Conference on Learning Representations, 2015.

[32] Shore J, Johnson R. Axiomatic derivation of the principle of maximum entropy and the principle

中国知网 https://www.cnki.net

of minimum cross-entropy[J]. IEEE Transactions on Information Theory, 1980, 26(1): 26-37.

[33] Powers D M. Evaluation: from Precision, Recall and F-measure to ROC, Informedness, Markedness and Correlation[J]. International Journal of Machine Learning Technology, 2011, 2(1), 37-63.

[34] Backblaze: https://f001.backblazeb2.com/file/Backblaze-Hard-Drive-Data.

[35] Schwarz T, Baker M, Bassi S, et al. Disk failure investigations at the internet archivep[C]. Work-in-progess session, NASA/IEEE Conference on Mass Storage Systems and Technologies(MSST2006). 2006.

[36] Pinheiro E, Weber W, Luiz Andr é Barroso. Failure trends in a large disk drive population[C]// Usenix Conference on File & Storage Technologies San Jose. USENIX, 2007.

[37] Smith G J. Adaptive event-based predictive failure analysis measurements in a hard disk drive: U.S. Oatent 6,771,440[P]. 2004-8-3.

[38] Zwart S P, Belleman R, Geldof P. High Performance Direct Gravitational N-body Simulations on Graphics Processing Unit I: An implementation in Cg[J]. New Astronomy, 2007.

[39] Shannon C E. A mathematical theory of communication[J]. Bell Labs Technical Journal, 1948, 27(4): 379-423.

[40] Gray R M. Entropy and information theory[M]. Springer Science & Business Media,2011.

[41] Mika S. Kernel PCA and de-noising in feature spaces[J]. Advances in Neural Information Processing Systems, 1999, 11.

[42] Ekaterini H, Konstantinos S, George P, et al. Assessment of the Eutrophication-Related Environmental Parameters in Two Mediterranean Lakes by Integrating Statistical Techniques and Self-Organizing Maps[J]. International Journal of Environmental Research and Public Health, 2018, 15(3): 547-549.

[43] Yu W, Gu Y, Li J, et al. Single-Pass PCA of Large High-Dimensional Data[J]. 2017.

[44] Costa C, Charalampous A, Konstantinidis A, et al. Decaying Telco Big Data with Data Postdiction[C]// 2018 19th IEEE International Conference on Mobile Data Management (MDM). IEEE Computer Society, 2018.

[45] Kim Y, Jernite Y, Sontag D, et al. Character-Aware Neural Language Models[J]. Computer Science, 2015.

[46] Walch F, Hazirbas C, Leal-Taix é, Laura, et al. Image-based Localization with Spatial LSTMs[J]. 2016.

[47] Chen Z , Liu Y , Liu S , et al. Mechanical state prediction based on LSTM neural netwok[C]// 中国控制会议. 2017.

[48] De l C V M, Bosch-Ramon V, Paredes-Fortuny X, et al. Coupling hydrodynamics and radiation

中国知网 https://www.cnki.net

calculations for star-jet interactions in active galactic nuclei[J]. Astronomy & Astrophysics, 2016, 591:A15.

[49] Li J, Stones R J, Wang G, et al. Being Accurate Is Not Enough: New Metrics for Disk Failure Prediction[C]// 2016 IEEE 35th Symposium on Reliable Distributed Systems (SRDS). IEEE, 2016.

[50] Yunhua S, Wenyang B, Qi Z. Prediction on hard disk failure of cloud computing framework by using SMART on COG-OS framework[J]. Journal of Computer Applications, 2014.

[51] Umbarkar A, Subramanian V, Doboli A. Linear Programming-Based Optimization for Robust Data Modeling in a Distributed Sensing Platform[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2014, 33(10): 1531-1544.

[52] Elerath J G, Schindler J. Beyond MTTDL: A closed-form RAID 6 reliability equation[J]. ACM Transactions on Storage, 2014, 10(2).

[53] Daroczy B, Vaderna P, Benczur A. Machine Learning Based Session Drop Prediction in LTE Networks and Its SON Aspects[C]// Vehicular Technology Conference. IEEE, 2015.

[54] O`Brien. Introduction to Information Systems[M]. MCGRAW-HILL/IRWIN, 2001.

[55] Nguyen B, Ge Z, Jacobus V D M, et al. ABSENCE: Usage-based Failure Detection in Mobile Networks[J]. 2015.

[56] 宋云华, 柏文阳, 周琦. 基于 COG-OS 框架利用 SMART 预测云计算平台的硬盘故障[J]. 计算机应用, 2014, 34(1):31-35.

[57] Jehan-François Pâris, Schwarz S J T, Amer S J A, et al. Protecting RAID Arrays against Unexpectedly High Disk Failure Rates[C]// IEEE Pacific Rim International Symposium on Dependable Computing. IEEE Computer Society, 2014.

[58] MeHiar-Smith P M RandeU B. SoRware reliability: The role of programmed exceptionhandling[C]. ACM SIGSOFT Software Engineering Notes: ACM, 1977, 2(2): 95-100.

[59] Sankar S, Shaw M, Vaid K, et al. Datacenter Scale Evaluation of the Impact of Temperature on Hard Disk Drive Failures[J]. Acm Transactions on Storage, 2013, 9(2): 1-24.

[60] Tai J, Sheng B, Yao Y, et al. Live Data Migration for Reducing SLA Violations in Multi-tiered Storage Systems[C]// IEEE International Conference on Cloud Engineering. IEEE, 2014.

[61] Queiroz L P, Rodrigues F C M, Gomes J P P, et al. A Fault Detection Method for Hard Disk Drives Based on Mixture of Gaussians and Non-parametric Statistics[J]. IEEE Transactions on Industrial Informatics, 2016: 1-1.

[62] Botezatu M M, Giurgiu I, Bogojeska J, et al. Predicting Disk Replacement towards Reliable Data Centers[C]// the 22nd ACM SIGKDD International Conference. ACM, 2016.

[63] Wang Y, Miao Q, Ma E W M, et al. Online Anomaly Detection for Hard Disk Drives Based on

中国知网 https://www.cnki.net

Mahalanobis Distance[J]. IEEE Transactions on Reliability, 2013, 62(1): 136-145.

[64] Wang Y, Ma E W M, Chow T W S, et al. A Two-Step Parametric Method for Failure Prediction in Hard Disk Drives[J]. IEEE Transactions on Industrial Informatics, 2014, 10(1): 419-430.

[65] Bengio Y. Learning Long-term Dependencies With Gradient Descent is Difficult[J]. IEEE Transactions on Neural Networks, 1994, 5: 157-166.

[66] Available: http://colah.github.io/posts/2015-08-Understanding-LSTMs/.

[67] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.

[68] Available: http://pandas.sourceforge.net.

[69] TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems[J]. 2016.

[70] Chen G, Zhao Y, Dan Pei, et al. Rewiring 2 Links is Enough: Accelerating Failure Recovery in Production Data Center Networks[C]// 2015 IEEE 35th International Conference on Distributed Computing Systems (ICDCS). IEEE, 2015.

[71] Gill P, Jain N, Nagappan N. Understanding Network Failures in Data Centers: Measurement, Analysis, and Implications[C]// Proceedings of the ACM SIGCOMM 2011 Conference on Applications, Technologies, Architectures, and Protocols for Computer Communications, Toronto, ON, Canada, August 15-19, 2011. ACM, 2011.

[72] Guo C, Yuan L, Xiang D, et al. Pingmesh: A Large-Scale System for Data Center Network Latency Measurement and Analysis.[C]// Acm Conference on Special Interest Group on Data Communication. ACM, 2015.

[73] Codeproject. http://www.codeproject.com/Articles/13582/Back-propagation-Neural-Net.

[74] Salfner F, Schieschke M, Malek M. Predicting failures of computer systems: a case study for a telecommunication system[C]// International Conference on Parallel & Distributed Processing IEEE Computer Society, 2006.

[75] 单莘．基于知识发现的告警相关性分析关键问题研究[D]．北京：北京邮电大学，2006.

[76] Ho T K. Random decision forests[C]// Document Analysis and Recognition, 1995. Proceedings of the Third International Conference on. IEEE Computer Society, 1995.

[77] Shatnawi M, Hefeeda M. Real-time failure prediction in online services[C]// IEEE INFOCOM 2015 - IEEE Conference on Computer Communications. IEEE, 2015.

[78] Lima F D D S, Pereira F L F, Chaves I C, et al. Evaluation of Recurrent Neural Networks for Hard Disk Drives Failure Prediction[C]// 2018 7th Brazilian Conference on Intelligent Systems (BRACIS). IEEE Computer Society, 2018.

[79] Zhang J, Wang J, He L, et al. Layerwise Perturbation-Based Adversarial Training for Hard Drive Health Degree Prediction[J]. 2018.

中国知网 https://www.cnki.net

[80] 兰云龙. 基于深度学习的磁盘健康度评估与故障预测技术研究[D]. 杭州电子科技大学，2017.4.

中国知网 https://www.cnki.net

致谢

时光荏苒，三年的研究生生涯转瞬即逝，回想这三年来的生活，有欢乐、有悲伤、有喜悦、有烦恼、有付出、有收获、有欢聚、有离别。正是这些一件件大大小小的事情让我从刚入学时的懵懂少年，成长为如今的顶天立地男子汉。我能在这短短的三年里有如此巨大的变化离不开支持我的父母，指导我的老师，帮助我的同学们，在此我向你们表示由衷的感谢！

在三年的研究生生涯里，我首先要感谢王定健、符兴斌老师以及王平老师，你们以严谨的学术思维、以身作则的态度、渊博的学识和看待问题独到的眼光都令我受益良多，你们教给我的不仅仅是书本上的知识，还有对待生活的态度、做人的道理、看待问题的格局、分析问题的眼光和方法，在论文的写作上对论文的严格要求和对我不厌其烦的指导都留下了深刻的印象，这些知识在未来的道路上将会继续指引我前行！

感谢和我一起去北京实习的兄弟们，在北京为期一年的实习期间我们互相帮助，共同进步让我学到了很多东西。感谢我的师兄吴翥，陶亮和袁野，是你们在我研一迷茫时指导我，在北京实习时帮助我，教会了我很多东西让我在学习和成长中少走了很多弯路。感谢逯超毅同学、姚荣欢同学、康艳龙同学和冯鲁汉同学，和你们在北京一起解决科研难题的日子、一起每天晚上坐一小时公交去健身房的日子、一起在找工作的日子互相学习交流的日子、一起帮助讨论学习论文的日子都令我印象深刻，和你们在北京相处一年的时光是我人生中宝贵的财富！

感谢我的室友葛仁义和柴延廷同学，你们给了我一个和谐温馨的寝室，让我在繁重的学习压力之外可以温馨的生活。感谢研究生 96#630 寝室的小伙伴们，是你们让我在研究生生活中快速适应学校的节奏和氛围！

感谢我大学和高中的几个好兄弟，是你们让我懂得了友谊天长地久这句话的真谛，你们在我研究生生涯里扮演了不可缺少的角色，让我可以从容的在学校和社会之间从容切换。感谢沈晴同学和逯超毅同学，在我写论文和实验的过程中给了我重要的建议和意见！

最后要感谢的是我的父母，如果没有你们在我背后默默的给我支持和鼓励，在我最迷茫的时候指点我，在我最无助的时候给予我支持，我就不会坚定不移的走上研究生这条科研的道路，是你们在我人生的道路上点亮了盏盏明灯为我指明了方向，我为作为你们的儿子而感到骄傲和自豪！

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net



西安電子科技大學
XIDIAN UNIVERSITY

地址：西安市太白南路2号
邮编：710071
网址：www.xidian.edu.cn

中国知网 https://www.cnki.net