分类号：181　　单位代码：10335

密　级：公开　　学　　号：22360325

浙江大学

硕士学位论文
（专业学位）

中文论文题目：基于机器学习的固态硬盘故障预测与寿命提升方法研究

英文论文题目：Solid State Drive Failure Prediction and Lifetime Enhancement Method Based on Machine Learning

申请人姓名：龙泳江

校内导师（组）：苏中根

行业导师：张　杨

专业学位类别、领域：电子信息、大数据技术与工程

研究方向：设备故障预测、数据工程

培养类型：全日制非定向

所在学院：工程师学院

论文提交日期

基于机器学习的固态硬盘故障预测与寿命提升方法研究

论文作者签名： _____

指导教师签名： _____

论文评阅人 1：隐名评阅

评阅人 2：隐名评阅

评阅人 3：隐名评阅

评阅人 4：

评阅人 5：

答辩委员会主席：梁克维，副教授，浙江大学数学科学学院

委员 1：庞天晓，教授，浙江大学数学科学学院

委员 2：袁细宁，高级工程师，浙江永保环境科技有限公司

委员 3：

委员 4：

委员 5：

答辩日期 2026 年 9 月 6 日

Solid State Drive Failure Prediction and Lifetime Enhancement Methods Based on Machine Learning

Author's signature: _____

Supervisor's signature: _____

Reviewer 1: Anonymous review

Reviewer 2: Anonymous review

Reviewer 3: Anonymous review

Reviewer 4: _____

Reviewer 5: _____

Chairperson: Kewei Liang, Associate Professor, School of Mathematical Sciences

Member 1: Tianxiao Pang, Professor, School of Mathematical Sciences

Member 2: Xining Yuan, Senior Engineer, Zhejiang Yongbao Environmental Technology Co., Ltd.

Member 3: _____

Member 4: _____

Member 5: _____

Date of oral defence: September 6, 2026

浙江大学研究生学位论文独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 **浙江大学** 或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名: 签字日期: 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解 **浙江大学** 有权保留并向国家有关部门或机构送交本论文的复印件和磁盘，允许论文被查阅和借阅。本人授权 **浙江大学** 可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密的学位论文在解密后适用本授权书）

学位论文作者签名: 导师签名:

签字日期: 年 月 日 签字日期: 年 月 日

致谢

衷心感谢我的导师苏中根教授在论文选题、研究思路、实验推进与论文撰写过程中给予的悉心指导与严格要求。在课题实施的各个阶段，导师始终以严谨的治学态度和耐心细致的指导帮助我不断完善研究方法、修正不足，使我能够顺利完成本论文。

同时，诚挚感谢我在平头哥实习期间的带教张杨师兄和张泽奇师兄。两位师兄在课题方向把握、技术实现与问题排查等方面提供了大量具体而有效的帮助，使我受益匪浅。

感谢宋雨婷师妹在数据处理、模型实现与实验设计过程中给予的支持与协助，你的经验分享对本研究推进起到了重要作用。

感谢平头哥公司提供 AIR 项目（SSD 失效预测与寿命提升）相关实践机会与实验平台，使我能够在真实业务场景中开展研究并验证方法可行性。

此外，感谢 502 实验室全体同学在日常交流与讨论中给予的支持与鼓励。大家的帮助和陪伴为本论文的完成提供了重要支撑。

摘要

随着云计算、大数据与人工智能应用的快速发展，数据中心规模持续扩大。固态硬盘（SSD）作为关键存储介质，其可靠性与寿命利用效率直接影响业务连续性和运维成本。本文针对规模化数据中心中 SSD 故障预警误报成本高、闪存块耐久差异未被充分利用这两大核心问题，以提升运维可靠性和资源利用率为目标，围绕盘级故障预警与块级寿命优化展开系统性研究。

针对现有盘级故障预测方法误报率偏高、难以捕捉近端突变前兆的问题，本文提出一种面向低误报约束的预测方法。该方法通过混合标注策略与短期时序突变特征，将监督信号与故障前兆的时间尺度对齐，在抑制标签噪声的同时有效放大微弱的故障信号。模型采用 RF、XGB 与 LGB 三种异构基学习器，并引入 Attention 模块进行样本级自适应加权融合，同时利用 Focal Loss 缓解类别不平衡，从而提升对稀疏故障样本的判别稳定性。在阿里云 MB1 与 MB2 数据集上的实验结果表明，该方法在维持极低误报率的前提下，分别取得了 0.919 与 0.490 的 $F_{0.5}$；其中 MB1 与最强基线并列最优，并以更低误报与更高精确率形成区分，能够对故障盘给出有效检出。

针对传统统一编程/擦除（PE）阈值策略浪费强块寿命的问题，本文设计了一套基于块级错误比特计数（FBC）的差异化寿命提升策略。该策略将块寿命预测转化为“强/弱块”二分类问题，并据此实施差异化的 PE 擦写上限管控，在不突破可靠性边界的前提下充分挖掘强块的剩余寿命。测试结果表明，该策略可带来约 17% 的累计可写入量提升。轻量化采集实验进一步验证了该策略在控制器端部署的可行性。

为验证上述算法的工程实用性，本文设计并实现了一套智慧 SSD 运维原型软件。该系统打通了从数据采集、模型推理到预警处置的完整业务闭环，并通过功能测试覆盖采集—推理—预警处置链路。

本文构建了从“盘级精准预警”到“块级寿命优化”再到“系统闭环落地”的完整技术链路。研究表明，在盘级侧落实运维误报成本约束、在块级侧落实可靠性边界约束，并辅以原型系统闭环验证，能够在保障存储可靠性的同时显著提升资源利用效率。这一工作为数据中心固态硬盘的可靠性运维与成本优化提供了可行的方法与实践参考。

关键词：固态硬盘；机器学习；低误报故障预警；寿命提升

Abstract

With the rapid development of cloud computing, big data, and artificial intelligence applications, datacenter scales continue to expand. Solid State Drives (SSDs), as key storage media, directly affect business continuity and operational costs through their reliability and lifetime utilization efficiency. This thesis addresses two core problems in large-scale datacenters: the high cost of false alarms in SSD failure warning, and the underutilization of flash block durability differences. With the goal of improving operational reliability and resource utilization, it conducts systematic research on drive-level failure warning and block-level lifetime optimization.

For the high false alarm rate of existing drive-level failure prediction methods and their difficulty in capturing near-end sudden-change precursors, this thesis proposes a prediction method oriented toward low false-alarm constraints. The method aligns supervisory signals with the time scale of failure precursors through a hybrid labeling strategy and short-term temporal mutation features, suppressing label noise while effectively amplifying weak failure signals. The model adopts three heterogeneous base learners (RF, XGB, and LGB), introduces an Attention module for sample-level adaptive weighted fusion, and uses Focal Loss to mitigate class imbalance, thereby improving discrimination stability for sparse failure samples. Experimental results on the Alibaba Cloud MB1 and MB2 datasets show that the method achieves $F_{0.5}$ scores of 0.919 and 0.490 respectively while maintaining an extremely low false alarm rate; on MB1 it ties the strongest baseline on $F_{0.5}$ while attaining lower false alarms and higher precision, enabling effective detection of faulty drives.

To address the problem that traditional unified Program/Erase (PE) threshold strategies waste the lifetime of strong blocks, this thesis designs a differentiated lifetime enhancement strategy based on block-level Fault Bit Count (FBC). The strategy transforms block lifetime prediction into a strong/weak block binary classification problem, and implements differentiated PE write limit control accordingly, fully exploiting the remaining lifetime of strong blocks without crossing reliability boundaries. Test results show that the strategy brings about a 17% improvement in cumulative writable capacity. Lightweight collection experiments further val-

idate the feasibility of deploying this strategy on the controller side.

To verify the engineering practicality of the above algorithms, this thesis designs and implements an intelligent SSD operation and maintenance prototype system. The system completes the full business loop from data collection and model inference to warning handling, and functional testing covers the acquisition–inference–alert handling pipeline.

This thesis constructs a complete technical chain from drive-level precise warning to block-level lifetime optimization to closed-loop system deployment. The research shows that enforcing an operational false-alarm cost constraint at the drive level and a reliability-boundary constraint at the block level, together with prototype closed-loop validation, can significantly improve resource utilization efficiency while ensuring storage reliability. This work provides feasible methods and practical references for reliability-oriented operation and cost optimization of SSDs in datacenters.

Keywords: solid-state drive; machine learning; low false alarm failure prediction; lifetime enhancement

缩略词表

英文缩写	英文全称	中文全称
SSD	Solid State Drive	固态硬盘
HDD	Hard Disk Drive	机械硬盘
NAND	Not AND Flash Memory	NAND 闪存
SMART	Self-Monitoring, Analysis and Reporting Technology	自我监控、分析与报告技术
FBC	Fault Bit Count	错误比特计数
LDPC	Low-Density Parity-Check	低密度奇偶校验码
ECC	Error Correction Code	纠错编码
PE	Program Erase	编程/擦除循环
TPR	True Positive Rate	真正例率（召回率）
FPR	False Positive Rate	假阳性率
ROC	A receiver operating characteristic curve	受试者工作特征曲线
AUC	Area Under the ROC Curve	ROC 曲线下面积
RF	Random Forest	随机森林
GBDT	Gradient Boosting Decision Tree	梯度提升决策树
SVM	Support Vector Machine	支持向量机
MLP	Multi-Layer Perceptron	多层感知机
ZB	Zettabyte (10^{21} Bytes)	泽字节
LP	Low Page	TLC 低位页
MP	Middle Page	TLC 中位页
UP	Upper Page	TLC 高位页

目录

致谢 I

摘要 III

Abstract V

缩略词表 VII

目录 IX

图目录 XIII

表目录 XV

1 背景介绍与国内外研究现状 1

1.1 研究背景 1

1.2 固态硬盘故障国内外研究现状 2

1.2.1 故障成因分析 3

1.2.2 固态硬盘故障预测算法 4

1.2.3 块粒度固态硬盘寿命预测 7

1.2.4 现有研究分析与不足 8

1.3 研究目标与本文主要工作 8

1.4 论文组织结构 10

2 相关理论基础 11

2.1 固态硬盘存储原理 11

2.1.1 NAND 闪存基本结构 11

2.1.2 编程与擦除操作 12

2.1.3 错误产生机理 13

2.1.4 纠错编码技术 14

2.2 固态硬盘故障容错技术 14

2.2.1 被动容错技术 14

2.2.2 主动容错技术 16

2.3 集成学习算法原理 17

2.3.1 随机森林模型 17

2.3.2 XGBoost 模型 18
2.3.3 LightGBM 模型 20
2.4 注意力机制与 Transformer 20
2.4.1 注意力机制基本原理 20
2.4.2 Transformer 模型 21
2.5 本章小结 22
3 基于近端突变标注与突变时序特征集成的固态硬盘故障预测方法 23
3.1 任务目标与问题设定 24
3.1.1 盘级预测任务 24
3.1.2 评估指标与盘级判定规则 24
3.2 数据集与预处理 26
3.2.1 数据集描述 26
3.2.2 数据预处理与 SMART 属性归纳 27
3.2.3 故障前兆数据观察 33
3.3 基于异构集成的故障预测模型构建 36
3.3.1 短期时序突变特征构造 36
3.3.2 混合标签降噪策略设计 37
3.3.3 异构集成预测 38
3.4 实验设置与结果分析 40
3.4.1 实验设置与对比方法 40
3.4.2 关键超参数 W 与 k 的选取 42
3.4.3 模型整体效果的验证与分析 44
3.4.4 突变时序特征有效性分析 47
3.4.5 标签策略有效性分析 48
3.4.6 异构集成有效性分析 49
3.4.7 预警时效性与提前量分析 50
3.4.8 适用边界与后续方向 53
3.5 本章小结 53
4 基于集成学习的固态硬盘寿命提升技术 55

4.1 问题动机与任务设定 55
4.1.1 块级寿命差异与优化动机 55
4.1.2 任务定义与评估指标 57
4.2 数据与方法 58
4.2.1 磨损数据集 58
4.2.2 逻辑块重建与寿命标签 59
4.2.3 特征构造与集成预测模型 62
4.2.4 差异化写入策略 62
4.3 实验结果与分析 63
4.3.1 实验设置 63
4.3.2 块寿命分类与策略收益 63
4.3.3 轻量化采集消融 65
4.3.4 方法局限性讨论 68
4.4 本章小结 68
5 智慧固态硬盘运维软件设计与实现 69
5.1 需求分析 69
5.1.1 功能需求 69
5.1.2 非功能需求 70
5.1.3 用例分析 70
5.2 系统概要设计 71
5.2.1 总体架构设计 71
5.2.2 功能模块划分 71
5.2.3 部署设计 72
5.2.4 技术选型 73
5.3 系统详细设计 73
5.3.1 设计过程与第三章方法衔接 73
5.3.2 预警生成流程设计 74
5.3.3 预警处置流程设计 74
5.3.4 预警状态设计 75

5.3.5 接口设计 75
5.4 数据库设计 75
5.4.1 数据库概念设计 76
5.4.2 逻辑结构设计 77
5.5 系统实现与功能落地 77
5.5.1 管理员模块实现 78
5.5.2 预警生成与处置流程实现 78
5.5.3 功能落地效果分析 79
5.6 系统测试 79
5.6.1 测试环境与方法 79
5.6.2 功能测试用例与结果 79
5.7 本章小结 80
6 总结与展望 81
6.1 全文工作总结 81
6.2 后续工作展望 82
参考文献 83
附录 87
A SMART 字段筛选剔除明细 87
B SMART 原始与归一化读数 Spearman 相关系数 88
C 盘级基线对比分轮明细 89
D 智慧 SSD 运维系统设计明细表 93
E 智慧 SSD 运维系统界面截图集 98

图目录

图 1.1 全球每年新产生的数据总量预测 1
图 1.2 本文研究框架与技术路线（第三至五章） 9
图 2.1 固态硬盘基本结构 12
图 2.2 闪存擦写原理 13
图 2.3 随机森林示意图 18
图 2.4 GBDT 算法迭代流程示意图 19
图 3.1 SSD 故障预测方法流程 23
图 3.2 盘级 TP/FP/TN/FN 判定示意 24
图 3.3 月度故障盘分布 26
图 3.4 日历缺失补全与剔除示意 29
图 3.5 日历缺失分布 29
图 3.6 MB1 故障盘 B 组属性时序 33
图 3.7 MB2 故障盘 B 组属性时序 33
图 3.8 B 组首跳距故障日分布 35
图 3.9 不同标签策略示意图 37
图 3.10 异构集成结构示意 39
图 3.11 W–k 验证集网格搜索的盘级 $F_{0.5}$ 热力图 43
图 3.12 三轮平均的 MB1/MB2 盘级基线性能对比 45
图 3.13 多方法提前预警天数分布对比 51
图 3.14 本文方法提前预警时间分布（分轮） 52
图 4.1 SLC、MLC 与 TLC 存储方式对比示意图 55
图 4.2 固定阈值策略与理想策略的块级 PE 次数对比示意图 56
图 4.3 分组逻辑示意图 60
图 4.4 块寿命标签构造流程 61
图 4.5 集成投票流程 63
图 4.6 不同读模式与页类型下的写入量提升率柱状对比 64
图 4.7 轻量化采集消融 66

图 5.1 智慧 SSD 运维系统用例图 70
图 5.2 软件总体架构图 71
图 5.3 预警生成流程 74
图 5.4 预警处置交互流程 74
图 5.5 智慧 SSD 运维系统 E-R 图 76
图 5.6 故障处理页面实现效果 78
图 E.1 磁盘管理界面 98
图 E.2 日志管理界面 98
图 E.3 故障管理界面 99
图 E.4 故障处理界面 99

表目录

表 3.1　数据集统计 …… 26
表 3.2　SMART 字段筛选结果 …… 28
表 3.3　日历时序质量汇总 …… 30
表 3.4　预处理剔除与保留 …… 31
表 3.5　SMART 属性 A/B 分组 …… 32
表 3.6　B 组属性跳变命中率 …… 34
表 3.7　B 组首跳窗口对比 …… 35
表 3.8　数据集时间划分 …… 40
表 3.9　W–k 验证集网格搜索结果（盘级 $F_{0.5}$） …… 43
表 3.10 MB1 三轮平均盘级性能对比 …… 44
表 3.11 MB2 三轮平均盘级性能对比 …… 45
表 3.12 突变特征消融实验 …… 47
表 3.13 训练标签消融实验 …… 49
表 3.14 异构集成分轮对比 …… 50
表 3.15 本文方法分轮提前预警统计 …… 51
表 4.1　逻辑块寿命分布统计 …… 61
表 4.2　不同读模式与页类型下的写入量提升率明细 …… 64
表 4.3　不同读取值下的写入量提升率 …… 66
表 4.4　不同磨损档位下的写入量提升率 …… 66
表 4.5　不同字线采样范围下的写入量提升率 …… 67
表 5.1　系统功能需求说明 …… 69
表 5.2　系统非功能需求说明 …… 70
表 5.3　系统功能模块划分 …… 72
表 5.4　服务层职责划分 …… 72
表 5.5　系统技术选型说明 …… 73
表 5.6　预警状态转换规则 …… 75
表 5.7　系统 REST 接口分层汇总 …… 75

表 5.8 数据库实体关系说明 77
表 5.9 系统核心数据表汇总 77
表 5.10 系统功能测试结果汇总 80
表 A.1 SMART 字段筛选剔除明细 87
表 B.1 筛选后 SMART 原始/归一化读数 Spearman 相关系数 88
表 C.1 MB1 盘级性能对比（分轮明细） 89
表 C.2 MB2 盘级性能对比（分轮明细） 91
表 D.1 系统核心用例说明 93
表 D.2 磁盘信息表字段设计 94
表 D.3 SMART 日志表字段设计 94
表 D.4 故障记录表字段设计 95
表 D.5 预警记录表字段设计 95
表 D.6 系统主要 REST 接口设计 96
表 D.7 系统功能测试用例及结果 97

1 背景介绍与国内外研究现状

1.1 研究背景

数字化转型持续推进，云计算、大数据、物联网与人工智能技术在各行业深度落地，各类业务持续产生海量异构数据并集中托管于规模化数据中心，推动全球存储基础设施规模持续扩张。据 Cloudscene 平台统计，截至 2024 年全球已建成运营的数据中心总量突破 11800 座，国内在建及投产数据中心共计 449 座[1]。依据 2024 版《数据存储 2030》白皮书预测[2]，2020 年全球数据总产量为 44 泽字节（Zettabyte，ZB），2025 年将攀升至 175ZB，至 2030 年总量预计突破 1003ZB，数据增长趋势如图 1.1 所示。海量数据集中存储模式下，硬件设备失效引发的数据丢失、业务中断问题，已成为存储可靠性领域亟待解决的核心难题。

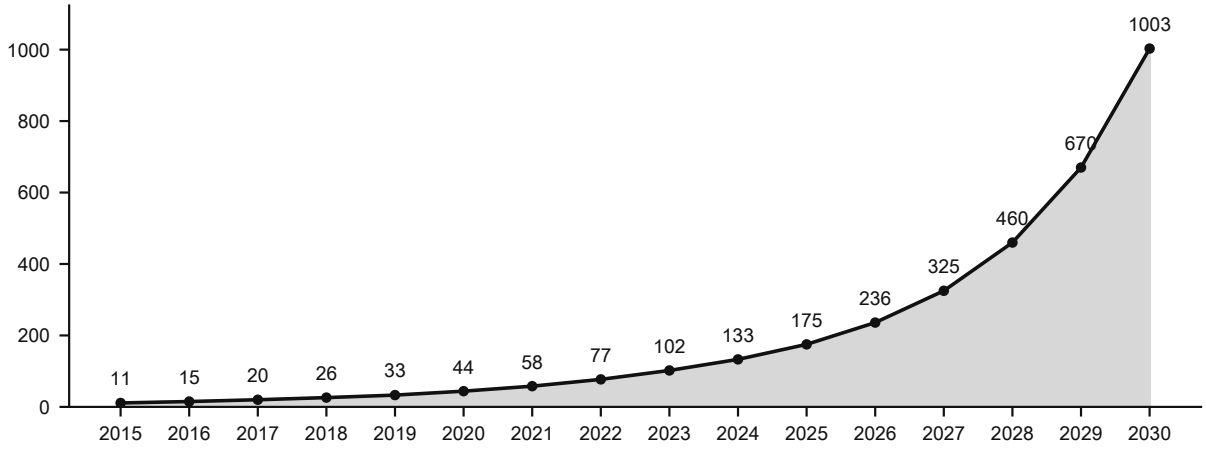


图 1.1 全球每年新产生的数据总量预测

为承载 PB 乃至 EB 级超大存储负载，数据中心底层存储集群普遍采用机械硬盘（Hard Disk Drive，HDD）与固态硬盘（Solid State Drive，SSD）两类硬件设备。HDD 依托磁性介质完成读写操作，具备单位存储成本低廉、断电数据长期留存的优势，但机械磁头结构抗震动、抗冲击性能较差，随机读写时延高，长期机械磨损会显著抬升设备故障率；基于 NAND 闪存（Not AND Flash Memory，NAND）介质的 SSD 弥补了 HDD 读写性能短板，拥有极低随机访问延迟。伴随闪存制造工艺持续迭代，SSD 单位容量成本逐年下降，现已成为云平台高性能业务场景的主流存储硬件。

即便二者硬件架构存在本质差异，大规模集群部署场景中硬件故障始终是数据可靠性的首要威胁。SSD 故障表征形式丰富多样，涵盖文件系统挂载异常、驱动程序丢失、缓冲区读写错误、底层介质校验报错等，故障诱因包含人工运维误操作、硬件链路故障、闪存本体老化劣化，常规修复手段包含设备重启、线缆重插拔、故障盘整机更换[3]。故障发生至处置完成的窗口期极易引发线上业务监控指标剧烈震荡、服务性能降级，极端场景下会造成永久性数据丢失。依托阿里云公开大规模 SSD 运维数据集统计结果，SSD 年度平均故障率可达 2.38%，故障总量会随集群部署规模同步线性增长[4]。

当前工业界主流容灾手段均属于事后被动容错方案，主要包含磁盘冗余阵列、多副本备份机制[5]、纠错编码（Error Correction Code，ECC）[6]三类。此类方案仅能在故障发生后完成数据恢复，执行过程会消耗大量计算、带宽与存储冗余资源，同时带来不可忽略的业务中断时延。目前所有商用 SSD 均搭载自我监控、分析与报告技术（Self-Monitoring, Analysis and Reporting Technology，SMART）自检系统，能够周期性采集硬件全维度运行时序指标。基于 SMART 时序数据构建主动故障预测模型，可提前识别高风险 SSD 并主动迁移数据、下线故障设备，从源头规避数据丢失风险，省去故障恢复阶段的各类资源开销。但长期大规模线上设备跟踪研究证实，仅依靠少量基础 SMART 指标搭建预测模型，难以在可控误报阈值内精准识别预失效硬盘，模型整体预警性能存在明显瓶颈[7]。为此，学术界与工业界持续探索多维度特征体系与高性能预测算法，以此提升 SSD 故障提前预警能力。

1.2 固态硬盘故障国内外研究现状

存储设备故障预测领域早期研究对象以机械硬盘 HDD 为主，现有工作普遍依托 SMART 监控指标、厂商自定义硬件观测参数、系统层性能时序数据训练预测模型。但 HDD 磁介质读写原理与 NAND 闪存擦写机制存在根本性区别，叠加不同存储厂商对 SMART 扩展指标定义不统一，即便硬件兼容标准 SMART 协议，故障退化时序特征也会随厂商、硬件型号产生巨大差异。上述客观约束导致成熟 HDD 故障预测框架无法直接迁移至 SSD 场景，不同型号 SSD 之间也难以复用同一套建模经验。基于该行业痛点，当前 SSD 可靠性相关研究划分为两大核心方向：SSD 多维度故障成因机理分析、面向 SSD 的故障预测算法优化设计。

1.2.1 故障成因分析

故障成因类研究普遍依托头部云厂商多年线上 SSD 运维全量时序数据，融合标准 SMART 指标、厂商私有遥测参数、服务器系统运行日志开展统计分析，系统拆解 SSD 失效诱发因素、时序演化路径与集群时空分布规律，为后续特征工程、预测模型设计提供底层理论支撑。该领域研究观测视角逐步演进：从单盘独立故障拓展至机架、节点集群级关联故障，观测粒度从整盘聚合指标下沉至闪存芯片、块、页底层电学误码特征。

Alter 等人依托 Google 超大规模数据中心多年 SSD 全量运行数据系统归纳 SSD 故障前兆与底层失效根因，证实介质磨损、控制器固件缺陷、机房温湿度与业务负载突变多因素耦合驱动 SSD 失效；单一编程/擦除循环（Program Erase，PE）擦写量或某一项孤立 SMART 指标无法完整解释故障演化规律，必须融合介质老化、固件运行、硬件错误日志、机房环境多维度信息综合建模[8]。在此基础上，Xu 等人从数据中心全栈系统视角出发，基于阿里云 7 座数据中心近 3 年、总计 45 万块 SSD 的线上运维数据集，针对系统标记 SSD 相关上报故障（RASR）开展统计分析，联合设备底层错误日志与上层运维工单，总结机房温升异常、读写负载分布不均、人工操作失误、软硬件交互冲突协同诱发故障的内在机理，并提炼轻量化工程缓解方案[3]。

Han 等人聚焦集群批量关联失效问题，利用阿里巴巴生产集群长期 SSD 运维时序数据，分析同机架、同服务器节点 SSD 故障时空聚集特征。实验证实电源供电波动、散热环境缺陷、同批次固件漏洞、硬件批次质量缺陷会引发短时间多设备集中失效，大幅削弱副本、纠删码传统容灾机制防护能力；SSD 失效并非独立随机事件，具备显著时间、空间相关性，为预测模型引入机房拓扑特征提供理论依据[9]。Ng 等人进一步补充机房拓扑维度失效规律，证实机架位置、服务器机型、业务负载类型会改变单盘故障基线风险，仅依靠单盘 SMART 指标无法刻画集群集中故障特征[10]。

为从闪存底层解释介质退化内在机理，Meza 等人依托 Meta 线上业务集群长期运行数据，将观测粒度下沉至 NAND 芯片层级，系统探究擦写循环、数据保持时长、读干扰、工作温度对原始比特错误率的影响规律。研究发现闪存内部不同块、页之间误码分布高度不均衡，单盘内部广泛存在可靠性薄弱的弱块、弱页；仅依靠整盘平均误码指标无法完整刻画介质全生命周期退化流程[11]。Gu 等学者指出传统 SMART 指标为控制器聚合统计结果，缺失芯片底层错误比特计数（Fault Bit Count，FBC），无法捕捉闪存单元

早期细微劣化，是现有预测模型精度受限的底层核心诱因[12]；罗铮等人基于 3D TLC 闪存加速老化实验开展研究，证明原生原始比特错误率随 PE 循环呈现非线性波动，不同芯片样本数据重叠度高，仅依靠全局擦写次数无法精准表征单块闪存真实磨损水平[13]。

Maneas 等人以 NetApp 多厂商混合企业级存储集群为研究对象，对比不同接口、不同容量等级 SSD 在真实业务负载下的可靠性差异与完整失效演化链路。实验证实企业 SSD 基础故障率偏低，但硬件型号、业务负载会造成可靠性巨大分化；设备失效存在清晰前置前兆，由可纠错错误累积、存储通道异常逐步发展为整机故障，统一模型无法适配全品类 SSD，工程落地需分硬件定制建模[14]。伴随 NVMe 协议 SSD 普及，Lu 等人依托阿里巴巴超百万块 NVMe SSD 监控日志、iostat 性能指标与故障工单，区分 fail-stop 突发性宕机故障、fail-slow 渐进性能退化两类失效模式。相较于传统 SATA SSD，NVMe 设备早期失效、读写模式适配鲁棒性更强，但机架级关联故障聚集效应更突出；观测周期内 1.41% 的 NVMe SSD 发生慢故障，性能退化至 HDD 级别，此类隐性性能衰减无法通过 SMART 指标提前识别，需补充系统时延指标构建专属检测框架[15]。Chakraborttii 等人系统性综述 HDD 与 SSD 差异化失效机理，明确 NVMe、ZNS 新型 SSD 存在慢故障、分区磨损等特有可靠性难题，为细分介质的故障建模提供完整理论框架[16]。

1.2.2 固态硬盘故障预测算法

SSD 故障预测核心任务依托带标注硬件时序数据集，训练机器学习模型拟合设备从健康向故障演化的概率分布。模型输入包含标准 SMART 指标、厂商私有遥测时序、服务器系统监控数据；当前主流研究以整盘粒度故障预警为核心，判定未来 30 天窗口内 SSD 是否失效，前沿工作逐步下沉至块粒度完成剩余寿命建模。领域通用评价指标为真正例率（True Positive Rate，TPR）、假阳性率（False Positive Rate，FPR），部分文献使用故障检测率（FDR）、故障报警误报率（FAR），对应 TPR、FPR。现有预测算法按建模思路划分为传统机器学习、深度学习时序网络、半监督 / 无监督异常检测三大类。

1.2.2.1 机器学习方法

SSD 故障预测早期研究依托统计检验、距离度量等浅层数据分析手段挖掘故障前兆，代表方法含 Wilcoxon 秩和检验、马氏距离、高斯混合模型，通过指标分布偏移识别异常样本，计算开销低、可解释性强，但默认指标与故障存在线性关联，难以捕捉复

杂非线性退化关系，对新型硬件、未知故障泛化能力较弱[17-19]。Luković 等人基于马氏距离搭建无监督 SSD 异常检测框架，嵌入前向序列特征选择、Box-Cox 正态变换与自适应判定阈值，在阿里云公开数据集实现极低误报率，验证轻量化方案适配线上实时预警场景[20]。针对集群慢故障识别缺失的工程痛点，Lu 等人基于混合 SSD/HDD 大规模时序数据集设计 PERSEUS 无侵入检测框架，仅依托磁盘延迟、吞吐时序判别故障。该框架采用 PCA 联合 DBSCAN 清洗时序异常，结合多项式回归构造动态判定阈值，并以分层风险评分量化故障严重程度。方案无需修改业务逻辑，可精准定位劣化盘，但服务器硬件异构、多盘同步故障场景下检测精度显著衰减[21]。

监督学习框架成熟后，学界将 SSD 故障预测抽象为二分类/多分类健康判别任务，支持向量机（Support Vector Machine，SVM）、贝叶斯网络、随机森林（Random Forest，RF）等模型均取得稳定基线精度[22-26]。Xu 等人开源阿里云 4 万块 MLC-SSD 为期两年的 SMART 时序与故障标签数据集，提出磨损更新集成特征排序筛选算法，以梯度提升决策树（Gradient Boosting Decision Tree，GBDT）、随机森林构建领域通用基线，为后续对比实验提供统一数据基准[4]。Wang 等人基于该开源数据集设计两套随机森林训练方案，分别采用纯随机采样均衡样本、Spearman 相关特征筛选 + 时序特征增强两条路径，但实验未严格区分训练/测试时序，存在信息泄露问题，无法直接迁移至线上流式预测[27]。面向腾讯云 30 万块三星 PM1733、PM9A3 私有遥测数据集，Zhang 等人提出多视图多任务随机森林，融合短期单点指标、直方图统计、长期时序趋势多类特征，同步完成故障分类、剩余寿命回归多任务学习，两款设备分别取得 40% TPR/72% $F_{0.5}$、42% TPR/61% $F_{0.5}$ 的实验效果[26]。针对工业落地样本失衡、模型可解释性差两大痛点，Wang 等人在 FAST 2026 提出 FailureMiner 框架，设计边界保留下采样策略保留分类混淆样本，结合 Apriori 频繁项集挖掘故障判定规则，在腾讯大规模 SSD 集群落地，弥补传统随机森林下采样丢失边界样本、单指标阈值误报偏高的缺陷[28]；Ng 等人提出 TopoHealth-ET 拓扑感知极限随机树，融合机房机架拓扑先验与 ExtraTrees 模型，在极度样本不平衡场景提升故障富集效率，配套大语言模型生成可审计故障解释[10]。

1.2.2.2 深度学习方法

长短期记忆网络、一维卷积神经网络、Transformer 等时序深度网络已在 HDD 故障预测领域充分验证，逐步迁移适配 SSD 时序退化建模任务[29-31]。

Chen 等人依托阿里云与 Solidigm 合作私有数据集开展 30 天提前预警研究，针对高误报带来的大规模换盘、数据重建成本问题，将精确率设为核心优化目标，采用分组 k 折交叉验证缓解时序过拟合，设计多树模型集成投票机制，在 0.35%−0.44% 极低年故障率场景下实现 100% 精确率、21% 召回率[32]。Koh 等人基于腾讯云 181507 块三星 PM9A3 数据集提出时序上下文注意力网络，放弃冗余特征强筛选策略，采用分组建模思路：LSTM 捕捉时序演化、交叉注意力 Transformer 挖掘指标间耦合关联，弥补传统串行 LSTM+Transformer 架构建模短板，实验取得 68% TPR、70% F1-score[33]。

Zhang 等人基于字节跳动 41-M、10-M 两套私有 SSD 遥测数据集，总结现有分类、异常检测三类落地瓶颈：静态特征无法适配线上指标权重动态变化、单一模型仅识别历史故障、统一阈值无法区分轻度退化与整机失效，据此设计突变相似度故障评级框架，引入轻量化半监督 Informer 长时序模型，两套数据集分别取得 37% TPR/61% $F_{0.5}$、34% TPR/66% $F_{0.5}$[34-35]。Gu 等人提出 APTN 老化感知伪孪生网络，创新性融合系统层 SMART 时序与芯片 FBC 底层误码特征，搭建异构双分支网络完成多源数据建模，搭配在线增量学习缓解模型概念漂移，长短周期故障预测性能全面超越仅依靠 SMART 的深度学习基线[12]。Chakraborttii 等人系统对比前馈神经网络、LSTM、1D-CNN、Transformer 等全系列时序网络，量化各类模型算力开销与时序拟合能力，给出数据中心实时推理轻量化模型选型规范[16]。

1.2.2.3 半监督或无监督方法

SSD 运维天然存在故障标注稀缺、正负样本极度失衡、线上持续出现未知失效模式等痛点，大量研究将故障预测转化为异常检测任务，仅使用海量健康盘数据训练模型，依靠重构误差、异常分数判别预失效设备，代表性模型包含单类隔离森林、自编码器、变分自编码器-LSTM、Informer 等[34,36-37]。

Chakraborttii 等人依托 Google 六年完整 SSD 运维数据集训练单类隔离森林、自编码器，仅使用健康样本规避故障样本偏置，对未见过的新型故障识别能力提升，受试者工作特征曲线下面积（Area Under the ROC Curve，AUC）指标最高上涨 9.5%[37]。Zhou 等人基于华为私有 SMART 数据集提出 DFP-VL 半监督预测模型，融合变分自编码器时序重构与 LSTM 时序拟合，仅依靠健康盘完成训练，通过重构概率量化设备健康度，并区分缓慢、瞬时两类退化模式，配套双精度检测器，最终实现 100% TPR、0.06% 极低

FPR[38]。Luković 等人提出的马氏距离无监督方案无需任何故障标注，仅依托健康样本构建多元正态基准，特征前向压缩降低推理开销，适配新集群冷启动预警，弥补深度自编码器训练成本高、调参复杂的短板[20]。

1.2.3 块粒度固态硬盘寿命预测

盘级 SMART、遥测指标均经过控制器固件聚合平滑，掩盖闪存块、页局部细微老化差异，无法精准还原底层介质完整失效过程。近年研究逐步下沉至块粒度，依托块级 FBC、分段 PE 擦写时序搭建精细化寿命预测模型，支撑自适应磨损均衡、动态低密度奇偶校验码（Low-Density Parity-Check，LDPC）纠错等底层可靠性优化策略。

Ma 等人针对 3D TLC 闪存块耐久差异化问题，提出原始比特错误率感知块寿命预测方案，融合 PE 次数、数据保持时长、块级误码特征训练 SVM，搭配增量学习缓解模型老化；实验证明不同数据保持场景下块可用 PE 循环平均提升 37.5%−86.3%[39]。Tian 等人面向 218 层 3D NAND 架构设计片上 AI 预测方案，将字线电学泄漏特征嵌入擦写流程实现低延迟原位采集，基于类别提升树搭建块好坏二分类模型，分类准确率 97%、故障块召回率 91%[40]。Fang 等人面向热存储 LDPC 动态调参需求，基于现场可编程门阵列平台量化 FBC 随 PE、读干扰的演化规律，搭建轻量化短期预警系统，97.63%−99.16% 样本预测误差控制在 10% 以内，实现自适应码率分配，前期释放更多可用闪存容量[41-42]。Fitzgerald 等人基于 19nm MLC 加速老化测试平台，仅利用出厂初始无损测量指标训练梯度提升机扇区寿命模型，在可控数据丢失风险下将闪存标称耐久提升 2 倍以上[43]。

Zhang 等人设计 3D TLC 块粒度 SVM 预测框架，配套现场可编程门阵列高速推理流水线降低硬件开销，块寿命分类准确率稳定维持 95%[44]；Raquibuzzaman 针对 3D 堆叠闪存层间耐久失衡缺陷，设计分层感知动态磨损均衡算法，分流读写负载至中层高耐久页面，整体擦写寿命提升 45%[45]；Zhang 等人量化 3D CT TLC 非对称比特翻转误差，提出自适应 LDPC 码率优化方案，降低解码迭代时延、提升高磨损阶段可靠性[46]。罗铮针对传统块寿命测试周期过长的痛点，设计可控字线电压激励加速 RET 测试，测评时长缩短 90.9%，融合激励前后原始比特错误率特征后 SVM 预测准确率达 87%[13]；Gu 等人进一步验证块级 FBC 底层误码是表征闪存老化核心特征，仅依赖聚合盘指标会丢失块间耐久差异，限制预测模型上限[12]。

1.2.4 现有研究分析与不足

尽管现有研究在故障机理统计、时序预测算法及闪存精细化管控等方面已有广泛积累，但结合本文的研究目标，仍存在两方面不足。

在盘级故障预测方面，当前主流研究大多基于厂商私有大规模时序数据集挖掘长期设备退化规律，针对阿里云公开开源 SMART 数据集的近端短期突变前兆建模尚显不足。多数算法未围绕数据中心运维低误报硬性约束做 $F_{0.5}$ 阈值联合调优，导致模型在线上的工程适配性受限[26,33-34,38]。

在块粒度寿命管理方面，现有工作多局限于健康度或剩余寿命的预测建模，缺乏从“预测输出”到“差异化读写调度”的工程闭环。鲜有研究测算差异化 PE 策略在可控可靠性风险下的容量与耐久提升收益，难以直接指导固件开发与运维系统的实际部署。

1.3 研究目标与本文主要工作

针对上述现有研究存在的两类核心缺陷，本文确立统一总体研究目标：在数据中心运维可接受故障误报水平约束下，同步提升 SSD 故障提前检出能力与 NAND 闪存介质整体耐久容量利用率。围绕该总体目标，本文拆解两大相互关联的核心问题开展系统性研究：第一，依托阿里云公开 MLC-SSD SMART 时序数据集，挖掘故障发生前近端短期突变时序前兆；以盘级 $F_{0.5}$ 分数为核心优化指标，设计混合标签降噪策略、短期突变时序特征构造、异构集成预测完整方案，实现 SSD 提前 30 天低误报故障预警。第二，依托实验室加速磨损得到的块级 FBC 细粒度时序数据构建闪存健康预测模型，基于强弱块判别结果设计差异化 PE 擦写上限管控策略，在不突破 LDPC 纠错可靠性安全边界的前提下，提升 SSD 整体累计可写入容量与实际服役寿命。

本文核心创新主线在于将运维场景低误报代价约束贯穿故障预测、块级寿命优化两大任务全流程：以盘级 $F_{0.5}$ 为核心优化指标，在验证集上联合调整分类阈值，平衡精确率、故障检出率与预警提前时长，将 FPR 稳定控制在运维可接受区间；块粒度寿命优化任务中，不依靠激进放宽全局 PE 阈值换取容量增益，在近零误判安全约束下区分强弱闪存块、分层配置写入上限，实现风险可控前提下耐久容量提升。

围绕两大核心研究问题与创新思路，本文完成三方面完整研究工作：（1）构建面向 30 天提前预警的 SSD 盘级故障预测框架：基于阿里云开源 SMART 数据集完成数据清

洗与 A/B 属性划分，归纳故障近端突变时序规律；设计混合标注方法抑制长时序静默段标签噪声；融合 W 阶 Lag 滞后特征、稀有加权 $r_k|\Delta|$ 突变幅值特征搭建短期时序输入；搭建 RF、XGBoost、LightGBM 异构基学习器，搭配样本级注意力自适应融合模块；在 MB1、MB2 两组子集以 $F_{0.5}$ 为目标调优阈值，取得均衡 TPR 与极低 FPR 的综合实验效果。（2）设计块粒度闪存寿命建模与差异化写入管控策略：依托高温加速磨损 FBC 时序数据构建块寿命分类标签；在有限 Wordline、单次读取、简化磨损档位等轻量化采集场景验证模型鲁棒性；基于强弱块二分类结果设计可固件部署的差异化 PE 上限调度方案，在测试集上基于模型预测定量测算相较于统一阈值策略约 17% 的累计写入提升收益。（3）整套算法工程化落地验证：设计并实现智慧 SSD 运维原型软件，搭建“数据接入—模型预警—人工处置—运行数据沉淀”全闭环业务流程，完整验证本文算法在真实数据中心运维场景的部署可行性。

本文完整研究内容与技术路线整体框架如图 1.2 所示：

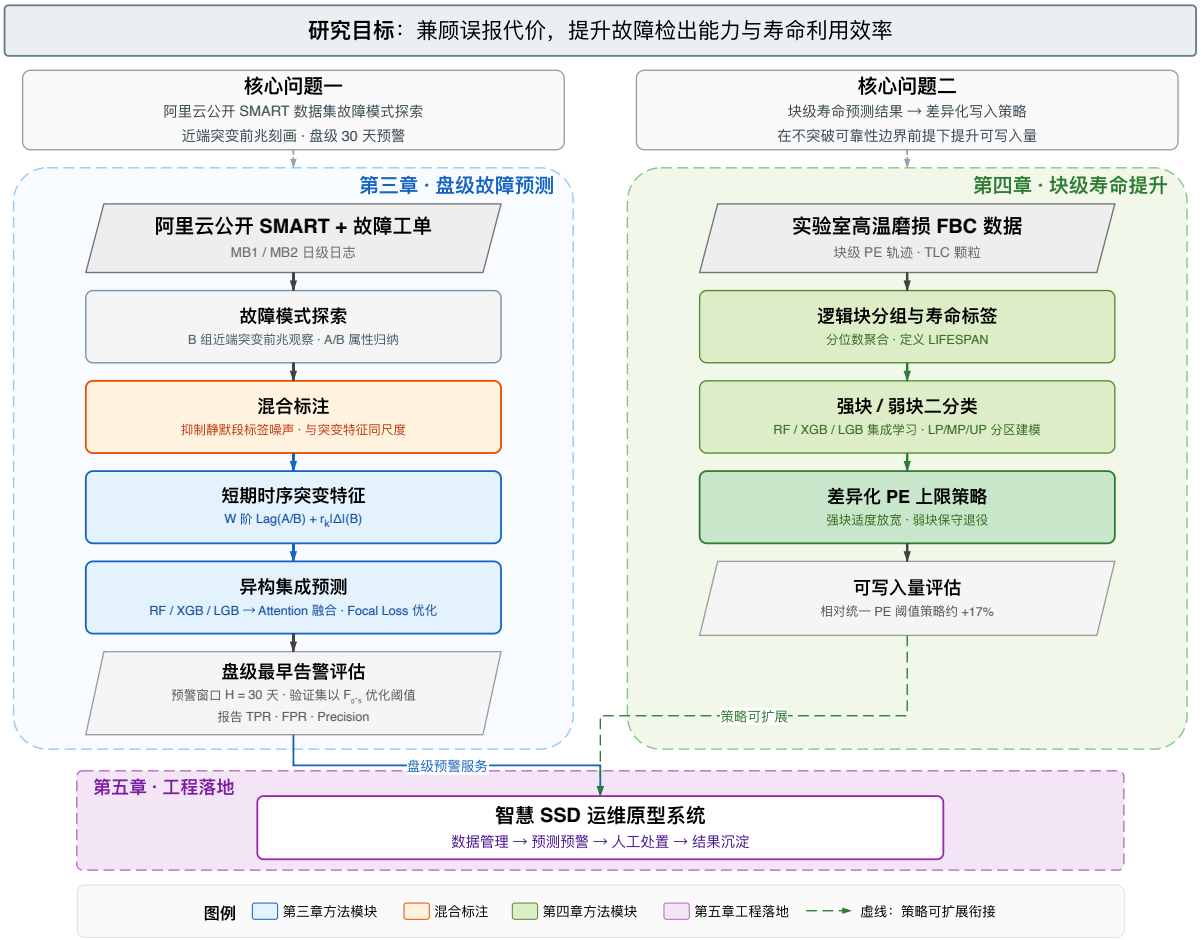


图 1.2 本文研究框架与技术路线（第三至五章）

1.4 论文组织结构

本文全文共划分六个章节，各章节研究内容与行文逻辑安排如下：

第一章（本章）为绪论。本章从全球数字化转型海量数据增长切入，阐述规模化数据中心存储可靠性核心挑战；对比 HDD、SSD 硬件架构与失效特征差异，分析 SSD 故障带来的业务损失；梳理传统被动容灾方案局限性；系统综述 SSD 故障成因、盘级预测、块粒度寿命管理三大方向国内外研究现状；归纳现有研究共性短板，明确本文研究目标、三大核心工作与创新点，说明全文章节排布逻辑。

第二章为相关理论基础。本章系统介绍 NAND 闪存分层结构、PE 编程擦除物理机理；阐述 SMART 监控体系与主动容错原理；讲解随机森林、XGBoost、LightGBM 等集成学习算法，以及注意力机制与 Transformer 等深度时序建模方法，为后续算法设计、对照实验提供理论支撑。

第三章为 SSD 盘级故障预测算法研究。本章详细介绍阿里云 SMART 数据集预处理流程，统计故障近端突变时序特征；完整阐述混合标注、短期突变时序特征、注意力异构集成整套方案；开展多组消融实验、多基线对比实验，汇报 MB1/MB2 盘级 TPR、FPR、$F_{0.5}$ 量化结果，分析模型优势与现有局限性。

第四章为 SSD 块粒度闪存寿命提升策略研究。本章介绍块级 FBC 数据采集与预处理流程，构建块健康二分类预测模型与差异化 PE 擦写管控策略，定量评估耐久容量提升幅度，并在轻量化采集条件下验证方法稳定性。

第五章为智慧 SSD 运维软件原型设计与实现。本章面向线上运维工程需求完成需求分析、系统概要架构、模块详细设计、数据库实体联系图与数据表设计；完整阐述算法服务、前后端功能开发流程；开展全场景功能测试，验证算法服务与运维流程的集成可行性。

第六章为总结与展望。本章全面归纳全文三项核心研究成果与创新结论；梳理本文研究存在的局限性；围绕多厂商混合 SSD 适配、跨域迁移学习、控制器端轻量化推理、端边云协同预警等方向提出后续拓展研究思路。

2 相关理论基础

本章节详细介绍与本文相关的研究技术及原理，包括固态硬盘存储结构与读写/擦除机制、错误产生与纠错原理、SMART 监控技术，以及随机森林、XGBoost、LightGBM 等集成学习算法与注意力机制、Transformer 等深度时序建模方法[31,47-50]。

2.1 固态硬盘存储原理

SSD 是一种基于闪存（Flash Memory）技术的非易失性存储设备，其核心存储介质为 NAND 闪存芯片。与传统的 HDD 相比，SSD 具有读写速度快、抗震性强、功耗低等优势，已广泛应用于数据中心和个人计算设备中。

2.1.1 NAND 闪存基本结构

NAND 闪存以浮栅场效应晶体管（Floating Gate MOSFET）作为基本存储单元（Cell），并通过浮栅中电子的存储状态来表示数据。其分层组织结构示意如图 2.1 所示。对应的主要层级包括：

1. 存储单元（Cell）：最基本的存储单位。按单元可存储的比特数可分为单层单元（Single-Level Cell, SLC）、多层单元（MLC）和三层单元（TLC）。其中，SLC 每单元存储 1 比特，可靠性与耐久性最好但成本较高；MLC 每单元存储 2 比特，在容量与成本之间折中；TLC 每单元存储 3 比特，容量密度更高、单位成本更低，但对噪声与老化更敏感。

2. 页（Page）：由多个存储单元组成，是 NAND 闪存的最小读写单位。以 TLC 为例，按同一字线（Wordline）上不同位的存储方式，常划分为低页（Low Page, LP）、中页（Middle Page, MP）和高页（Upper Page, UP）。不同页类型的错误率存在差异，通常 LP 页较低而 UP 页相对较高。

3. 块（Block）：由多个页组成，是 NAND 闪存的最小擦除单位。一个块通常包含数百个页，通常取 2 的倍数如 256 或 512 页。受 NAND 物理特性限制，数据写入前需要先擦除，而擦除只能以块为单位进行。

4. 平面（Plane）：由多个块组成。同一平面内的块可并行操作，从而提升读写吞吐。

5. Die：由多个平面组成，是封装在芯片中的相对独立单元，亦称 LUN。多个 Die 可并行工作，进一步提升 SSD 的整体并行度与性能。

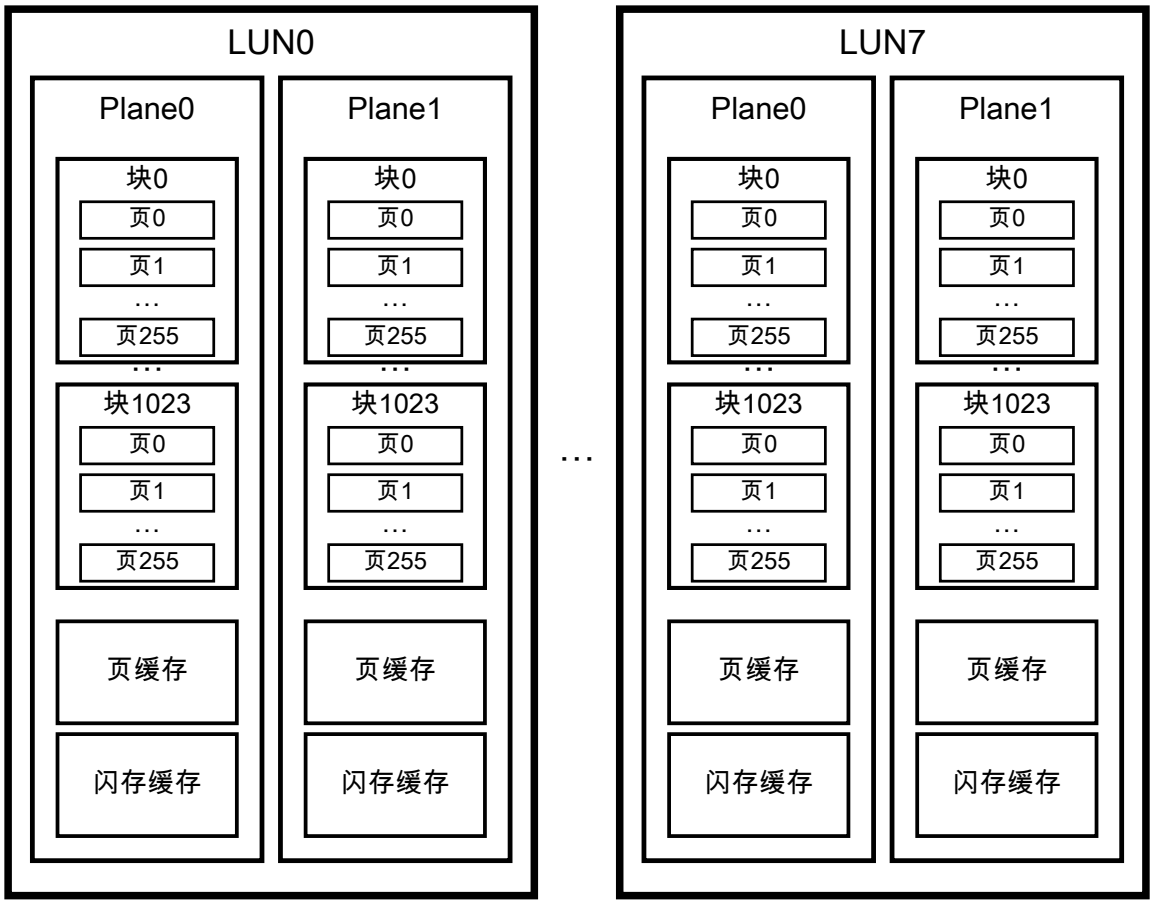


图 2.1 固态硬盘基本结构

2.1.2 编程与擦除操作

NAND 闪存的数据操作可归纳为编程（Program）与擦除（Erase）两类。两者的基本机理如图 2.2 所示，具体过程如下：

1. 编程操作：将数据写入存储单元的过程。通过向控制栅施加高电压，使电子通过隧道氧化层注入浮栅，改变浮栅中的电子数量，从而改变存储单元的阈值电压，实现数据写入。编程操作以页为单位进行，但只能将存储单元从低电压状态（擦除状态）编程到高电压状态，不能反向操作。

2. 擦除操作：将存储单元恢复到初始状态（低电压状态）的过程。通过向衬底施加高电压，使浮栅中的电子通过隧道氧化层被移除。擦除操作以块为单位进行，且擦除次数有限，这是限制 SSD 寿命的主要因素之一。

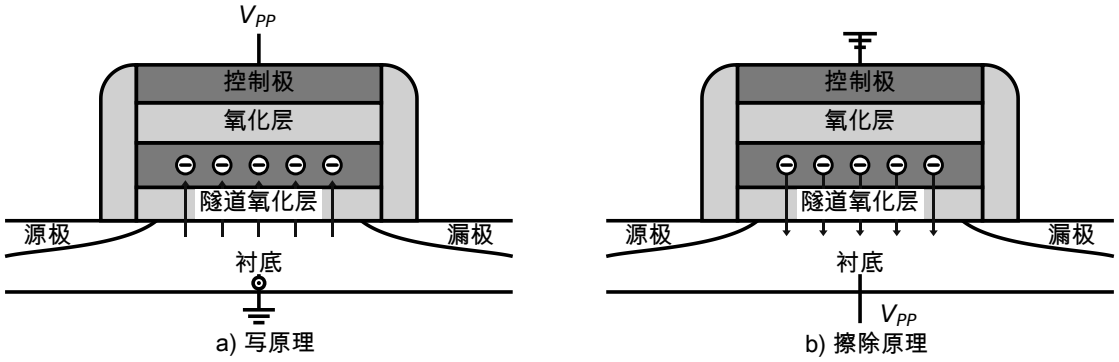


图 2.2 闪存擦写原理

每次完整的编程-擦除循环称为一次 PE 操作。随着 PE 次数的增加，存储单元的物理特性会逐渐退化：浮栅捕获电子的能力下降，阈值电压窗口变窄，导致读取时更容易出现错误。因此，PE 次数是衡量 SSD 寿命和可靠性的重要指标。

2.1.3 错误产生机理

在 SSD 的使用过程中，多种因素会导致存储单元中出现错误比特（Fault Bit），主要包括：

1. 编程/擦除老化：随着 PE 次数的增加，浮栅与隧道氧化层之间的界面陷阱逐渐增多，导致电子捕获能力下降，阈值电压分布发生偏移，读取时更容易出现误判。

2. 数据保持时间：长时间静置后，浮栅中捕获的电子可能通过隧道氧化层泄漏，导致阈值电压下降，读取数据与写入数据不一致。数据保持时间越长，电荷泄漏越严重，错误率越高。

3. 读干扰（Read Disturb）：在读取操作过程中，虽然读取电压较低，但仍会对相邻存储单元产生轻微影响。多次读取操作累积后，可能导致相邻单元的阈值电压发生微小偏移，产生读干扰错误。

4. 温度影响：高温环境会加速电荷泄漏和界面陷阱的形成，显著增加错误率。根据 Arrhenius 方程，温度与老化速率之间存在指数关系，因此温度是影响 SSD 可靠性的重要环境因素。

2.1.4 纠错编码技术

本节从 SSD 控制器实现出发，对 LDPC 作面向应用的概念性说明。

为抵御上述错误，企业级 SSD 控制器中通常内置 ECC 模块。目前广泛采用的是 LDPC，最早由 Gallager 提出[51]。LDPC 码的工作原理如下：

1. 编码阶段：在写入数据前，对原始数据比特序列进行编码，插入冗余校验比特，生成编码后的数据块。

2. 译码阶段：在读取数据时，LDPC 译码器依据接收数据比特与校验比特进行译码。最经典的迭代译码算法是基于 Tanner 图的置信传播（BP）算法，通过在变量节点与校验节点之间传递概率信息并迭代更新，逐步收敛到对发送比特的估计。只要错误比特数量不超过 LDPC 的纠错能力上限，译码器通常可成功恢复原始数据。

若块 FBC 超出 LDPC 纠错上限，则标记为坏块。厂商预留冗余块用于替换，但其资源有限；坏块过多会造成 SSD 可用容量、并行写入性能大幅衰减，直至设备寿命终止。

2.2 固态硬盘故障容错技术

为保障数据中心的存储可靠性，需要采用多种容错技术来应对 SSD 故障。根据故障处理时机的不同，容错技术可分为被动容错技术和主动容错技术两大类。

2.2.1 被动容错技术

被动容错技术是指在故障发生后进行数据恢复的容错机制。这类技术通过数据冗余和分布策略来保证数据的可靠性，主要包括数据冗余策略和数据分布策略。

2.2.1.1 数据冗余策略

数据冗余策略通过在多个存储节点上保存数据的多个副本或编码后的校验信息，使得在部分节点故障时仍能恢复原始数据。主要方式包括多副本和纠删码两种：

1. 多副本策略：将数据复制为 n 份，分布到 n 个存储节点中。每个存储节点都可以独自对外提供该数据的读服务，具有良好的访问负载均衡特性。当其中一个存储节点发生故障导致数据丢失时，分布式存储系统可直接通过复制其他任意副本存储节点上的数据来进行恢复。通常情况下，分布式存储系统中的多副本方式默认为三副本（$n=3$），即每个数据块保存 3 个副本，最多可容忍 2 个节点同时故障。

   多副本策略的优点包括：访问负载均衡、读写性能高、数据恢复开销小而快。但其缺点也明显：存储利用率低（三副本策略的存储利用率仅为 33%）、存储成本高。

2. 纠删码策略：一种基于编码技术的冗余方案。纠删码首先将数据切分成均等的 k 个数据块，并对这 k 个数据块进行编码，生成 m 个校验块。数据块和校验块分布在不同的存储节点上，只有拥有数据块的存储节点能对外提供该数据的读服务。在恢复数据时，纠删码方式可以读取任意 k 个存活的数据块和校验块来进行解码，就能恢复所丢失的数据。常用的纠删码配置包括 RS(10,4)（10 个数据块，4 个校验块，可容忍 4 个节点故障）等。

   纠删码策略的优点包括：存储利用率高（例如 RS(10,4) 的存储利用率为 71.4%）、存储成本低。但其缺点在于：不利于访问负载均衡、数据恢复开销大而慢（需要读取多个节点并进行解码计算）。

2.2.1.2 数据分布策略

数据分布策略通过将数据分散存储到多个物理设备上，降低单点故障的影响范围。常见的分布策略包括：

1. 条带化（Striping）：将数据块分割成多个条带，分布到不同的存储设备上，提升并行读写性能。

2. RAID 技术：通过将多个物理盘组合成逻辑卷，提供数据冗余和性能提升。常见的 RAID 级别包括 RAID 0（条带化，无冗余）、RAID 1（镜像）、RAID 5（分布式奇偶校验）、RAID 6（双重分布式奇偶校验）等。

被动容错技术的共同特点是：只能在故障发生后进行数据恢复，属于“事后补救”机制。虽然能够在一定程度上保障数据可靠性，但故障恢复过程需要消耗一定的时间和

计算资源，可能导致系统服务降级。

2.2.2 主动容错技术

主动容错技术相较于被动容错技术，能够利用硬盘故障预测模型来提前感知硬盘故障的发生，为危险数据的保存和迁移争取时间，采取数据提前恢复策略来缓解系统服务降级和分摊开销，相对来说风险小、成本低。

2.2.2.1 SMART 技术基础

目前，几乎所有的硬盘都支持 SMART 技术。SMART 是一种自动的硬盘状态检测与预警系统和规范，通过在硬盘硬件内的检测指令对硬盘的硬件，如扇区分配计数、通电时间、重启次数、错误计数等，运行情况进行监控、记录，并与供应商所设定的预设安全值进行比较。若监控情况将或已超出预设安全值的安全范围，就可以通过主机的监控硬件或软件自动向用户发出警告并进行轻微的自动恢复，以提前保障硬盘数据的安全。除一些出厂时间极早的硬盘外，现在大部分硬盘均配备该项技术。

虽然 SMART 技术的直接故障检测率仅有 3–10%，但可以利用它记录下硬盘的各种运行状态数据，即 SMART 属性。SMART 属性主要包括两类：

1. 硬盘读写属性：反映硬盘读写操作相关的指标，如逻辑块地址（LBA）写入总数、LBA 读取总数、重映射扇区计数、编程失败计数、擦写失败计数等。

2. 硬盘运行状态指标：包含反映实时环境的温度，记录累计损耗的通电时间、通电周期计数等。

2.2.2.2 基于 SMART 的故障预测

从 SMART 属性信息中刻画硬盘健康状态并预测未来故障，在方法学上可归结为机器学习中的监督学习问题[49-50]，工程实现上常采用机器学习或深度学习等模型。此类硬盘故障预测模型基于大量历史盘片的时序或截面数据训练，其收集的每条硬盘数据都包含了许多 SMART 属性。不同供应商生产的硬盘，其收集的数据的 SMART 属性和个数也不尽相同，并且还会有一些供应商所添加的独有属性，但收集的 SMART 属性大多是一样的，如通电时间、重映射扇区计数、无法校正的错误、设备开关次数等。

每个SMART属性都有一个原始值(Raw Value)和一个归一化值(Normalized Value)。原始值是由硬盘传感器中的内部软件直接收集的，反映属性的实际测量值；归一化值是通过使用供应商特定的方法将相关的原始值映射到一个字节（0-255）来获得的，通常值越大表示健康状态越好，当归一化值下降到阈值以下时，可能表示硬盘存在故障风险。

故障预测模型预判硬盘故障并预警时，系统可提前执行以下措施：

1. 数据迁移：将危险数据从即将故障的硬盘迁移到健康的硬盘上，避免数据丢失。
2. 负载重分配：减少对即将故障硬盘的读写负载，延长其剩余寿命。
3. 提前替换：在故障发生前安排维护窗口，提前替换即将故障的硬盘，避免突发故障对系统造成影响。

主动容错技术通过提前预警和预防性措施，能够显著降低故障恢复带来的时间开销，降低SSD故障引发的数据丢失风险，提升系统整体可靠性。

2.3 集成学习算法原理

在机器学习框架下，集成学习（Ensemble Learning）通过构建并组合多个“弱学习器”(Weak Learners)，以提升整体预测性能与泛化能力[49]。与单一模型相比，集成方法能够在一定程度上降低方差和偏差，对噪声和异常点更具鲁棒性，在工业界的大规模故障预测任务中得到广泛应用。下文在不展开一般性理论证明的前提下，结合本文所用树模型基学习器，概述随机森林与梯度提升族算法的要点。

2.3.1 随机森林模型

随机森林是一种典型的Bagging集成算法，由Leo Breiman于2001年提出[52]。其基本思想是对训练集进行自助采样（Bootstrap），训练多个相互独立的决策树分类器，并在预测阶段通过投票或平均的方式得到最终预测结果，如图2.3所示：

在每棵树的训练过程中，随机森林在节点划分时仅从特征子集中选择最优划分特征，从而引入额外的随机性，降低不同树之间的相关性。得益于多棵树的集成，随机森林对单棵树容易出现的过拟合问题有一定抑制作用，同时在处理高维特征、非线性关系以及特征尺度差异时表现稳定，适合作为SSD故障预测中的基线模型。

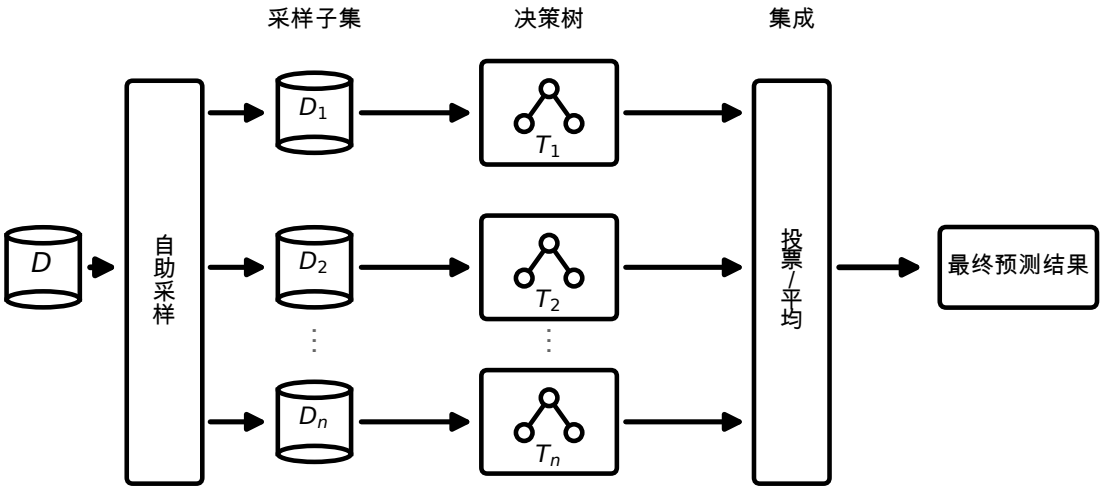


图 2.3 随机森林示意图

随机森林的训练与预测过程可用如下文字与公式表示。给定训练集

$$D = \{(x_i, y_i)\}_{i=1}^{N}, \tag{2-1}$$

设森林中决策树数量为 n，每个节点分裂时从全部 M 个特征中随机抽取 m 个特征作为候选集合。

对于第 k 棵树（$k = 1, \ldots, n$），先通过有放回抽样得到子集 $D_k \sim \text{Bootstrap}(D)$，再在 D_k 上训练决策树 T_k。在每个节点处，从候选特征集合 S_k 中选择使划分指标最大的特征与阈值，即

$$(j^*, s^*) = \arg\max_{j \in S_k,\, s} \Delta(j, s), \tag{2-2}$$

其中 $\Delta(j, s)$ 表示按特征 j 和划分点 s 划分后的增益（如信息增益或基尼指数下降量）。

对新样本 x，所有子树给出预测 $\{T_k(x)\}_{k=1}^{n}$。最终类别由多数投票确定：

$$F(x) = \arg\max_{c} \sum_{k=1}^{n} \mathbf{1}(T_k(x) = c), \tag{2-3}$$

其中 c 为类别标签，$\mathbf{1}(\cdot)$ 为示性函数。

2.3.2 XGBoost 模型

XGBoost（Extreme Gradient Boosting）是 GBDT 算法的高效实现，由 Chen 和 Guestrin 于 2016 年正式提出[53]。图 2.4展示了 GBDT 算法的基本迭代流程。

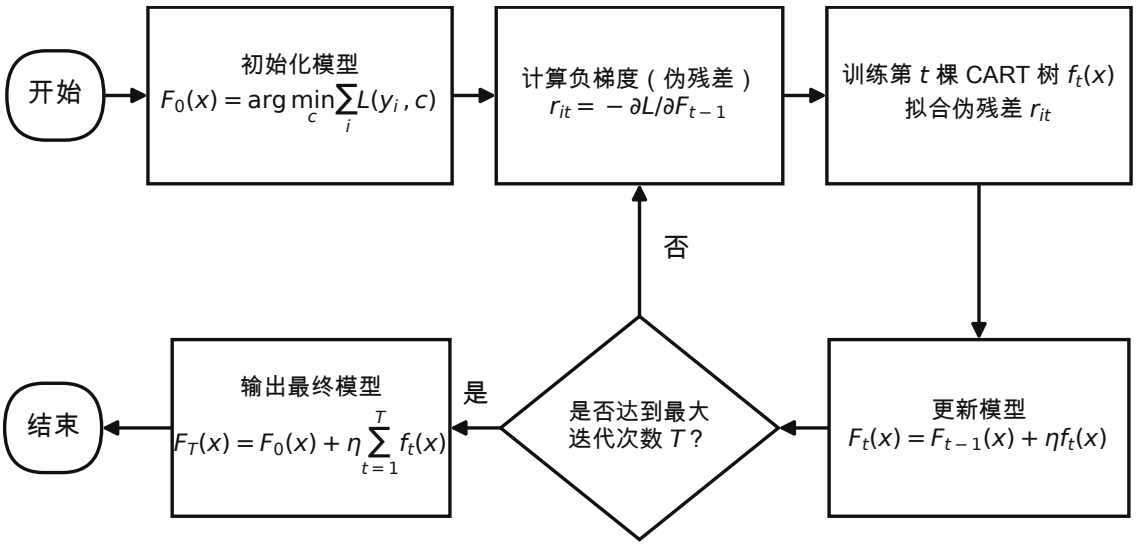


图 2.4 GBDT 算法迭代流程示意图

GBDT 采用加性模型（Additive Model）策略，通过串行训练的方式逐轮叠加树基学习器。在每一轮迭代 t 中，算法通过拟合当前模型损失函数的负梯度（即残差近似）来生成新的决策树 $f_t(x)$，并按如下方式更新模型：

$$F_t(x) = F_{t-1}(x) + \eta f_t(x), \quad t = 1, \ldots, T, \tag{2-4}$$

其中 η 为学习率，$F_t(x)$ 表示第 t 轮迭代后的强学习器，$f_t(x)$ 为第 t 棵弱学习器（CART 树）。由上述递推关系反复展开，可得最终强学习器的显式形式：

$$F_T(x) = F_0(x) + \eta \sum_{t=1}^{T} f_t(x), \tag{2-5}$$

即 $F_T(x)$ 由初始模型 $F_0(x)$ 与 T 棵弱学习器的加权和构成，体现了 GBDT 的线性叠加结构。

相较于传统 GBDT，XGBoost 在目标函数中引入了二阶泰勒展开（利用二阶导数信息）及显式的正则化项，有效防止了过拟合。同时，结合缺失值自动处理、加权分位数 sketch 近似分裂及并行化计算等工程优化，XGBoost 在保持高预测精度的同时显著提升了训练效率。

针对 SSD 故障预测任务，XGBoost 具备显著优势：一方面，它能有效捕捉 SMART 属性等高维特征间的非线性关系与复杂交互；另一方面，模型输出的特征重要性评分（Feature Importance）能够为关键故障指标的筛选及结果的可解释性分析提供量化依据。

2.3.3 LightGBM 模型

LightGBM 是基于梯度提升框架的高效决策树集成算法，由 Guolin Ke 等人在 2017 年提出[54]。其核心特点包括基于直方图的离散化分裂算法（Histogram-based Decision Tree）、按叶生长（Leaf-wise）的树生长策略以及对大规模数据友好的高效并行机制。相比 XGBoost，LightGBM 更侧重训练效率优化：通过特征分桶与直方图复用降低分裂计算开销，并采用单边梯度采样（GOSS）与互斥特征捆绑（EFB）进一步减少计算量和内存占用，使其更适用于大规模、高维数据的快速训练与迭代。在数据中心 SSD 故障预测中，LightGBM 常用于在保证效果的前提下缩短训练与推理时间，便于周期性更新与部署。

本文以 RF、XGBoost 与 LightGBM 作为归纳偏置不同的异构基学习器，并在第三章通过注意力机制对其输出概率做样本级自适应融合；Transformer 等深度时序网络作为对比基线的建模背景，见下文 §2.4。

2.4 注意力机制与 Transformer

除树模型集成外，SSD 故障预测亦广泛采用深度神经网络直接建模 SMART 时序序列，注意力（Attention）机制是建模时常用的一个模块。Attention 机制通过为不同输入分量分配自适应权重，突出与当前预测目标更相关的信息；Transformer 则以自注意力为核心，并行刻画多变量时序内部的时间依赖与指标间耦合关系[29,31,33-34]。本节先介绍 Attention 的一般形式，再概述 Transformer 结构及其在 SSD 时序建模中的应用场景。

2.4.1 注意力机制基本原理

注意力机制核心思想是：给定查询向量（Query），在键值对（Key–Value）上计算相关性得分，归一化得权重，再对 Value 加权求和得上下文表示。设长度为 n 的得分为 $\mathbf{s} = (s_1, \ldots, s_n)^{\mathsf{T}}$，softmax 函数将其映射为权重向量 $(\alpha_1, \ldots, \alpha_n)^{\mathsf{T}}$，其中第 j 个分量为

$$\alpha_j = \frac{\exp(s_j)}{\sum_{k=1}^{n} \exp(s_k)}, \quad j = 1, \ldots, n, \tag{2-6}$$

满足 $\alpha_j \geq 0$ 且 $\sum_{j=1}^{n} \alpha_j = 1$，从而将任意实数得分转化为非负、归一化的注意力权重。

进一步设查询矩阵 Q、键矩阵 K、值矩阵 V，缩放点积注意力（Scaled Dot-Product Attention）定义为

$$\mathrm{Attention}(Q,K,V)=\mathrm{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}}\right)V, \tag{2-7}$$

其中 d_k 为键向量维度，分母 $\sqrt{d_k}$ 用于缓解点积随维度增大而数值不稳定的问题；$\mathrm{softmax}(\cdot)$ 对矩阵 $QK^{\mathsf{T}}/\sqrt{d_k}$ 的每一行按式 (2-6) 计算权重。对单个查询向量 $\mathbf{q}$ 与 n 组键值对 $(\mathbf{k}_j,\mathbf{v}_j)$，记 $s_j=\mathbf{q}^{\mathsf{T}}\mathbf{k}_j/\sqrt{d_k}$，则对应上下文表示为 $\sum_{j=1}^{n}\alpha_j\mathbf{v}_j$。在多头注意力（Multi-Head Attention）中，将 Q,K,V 分别投影至 h 个子空间并行计算式 (2-7)，再将各头输出拼接并线性变换，以同时捕捉不同子空间中的关联模式。

从功能上看，注意力等价于对一组候选信息做内容相关的加权汇聚：权重大的分量对输出贡献更大。该形式既可用于序列内部不同时间步或不同 SMART 属性之间的关联建模（如 Transformer 中的自注意力），也可用于对多个判别器输出分配样本自适应权重（如集成融合）。本文第三章对 RF、XGBoost 与 LightGBM 基分类器概率的融合即采用 softmax 加权形式。

2.4.2 Transformer 模型

Transformer 由 Vaswani 等人于 2017 年提出，最初面向序列到序列任务，现已成为时序预测与多变量序列建模的常用骨干网络[31]。与依赖逐步递归的循环神经网络不同，Transformer 通过堆叠的自注意力层并行处理整段输入序列，在训练效率与长程依赖建模方面具有优势。

标准 Transformer Encoder 的主要组成包括：

1. 输入嵌入与位置编码：将各时间步的多维 SMART 读数映射为 d 维向量，并叠加位置编码以保留日级时序顺序信息。

2. 多头自注意力层：在同一序列内，以各时间步为 Query，对其余时间步为 Key/Value 计算式 (2-7)，使每个时刻的表示融合全局上下文，从而刻画指标随时间的演化及不同属性间的交互。

3. 前馈网络与残差连接：每个注意力子层后接两层全连接网络，并配合层归一化与残差连接，以稳定深层训练。

将上述 Encoder 块重复堆叠 L 次，即可由原始 SMART 时序得到高层语义表示，再接分类或预测头完成故障判别。SSD 盘级故障预警属于“读入整段时序、输出是否失效”的判别任务，第三章 TCAN 等对比基线主要依赖 Encoder 或以其为核心的变体完成特征编码，无需逐步生成输出序列[33]。完整 Transformer 还包含 Decoder，通过带掩码的自注意力与对 Encoder 输出的交叉注意力逐步生成目标序列，适用于机器翻译、多步时序预测等 Seq2Seq 场景；Mut-RF 基线所采用的 Informer 即基于 Encoder–Decoder 结构预测未来 SMART 读数[34-35]，具体设定见第三章对比实验。

面向长序列时序建模，标准 Transformer 亦衍生出多种变体：Informer 通过 ProbSparse 注意力降低长序列计算开销；PatchTST 将子序列切分为 patch 后送入 Transformer，以提升长期预测效率[55]；iTransformer 则在变量维度而非时间维度施加自注意力，以强化多变量 SMART 指标间的关联建模[56]。上述方法为 SSD 时序退化建模提供了丰富的网络结构选择。

2.5 本章小结

本章系统介绍了与全文研究相关的存储原理与机器学习基础，为后续 SSD 故障预测与寿命提升方法的设计提供理论支撑。

在存储层面，阐述了 NAND 闪存的分层结构、PE 机理及编程老化、数据保持、读干扰等主要错误来源，并说明了 LDPC 纠错与 FBC 阈值在块级可靠性边界中的作用。在容错层面，区分了多副本、纠删码等被动容错与基于 SMART 的主动容错思路，明确了从 SMART 时序数据出发进行监督学习故障预测的基本问题设定。

在算法层面，介绍了随机森林、XGBoost 与 LightGBM 三类集成学习模型：随机森林通过 Bagging 与特征随机化降低方差，梯度提升树族通过串行拟合残差捕捉非线性退化关系，LightGBM 则进一步面向大规模数据优化训练效率。本文以三者作为归纳偏置不同的异构基学习器，并在第三章通过注意力机制对其输出概率做样本级融合。

此外，本章还概述了注意力机制的基本形式与 Transformer Encoder 结构，说明了 softmax 加权、缩放点积自注意力等核心运算，并指出 Decoder 及 Informer 等变体在多步时序预测中的应用场景。上述内容为第三章盘级故障预测实验中的深度学习对比基线，以及本文异构集成融合模块提供了统一的理论背景。

3　基于近端突变标注与突变时序特征集成的固态硬盘故障预测方法

盘级 SSD 故障预测是数据中心主动容错的重要环节，其结果用于提前迁移数据、更换风险盘，对保障存储可靠性与在线服务稳定具有重要意义。前两章已介绍相关研究背景，以及 SMART 监控原理、随机森林与梯度提升树等集成学习算法，以及注意力机制与 Transformer 等深度时序建模方法，为后续建模与评估奠定了理论与方法基础。

本章面向盘级 30 天预警任务，立足于正样本极度稀疏与近端突变信号弱且易被淹没并存的实际痛点。一方面，既有方案多在较长观测窗口下对高维 SMART 属性进行 Lag、滑动统计等复杂特征工程[4,26-27]，易稀释失效前极短时段内 B 组属性的阶跃突变，使近端前兆难以保留；另一方面，若将故障日前整段 30 日窗口均标为正样本，会把首次跳变前长期静默的日样本引入训练，形成标签噪声。

针对上述问题，本章依次提出三项相互衔接的技术。在标注层面，采用混合标注策略：在首次跳变观测基础上，将正样本进一步限制于故障前短期时间窗口，使监督信号与突变特征及盘级检出时效同尺度对齐。在特征层面，构造短期时序突变特征：以 W 阶 Lag 保留 A/B 组近期读数水平，并对 B 组追加稀有加权后的按日差分绝对值以刻画突变强度。在模型层面，采用 RF、XGB 与 LGB 等异构基学习器输出故障概率，由 Attention 模块做样本级自适应加权融合，并以 Focal Loss 缓解类别不平衡、提升判别稳定性[57]。上述三部分构成完整的盘级故障预测流程，如图 3.1 所示：



图 3.1 SSD 故障预测方法流程

3.1　任务目标与问题设定

3.1.1　盘级预测任务

设数据中心内第 i 块 SSD 在离散日历日 t 产生一条 SMART 日志，记其原始属性向量为 $\mathbf{x}_{i,t} \in \mathbb{R}^d$。给定该盘截至时刻 T 的历史观测序列 $\{\mathbf{x}_{i,t}\}_{t \le T}$，盘级故障预测任务旨在判断该盘在评估窗口内是否会在未来 H 天内发生故障；若判定为有风险，则进一步给出最早一次故障告警日期，供盘级评估使用。

本文盘级任务与评估口径参考 PAKDD2020 阿里巴巴智能运维算法大赛公开设定[58]，预测窗口取 $H = 30$ 天。与样本级二分类相比，盘级任务更贴近生产部署：需将同一块 SSD 的多条日志聚合为一次告警，以模拟更换故障盘的实际流程。在此评估口径下，过早误报会导致健康盘被提前更换，从而抬高运维成本。

3.1.2　评估指标与盘级判定规则

基于上述盘级评估框架，对测试集中每块 SSD 在评估时间窗口内逐盘判定，判定示意如图 3.2：

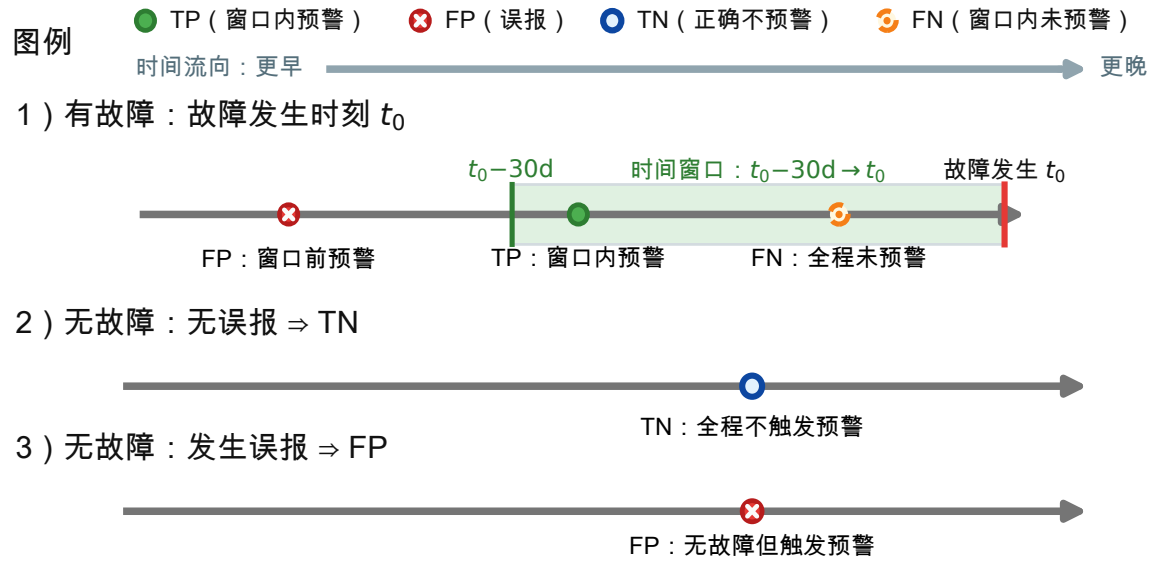


图 3.2 盘级 TP/FP/TN/FN 判定示意

具体的来说，若存在至少一条样本被预测为故障，则取最早一次预测为正的日期 t_{alarm} 作为该盘的告警时刻，并据此区分真正例与假正例。若 t_{alarm} 后 30 天内该盘确实

发生故障，计为真正例（TP）；若 t_{alarm} 距离故障超过 30 天，则计为假正例（FP）；若该盘在数据集中从未记录故障却被触发告警，也计为 FP；若评估窗口内始终未触发告警，则进一步区分假负例与真负例：若发生故障未能被检出，计为假负例（FN）；若未记录故障且始终未触发告警，计为真负例（TN）。

为对比各模型在盘级 SSD 故障预测任务上的表现，本研究选取了四个在故障预测领域被广泛使用的评价指标：TPR、FPR、精确率（Precision）和 $F_{0.5}$ 分数。由于本章以盘级最早告警为评估单位，需先依据上述规则将测试集中每块 SSD 划分为 TP、FP、FN 或 TN，再在整个测试集的全部盘上统计各指标。其中，TPR 与 FPR 分别刻画对实际故障盘的检出能力与对健康盘的误报水平，Precision 与 $F_{0.5}$ 则进一步衡量预警结果的精确性与综合权衡。下面分别介绍各评估指标的定义。

TPR 表示故障盘中被成功预警的比例，也称为召回率（Recall）。该指标反映模型对真实故障盘的覆盖能力，TPR 越高，说明漏检的故障盘越少，其计算公式如下：

$$\text{TPR} = \frac{TP}{TP + FN}, \tag{3-1}$$

其中，TP 表示被正确预警的故障盘数，FN 表示发生故障但未触发告警的盘数。

FPR 表示健康 SSD 中被误判为故障并触发告警的比例，该指标直接关系到健康盘是否会被提前更换，FPR 越低，由误报导致的运维成本越小。其计算公式如下：

$$\text{FPR} = \frac{FP}{FP + TN}, \tag{3-2}$$

其中，FP 表示被误报为故障的健康盘数，TN 表示未触发告警且未发生故障的盘数。

Precision 表示所有触发告警的 SSD 中实际发生故障的比例。该指标反映预警结果的可信程度，Precision 越高，说明每次告警对应真实故障的可能性越大，有助于减少对健康盘的提前更换。其计算公式如下：

$$\text{Precision} = \frac{TP}{TP + FP}, \tag{3-3}$$

其中，$TP + FP$ 为触发告警的盘数。

$F_{0.5}$ 分数是 F_β 分数在 $\beta = 0.5$ 时的特例，对 Precision 赋予高于 TPR 的权重。Xu 等人[4]指出，一旦 SSD 被预测为故障，运维人员通常会将其下线送检；因此，误将健康盘判为故障（低 Precision）的代价高于漏检故障盘（低 Recall）。在大规模 SSD 部署场景

下，采用 $F_{0.5}$ 而非 F_1 分数，即令 Precision 的权重为 TPR 的两倍，更符合上述运维代价结构。其计算公式如下：

$$F_{0.5} = \frac{(1+0.5^2)\cdot \mathrm{Precision}\cdot \mathrm{TPR}}{0.5^2\cdot \mathrm{Precision} + \mathrm{TPR}}. \tag{3-4}$$

3.2　数据集与预处理

3.2.1　数据集描述

本研究采用开源的阿里云 SMART 公开数据集[4]。数据来自阿里云五个 SSD 数据中心，观测期为 2018 年 1 月至 2019 年 12 月，内容包括日级 SMART 日志及故障工单记录。MB1 与 MB2 均为 MLC-SSD，SMART 属性集合相近，故障样本活跃，因此选择作为研究对象。表 3.1 汇总本文实验所用数据集的主要规模与字段统计。

表 3.1 数据集统计

统计项	MB1	MB2
SSD 总数	44 401	48 811
故障工单数（盘级）	1 807	604
年化故障率 AFR	2.52%	0.71%
平均每盘记录数	591.5	635.3
记录数量	26,261,218	31,008,712
空值率	62.79%	64.76%

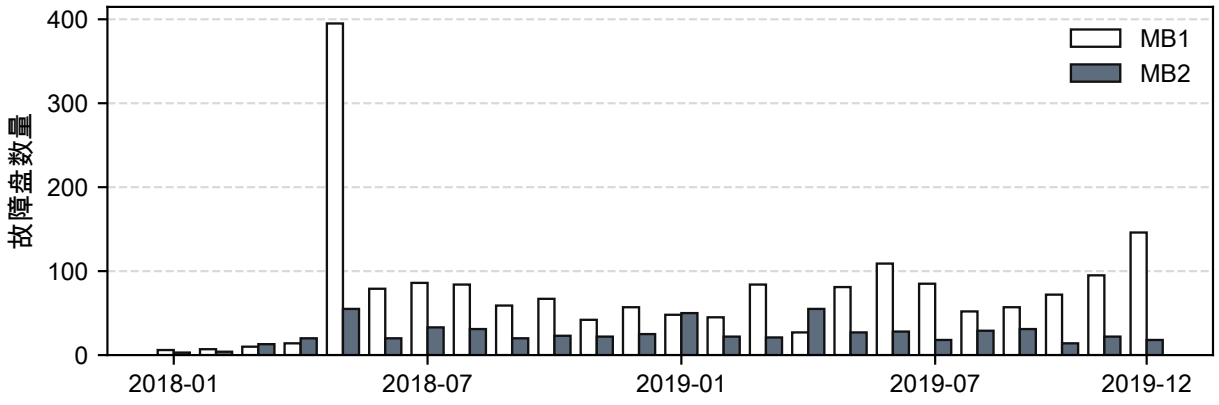


图 3.3 月度故障盘分布

图 3.3 展示了数据集月度故障 SSD 盘数量变化。2018 年 1—4 月两类硬盘故障数量均维持低位，推测因数据集年初批量上线，硬盘服役周期较短、故障风险尚未累积，也存在初期 SMART 采集与工单记录未全覆盖在线磁盘的可能。MB1 在 2018 年 5 月故障量出现峰值，同期 MB2 故障数小幅上涨但增幅有限，或受批次硬盘集中老化失效、运维批量换盘下线等外部因素叠加影响，该月数据无法代表两款硬盘常规故障水平。剔除上线初期低故障区间与 MB1 五月异常峰值后，2018 下半年至 2019 年两类硬盘月度故障数量走势平稳；该时段观测周期充足、每月均产生故障样本，形成完整连续数据序列，适用于本文主体实验的训练与测试区间。

3.2.2 数据预处理与 SMART 属性归纳

阿里云公开日日志中，同一 SMART 属性 ID 往往同时上报原始计数与厂商归一化读数，下文分别记为 r_i 与 n_i。受采集中断、字段未定义等因素影响，部分列在全体样本上恒为空、无变化，或两类读数之间高度单调相关。本文在数据级预处理阶段依次完成字段筛选、缺失补全与机制归纳。

其中字段筛选旨在剔除无效与冗余列，得到稳定、可解释的 SMART 输入，需判断同一属性 ID 下 r_i 与 n_i 是否携带重复信息，如果认为二者信息高度重叠，那么仅保留物理含义更直接的原始读数。本文采用 Spearman 秩相关系数衡量二者的关联强度，Spearman 系数是一种非参数统计量，通过比较两变量取值的秩次刻画关联。具体的来说，设 r_i 与 n_i 在 n 个样本上构成配对观测，第 k 对样本的秩次差为 d_k，则

$$\rho_s = 1 - \frac{6\sum_{k=1}^{n} d_k^2}{n(n^2-1)}. \tag{3-5}$$

ρ_s 取值范围为 $[-1,1]$，$|\rho_s|$ 越大表示单调相关越强。相较常见的 Pearson 相关系数，Spearman 基于秩次计算，不要求线性关系，同时允许空值存在，对厂商归一化可能引入的非线性单调映射更为稳健，因此选择用 Spearman 系数进行原始读数与归一化读数之间的冗余判定。

3.2.2.1 字段筛选

数据集中每条记录除 SSD 盘标识、观测日期与型号外，含 102 列 SMART 读数（51 个属性 ID 各含 r_i、n_i 一列）。然而，如表 3.1 所示，两型号列级空值率分别达 62.79% 与

64.76%，部分属性在全体样本上恒为空、恒为常数，或 r_i 与 n_i 高度单调相关，有效信息密度较低。为此，本文在建模前对 SMART 字段进行列级筛选，剔除无效与冗余读数，以提升输入质量与可解释性。字段筛选分三步进行，各步判定条件与结果汇总如表 3.2 所示；各步剔除的具体读数列及原因见附表 A.1。

第一步于全数据集上剔除恒为空列。若某列在全体样本上缺失，说明该 SMART 属性在公开日志中从未上报，予以删除，两种型号均剔除 34 列。

第二步分别在 MB1、MB2 子集上剔除零方差列。若列中存在非空取值但全体样本仅取同一常数，则认为该列无法提供区分信息，予以删除。两型号因常数列构成略有差异，MB1 剔除 36 列、MB2 剔除 39 列。

第三步于在 MB1、MB2 子集上计算各属性 ID 的 Spearman 系数 ρ_s，取阈值 $|\rho_s| > 0.8$。超过阈值时认为 n_i 可由 r_i 单调导出，剔除 n_i 并保留 r_i；否则 r_i 与 n_i 均保留。按此规则，MB1 剔除 12 列 n_i，MB2 剔除 10 列 n_i。各属性 ρ_s 统计见附表 B.1。

表 3.2 SMART 字段筛选结果

统计项	MB1	MB2
原始 SMART 读数列数	102	102
全空列剔除数	34	34
零方差列剔除数	36	39
r–n 冗余列剔除数（仅 n_i）	12	10
筛选后保留读数列数	20	19
筛选后保留属性 ID 数	16	15

经上述筛选，MB1 保留 16 个属性 ID 共 20 列读数，MB2 保留 15 个属性 ID 共 19 列读数，表 3.5对各属性的中文名称、机制类型进行了整理。其中磨损相关属性 12、180、241、242 的 $|\rho_s|$ 较低，r_i 与 n_i 提供互补信息，故保留两类读数，错误计数与温度类属性多数 $|\rho_s| \approx 1$，仅保留物理含义更直接的 r_i 属性。

3.2.2.2 日历级时序质量分析

除字段的单元格存在空值外，各盘在日历轴上还存在整日 SMART 日志缺失（时序中断），需要在建模前评估时序质量并进行日历集补全与剔除，如图 3.4 所示：

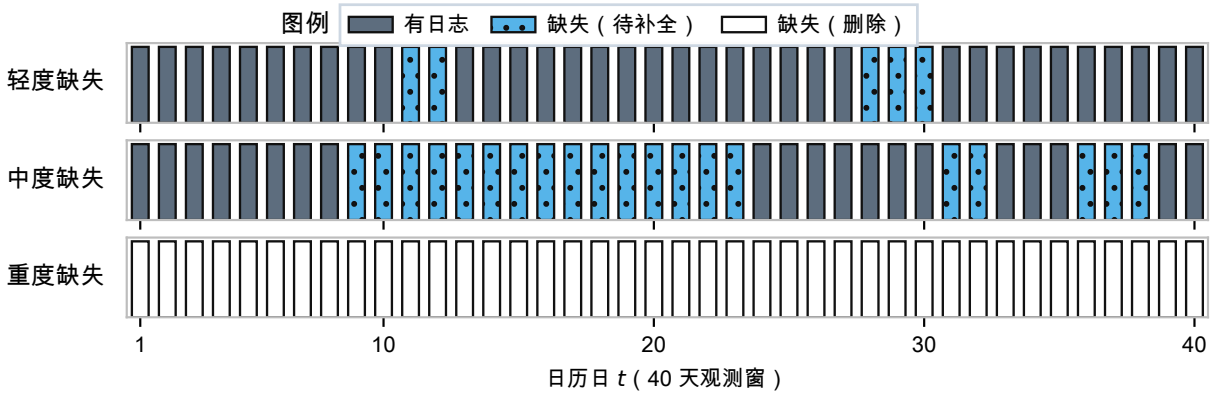


图 3.4 日历缺失补全与剔除示意

对每块盘 i，定义以下盘级指标：首末观测日 $t_{\mathrm{first},i}$、$t_{\mathrm{last},i}$；最长连续缺失天数 $G_{\max,i}$（相邻观测间隔减 1 的最大值）；日历跨度 $\mathrm{span}_i = t_{\mathrm{last},i} - t_{\mathrm{first},i} + 1$；实际观测天数 $n_{\mathrm{obs},i}$ 及覆盖率 $\mathrm{cov}_i = n_{\mathrm{obs},i}/\mathrm{span}_i$；中断次数 $n_{\mathrm{gap},i}$（间隔 >1 天的次数）。其中 $n_{\mathrm{obs},i}$ 刻画有效观测长度，下文将据此设定最小观测日数阈值。依据 $G_{\max,i}$ 与 cov_i，将盘划分为轻、中、重度缺失三档，分别采取前向填充或整盘剔除。

表 3.3 列出了数据集的日历级时序质量汇总，两型号 SSD 缺失形态相近：约 99% 的盘至少出现过一次中断，但 $G_{\max} \le 7$ 天的盘占 63.5%–65.7%，$\mathrm{cov} \ge 0.95$ 的盘占 68%–70%，多数属轻度缺失，可经前向填充继续使用。满足 $G_{\max} > 30$ 或 $\mathrm{cov} < 0.5$ 的重度缺失盘占 13.8%–16.2%，因其观测窗过碎、补全后可靠性不足，拟整盘剔除；中度缺失盘（$8 \le G_{\max} \le 30$）仍予保留。

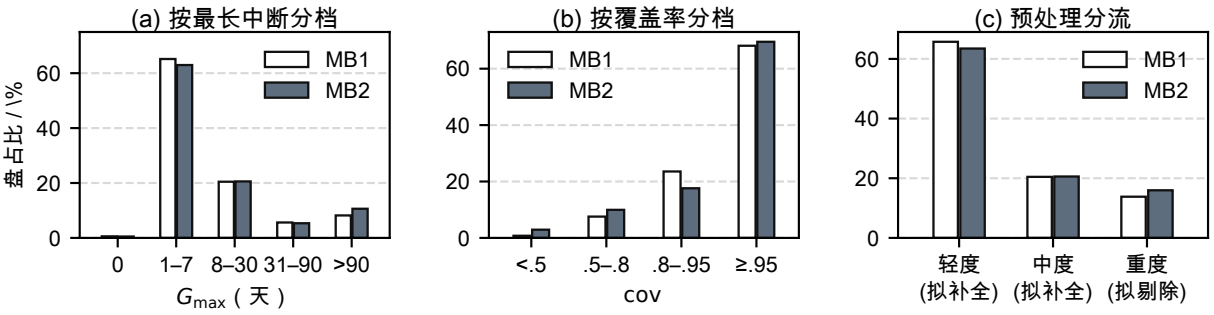


图 3.5 日历缺失分布

图 3.5(a)–(b) 表明 $G_{\max}$ 集中在 1–7 天区间，(c) 的分档占比与表 3.3 一致。需说明的是，高覆盖盘的故障率反而更高（例如 MB1 中 $\mathrm{cov} \geq 0.95$ 段的故障率约 4.8%，而 < 0.95 段仅约 2.5%），这表明盘在失效前的日志往往仍较连续。因此，按 $G_{\max}$ 与 cov 剔除重度缺失盘，其核心依据是可建模性而非故障率；实际上，拟剔除的重度缺失盘仅占 MB1 故障盘的 12.3%、MB2 的 9.3%。

表 3.3 日历时序质量汇总

统计项	MB1	MB2
盘数	44 401	48 811
存在日历中断的盘占比	99.4%	99.5%
平均中断次数 $\overline{n_{\mathrm{gap}}}$	10.7	12.6
平均覆盖率 $\overline{\mathrm{cov}}$	0.929	0.914
覆盖率中位数	0.963	0.966
$G_{\max} \leq 7$ 天盘占比	65.7%	63.5%
$8 \leq G_{\max} \leq 30$ 天盘占比	20.5%	20.6%
$G_{\max} > 30$ 天盘占比	13.8%	16.2%
$\mathrm{cov} \geq 0.95$ 盘占比	68.1%	69.5%
$\mathrm{cov} < 0.5$ 盘占比	0.8%	2.9%

3.2.2.3 建模样本筛选与缺失补全

综合字段筛选与上述时序质量分析，样本级与盘级剔除规则汇总如表 3.4 所示。

盘级剔除依据两类互补条件，第一是有效观测总日数不足，第二是日历缺失比例过高。对盘 i，记其在建模有效区间 $[t_{\mathrm{first},i},\, \min(t_{\mathrm{last},i},\, t_{\mathrm{fail},i})]$（健康盘取 $t_{\mathrm{last},i}$）内的实际有日志天数为 $n_{\mathrm{obs},i}$。本文盘级预测窗口取 $H = 30$ 天，若 $n_{\mathrm{obs},i} < 30$，则难以形成与预警窗口相匹配的时序样本，故将此类盘整盘剔除。对满足 $G_{\max,i} > 30$ 或 $\mathrm{cov}_i < 0.5$ 的重度缺失盘，因其观测窗过碎，前向填充后的时序难以保证标签可靠，故亦整盘剔除。通过上述两项检验后，保留轻度缺失（$G_{\max} \leq 7$）与中度缺失（$8 \leq G_{\max} \leq 30$）盘，并进入补全流程。

原始日志存在上述整日缺失与列级空值，缺失可能由采集中断、设备离线或字段未上报引起。此外，部分故障盘在标注故障日后仍持续上报 SMART 日志（可能是因为盘位未及时更换或标识未回收），此类故障后的观测数据对于预测故障发生并无价值，所以对标注故障盘删除 $d_s > t_{\text{fail}}$ 的样本，仅保留 $d_s <= t_{\text{fail}}$ 的日志。对表 3.4 中保留盘，在 $[t_{\text{first}}, \min(t_{\text{last}}, t_{\text{fail}})]$（健康盘取 t_{last}）上按日历日补全时间轴。

具体的来说，如果 X_{t-1} 存在，那么特征列采用前向填充 $X_t = X_{t-1}$，如果 X_{t-1} 不存在，先在无前值的首行使用该列所有样本的均值填充，再沿时间轴向前填充。

表 3.4 预处理剔除与保留

对象	规则	MB1	MB2
SMART 列	全空 / 零方差 / $\lvert\rho_s\rvert > 0.8$ 冗余 n_i	列级删除	
数据集早期样本	2018 年 5 月及之前时间的样本	样本级删除	
故障后无效样本	故障盘删除 $d_s > t_{\text{fail}}$ 的样本（保留故障日）	样本级删除	
有效观测日数不足盘	$n_{\text{obs},i} < 30$（建模有效区间内）	盘级删除	
重度缺失盘	$G_{\max} > 30$ 或 $\text{cov} < 0.5$	盘级删除	
保留盘数	进入补全与建模	38 812	43 128
保留故障盘	2018–2019 可标注故障	1 132	460

3.2.2.4 SMART 属性机制归纳

经上述筛选后，共保留 16 个有效 SMART 属性 ID、20 列读数（每个 ID 均含原始读数；其中属性 12、180、241、242 另含归一化读数），根据语义将其整理如表 3.5 所示。

依据 SSD 故障机理，属性可概括为两类：（1）为随开机/使用单调累积的磨损与使用量指标（如通电时间、LBA 读写总量等），以及环境类温度读数；（2）其余属性，含错误计数、重映射与备用块等异常/突变类信号，健康盘长期接近 0 或仅缓慢背景变化，失效前常出现突变[4]。因此定义 A 组属性 ID 集合 $\mathcal{A} = \{9, 12, 177, 190, 194, 241, 242\}$，B 组 $\mathcal{B} = \{5, 180, 181, 182, 183, 184, 187, 195, 199\}$（归一化读数 n_i 与其对应 r_i 同组）。

表 3.5 SMART 属性 A/B 分组

ID	中文名称	英文名称	特征类型
A 组			
9	通电时间累计	Power-On Time Count	单调累积
12	通电周期计数	Power Cycle Count	单调累积
177	磨损范围对比值	Wear Range Delta	单调累积
190	气流温度	Airflow Temperature	环境指标
194	温度	Temperature	环境指标
241	LBA 写入总数	Total LBAs Written	单调累积
242	LBA 读取总数	Total LBAs Read	单调累积
B 组			
5	重映射扇区计数	Reallocated Sectors Count	异常/突变
180	未用的备用块计数	Unused Reserved Block Count Total	异常/突变
181	编程失败计数	Program Fail Count	异常/突变
182	擦写失败计数	Erase Fail Count	异常/突变
183	串口降速错误计数	SATA Downshift Error Count	异常/突变
184	点到点错误检测计数	End to End Error Detection Count	异常/突变
187	无法校正的错误	Reported Uncorrectable Errors	异常/突变
195	编程错误块计数	Program Failure block Count	异常/突变
199	Ultra ATA 访问校验错误率	Ultra ATA CRC Error Rate	异常/突变

注：归一化读数 n_i 与其对应 r_i 同组（表中仅列属性 ID）。

3.2.3　故障前兆数据观察

字段筛选与样本预处理后，本节在构建好的数据集上对 B 组属性的故障前时序开展探索性观察。概括而言，故障盘 B 组读数呈现三点规律：(1) 失效前，故障盘 B 组属性常出现显著跳变，与健康盘区分明显；(2) 上述跳变多集中于距故障日较近的短窗口内；(3) 同时，相当比例故障盘在 30 日预警窗内未出现可分辨跳变，前兆信号因而呈现稀疏性与盘间异质性。下文分别从典型盘时序展示、盘级跳变命中率，以及盘级首跳时间与静默盘占比展开分析。

图 3.6、图 3.7 分别在 MB1、MB2 上各选取某一故障月份中的 6 块故障盘，展示其故障前约一个半月内 B 组属性的读数时序；每条曲线对应一块盘的一个 B 组属性，图中虚线标示故障日期。

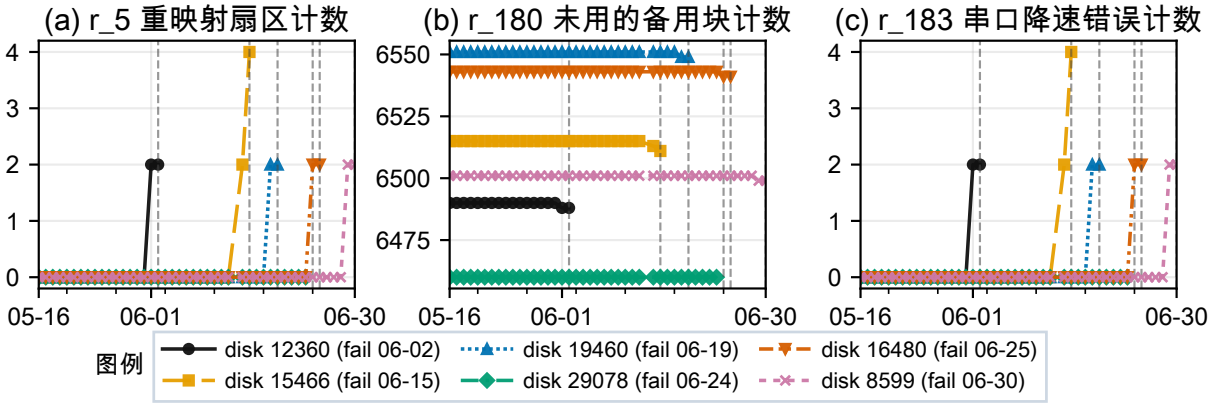


图 3.6 MB1 故障盘 B 组属性时序

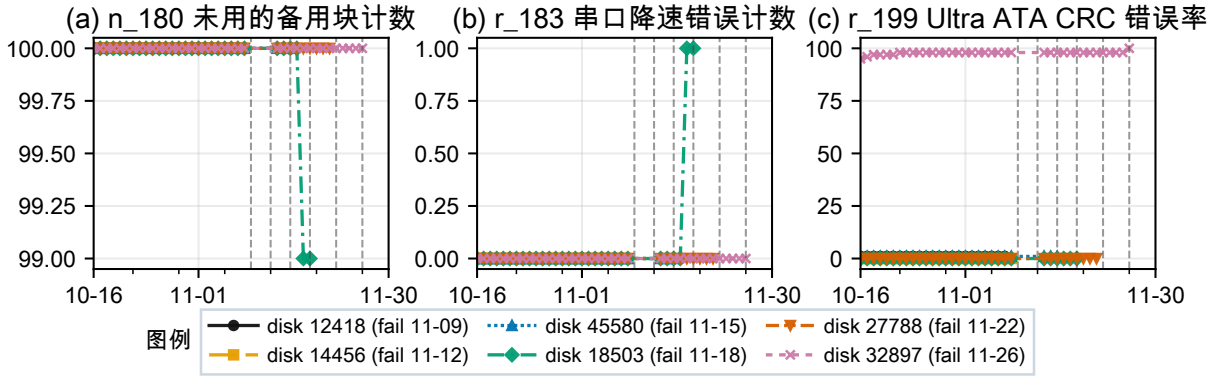


图 3.7 MB2 故障盘 B 组属性时序

由图可知，两类型号均呈现“长期平稳、近端突变”的共性。B 组读数在故障前多保持稳定，其跳变多发生于距故障日数日至数周的短窗口内，与前述第（2）点相符。

MB1 样例中，多数盘在失效前可观察到属性 5、180、183 等信号的阶跃跳变，幅度较健康盘形成明显对照，直观对应第（1）点所描述的显著跳变及较高盘级命中率。

MB2 样例则盘间差异更为突出：仅部分盘在近端出现弱阶跃，其余多块盘在整个展示窗口内读数平坦、未见可分辨突变，不同盘触发的属性与时点亦不一致，呼应第（3）点关于稀疏性与异质性的判断；即便存在跳变的盘，其信号强度整体亦弱于 MB1。

表 3.6 B 组属性跳变命中率

B 组属性	W/天	MB1 故障盘	MB1 健康盘	MB2 故障盘	MB2 健康盘
	7	65.1	0.0	11.8	0.0
5、180、183	30	68.0	0.1	12.5	0.0
	90	72.7	0.1	11.6	0.1
	7	64.7	0.0	11.6	0.0
n_{180}	30	67.4	0.1	12.1	0.0
	90	71.9	0.1	11.1	0.1
	7	0.7	0.0	5.4	0.1
199	30	0.9	0.1	6.6	0.3
	90	1.0	0.1	5.8	0.6

注：于锚点日前 W 日窗口内，相邻原始观测日间 $|\Delta| > 0$ 计为跳变；故障盘锚点为 t_{fail}，健康盘为 t_{last}。属性 5、180、183 在 MB1 上命中率相同，故合并列出。

进一步在盘级统计故障前跳变命中率，如上表 3.6 所示。$W = 30$ 日时，MB1 属性 5/180/183 命中率约 68.0%（健康盘不足 0.1%），MB2 约 12.5%；199 仅 0.9%/6.6% 且健康盘偶有波动，各属性指示能力差异明显。随 W 由 7 日延至 90 日，MB1 主力属性命中率自 65.1% 缓升至 72.7%，增量有限。扩展检索至全部 B 组读数列后，$W = 30$ 日约 69.8%/19.3% 故障盘至少出现一次跳变。

表 3.6 仅能显示故障前是否出现过跳变，不能说明首次跳变距故障日的时间。下文在 $(t_{\text{fail}} - 30,\, t_{\text{fail}}]$ 内对每块故障盘、于全部 B 组属性上检索 $|\Delta| > 0$ 的最早跳变，记观测日为 $t_{\text{first_jump}}$，定义距故障日 $d = t_{\text{fail}} - t_{\text{first_jump}}$（天）；窗口内均无跳变者记为静默故障盘，并以全部故障盘为分母给出 d 的逐日分布，如图 3.8 所示。

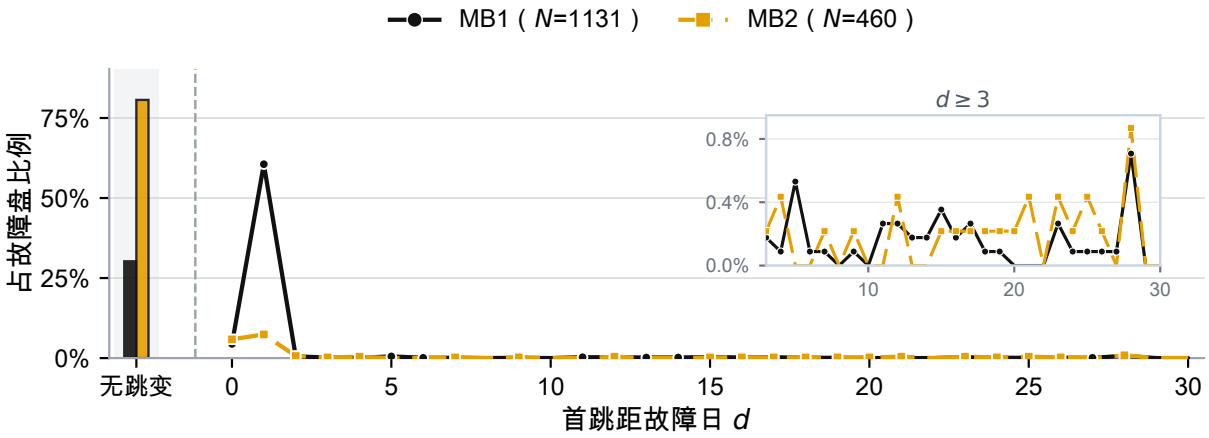


图 3.8 B 组首跳距故障日分布

注：左柱为无跳变占比；折线为有跳变盘的 d 日分布；右上的小图为 $d \geq 3$ 局部放大。

由图 3.8 可见，MB1/MB2 分别有 30.2%/80.7% 为静默故障盘（30 日内 B 组均无 $|\Delta| > 0$）。除静默盘外，$d = 1$ 占比最高（占全部故障盘 60.6%/7.4%），$d \leq 3$ 累计达 65.7%/14.1%，首跳多集中于近故障短窗口；$d > 3$ 后各日占比均低于 1%，远处跳变极为稀疏，支持后续将 k 与 W 取 1–3 日量级。

为区分“预警时间窗口内无信号”与“全盘寿命时间上无信号”，在故障盘上并列统计 $(t_{\text{fail}} - 30, t_{\text{fail}}]$ 与 $(t_{\text{first}}, t_{\text{fail}}]$ 两窗口（后者中位跨度约 340/283 天），如表 3.7 所示：

表 3.7 B 组首跳窗口对比

型号	N	30 日预警窗口 $(t_{\text{fail}} - 30, t_{\text{fail}}]$		全观测期 $(t_{\text{first}}, t_{\text{fail}}]$	
		有跳变	静默	有跳变	静默
MB1	1 131	69.8%	30.2%	76.1%	23.9%
MB2	460	19.3%	80.7%	22.0%	78.0%

表 3.7 表明，MB1 全观测期内 76.1% 故障盘曾有 B 组跳变（30 日内 69.8%），其中 6.4% 仅在全观测期出现首跳，失效前长期维持与健康盘相近的零基线读数；MB2 两窗口结果接近（22.0% vs 19.3%），静默盘占主导，说明该型号前兆整体微弱而非预警窗截断所致。综上，B 组前兆稀疏且盘间差异大且出现在接近故障时刻，相当比例故障盘在 30 日预警窗内缺乏可分辨突变，由此引出下文首跳对齐标签与加权突变特征设计。

3.3　基于异构集成的故障预测模型构建

3.3.1　短期时序突变特征构造

第 3.2.3 节观察表明，B 组属性失效前常按日跳变，且近期跳变与盘级故障关联更强。同时，各 B 组属性健康盘跳变命中率差异显著（表 3.6）：故障相关属性（如 5、180、183）几乎不跳变，少数属性（如 199）偶有波动。借鉴 MSFRD[34] 将稀少突发跳变作为故障相关信号、并依据健康样本跳变频率赋权强调的思路，本文在按日差分基础上为各 B 组属性引入静态稀有权重，抑制常见跳变噪声、突出稀少突变前兆。据此构造短期时序突变特征：以 W 阶 Lag 保留 A/B 组近期读数，对 B 组追加稀有加权按日突变，口径同 3.2.3 节 $|\Delta|>0$ 跳变定义。A 组（$\mathcal{A}$）刻画磨损与环境背景，B 组（$\mathcal{B}$）承载异常计数，突变主要由 B 组加权突变 $\tilde{\delta}$ 编码。

具体的来说，对每块故障盘 i 与原始观测日 t，记属性 k 的读数为 $x_{i,t,k}$，回看窗口 $W\in\mathbb{N}^{+}$ 为待选超参数。对特征属性 $k\in\mathcal{A}\cup\mathcal{B}$ 先构造 Lag 特征 $\ell^{(j)}_{i,t,k}=x_{i,t-j,k}$ $(j=1,\dots,W)$，然后对 $k\in\mathcal{B}$ 先计算按日差分绝对值

$$\delta_{i,t,k}=\left|x_{i,t,k}-x_{i,t-1,k}\right|, \tag{3-6}$$

再在每轮实验的训练集健康样本 $\mathcal{H}_{\mathrm{tr}}$ 上统计属性 k 的跳变频率

$$\hat{f}_k=\frac{1}{|\mathcal{H}_{\mathrm{tr}}|}\sum_{(i,t)\in\mathcal{H}_{\mathrm{tr}}}\operatorname{sgn}(\delta_{i,t,k}), \tag{3-7}$$

并定义静态稀有权重

$$r_k=-\log\left(\hat{f}_k+\varepsilon\right), \tag{3-8}$$

其中 $\operatorname{sgn}(\cdot)$ 为符号函数，$\varepsilon>0$ 为平滑常数，本文取 $\varepsilon=10^{-10}$。r_k 仅随属性 k 变化，其数值越大，表示该属性在健康盘上的跳变越稀少，对 $k\in\mathcal{B}$ 构造稀有加权突变特征

$$\tilde{\delta}_{i,t,k}=r_k\cdot\delta_{i,t,k}, \tag{3-9}$$

$\tilde{\delta}_{i,t,k}$ 随样本而变，无跳变时 $\delta_{i,t,k}=0$ 故 $\tilde{\delta}_{i,t,k}=0$。当稀少属性出现跳变时，$\tilde{\delta}_{i,t,k}$ 被放大，从而在特征空间中更为突出。每轮实验在训练月份的健康样本上估计 $\{r_k\}$ 后固定用于该轮验证与测试，不使用故障样本或测试集信息。每个 (i,t) 样本的特征由 Lag 与 $\{\tilde{\delta}_{i,t,k}\}_{k\in\mathcal{B}}$ 拼接，共 $|\mathcal{A}|W+|\mathcal{B}|(W+1)$ 维。W 控制 Lag 回看的日历长度，过小则上下文不足，过大则远早读数与近端失效关联减弱，通过实验确定最优 W。

3.3.2　混合标签降噪策略设计

在第 3.2.3 节中的观察表明，部分故障盘存在静默故障问题：这些故障盘在预警时间窗口内的 B 组特征长期保持不变，直到临近故障才会产生跳变，甚至故障发生后也不会产生跳变。这类静默故障盘难以与正常运行的盘区分，将它们的样本标记为正样本可能会引入标签噪声，导致模型将健康样本误判为故障样本的风险增加。为了保留失效前变化信息的同时减少噪声带来的风险，本文提出一种将固定窗口标签与首次跳变观测标签取交集的混合标记策略。图 3.9 给出了固定长窗、固定短窗、故障当日窗口、首跳窗口与本文混合标记策略的直观示意。

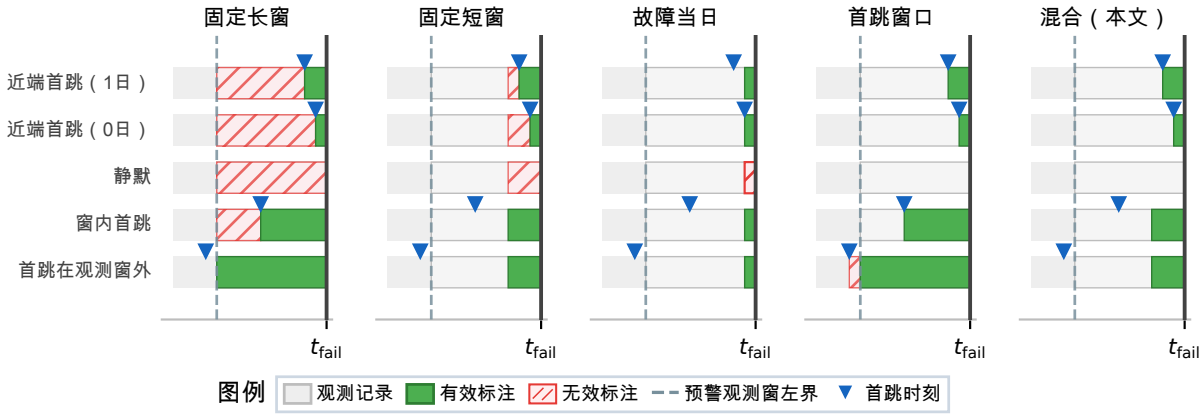


图 3.9 不同标签策略示意图

注：固定窗口从左至右为全长窗、k=3 短窗及 k=0 故障当日；绿色为有效正例，斜线填充为无效正例。

固定窗口标记是一种常用的标记策略，具体的来说，对故障盘 i，记故障日为 $t_{\text{fail},i}$，回看窗口长度 k，定义：

$$y_{i,t}^{\text{fix}} = \begin{cases} 1, & t_{\text{fail},i} - k \le t \le t_{\text{fail},i}, \\ 0, & \text{其余}. \end{cases} \tag{3-10}$$

对健康盘，该策略恒为 0。当 $k = 0$ 时，式 (3-10) 退化为故障当日窗口。该策略实现简单、几乎不引入静默段误标，但正例极为稀疏，且无法利用首跳至故障前数日的征兆信息，对静默故障盘虽可在故障日标正，却几乎不提供可学习的提前预警样本。将 k 增大至故障前短窗，则可在保留近端失效变化的同时扩大正例规模，但无法将首跳前的静默段从正类中剥离，亦无法排除静默故障盘。

首次跳变观测标签以第 3.2.3 节的首跳观测为界，仅在样本已出现 B 组可分辨跳变前兆之后标为正例，从而将预警窗内首跳前的零基线段标为负例。跳变口径与式 (3-6) 一致，在相邻原始观测日间，若存在特征属性 $k \in \mathcal{B}$ 使 $\delta_{i,t,k} > 0$，则 t 为跳变日，对故障盘 i，于预警窗 $(t_{\text{fail},i} - 30,\, t_{\text{fail},i}]$ 内取最早跳变日

$$t_{\text{jump},i} = \min\left\{t :\, \exists k \in \mathcal{B},\, \delta_{i,t,k} > 0,\, t_{\text{fail},i} - 30 < t \le t_{\text{fail},i}\right\}. \tag{3-11}$$

对存在最早跳变日 $t_{\text{jump},i}$ 的故障盘 i，定义首次跳变观测标签为：

$$y_{i,t}^{\text{jump}} = \begin{cases} 1, & t_{\text{jump},i} \le t \le t_{\text{fail},i}, \\ 0, & t_{\text{fail},i} - 30 \le t < t_{\text{jump},i}. \end{cases} \tag{3-12}$$

对不存在跳变日的故障盘 i 与健康盘，该标签恒为 0。

固定窗口与首次跳变观测混合标记对上述两种标注取逻辑与，也就是仅当样本同时处于故障前 k 日短窗且已观测到 B 组首跳时标为正例，即

$$y_{i,t} = y_{i,t}^{\text{fix}} \cdot y_{i,t}^{\text{jump}}, \tag{3-13}$$

有首跳盘的有效正样本区间为 $[\max(t_{\text{jump},i},\, t_{\text{fail},i} - k),\, t_{\text{fail},i}]$，其余首跳前的样本与健康盘的样本恒为 0。

这种标记策略在捕捉图 3.6 与图 3.7 所示故障盘失效前变化的同时，减少无跳变样本对模型的干扰。

3.3.3　异构集成预测

盘级故障预测中正负样本极度不平衡，不同的分类器对稀疏突变信号的拟合偏好存在差异，单一学习器易出现判别不稳定。为此，本文在 §3.3.1 所构造的短期时序突变特征上采用两层 stacking，第一层训练多种异构基分类器并输出故障概率，第二层以注意力机制对基分类器概率做样本级自适应加权融合，优化目标采用 Focal Loss 以强化对少数类故障样本的关注。整体结构如图 3.10 所示。

对于异构基分类器训练，设样本 (i,t) 的短期时序突变特征向量为 $\mathbf{z}_{i,t} \in \mathbb{R}^{16W+9}$（由 Lag 特征与式 (3-9) 拼接而成），标签为 $y_{i,t} \in \{0,1\}$。设异构基分类器集合 $\mathcal{M} = \{M_m\}_{m=1}^{N}$，其中 $N \ge 2$ 为基学习器数量，M_m 可取 Bagging 族、梯度提升树等不同归纳偏置的学习器，在 $\mathbf{z}_{i,t}$ 上分别训练各 M_m。因划分准则、集成方式与优化目标各异，各基分类器对同

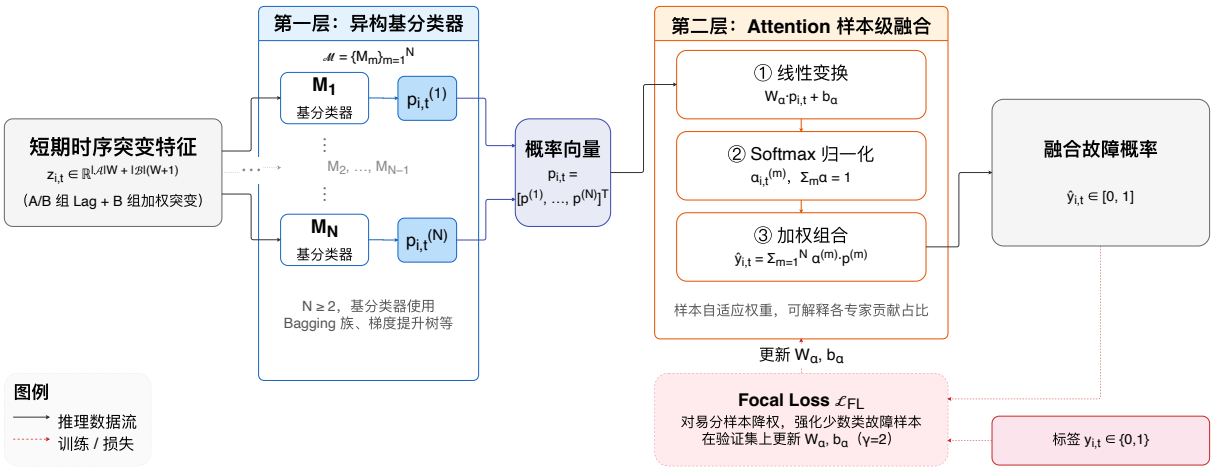


图 3.10 异构集成结构示意

一突变特征可形成不同的样本级判别边界。在验证月份上，各基分类器对样本 (i,t) 输出故障概率

$$p_{i,t}^{(m)} = M_m(\mathbf{z}_{i,t}), \quad m = 1, \ldots, N, \tag{3-14}$$

拼接为基分类器概率向量 $\mathbf{p}_{i,t} = [p_{i,t}^{(1)}, \ldots, p_{i,t}^{(N)}]^{\mathsf{T}} \in \mathbb{R}^N$。融合模块不再直接接触原始 SMART 特征，而仅利用各基分类器已提炼的故障倾向信息。

对于模型融合，将 $\mathcal{M}$ 中 N 个基分类器视作 N 个专家，以 $\mathbf{p}_{i,t}$ 为查询上下文，为各专家分配样本自适应权重：

$$(\alpha_{i,t}^{(1)}, \ldots, \alpha_{i,t}^{(N)})^{\mathsf{T}} = \mathrm{softmax}(W_\alpha \mathbf{p}_{i,t} + \mathbf{b}_\alpha), \tag{3-15}$$

其中 $W_\alpha \in \mathbb{R}^{N\times N}$、$\mathbf{b}_\alpha \in \mathbb{R}^N$ 为待学习参数，$\mathrm{softmax}(\cdot)$ 按元素归一化使 $\sum_{m=1}^{N} \alpha_{i,t}^{(m)} = 1$。样本级融合概率取专家概率的组合：

$$\hat{y}_{i,t} = \sum_{m=1}^{N} \alpha_{i,t}^{(m)}\, p_{i,t}^{(m)}. \tag{3-16}$$

式 (3-16) 保证 $\hat{y}_{i,t} \in [0,1]$；权重 $\alpha_{i,t}^{(m)}$ 可直接解释各基分类器对当前样本的贡献占比，相较固定平均或 MLP 黑箱映射更具可解释性。训练时以 Focal Loss 替代标准交叉熵，对易分样本降权、对难分故障样本赋更高梯度：

$$\mathcal{L}_{\mathrm{FL}} = -\alpha_t (1-p_t)^{\gamma} \log p_t, \quad p_t = \begin{cases} \hat{y}_{i,t}, & y_{i,t} = 1 \\ 1-\hat{y}_{i,t}, & y_{i,t} = 0 \end{cases} \tag{3-17}$$

其中 α_t 为类别平衡权重（正类取 0.75、负类取 0.25），$\gamma \geq 0$ 为聚焦参数（本文取 $\gamma = 2$）。在验证集样本上最小化 $\sum_{(i,t)} \mathcal{L}_{\mathrm{FL}}$ 以更新融合模型参数。

3.4　实验设置与结果分析

3.4.1　实验设置与对比方法

3.4.1.1 数据集划分

实验在预处理后的 MB1、MB2 子集上进行。因为 SSD 故障预测属于时序预测任务，随机划分会产生时间泄露，模型提前获取未来日志，线上部署失效，所以采用滚动训练 / 验证 / 测试完全复现真实运维时序数据流。

数据集按月做时间顺序划分，训练窗自 2018 年 6 月（剔除入池早期样本后的首个可用月）起算；月份以 2018 年 1 月为第 1 月编号。采用三轮划分，每轮以连续训练月份拟合模型、以紧邻 1 个月为验证集、再之后 1 个月为测试集（例如第 1 轮对应日历约为训练 2018 年 6 月至 2019 年 7 月、验证 2019 年 8 月、测试 2019 年 9 月），具体如表 3.8 所示。各轮测试集时间不重叠，三轮测试集上的盘级指标取算术平均作为最终结果。

表 3.8 数据集时间划分

轮次	训练集（月）	验证集（月）	测试集（月）
1	6–19	20	21
2	6–20	21	22
3	6–21	22	23

3.4.1.2 训练与评估流程

在表 3.8 所示三轮划分下，MB1 与 MB2 分别独立开展实验。每轮先在训练月份上构造混合标注与短期时序突变特征，其中稀有权重 $\{r_k\}$ 仅由该轮训练月健康样本估计，并固定用于同轮验证与测试，不使用故障样本或测试集信息。

本文方法每轮实验流程如下：（1）在训练月份上拟合 RF、XGB、LGB 三个基分类器；（2）在验证月份上计算各基分类器输出的样本级故障概率 $\mathbf{p}_{i,t}$，使用 Focal Loss 训练融合模块，并在验证集上扫描样本级分类阈值，按盘级聚合后选取使 $F_{0.5}$ 最优的阈值；（3）将训练集与验证集合并后重训各基分类器，对测试月份推理并经模型融合得到最终输出。验证月份不参与基分类器训练，其概率仅用于融合模块拟合与阈值选取。超

参数 (W, k) 的网格选取同样仅依据各轮验证月盘级 $F_{0.5}$（三轮算术平均），测试月不参与任何超参或阈值选择，仅用于最终评价。

盘级评估指标采用 TPR、FPR、Precision 与 $F_{0.5}$。测试月评估盘取该月出现过的盘。对各方法，若某日因历史窗不足等无法构造有效特征，则不参与推理、不告警；若整盘在测试月均无有效特征，盘级视为未预警，等价于将该盘预测为健康盘。

主实验统一采用混合标注与 Lag+$r_k|\Delta|$ 完整突变特征；标签策略与突变特征消融在固定其余设定下替换单一组件，样本级阈值取 0.5。异构集成消融中将集成输出与 RF、XGB、LGB 单基结果对比时，单基学习器省略集成融合步骤，仅在验证集上调整参数。

3.4.1.3 对比模型介绍

为全面评估所提方法的性能，本文将其与一系列基线方法进行了对比，这些基线涵盖启发式规则、无监督学习模型、传统机器学习模型、深度学习模型和集成模型。

- Mut-Rule：启发式规则基线，口径同 3.2.3 节：在非补全的相邻原始观测日上，若任一 B 组属性满足 $|\Delta| > 0$，则将该日判为告警；盘级取测试月内最早告警日；该基线不训练模型，用于量化“仅凭跳变告警”在低误报约束下的上限与代价。
- RF[4]：采用 30 日固定窗口标签，对 SMART 数据构造 7 天 / 3 天时间窗口内的统计特征，使用 XGBoost 进行特征筛选（MB1 保留 28%、MB2 保留 26%）去除冗余特征，使用随机森林模型作为分类器进行故障预测。
- AE[37]：无监督设定下，仅以训练月内健康盘当日 16 维 SMART 为输入，故障盘整盘剔除，在训练样本上 StandardScaler 标准化后，采用 MLP 自编码器（50→25→25→50，tanh），以 MSE 重构损失与 Adam 优化（100 epoch，patience=5）学习正常模式。
- TCAN[33]：采用故障当日标签与 10 日 SMART 序列输入，190/194 为波动组、其余为单调组；对训练集 1:100 降采样后 Min-Max 归一化，使用 TCAN（LSTM–Transformer 交叉注意力 + 特征分组，BCE，Adam，100 epoch）进行训练。
- MVT-RF[26]：采用 30 日固定窗口标签，对 SMART 原始读数构造序列相关与直方图多视图特征，并拼接为组合特征。对原始特征、序列特征、直方图特征和组合特征分别进行特征筛选（原始特征不进行）并训练随机森林模型，使用得到的四个随机森林投票得出故障预测结果。
- Mut-RF[34]：采用 30 日固定窗口标签，以健康盘的回看 7 日 SMART 时序作为模

型输入；先训练 Informer 时序预测骨干：输入 7 日观测序列预测未来 3 日 SMART 指标，使用 Adam 优化器、MSFRD 加权稀有损失训练，最大迭代 100 轮、早停阈值 patience= 5；训练完成后，基于加权残差计算突变稀有度分数（对预测残差平方加权属性稀有权重并增加稀有正则项），再提取连续 10 阶滞后突变分数构成输入特征集，送入随机森林完成盘故障判别。

上述文献方法多在私有数据集上验证，且尚未见与本文实验设定完全一致的公开实现。为此，使用与本文一致的数据预处理得到的特征、时间划分与盘级指标口径下，对 Mut-Rule 启发式规则以及 Xu 式 RF 对照、MVT-RF、AE、TCAN 与 Mut-RF 等文献方法进行了复现。其中 Mut-RF 分为 Informer 时序训练与随机森林分类两步：Informer 大规模时序推理依赖云端 vGPU 加速，后续随机森林训练、其余基线（Mut-Rule/RF/AE/TCAN/MVT-RF）全部在 Apple M2 芯片、16GB 内存 MacBook Air 上完成，代码统一基于 Python 3.9.6 实现。

3.4.2　关键超参数 W 与 k 的选取

前述方法含两个相互耦合的超参数：回看窗口 W 决定 Lag 与 $\tilde{\delta}$ 突变特征所覆盖的近期观测长度（§3.3.1），标注短窗 k 则通过式 (3-13) 将正样本限制于故障前 k 日与 B 组首跳对齐的交集区间。二者分别作用于特征编码与监督信号构造，其取值宜与盘级 30 日评估窗口及 B 组首跳时间尺度（图 3.8，$d \leq 3$ 累计占 65.7%）同阶匹配。在报告与文献基线方法的对比及后续消融实验之前，本节先在 MB1/MB2 上联合搜索 (W, k)，并为各型号确定主实验配置 (W^*, k^*)。超参数 (W, k) 仅依据各轮验证月上的盘级 $F_{0.5}$（三轮算术平均）选取；分类阈值仍在验证集上扫描。测试月不参与任何超参或阈值选择，仅用于最终评价。图 3.11 给出验证集网格整体分布，表 3.9 列出各格数值便于核对。

结合图 3.11 与表 3.9，就 W 而言，W=0 时 Lag 特征退化为空，输入仅含 B 组按日差分。MB1 在该行 k=0 与 k=2 上验证集 $F_{0.5}$ 仅为 0.059 与 0.081，明显低于 $W \geq 1$ 区域；其中 k=2 格上，RF、XGB、LightGBM 与 Attention 集成的三轮平均盘级 $F_{0.5}$ 在验证集上分别为 0.878、0.871、0.041 与 0.081，在测试集上分别为 0.873、0.867、0.011 与 0.077。可见稀疏跳变仍可被 RF 与 XGB 利用，低谷主要由 LightGBM 失效并牵连集成所致，这可能与类别极不平衡下 boosting 对难例过敏感有关。$W \geq 1$ 引入 Lag 后该低谷消失。MB1 在 W=1–3 且 $k \geq 1$ 时 $F_{0.5}$ 均在 0.90 以上，W=1 达到最优 0.918；MB2 在

表 3.9 W–k **验证集网格搜索结果（盘级** $F_{0.5}$**）**

	MB1					MB2			
$W\backslash k$	k=0	k=1	k=2	k=3	k=4	k=0	k=1	k=2	k=3
0	0.059	0.412	0.081	0.588	0.881	0.354	0.565	0.565	0.565
1	0.806	**0.918**	**0.918**	0.912	**0.914**	0.471	**0.592**	0.592	**0.603**
2	0.895	0.917	0.906	**0.917**	0.910	**0.500**	0.581	**0.603**	**0.603**
3	**0.908**	0.914	0.914	0.906	**0.914**	**0.500**	**0.592**	0.526	0.592

注：加粗与下划线分别表示该列最大与次大值。

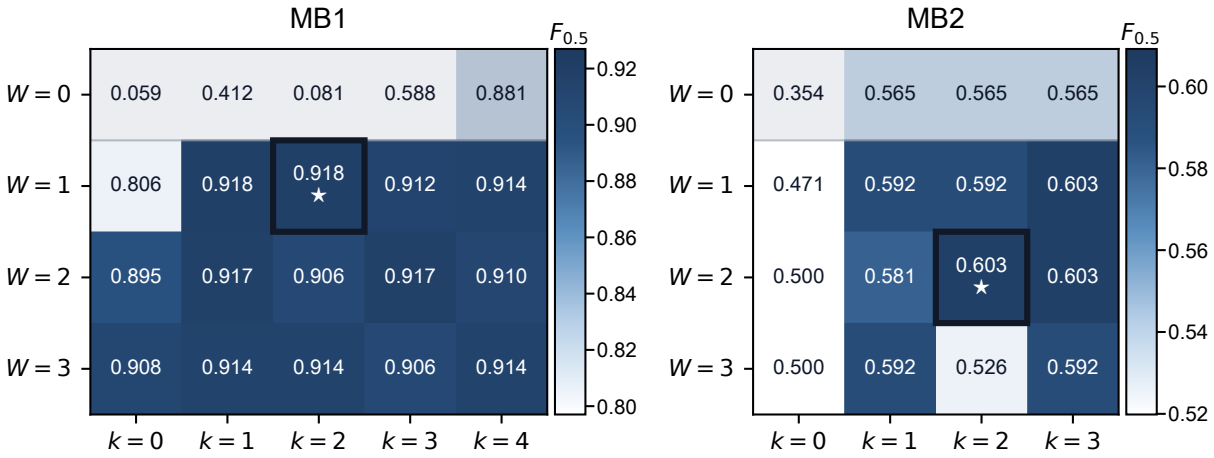


图 3.11 W–k **验证集网格搜索的盘级** $F_{0.5}$ **热力图**

注：左、右分别为 MB1 与 MB2；W=0 行（灰底）表示 Lag 特征退化情形，色深聚焦 $W\geq 1$ 主搜索区；加粗框与星标为各型号选取的最优格 (W^*, k^*)。

W=0、$k\geq$1 时可达 0.565，最优区落在 W=1–2，峰值为 0.603。两型号最优 W^* 分别为 1 日与 2 日，与图 3.8 中 B 组首跳多集中于故障前 1–2 日的观察一致。

就 k 而言，k=0 在两型号上均明显落后。以 MB1 的 W=1 行为例，验证集 TPR 仅为 0.481；将 k 扩至 1–2 日后 TPR 升至 0.743、$F_{0.5}$ 升至 0.918，再增至 k=3–4 时 TPR 基本不再提高。检出能力在短窗内迅速抬升并趋于平台，与图 3.8 中首跳多集中于故障前数日、$d \leq 3$ 累计占 65.7% 的统计相符。MB1 上 $(1,1)$ 与 $(1,2)$ 的验证集 $F_{0.5}$ 同为 0.918、TPR 同为 0.743，本文取 k^*=2，以便在验证集指标持平的条件下保留更多近端正例。MB2 上 $(2,2)$、$(1,3)$ 与 $(2,3)$ 同为 0.603，本文取 k^*=2，使主配置落在与 W^* 配套的 $(2,2)$。

综合两维搜索，按验证集盘级 $F_{0.5}$ 确定 MB1 主配置为 W^*=1、k^*=2，MB2 为 W^*=2、k^*=2，最优格均落在 $W\geq$1 的稳定区域。后续主结果、消融与提前量分析均固定上述配置，并在测试集上报告最终性能。

3.4.3　模型整体效果的验证与分析

在 §3.4.2 确定各型号最优 (W^*, k^*) 后，本节将本文异构集成与 Mut-Rule 及文献复现基线进行对比，采用盘级 TPR、FPR、Precision 与 $F_{0.5}$ 四项指标评估。三轮平均结果见表 3.10、3.11 与图 3.12；各轮次 TP/FP 与分项明细见附表 C.1、C.2。其中除 FPR 外均保留三位小数，FPR 以科学计数法表示；加粗与下划线分别表示同列最优与次优。

表 3.10 MB1 三轮平均盘级性能对比

方法	TPR	FPR	Precision	$F_{0.5}$
本文方法	0.733	$\underline{2.71 \times 10^{-5}}$	**0.981**	**0.919**
Mut-Rule	**0.777**	1.07×10^{-3}	0.564	0.595
RF	0.765	1.18×10^{-4}	0.935	0.895
AE	0.038	1.34×10^{-3}	0.043	0.042
TCAN	0.000	**0**	0.000	0.000
MVT-RF	$\underline{0.769}$	4.53×10^{-5}	$\underline{0.967}$	**0.919**
Mut-RF	0.020	3.63×10^{-5}	0.500	0.086

注：加粗与下划线分别表示同列最优与次优；FPR 并列最优时均可加粗。

表 3.11 MB2 三轮平均盘级性能对比

方法	TPR	FPR	Precision	$F_{0.5}$
本文方法	0.187	**0**	**1.000**	**0.490**
Mut-Rule	**0.271**	3.40×10^{-3}	0.031	0.037
RF	0.079	8.14×10^{-6}	0.500	0.240
AE	0.112	1.90×10^{-3}	0.022	0.026
TCAN	0.000	**0**	0.000	0.000
MVT-RF	0.143	**0**	**1.000**	0.412
Mut-RF	0.000	**0**	0.000	0.000

注：加粗与下划线分别表示同列最优与次优；FPR 并列最优时均可加粗。

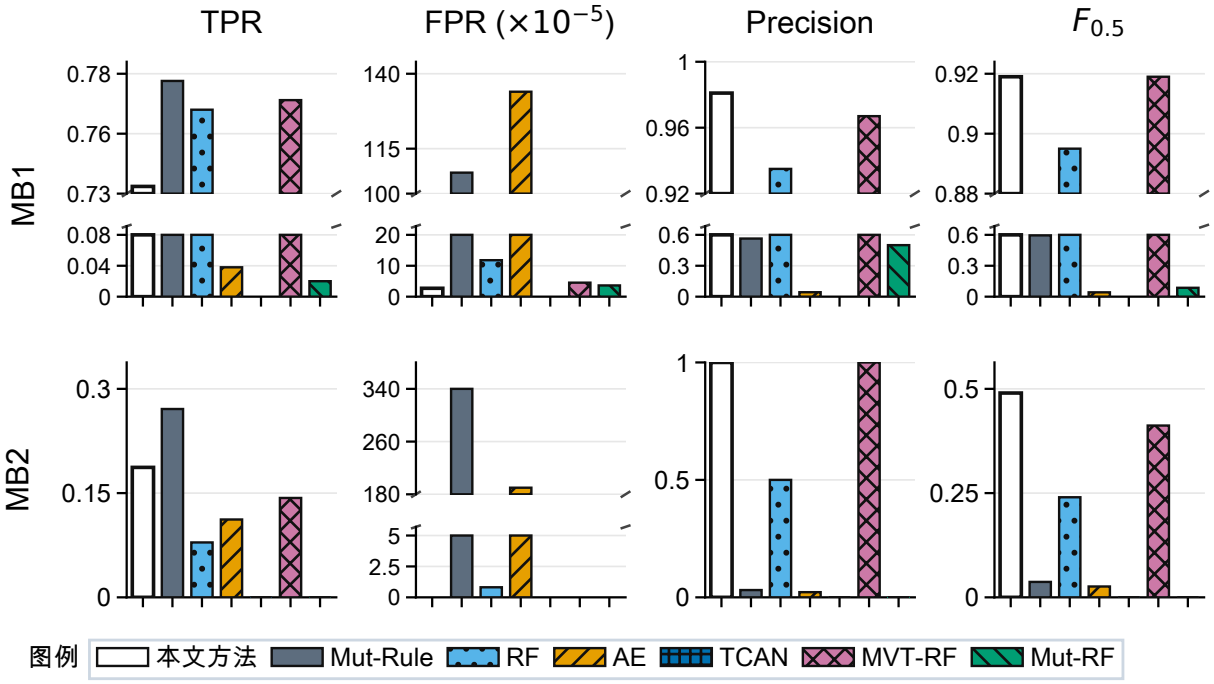


图 3.12 三轮平均的 MB1/MB2 盘级基线性能对比

注：上、下两行分别为 MB1 与 MB2；各子图 y 轴含义由列标题给出，其中 FPR 纵轴刻度为 $\times 10^{-5}$（读数需乘以 10^{-5}）；部分子图采用断轴以同时展示高低值差异。

通过比较本文提出模型与基准模型在测试集上所得出的结果，可以得到以下结论。

Mut-Rule 将 B 组任一原始跳变直接视为告警，能够捕获第 3.2.3 节所述近端突变前兆：MB1 三轮平均 TPR 达 0.777，甚至略高于本文方法与 MVT-RF；MB2 平均 TPR 亦为各方法最高（0.271）。然而健康盘上属性 199 等偶发波动同样触发规则，FPR 分别升至 1.07×10^{-3} 与 3.40×10^{-3}，较本文方法高约两个数量级，Precision 与 $F_{0.5}$ 随之显著下降（MB1 0.595、MB2 0.037）。这表明“有跳变即可预警”虽能抬高召回，但无法满足数据中心低误报约束，也说明后续稀有加权与监督学习并非冗余。

Xu 式 RF 对照在 3 日与 7 日自然日窗上为各 SMART 读数构造统计量，经 XGB 筛选后实际输入维数为 MB1 62 维、MB2 54 维，长于本文 W=1/2 的短期 Lag 与 $r_k|\Delta|$ 表征（25/41 维）。在 MB1 上其 TPR 略高于本文方法（0.765 vs. 0.733），但 FPR 高了一个数量级（1.18×10^{-4} vs. 2.71×10^{-5}），导致盘级 $F_{0.5}$ 相对略低（0.895 vs. 0.919），实验表明，虽然更长的时间窗口与更丰富的统计特征有助于提升故障盘的检出率，但也增加了将健康盘背景波动误判为前兆的风险，导致在盘级评估中误报代价显著增加。

AE 无监督不使用故障标签，无法学习故障专属时序模式，误报极高。AE 为无监督设定，训练阶段不使用故障标签，输入仅为单日 16 维原始读数，模型无法从标注中学习故障前窗口与 SMART 模式的对应关系，此外，异常分数由逐样本重构均方误差给出，对各属性等权计分，而 SMART 退化往往体现为少数属性的缓变或稀少跳变，关键信号易被背景噪声淹没，再经盘级规则取 30 日内最早超阈值告警，样本级误判在盘级评估中被进一步放大，故 AE 在 MB1/MB2 上 TPR 与 $F_{0.5}$ 均明显偏低。

TCAN 仅故障当日标注，正样本极度不平衡，模型偏向全健康判别。TCAN 采用故障当日标签与 10 日 SMART 序列输入，训练时对健康盘约 1:100 降采样，以 BCE 优化且未对正类加权，负类梯度主导下模型倾向于将全部样本判为低风险，样本级概率普遍低于判定阈值 0.5，故盘级评估中健康盘与故障盘均未触发告警，MB1/MB2 上 TPR 与 FPR 均为 0。此外，监督正例仅落在故障日当天，相对其他标签策略得到的正样本更为稀疏，模型难以有效学习故障前兆。

MVT-RF 多视图长时序特征引入静默噪声，误报率高于本文方法。MVT-RF 使用了时序、直方图、序列等多种特征，集成 4 个随机森林模型投票，挖掘出了更多的故障信息，在 MB1 上其 TPR 略高于本文方法（0.769 vs. 0.733），但 FPR 更高（4.53×10^{-5} vs. 2.71×10^{-5}），Precision 也略低于本文方法（0.967 vs. 0.981）；盘级 $F_{0.5}$ 与本文方法并列

最优。本文在综合指标持平的同时误报更少、精确率更高，更符合低误报的工程需求。

Mut-RF 采用 30 日固定窗口标签，以健康盘的 7 日 SMART 时序送入 Informer 预测未来 3 日指标，依托稀有权重计算突变分数，截取连续 10 阶滞后突变特征送入随机森林完成判别。突变分数对业务周期波动与故障短时跳变不加区分，无法针对退化指标赋予差异化权重，特征内有效故障信息占比极低。MB1 三轮平均 TPR 仅 0.020，MB2 无任何故障检出，尽管 FPR 维持较低水平，但极低检出率使其无法完成 SSD 盘提前预警，稀有权重计算突变分数难以剥离平稳噪声、捕获早期微弱异常。

综合两套数据集三轮平均结果，本文异构集成方法在 MB1 上与 MVT-RF 的盘级 $F_{0.5}$ 并列最优，并以更低 FPR、更高 Precision 形成区分；在 MB2 上取得最优 $F_{0.5}$。整体上，方法在控制误报的同时兼顾故障检出，综合盘级预警效果优于其余对比基线。

3.4.4　突变时序特征有效性分析

为了表明本文提出的突变时序特征的有效性，本节对比 §3.3.1 所定义的完整短期时序突变特征（Lag+$r_k|\Delta|$，本文方法）与两类消融基线：单 Lag（仅保留 A/B 组 W 阶 Lag 读数，不引入 B 组按日差分）与单 $r_k|\Delta|$（仅保留 B 组稀有加权差分，不引入 Lag 读数）。前者仅编码近期 SMART 读数水平，后者仅编码按日突变强度，二者均缺少另一路信息，结果见表 3.12，表中报告的指标为 $F_{0.5}$ / TPR / Precision。

表 3.12 突变特征消融实验

型号	轮次	完整特征	单 Lag	单突变特征
MB1	R1	**0.947**/**0.783**/1.000	0.785/0.422/1.000	0.102/0.022/1.000
	R2	**0.895**/**0.708**/0.958	0.795/0.492/0.939	0.075/0.016/1.000
	R3	**0.914**/**0.710**/0.985	0.848/0.551/0.980	0.054/0.011/1.000
	平均	**0.919**/**0.733**/0.981	0.809/0.488/0.973	0.077/0.016/1.000
MB2	R1	**0.686**/**0.304**/1.000	0.192/0.045/1.000	**0.686**/**0.304**/1.000
	R2	**0.556**/0.200/1.000	0.000/0.000/0.000	**0.556**/0.200/1.000
	R3	**0.227**/**0.056**/1.000	0.000/0.000/0.000	0.192/**0.056**/0.500
	平均	**0.490**/**0.187**/1.000	0.064/0.015/0.333	0.478/**0.187**/0.833

表 3.12 表明，三类配置的精确率均较高且彼此差异有限，因此 $F_{0.5}$ 的变化主要来自 TPR 的不同，增益源于对故障征兆的更有效识别。

在 MB1 上，完整特征均值 0.919/0.733 优于单 Lag 的 0.809/0.488 与单 $r_k|\Delta|$ 的 0.077/0.016。单 Lag 仅编码近期读数水平，为次优；单 $r_k|\Delta|$ 在 k=2 短窗下几乎失效，情形与 §3.4.2 中 W=0、k=2 的低谷相近，说明缺少水平上下文时仅靠突变通道难以支撑稳定预警，完整“水平 + 变化”拼接更为必要。

在 MB2 上，R1/R2 完整配置与单 $r_k|\Delta|$ 完全相同，单 Lag 均值仅 0.064/0.015。该型号前兆稀疏、读数长期平坦，突变通道已承载主要判别信号；完整均值 0.490/0.187 仍略优于单 $r_k|\Delta|$ 的 0.478/0.187，Lag 仍有边际补充。

综上所述，Lag 与 $r_k|\Delta|$ 联合构造在 MB1 上显著优于任一路单独使用；在 MB2 上以突变通道为主，完整拼接仍保持最优或持平，验证了 §3.3.1 的特征设计。

3.4.5　标签策略有效性分析

为验证 §3.3.2 所提混合标注策略的有效性，本节仅替换训练标签，其余设定不变。四种对照分别对应不同监督偏置：首跳标记保留跳变后的全部正例，监督区间偏宽；故障当日标记正例极度稀疏；3 日固定短窗扩大近端正例，但未剥离首跳前静默段；30 日固定长窗进一步引入远端噪声。本文方法将首跳观测与固定短窗取交集。结果见表 3.13，表中报告盘级 $F_{0.5}$ 与 TPR。

表 3.13 表明，五种标签策略中混合标注在 MB1/MB2 上三轮均值 $F_{0.5}$ 均为最优。与表 3.12 类似，各策略 FPR 均接近 0，$F_{0.5}$ 差异主要来自 TPR 与精确率之间的权衡。

在 MB1 上，本文方法均值 $F_{0.5}$ 最优（0.919/0.733），首跳标记 TPR 略高（0.746）但 $F_{0.5}$ 落后（0.896）；3 日与 30 日固定窗接近但仍次优，当日标记最差（0.811/0.500）。固定窗无法剥离首跳前静默段（图 3.9），长窗跨轮不稳定；交集标注与首跳近端统计（图 3.8）同尺度，$F_{0.5}$ 综合更优。

在 MB2 上，本文方法两指标均最优（0.490/0.187），3 日短窗 TPR 持平但 $F_{0.5}$ 略低；当日标记（R3 归零）与 30 日长窗显著落后。弱信号下长窗引入静默段噪声、当日正例过稀，交集标注仍能保留近端跳变监督。

分轮看，R3 测试月各策略普遍回落，MB2 尤为明显（本文方法 TPR 由 R1 的 0.304 降至 R3 的 0.056），提示时间漂移的影响；其中当日标记与 30 日长窗跌幅最大，混合标

表 3.13 训练标签消融实验

型号	轮次	本文方法	首跳标记	当日标记	3 日固定短窗	30 日固定长窗
MB1	R1	**0.947**/0.783	0.898/**0.804**	0.828/0.533	0.921/0.761	0.928/0.783
	R2	**0.895**/0.708	0.887/**0.723**	0.792/0.460	**0.895**/0.708	0.868/0.708
	R3	0.914/0.710	0.904/0.710	0.812/0.506	**0.918**/**0.720**	0.894/0.710
	平均	**0.919**/0.733	0.896/**0.746**	0.811/0.500	0.911/0.730	0.897/0.733
MB2	R1	**0.686**/**0.304**	0.652/0.273	0.192/0.045	**0.686**/**0.304**	0.595/0.227
	R2	**0.556**/**0.200**	**0.556**/**0.200**	**0.556**/**0.200**	**0.556**/**0.200**	0.357/0.100
	R3	**0.227**/**0.056**	0.192/**0.056**	0.000/0.000	0.192/**0.056**	0.192/**0.056**
	平均	**0.490**/**0.187**	0.467/0.176	0.249/0.082	0.478/**0.187**	0.382/0.128

注与首跳/短窗策略相对更稳。

综上所述，固定窗口单独使用无法剥离首跳前静默段的标签噪声，首跳单独使用监督区间过宽，当日标记正例过稀；取二者交集既保留近端失效变化、又抑制静默段误标，在 MB1/MB2 上均取得最优三轮平均 $F_{0.5}$，验证了 §3.3.2 混合标记策略的有效性。

3.4.6　异构集成有效性分析

为说明 §3.3.3 异构集成预测的有效性，本节对比了 Attention + FocalLoss 集成输出与 RF、XGB、LGB 三个基学习器的单模型结果。三基学习器对稀疏突变信号的拟合偏好各异；若集成能在同一评估协议下取得优于或不低于任一单基的稳定表现，则证明了样本级加权融合的必要性。结果见表 3.14，评估指标为 $F_{0.5}$ / TPR。

对表 3.14 的结果分析如下。在 MB1 上，异构集成三轮测试的均值 $F_{0.5}$ 最高（0.919），略优于 XGB（0.918）与 RF（0.916）；TPR 则略低于 XGB/RF（0.733 vs. 0.753/0.749）。分轮看，R1 中 RF 领先（0.954/0.804），R2 中集成 $F_{0.5}$ 最优（0.895），R3 则 XGB 单基最优（0.919/0.753），集成（0.914/0.710）介于 XGB 与 RF 之间。总体而言，在主配置下 MB1 的异构集成能够互补不同基学习器，综合指标略优或与最强单基接近，并减轻单一模型对特定轮次的过拟合；§3.4.2 已说明，退化特征下个别基学习器失效时集成也会受损，故融合收益仍以各基学习器可学为前提。

表 3.14 异构集成分轮对比

型号	轮次	集成结果	RF	XGB	LGB
MB1	R1	0.947/0.783	**0.954**/**0.804**	0.947/0.783	0.824/0.652
	R2	**0.895**/0.708	0.887/**0.723**	0.887/**0.723**	0.799/0.662
	R3	0.914/0.710	0.908/0.720	**0.919**/**0.753**	0.841/0.559
	平均	**0.919**/0.733	0.916/0.749	0.918/**0.753**	0.822/0.624
MB2	R1	**0.686**/**0.304**	0.652/0.273	**0.686**/**0.304**	**0.686**/**0.304**
	R2	**0.556**/0.200	**0.556**/0.200	**0.556**/0.200	0.500/**0.300**
	R3	**0.227**/**0.056**	0.192/**0.056**	0.192/**0.056**	0.192/**0.056**
	平均	**0.490**/0.187	0.467/0.176	0.478/0.187	0.460/**0.220**

在 MB2 上，三轮均值显示异构集成 $F_{0.5}$ 为 0.490 居首，TPR 为 0.187，与 XGB 持平并略高于 RF；LGB 的 TPR 达 0.220，但 $F_{0.5}$ 仅 0.460。分轮看，R1 中集成与 XGB、LGB 并列最优；R2 中 RF、XGB 与集成的 $F_{0.5}$ 均为 0.556；R3 各方法均下滑，集成 $F_{0.5}$ 仍高于三基。弱信号型号上，集成主要带来小幅而稳定的 $F_{0.5}$ 抬升。

综上所述，在完整特征与主超参配置下，所提方法在保持高精确率的同时具有较好的跨轮稳定性。

3.4.7　预警时效性与提前量分析

§3.4.3 已从 TPR/FPR 等盘级指标比较各方法检出能力，但对已被检出的 TP，仍缺少距故障日提前量的刻画，亦难以判断各方法是否存在系统性的“更早告警”优势。为此，本节先做三轮合计口径下的横向对比，再在最优配置下按测试月细读本文方法的 d 分布，最后联系混合标注讨论近端集中的成因。记提前预警天数 $d = t_{\text{fail}} - t_{\text{alarm}}$，评估协议与 §3.4.3 一致；横向对比见图 3.13，本文方法分轮结果见表 3.15 与图 3.14。

下文以 n 记各方法在三轮测试上合计的 TP 盘数（即图 3.13 中同行格内盘数之和）。MB1 上，本文方法、RF 与 MVT-RF 的 n 分别为 148、157 与 156，检出规模接近；三者已检出 TP 均高度近端，$d \le 1$ 者分别为 146、153 与 154 块（占各行 97.5%–98.7%），且均以 $d = 1$ 格为主，$d = 8$–30 远端仅各 1–3 块。头部方法在提前量上未见系统性差异；

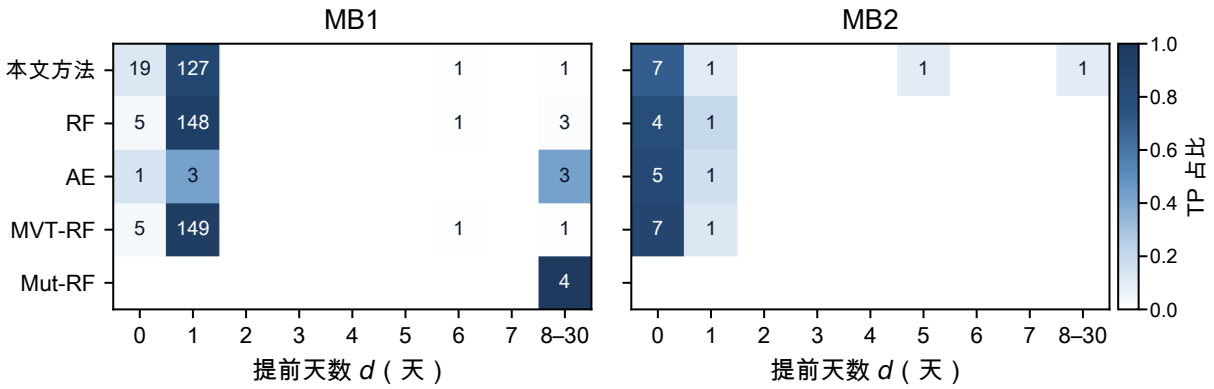


图 3.13 多方法提前预警天数分布对比

注：格内为 TP 盘数，底色为占同行合计的比例；$d = 0..7$ 逐日列出，$d = 8$–30 因远端 TP 稀疏而合并为一列。

方法间 $F_{0.5}$ 差距主要体现是否误报与 FPR 控制（见 §3.4.3）。AE 与 Mut-RF 在 MB1 上 n 仅分别为 7 与 4，Mut-RF 合计 TP 全部落在 $d = 8$–30；二者 TPR 偏低且 §3.4.3 中 FP 明显多于头部方法，在误报未受控的前提下，不宜据本图对其提前量作稳定对比。

MB2 上，各行 n 仅为 5–10，样本偏小；本文 $n = 10$ 居各行之首。在已检出盘上，各方法 d 分布均近端集中于 $d = 0$–1，本文另在 $d = 5$ 与 $d = 8$–30 各 1 块，为唯一含较长提前量的方法。

合计对比尚不能说明近端集中是否随测试月变化。表 3.15 与图 3.14 按 R1–R3 细读本文最优配置（§3.4.2 最优格，混合标注，Lag + $r_k|\Delta|$ 特征，异构集成），重点观察 TP/FN 规模与 d 分布是否同步波动。

表 3.15 本文方法分轮提前预警统计

型号	测试月	TP	FN	FP	TN	提前天数中位数 d	d=1 占比	$d \le 1$ 占比
MB1	R1	36	10	0	36 889	1 天	91.7%	97.2%
	R2	46	19	2	36 956	1 天	93.5%	97.8%
	R3	66	27	1	36 626	1 天	77.3%	100%
MB2	R1	7	16	0	41 305	0 天	14.3%	85.7%
	R2	2	8	0	41 039	2.5 天	0%	50.0%
	R3	1	17	0	41 080	0 天	0%	100%

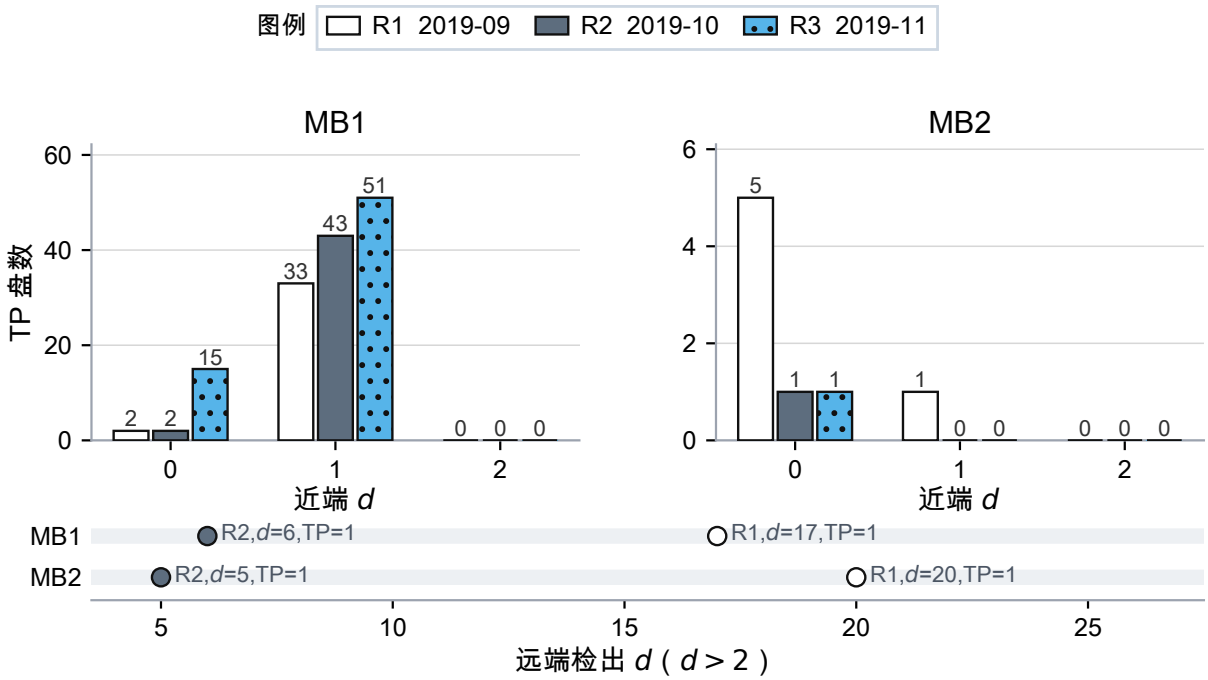


图 3.14 本文方法提前预警时间分布（分轮）

注：因近端与远端检出量级差异大，分上下两排绘制。上排为近端 $d \in \{0,1,2\}$ 分轮柱图；下排为 $d>2$ 时间轴，每个标记点对应一次检出，旁注给出轮次、d 与 TP 盘数。

表 3.15 与图 3.14 显示，对本文方法而言，检出规模与提前量宜分开解读。MB1 三轮提前天数中位数均为 1 天，$d=1$ 占 77%–94%，$d\le 1$ 占 97%–100%，已检出盘的告警时刻普遍贴近故障日；仅 R1、R2 各 1 例 $d>2$ 远端检出（R1，d=17，TP=1；R2，d=6，TP=1），不影响总体判断。R3 TP 增至 66 块而 d 分布仍近端集中，说明规模扩张并未改变已检出盘的时效形态。关于 R3 统计口径：可评估故障盘共 93 块（66 TP + 27 FN），而按故障单中的故障时间落入 2019-11 统计的故障盘数 FAIL=95，二者差异源于口径不完全对齐——6 块盘虽故障日在 11 月但测试月内无可用 SMART 日志而未纳入评估；4 块 TP 于 11 月 30 日告警、故障日在 12 月 1 日，计入 TP + FN 但不计入 11 月 FAIL，属跨月边界情形。MB2 各轮 TP 仅 1–7 块：R1 以 $d=0$ 为主（6/7 满足 $d\le 1$），含 1 例 $d=20$ 远端检出；R2 两例 TP 分处 $d=0$ 与 $d=5$，故 $d\le 1$ 占比为 50%。随测试月由 R1 推进至 R3，TPR 由 30.4% 降至 5.6%，但柱形仍集中于 $d=0$–1，与图 3.13 中 MB2 合计行一致，再次表明弱信号下漂移主要侵蚀检出能力。

横向对比与分轮细读均显示，已检出 TP 高度集中于故障前 0–1 日。该形态与混合标注所限定的监督区间相契：正样本取故障前 k 日短窗（MB1 k=2、MB2 k=2）与 B 组

首跳近端突变（图 3.8）的时间尺度。此外，三轮测试中不存在首次告警距故障日超过 30 天的“过早告警”，说明宽窗训练标签未在部署口径下诱发远端虚警。

3.4.8 适用边界与后续方向

需要指出，本章结论主要建立在阿里云公开的两种 MLC-SSD 子集上。跨厂商、跨工艺的泛化尚未验证，特征与标签策略仍依赖所观察的 SMART 分布。

在该范围内部署时，方法优先压低误报，相应代价是漏报上升，以及告警时刻更靠近故障日。MB1 上 FPR 为 2.71×10^{-5}、Precision 为 0.981，与 §3.1.2 所述运维代价结构一致；突变信号更弱的 MB2 在严控误报下 TPR 仅约 0.19，静默故障盘仍难检出。已检出故障盘的提前量中位数为 1 天，留给数据迁移与换盘的时间有限。

随测试月推进，第 3 轮各配置表现普遍回落，后续可引入在线更新或漂移自适应。突变特征目前以 B 组异常属性为主，对 A 组磨损背景的刻画尚不充分，静默故障场景仍需继续攻关。

3.5 本章小结

本章面向数据中心盘级 SSD 30 天故障预警任务，在主动容错场景下系统分析了 SMART 时序演化规律与失效前兆识别问题。针对正样本极度稀疏、B 组异常属性近端突变信号微弱且易被长窗特征稀释、静默故障盘引入标签噪声等难点，提出由近端突变标注、短期时序突变特征构造与异构集成模型构成的盘级故障预测方法，总体流程如图 3.1 所示。

方法设计遵循“长期平稳、近端突变”的前兆规律。基于 B 组属性故障前时序观察与盘级跳变统计，将 SMART 属性划分为磨损/环境类 A 组与异常/突变类 B 组；在标注层面，将固定短窗标签与首跳观测标签取交集，使监督信号与突变特征窗口及盘级检出时效同尺度对齐，在保留近端失效变化的同时抑制首跳前静默段的标签噪声；在特征层面，以 W 阶 Lag 保留 A/B 组近期读数水平，并对 B 组引入基于健康样本跳变频率的静态稀有权重，构造 $r_k|\Delta|$ 加权突变特征，以突出稀少阶跃前兆、抑制常见波动噪声；在模型层面，采用 RF、XGB 与 LGB 三种异构基学习器输出故障概率，由 Attention 模块进行样本级自适应加权融合，并以 Focal Loss 缓解类别不平衡。上述设计表明，将标签、

特征与模型在突变时间尺度上对齐，是提升 SSD 盘级故障预警有效性的关键思路。

实验在阿里云公开 SMART 数据集 MB1、MB2 子集上开展，采用按日历月滚动的时间顺序划分与盘级最早告警评估协议。(W,k) 仅按验证集盘级 $F_{0.5}$ 选取，两型号最优配置分别为 MB1 的 W=1、k=2 与 MB2 的 W=2、k=2，与 B 组首跳集中于故障前短窗口的统计结论一致。在该配置下，异构集成三轮测试均值在 MB1 上取得 $F_{0.5}$=0.919、TPR 0.733、Precision 0.981，与 MVT-RF 的 $F_{0.5}$ 并列最优且误报更低；在 MB2 上取得 $F_{0.5}$=0.490、TPR 0.187、Precision 1.00；MB1 已检出故障盘的提前预警天数中位数为 1 天，表明方法能够在贴近故障日的近端窗口内给出有效告警。标签策略、突变特征与异构集成三类消融实验进一步验证了各组件的贡献。

综上，本章完成了从数据观察、方法设计到实验验证的完整讨论，为数据中心存储主动容错提供了具有参考价值的技术方案。需要指出的是，方法在 MB2 等弱信号型号上检出率仍偏低，已检出盘的提前量中位数仅 1 天，静默故障盘与时间漂移仍是后续需要重点突破的方向。

4 基于集成学习的固态硬盘寿命提升技术

4.1 问题动机与任务设定

4.1.1 块级寿命差异与优化动机

固态硬盘的底层结构通常由存储介质和纠错算法共同构成。按单元可存储比特数划分，SLC 每个单元存储 1 bit，MLC 每个单元存储 2 bit，TLC 每个单元存储 3 bit，如图 4.1 所示。随着单元存储比特数增加，容量密度与成本效率提升，但阈值电压分布更密集、噪声容限更低，对老化与环境扰动更敏感。当前数据中心广泛采用 TLC 闪存，因而其可靠性退化机理与寿命管理问题尤为关键。

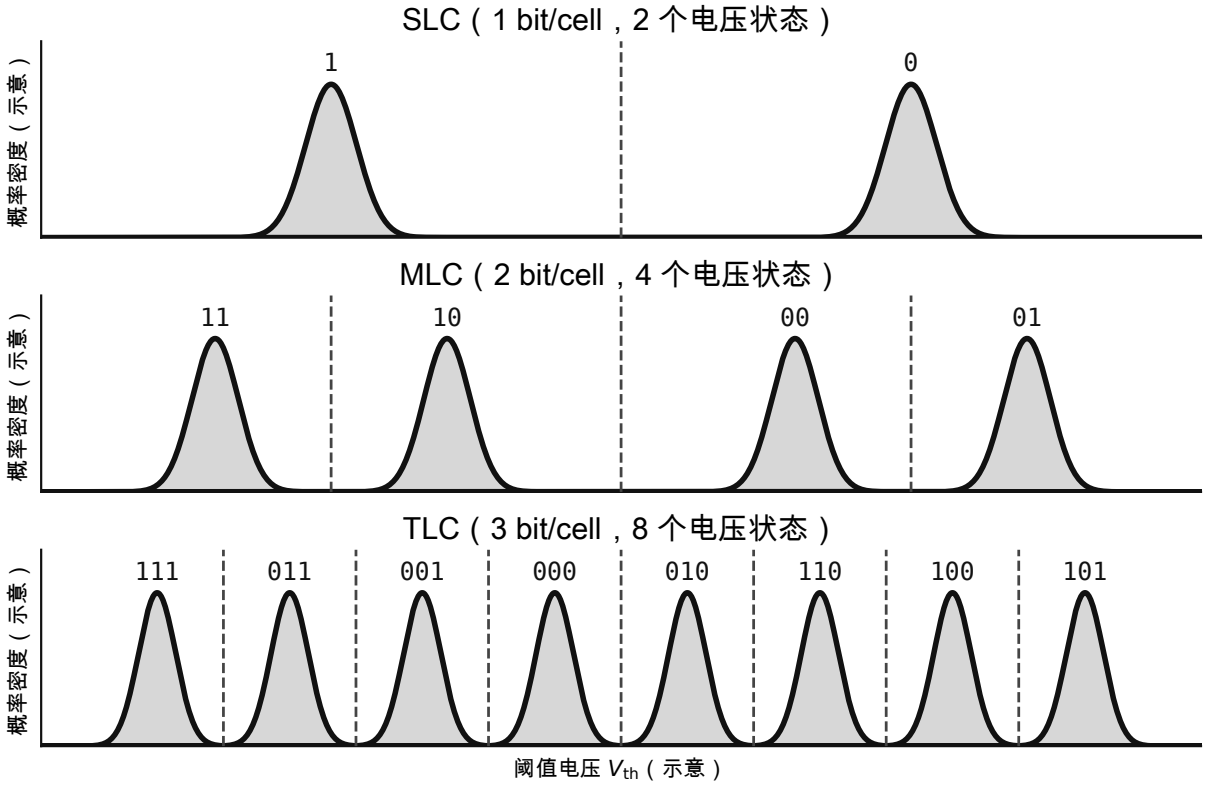


图 4.1 SLC、MLC 与 TLC 存储方式对比示意图

闪存单元的擦写损耗与电荷保持衰减是产生存储错误的两大核心诱因：反复编程擦除会持续削弱单元陷阱捕获电子的能力；长期静置高温环境会造成存储电子逃逸，多次连续读操作还会引入读干扰噪声。上述因素均会导致读出比特与原始写入比特不一致，

产生错误比特。为抑制存储错误，企业级 SSD 控制器普遍集成 LDPC 纠错模块：数据写入阶段对原始比特流编码并附加校验冗余；数据读取时，若错误比特总数未超过 LDPC 译码纠错上限，即可完整恢复原始数据；一旦错误比特突破纠错阈值，对应闪存块将被标记为失效坏块。厂商出厂时会预留少量冗余块用于替换运行过程中产生的坏块，但冗余硬件资源总量有限，当坏块数量持续累积，SSD 有效存储容量与并行写入吞吐能力将出现明显衰减。

现有工业寿命管理方案采用保守统一的全局最大 PE 阈值：该方案忽略闪存块间耐久性差异，只要任意块的擦写次数达到预设阈值，即判定固态硬盘接近寿命终点；同时系统依托磨损均衡算法均匀分配写入负载，延缓各块触及擦写上限的时间[59-60]。

但“全局固定 PE 阈值 + 全局磨损均衡”的传统架构隐含一个不符合实际的核心假设：所有闪存块的耐久性能完全同质。Fitzgerald 等人[43] 已证实不同扇区的错误比特计数随擦写次数增长速率存在显著分化；进一步实验观测表明，该差异同样存在于闪存块粒度。部分耐久性能较差的弱块仅经历少量擦写就逼近 LDPC 纠错临界值，而耐久性能优异的强块在高擦写次数下仍维持较低错误计数，具备充足剩余写入余量。若统一限制所有块的最大擦写次数，强块未被利用的耐久潜力将被完全浪费，块级擦写次数分配差异如图 4.2 所示。

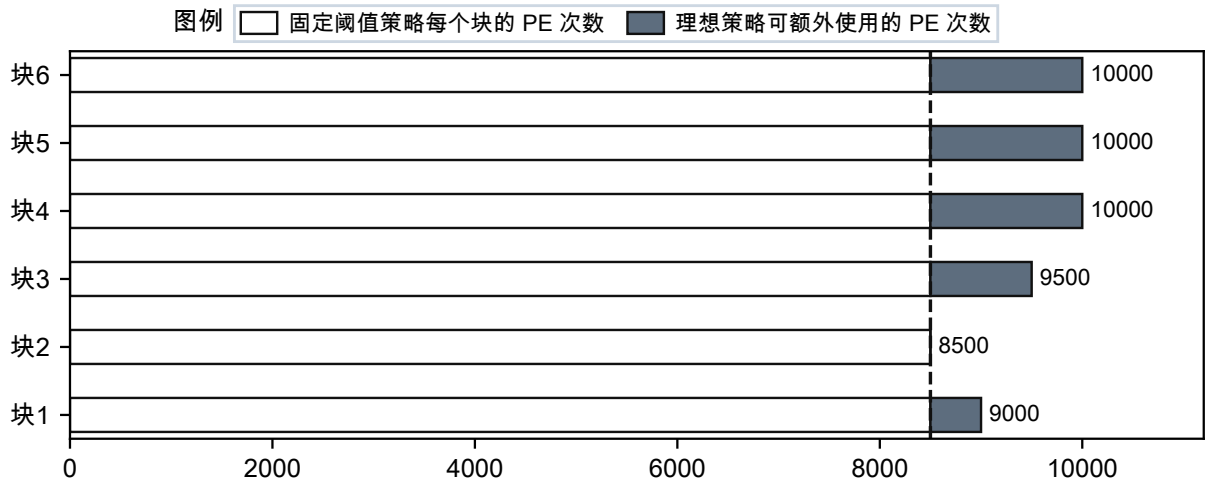


图 4.2 固定阈值策略与理想策略的块级 PE 次数对比示意图

从系统可靠性角度分析，传统统一阈值策略存在以下问题：

1. 资源浪费：强块在达到统一阈值时仍具备较大写入余量，这部分容量被保守策略浪费，降低了 SSD 的整体写入耐久性（Total Bytes Written）。

2. 性能退化：在企业级 SSD 中，当可用块数量减少时，Die 级别的并行度下降，可能导致 I/O 性能抖动和延迟增加。

3. 成本效率低：对于追求高写入耐久性的应用场景，如日志存储、数据库重做日志等，统一阈值策略无法充分利用硬件潜力，增加了单位写入成本。

针对上述问题，本章依托实验室高温 TLC 颗粒磨损实验得到的块级 FBC 数据，构建基于集成学习的块寿命预测模型，并设计差异化 PE 擦写管控策略：对强块挖掘额外可写入空间，对弱块采用更保守的使用策略，在不突破 LDPC 纠错安全边界的前提下提升 SSD 整体可写入量。后续各节依次介绍数据与方法设计，并通过实验验证分类可行性与策略收益。

4.1.2 任务定义与评估指标

设第 i 个逻辑块在早期 PE 档位（0、1000、2000、3000 次）Fresh 条件下采集到的 FBC 统计特征向量为 $\mathbf{x}_i$，块级寿命预测任务旨在学习映射 $f(\mathbf{x}_i) \in \{0,1\}$：输出 0 表示强块，可安全使用至目标 PE 次数 10000；输出 1 表示弱块，在达到目标 PE 前即可能逼近纠错边界。

在模型评估层面，由于弱块样本极度稀少，本文以弱块召回率为核心优化目标，同时要求对强块的误报率尽可能低，以呼应全文“近零误判”的安全约束。在策略评估层面，写入量相对提升率 R_{imp} 在测试集上、根据模型预测结果计算，而非使用全量数据的真实标签。记测试集规模为 n_{test}，LP/MP/UP 三模型投票后的集成预测与真实标签构成混淆矩阵 TN、FP、FN、TP（正类为弱块，标签为 1）。统一 PE 阈值策略下测试集累计可写入量为

$$W_{\text{base}} = n_{\text{test}} \cdot PE_{\text{base}}, \tag{4-1}$$

差异化策略下，按预测结果分配 PE 上限：预测为强块（TN）取 PE_{strong}，预测为弱块（FP、TP）取 PE_{weak}，即

$$W_{\text{pred}} = TN \cdot PE_{\text{strong}} + (FP + TP) \cdot PE_{\text{weak}}. \tag{4-2}$$

写入量相对提升率定义为

$$R_{\text{imp}} = \frac{W_{\text{pred}} - W_{\text{base}}}{W_{\text{base}}} \times 100\%. \tag{4-3}$$

仅当 $FN = 0$（无弱块被误判为强块）时报告 R_{imp}，以避免弱块获得过高 PE 上限、突破 LDPC 纠错安全边界。块级代表性 FBC 须保持在纠错能力边界（本章取 151）以内。

4.2 数据与方法

4.2.1 磨损数据集

本章使用的数据来自实验室搭建的高温加速磨损测试平台，测试对象为采用 TLC 颗粒的 SSD。测试过程中，在受控环境温度下对多个块执行多轮编程/擦除操作，在不同 PE 档位和数据保持条件，例如 Fresh、3M40C 下反复读取，并记录块级错误计数信息，从而获得块级 FBC 与 PE 行为数据。

高温加速磨损测试是一种常用的可靠性评估方法，其基本原理是通过提高环境温度来加速电荷泄漏和陷阱老化过程，从而在较短时间内模拟长期使用效果，在固态存储与通用可靠性分析中被广泛采用[13,39,43,45,61-63]。根据 Arrhenius 方程，温度与老化速率之间存在指数关系，因此适当提高测试温度可以显著缩短实验周期。本实验采用 85 摄氏度的高温环境，结合快慢磨损比例（9:1）的写入模式，模拟实际使用场景下的磨损过程。

测试过程中，在每个 Die 中选取一个连续区域，包含 10 个 Block，分别对应不同的 PE 档位（PE0、1K、2K、3K、7.5K、8K、8.5K、9K、9.5K、10K）。磨损过程使用随机数模拟实际写入行为，以更贴近真实应用场景。采集的数据使用 TLC SSD，主要字段如下：

- Level：编程/擦除次数，即块所处的磨损阶段，反映了块在全生命周期中的进度。PE 次数越高，表示块经历的磨损越严重。
- ReadType：读取类型，可以分为 BestRead 和 DefaultRead。DefaultRead 表示控制器使用默认的读电压门限进行读取，这是正常操作模式下的标准读取方式；BestRead 表示控制器在多个电压门限组合中进行扫描，选择错误最少的组合进行读取，能够获得更准确的 FBC 值，但读取时间更长。
- PageType：页类型，对于 TLC 颗粒通常包括 LP、MP、UP。不同页类型由于存储的比特位不同，其错误行为存在差异：LP 页通常错误率较低，UP 页错误率相对较高。

- WL：Wordline 编号，用于区分块内部的字线位置。每个块包含多个 Wordline，不同 Wordline 的物理位置和制造工艺可能存在细微差异，导致错误行为不完全一致。
- BlockFilter：块编号，用于唯一标识不同的物理块，便于追踪和分析特定块的行为轨迹。
- DR：数据保持条件，反映了数据在不同保持时间和温度下的稳定性。Fresh 表示刚写入后立即读出，此时电荷状态较为稳定，错误率较低；3M40C 表示在 40 摄氏度环境下放置三个月后读出，模拟长期存储后的数据保持情况，此时由于电荷泄漏，错误率会明显增加。
- Value0–Value3：在同一条件下多次读取得到的 FBC 值，用于刻画读取结果的波动情况。由于闪存读取过程存在随机性，多次读取可能得到不同的 FBC 值，通过多次采样可以更准确地估计块的错误水平。

这些字段综合描述了块在不同磨损阶段、不同保持时间和不同读模式下的错误行为，为后续的数据预处理、特征提取和寿命预测建模提供了基础。

4.2.2 逻辑块重建与寿命标签

由于数据采集时间有限，我们无法在所有 PE 档位下同时采集同一物理块在 Fresh 状态和 3M40C 状态下的完整 FBC 轨迹。为在分析上近似获得同一块在不同 PE 次数和不同保持条件下的行为，本文做出如下假设：同一标签下但编号不同的块由于物理位置相近、工艺一致，具有相似的磨损特性。

基于该假设，将块编号 BlockFilter 的数值对 4 取余进行分组，在逻辑上认为每个组对应一个逻辑块，组内不同物理块在不同 PE 档位上的数据共同构成该逻辑块的观测轨迹。如图 4.3 所示：

对于块编号 b，其所属的逻辑块组定义为：

$$G(b) = b \bmod 4, \tag{4-4}$$

公式中的 $G(b)$ 的取值为 0、1、2、3。

这种处理虽然引入了一定近似误差，但在有限实验样本下显著提升了轨迹的完整性，使得我们能够在每个逻辑块上获得更密集的 PE 档位观测。

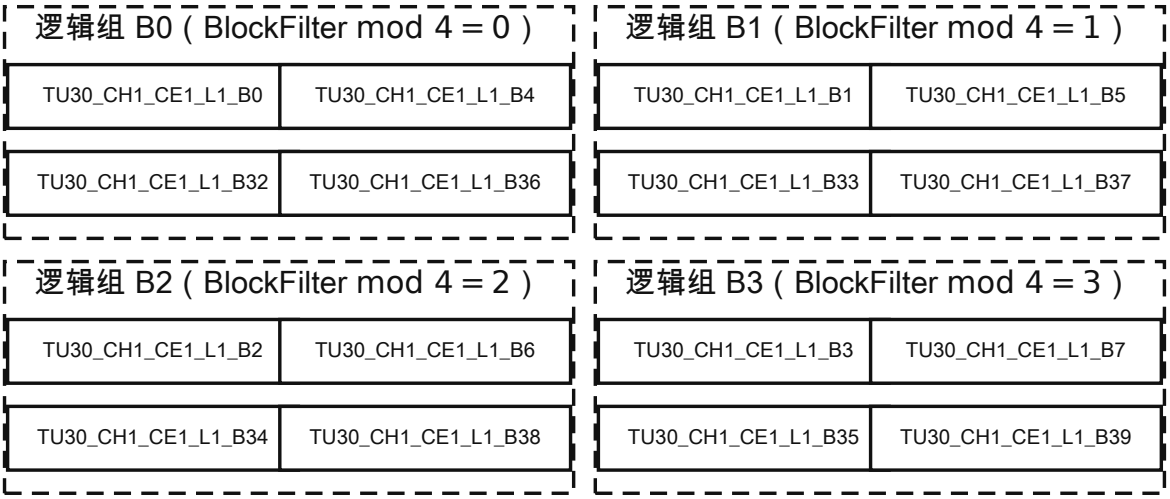


图 4.3 分组逻辑示意图

为了确定单个块的可读写次数上限，需要先从多次读取得到的 FBC 中提取稳定的块级指标。本文的做法是：对于每个逻辑块和每个 PE 档位，聚合该块所有 Wordline、所有 PageType 在 BestRead 条件下的 Value0–Value3，计算其 99 分位数作为当前块在该 PE 档位的代表性 FBC。

对于逻辑块 i 在 PE 档位 p 下的 FBC 值集合 $S_{i,p}$，代表性 FBC 定义为：

$$\mathrm{FBC}_{i,p} = P_{99}(S_{i,p}), \tag{4-5}$$

公式中的 P_{99} 表示 99 分位数函数。选择 99 分位数而非均值或中位数的原因在于：在工程实践中，更关心最坏情况下的错误水平，高分位数能够更好地反映块在极端条件下的行为，更贴近 LDPC 纠错能力的实际边界。

随后，参考 TLC 颗粒厂商建议的使用读写次数 8500 次 PE，选定 151 作为极限使用 FBC 阈值。该阈值的设定基于以下考虑：一是 151 个错误比特接近当前 TLC SSD 中 LDPC 译码器的纠错能力上限，超过该阈值后译码失败概率显著增加；二是考虑到实际运行环境中的温度波动、数据保持时间等因素，需要在理论纠错上限之下预留一定安全裕量；三是该阈值与厂商推荐的 8500 次 PE 寿命相对应，在工程实践中已有经验支撑。

由于无法采集更密集的 PE 档位，如每 100 次 PE 采集一次，为保证在标记的寿命时间内 FBC 一定小于阈值，将第一次观测到代表性 FBC 达到或超过 151 时的 PE 档位的前一个档位视为该块的极限可用 PE 次数，并将该寿命字段记为 LIFESPAN。数学上，

寿命变量 LIFESPAN 定义为：

$$\mathrm{LIFESPAN}_i = \max\{p : \mathrm{FBC}_{i,p} < 151\} - \Delta p, \tag{4-6}$$

公式中的 Δp 表示 PE 档位的间隔。

在完成寿命标签定义后，可以统计所有逻辑块的寿命分布。当前实验数据中，共有 256 个逻辑块，其中寿命为 10000 的块有 251 个，而寿命小于 10000 的块仅有 5 个。这种高度不平衡的分布反映了测试样本中强块占主导地位的特点。各寿命档位的细分统计如表 4.1 所示：

表 4.1 逻辑块寿命分布统计

寿命（LIFESPAN）	7500	8000	8500	9000	9500	10000
块数量	1	0	1	2	1	251

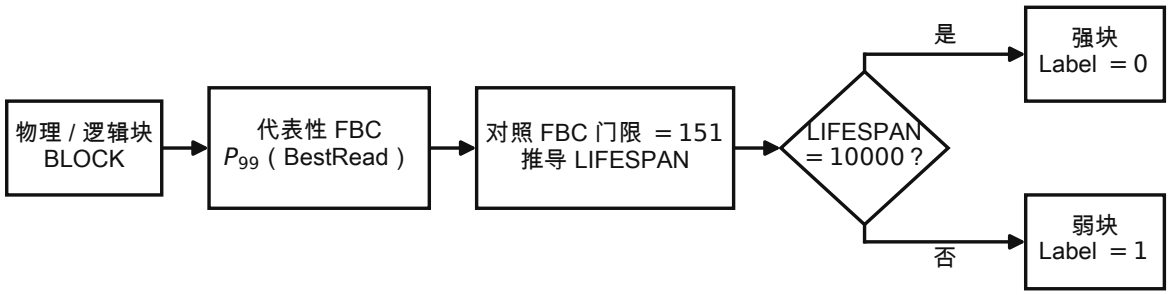


图 4.4 块寿命标签构造流程

如图 4.4 所示，基于工程上对可安全工作到 10000 次 PE 的块的需求，可将寿命预测问题转化为二分类任务，目标是识别可安全使用到 10000 次 PE 的强块。建模时，将寿命等于 10000 的块标记为负样本（强块，标签为 0），将寿命小于 10000 的块标记为正样本（弱块，标签为 1）。相比直接回归精确寿命值，这种二分类形式更易建模和优化，也更贴合工程中“是否能达到目标 PE 次数”的判定需求，并且对寿命定义中的不确定性更具鲁棒性。

4.2.3 特征构造与集成预测模型

对于每一个逻辑块，利用其在 PE 为 0、1000、2000、3000 次时 Fresh 条件下的 FBC 分布进行特征构造。选择这四个早期 PE 档位的原因在于：在块的使用初期采集特征，符合实际应用场景（SSD 部署前或运行初期进行测试）；这四个档位覆盖了从全新到中度磨损的阶段，能够较好地反映块的初始状态和早期退化趋势；同时这四个档位的数据采集相对完整，能够保证特征构造的可靠性。

在每个 PE 档位上，计算如下统计特征：

位置特征包括：均值，反映 FBC 分布的中心趋势；95 分位数（P_{95}），反映分布的上界，接近最坏情况；99 分位数（P_{99}），反映极端情况下的错误水平。

离散程度特征包括：最大值和最小值，给出 FBC 分布的上界和下界；方差，反映 FBC 值的波动程度；极差（最大值减去最小值），反映分布的范围。

上述特征用于描述当前分布下的 FBC 行为。为了刻画错误随 PE 增长的演化速度，进一步构造跨 PE 档位的差分特征，例如：均值增量 $\Delta\text{mean} = \text{mean}_{\text{PE=3000}} - \text{mean}_{\text{PE=0}}$，反映平均错误水平的增长幅度；均值相对增幅 $\Delta\text{mean}/\text{mean}_{\text{PE=0}}$，归一化的增长比例；99 分位数增量 $\Delta P_{99} = P_{99,\text{PE=3000}} - P_{99,\text{PE=0}}$，反映极端错误水平的增长。

这些特征从静态分布和动态变化两个维度综合刻画了块在磨损过程中的错误行为，为后续的寿命预测模型提供了输入。特征的总数约为每个 PE 档位 7 个统计特征，加上跨档位的差分特征，总计约 30 到 40 个特征。

考虑到特征数量中等、存在非线性关系、且样本数量有限（仅 256 个块），本文采用 XGBoost、RandomForest 与 LightGBM 三种集成学习模型进行块寿命预测。由于 LP、MP、UP 与 label 的对应关系存在一定差异，在数据量有限的情况下容易导致过拟合，本文分别针对 LP、MP、UP 建模，并采用投票机制对最终分类结果进行融合。集成投票流程如图 4.5 所示：

4.2.4 差异化写入策略

传统 SSD 寿命管理采用全局 PE 上限 PE_{base}（本章取 8500 次），不区分块间差异；测试集基线累计可写入量为 $W_{\text{base}} = n_{\text{test}} \cdot PE_{\text{base}}$。

基于寿命预测模型的输出，本文设计预测驱动的差异化写入策略：在 SSD 部署前

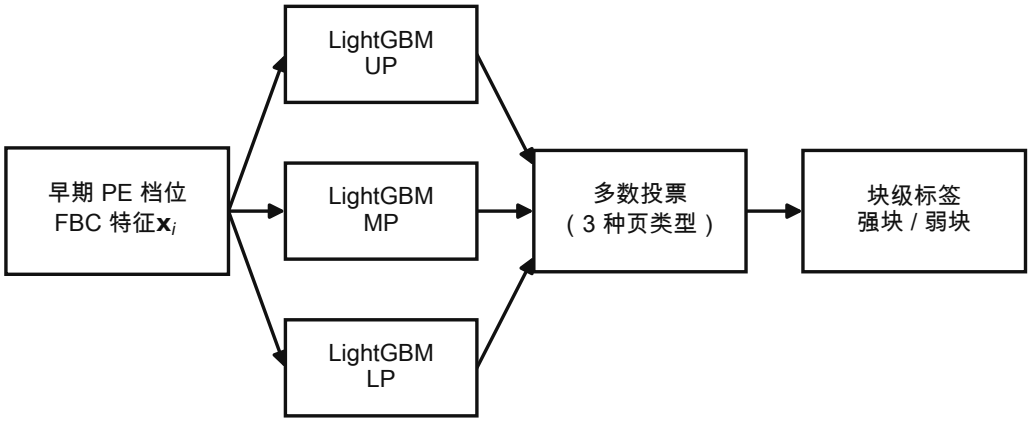


图 4.5 集成投票流程

或运行初期，当块磨损至早期 PE 档位（0、1000、2000、3000 次）时，采集 FBC 并构造特征，经 LP/MP/UP 集成投票识别强块与弱块。对预测为弱块的单元取保守上限 $PE_{\text{weak}} = 7500$ 次（来自实验中 PE=3000 档位之后观测到的最低 PE 水平）；对预测为强块的单元取 $PE_{\text{strong}} = 10000$ 次（与强块目标寿命一致）。写入调度中优先将压力分配给强块。测试集差异化累计可写入量按式 (4-2) 计算，策略收益 R_{imp} 按式 (4-3) 在测试集上、依据模型预测与混淆矩阵得到，且仅当 $FN = 0$ 时报告。

4.3 实验结果与分析

4.3.1 实验设置

实验按 8:2 分层划分训练集与测试集（$n_{\text{test}} = 52$）；在训练集上进行 3 折交叉验证与网格搜索，以弱块召回率为优化目标。对比 XGBoost、RandomForest 与 LightGBM 三种模型，并在 BestRead 与 DefaultRead 两种读模式下评估；各配置的策略收益均以测试集 R_{imp} 衡量。

4.3.2 块寿命分类与策略收益

在最优配置下，三种模型经 LP/MP/UP 投票融合后，测试集混淆矩阵均为 $TN = 51$、$TP = 1$、$FP = 0$、$FN = 0$，弱块召回率为 100% 且无强块被误判为弱块。取 $PE_{\text{base}} =$

8500、$PE_{\text{weak}} = 7500$、$PE_{\text{strong}} = 10000$，则 $W_{\text{base}} = 442{,}000$，$W_{\text{pred}} = 517{,}500$，由式 (4-3) 得 DefaultRead 集成配置下 $R_{\text{imp}} \approx 17.08\%$。

不同读模式与页类型分区建模下的 R_{imp} 如表 4.2、图 4.6 所示。

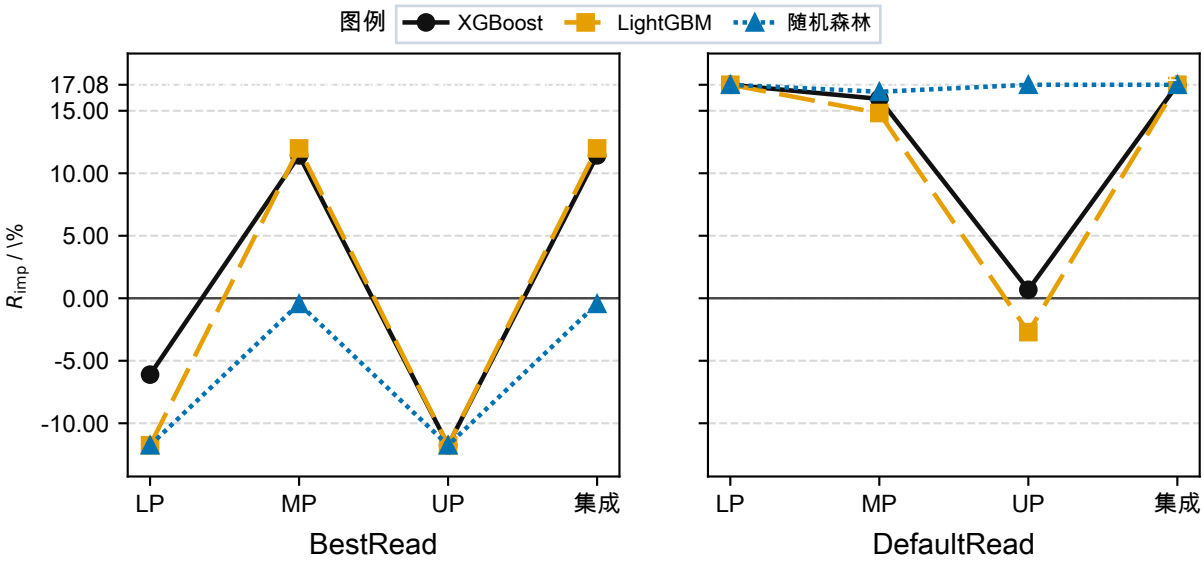


图 4.6 不同读模式与页类型下的写入量提升率柱状对比

表 4.2 不同读模式与页类型下的写入量提升率明细

读取方式	模型	LP	MP	UP	集成
BestRead	XGBoost	-6.11%	11.43%	-11.76%	11.43%
BestRead	LightGBM	-11.76%	11.99%	-11.76%	11.99%
BestRead	随机森林	-11.76%	-0.45%	-11.76%	-0.45%
DefaultRead	XGBoost	17.08%	15.95%	0.68%	17.08%
DefaultRead	LightGBM	17.08%	14.82%	-2.71%	17.08%
DefaultRead	随机森林	17.08%	16.52%	17.08%	17.08%

从读模式整体表现来看，DefaultRead 方案下集成模型的耐久提升幅度稳定保持在 17% 左右，综合表现全面优于 BestRead。进一步对比 LP、MP、UP 三类页面的指标可以发现，不同页面的可利用耐久提升幅度差异显著，该规律能够由 Raquibuzzaman 等[45]的层间耐久机理予以解释：3D 堆叠 NAND 闪存受制造工艺影响，存储层耐久存在天然分层特性，顶层与底层页面老化速度更快、极限 PE 循环更低，中层 MP 页面耐久性能

最优，因此实验中 MP 对应的写入提升效果波动最小。

对比两种读取模式下的指标差异：BestRead 依靠多档电压扫描选取最优读阈值，虽能降低单次读取误码，但会重构页面间错误分布；在本实验小样本数据集条件下，该特性放大了 LP、UP 页面的性能波动，甚至出现负增益。而 DefaultRead 为 SSD 控制器原生标准读取策略，完全匹配线上业务常态负载，各类模型在该模式下大多取得正向写入收益，其中随机森林对三类页面均能稳定输出正向提升，鲁棒性最优。

4.3.3 轻量化采集消融

前述实验在实验室条件下使用了四次重复读取（Value0–Value3）、四个早期 PE 档位（0/1000/2000/3000）以及块内全量 Wordline 采样。实际控制器端若照搬该配置，需要在块生命周期的多个节点反复触发额外读操作并遍历大量字线，将显著增加在线采集时延与测试窗口占用。为此，本文从读取次数、磨损档位覆盖与 Wordline 采样范围三个维度设计轻量化采集方案，并在固定 LP/MP/UP 集成建模流程下，以测试集 R_{imp} 评估各方案相对全量特征的收益保留程度。

1. 单次读取方案。实验室数据中 Value0–Value3 为同一条件下的四次独立采样，用于刻画 FBC 波动；而在线场景往往只能承受一次附加读操作。该方案仅保留 Value0–Value3 中的单次读数构造特征，考察以单次读替代多次重复读是否仍足以支撑块寿命判别与策略收益评估。各读取值下的 R_{imp} 如表 4.3 所示。

2. 稀疏磨损档位方案。全量特征要求块在 PE=0/1000/2000/3000 四个节点均完成 FBC 采集，适用于出厂标定或专门老化测试；而服役中的块往往仅能在当前 PE 进度附近插入一次探测读。该方案分别仅保留单一 Level 参与建模，考察单点快照相对多档轨迹的信息损失。各磨损档位下的 R_{imp} 如表 4.4 所示。

3. 有限 Wordline 采样方案。全量 Wordline 遍历需对块内逐字线读取，采集开销与块容量成正比；控制器更可行的做法是在空间上抽取代表性字线窗口。该方案将 Wordline 范围由全量逐步收缩至 0–0、0–49 等子区间，考察局部采样能否代表块级 FBC 分布。各字线采样范围下的 R_{imp} 如表 4.5 所示。

三类轻量化设定下 BestRead 与 DefaultRead 的 R_{imp} 变化趋势汇总于图 4.7；对应数值见表 4.3–4.5。

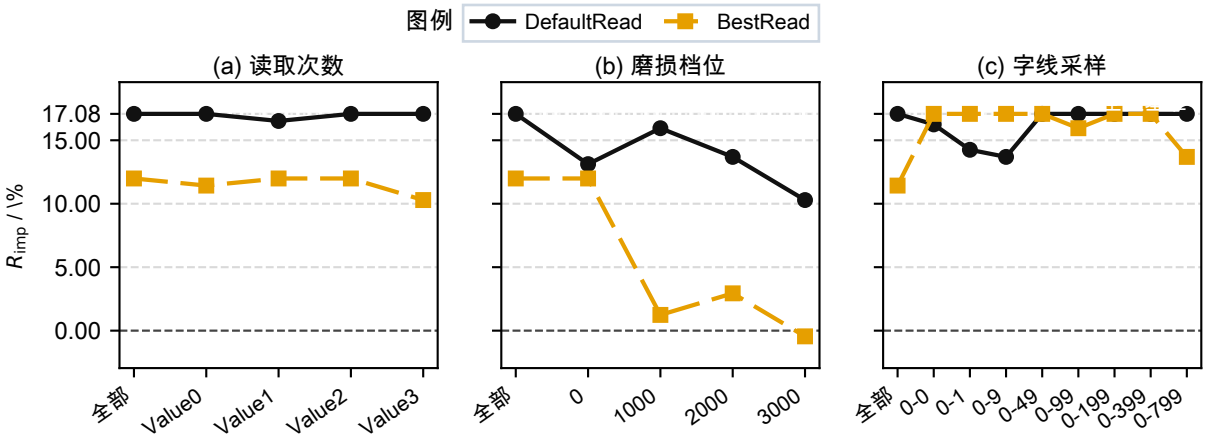


图 4.7 轻量化采集消融

表 4.3 不同读取值下的写入量提升率

ReadType	全部	Value0	Value1	Value2	Value3
BestRead	11.99%	11.43%	11.99%	11.99%	10.29%
DefaultRead	17.08%	17.08%	16.52%	17.08%	17.08%

表 4.4 不同磨损档位下的写入量提升率

ReadType	全部	0	1000	2000	3000
BestRead	11.99%	11.99%	1.24%	2.94%	-0.45%
DefaultRead	17.08%	13.12%	15.95%	13.69%	10.29%

表 4.5 不同字线采样范围下的写入量提升率

Wordline 设置	BestRead	DefaultRead
全部	11.43%	17.08%
0-0	17.08%	16.25%
0-1	17.08%	14.25%
0-9	17.08%	13.69%
0-49	17.08%	17.08%
0-99	15.95%	17.08%
0-199	17.08%	17.08%
0-399	17.08%	17.08%
0-799	13.69%	17.08%

对表 4.3–4.5 中的实验结果，下面依次从采集成本、收益保留与部署建议三个角度展开讨论。

在采集成本上，DefaultRead 的效果普遍比 BestRead 更好，单次读取方案将同一条件下的重复读降为 1 次，开销最低；稀疏磨损档位方案将多节点轨迹压缩为单点快照，适合块已处于中后期 PE 阶段的在线探测；有限 Wordline 方案的开销介于两者之间，Wordline 0–49 子集已可将遍历规模显著压缩，而全量 Wordline 仍是最重配置。

在收益保留维度上，DefaultRead 模式下各轻量化子集均存在可维持 17.08% 完整写入增益的配置，印证 Fitzgerald 等人[43] 提出的“早期少量观测即可完成块耐久判别”核心结论。稀疏档位中 PE=1000、单次读取 Value0/Value2/Value3、Wordline 0 49 均能完整保留全量特征的耐久提升效果；反观 Best 模式对采集条件高度敏感，磨损后期档位、窄字线区间易出现负收益，稳定性较差，不适合线上默认配置。结合 Raquibuzzaman 等[45] 层间耐久差异结论可解释该现象：BestRead 动态调整读取电压，会放大顶层、底层弱页与中层强页的误码差异，小样本轻量化输入下模型易出现判别偏移；而 DefaultRead 为控制器出厂标准读策略，误码分布更稳定，少量观测样本即可稳定区分强弱块。

在部署建议上，若控制器仅能承担最小侵入式采集，可优先采用 DefaultRead + 单次 Value0（或 Value2/Value3）+ Wordline 0–49 的组合，在三个维度上同时轻量化且 R_{imp}

与全量特征一致；若块尚处于早期寿命且可插入一次标准探测，Level=1000 单点快照是磨损维度上较均衡的折中。三者并不互斥：Wordline 局部采样降低空间开销，单次读取降低时间开销，稀疏档位适应“无法回溯早期 PE 节点”的服役约束，共同构成由重到轻的分级部署路径。

4.3.4 方法局限性讨论

虽然本章方法在实验数据上取得较好效果，但仍存在局限性：当前仅包含 256 个逻辑块且强块占比高，实际大规模部署中的寿命分布可能更复杂，仍需扩大样本验证；方法依赖高温加速磨损测试，实际场景未必能对全部块完成完整测试，需探索更轻量方案；模型主要基于 Fresh 条件下的 FBC 数据，不同温度与数据保持时间可能影响预测准确性；此外，模型在特定 TLC-SSD 上训练，不同厂商与型号可能需要重训或调参，在线运行时也需进一步平衡精度与计算开销。

4.4 本章小结

本章围绕块粒度闪存寿命提升展开研究。首先分析了统一 PE 阈值策略的局限，明确了块级二分类任务与测试集写入量相对提升率 R_{imp} 两类评估指标。随后，基于实验室高温磨损数据完成逻辑块分组、寿命标签构造、早期 FBC 特征提取与 LP/MP/UP 集成预测，并设计了预测驱动的差异化 PE 擦写策略。

实验表明，模型在测试集上实现弱块完全识别且无误报强块；DefaultRead 集成配置下 $R_{\mathrm{imp}} \approx 17.08\%$。轻量化采集消融进一步表明，在部分读取值、少量磨损档位或中等规模 Wordline 采样下，策略收益仍可接近全量设置，为控制器端部署提供了参考。

5 智慧固态硬盘运维软件设计与实现

为验证第三章 SSD 故障预测方法在真实运维场景中的可落地性，本章设计并实现智慧 SSD 运维原型系统。系统以“日志采集—周期预测—预警处置—故障沉淀”为主线，按照软件工程基本流程完成需求分析、概要设计、详细设计、数据库设计、系统实现与系统测试；其中，用例分解明细、字段级表结构、完整 REST 路径及测试步骤收录于附录，正文侧重阐述设计思路、关键流程与实现验证。

5.1 需求分析

5.1.1 功能需求

系统面向数据中心 SSD 日常运维，建设目标是在统一平台上完成设备资产、运行日志与故障事件的治理，提供基于历史 SMART 日志的周期预警能力，并形成“预警生成—人工确认/忽略—结果沉淀”的闭环流程，为后续模型迭代与策略优化保留可追溯的数据基础。结合运维实际，功能需求可归纳为四类，如表 5.1 所示；其中预测分析类需求直接对接第三章离线流水线，可扩展性需求则通过算法服务与业务服务解耦予以满足。

表 5.1 系统功能需求说明

需求类别	需求描述
基础数据管理	支持对 SSD 盘信息、SMART 日志与故障记录的增删改查及按序列号、日期检索
预测分析	按周期对增量日志执行预处理、特征构造与模型推理，生成预警记录及关联日志快照
交互与可视化	提供列表分页、详情查看、预警状态更新等运维高频操作界面
可扩展性	支持预测模型、特征构造模块与规则引擎的替换与升级，接口与数据表保持向后兼容

5.1.2 非功能需求

除功能需求外，原型系统还需满足可用性、可维护性与数据一致性等工程约束，如表 5.2 所示。非功能与功能需求中的“可扩展性”相互补充：前者强调算法服务与业务解耦、模型可独立更新，后者要求接口与数据表保持向后兼容。

表 5.2 系统非功能需求说明

需求类别	需求描述
可用性	核心管理页面在常规浏览器下可正常访问，列表查询响应时间在秒级
可维护性	采用前后端分离与分层架构，业务模块边界清晰，便于独立演进
数据一致性	预警确认后同步更新预警状态并写入故障记录，保证处置链路可追溯
安全性	通过登录鉴权控制管理操作，敏感写操作需经后端校验
可扩展性	算法服务与在线业务服务解耦，模型文件与阈值配置可独立更新

5.1.3 用例分析

系统主要参与者为运维用户；定时调度器作为外部时间触发源，周期性地自动执行故障预警生成。围绕设备资产维护、日志采集、预警生成与预警处置四类场景，将系统功能分解为主用例与子用例，二者之间采用 UML 包含（include）关系，如图 5.1 所示。

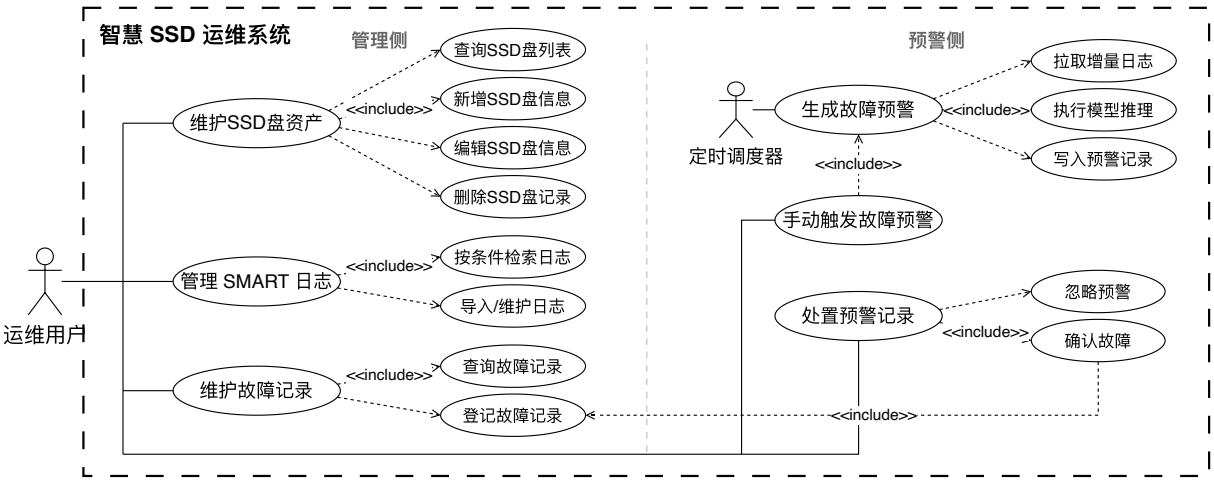


图 5.1 智慧 SSD 运维系统用例图

从运维流程看，四类场景依次对应“先维护资产与日志、再触发预测、最后人工处置并沉淀故障记录”的闭环链路：资产维护用例为日志导入与预警关联提供统一 SSD 盘标识；日志管理用例按序列号与日期维护 SMART 时序输入；预警生成用例由调度器或人工触发增量预测并写入 pending 记录；预警处置用例则支持运维人员确认故障或忽略预警，并驱动故障表联动更新。各子用例的完整说明见附表 D.1。

5.2 系统概要设计

5.2.1 总体架构设计

系统总体架构如图 5.2 所示，采用“业务层—服务层—数据层—基础层”四层设计。业务层由前端承载 SSD 盘管理与预警处理等运维功能；服务层分为数据管理服务与故障预测算法服务，前者负责盘、日志、故障与预警等数据的增删改查，后者封装第三章的预处理、特征构造、推理与故障判定，支持定时调度或手动触发；数据层以 MySQL 存储业务数据，模型文件可置于对象存储（如 S3/OSS）以便独立更新；基础层提供计算、存储与网络支撑。

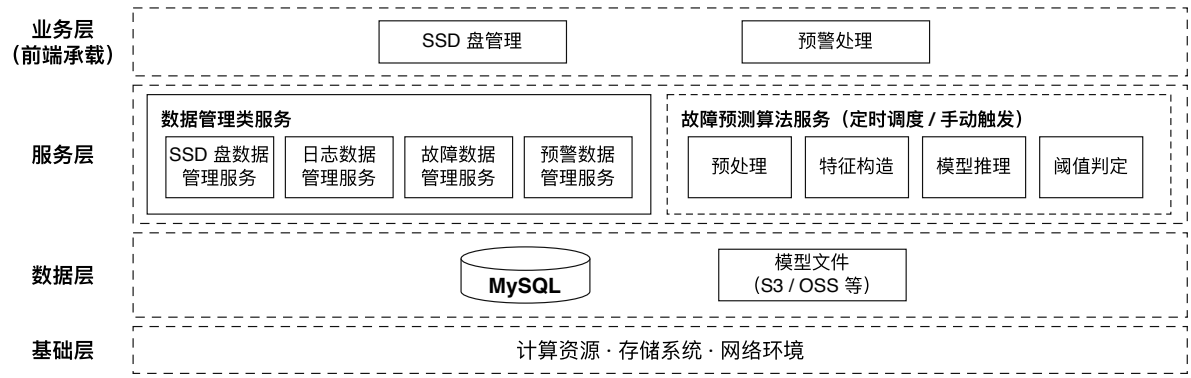


图 5.2 软件总体架构图

5.2.2 功能模块划分

在逻辑结构上，系统划分为前端展示层、后端服务层、算法服务层与数据持久层四个模块，各模块职责如表 5.3 所示。其中，后端服务层承担 REST 接口与业务状态流转，算法服务层独立封装预测流水线，与业务服务解耦，便于模型与阈值配置的热更新。

服务层内部按职责可细分为五类服务：SSD 盘、日志、故障与预警数据管理服务，

以及独立的故障预测算法服务。数据管理服务由后端服务层调用，负责业务数据的持久化与检索；故障预测算法服务由定时调度器或手动触发接口调用，读取增量日志并输出预警结果，再交由预警数据管理服务写入数据库。五类服务的对应关系如表 5.4 所示。

表 5.3 系统功能模块划分

模块	主要职责	关键组件
前端展示层	页面交互、表单校验、列表检索与状态展示	Vue3、TypeScript、Vite
后端服务层	REST 接口、业务逻辑、预警状态流转	Java 业务服务、数据访问层
算法服务层	增量日志拉取、特征构造、模型推理、阈值判定与预警结果输出	定时调度任务、Python 预测脚本、模型文件
数据持久层	资产、日志、预警与故障数据存储	MySQL 数据库

表 5.4 服务层职责划分

服务名称	主要职责
SSD 盘数据管理服务	SSD 盘资产主数据的增删改查
日志数据管理服务	SMART 日志的导入、检索与维护
故障数据管理服务	故障记录的登记与查询
预警数据管理服务	预警记录的查询、状态更新与持久化
故障预测算法服务	预处理、特征构造、模型推理与阈值判定

5.2.3 部署设计

系统采用前后端分离部署方式：运维人员通过浏览器访问前端静态资源，前端通过 HTTP 调用后端 REST 接口，后端服务层连接 MySQL 数据库并编排业务逻辑；算法服务层由定时调度器周期触发，经日志数据管理服务读取增量 SMART 日志，完成推理后将结果交由预警数据管理服务持久化。该部署方式使算法服务与在线业务服务相互解耦，便于模型文件与阈值配置的独立升级。

5.2.4 技术选型

系统主要技术选型及理由如表 5.5 所示。前端选用 Vue3 与 TypeScript 以提升组件复用与类型约束能力；后端选用 Java 分层架构以隔离业务逻辑与数据访问；数据库选用 MySQL 以支持日志与预警的关联检索；算法侧采用“定时调度 + Python 脚本”组合，以便直接复用第三章离线建模代码。

表 5.5 系统技术选型说明

层次	技术选型	选型理由
前端	Vue3 + TypeScript + Vite	组件化开发效率高，类型约束有助于降低界面逻辑错误
后端	Java	分层结构清晰，便于实现业务服务与数据访问解耦
数据库	MySQL	支持结构化存储与关联查询，满足日志与预警时序检索需求
算法后端	定时调度 + Python 推理脚本	与业务服务解耦，便于复用第三章离线建模流程或迭代预测模型

5.3 系统详细设计

5.3.1 设计过程与第三章方法衔接

详细设计阶段的核心任务，是将第三章盘级故障预测方法（图 3.1）映射为可周期运行的工程流程。离线训练阶段已完成字段筛选、缺失补全与 A/B 属性归纳，并采用混合标注构造训练样本，以 W 阶 Lag 与 B 组稀有加权突变特征 $r_k|\Delta|$ 为输入，训练 RF、XGB 与 LGB 异构基学习器及 Attention 融合模块；模型参数、稀有权重 $\{r_k\}$ 与盘级判定阈值固化为配置文件。在线推理阶段不再重复标注与训练，而由日志数据管理服务维护 SMART 读数并识别增量记录，故障预测算法服务执行与第三章一致的预处理与短期时序突变特征构造，经异构集成得到样本级概率，再按盘级最早告警规则聚合为盘级判定；超阈值时由预警数据管理服务写入告警日期、评分与关联日志快照。在线业务服务

仅负责预警状态查询与流转，不参与模型训练，以保证算法迭代与业务发布相互独立。

5.3.2 预警生成流程设计

预警生成由离线预测任务驱动，经故障预测算法服务执行。任务可由定时调度器周期触发，也可由运维用户通过手动触发接口发起一次增量预测，适用于日志批量导入后即时验证模型输出的场景。其处理链路遵循第 3.3.1–3.3.3 节所述“预处理—Lag 与 $r_k|\Delta|$ 特征构造—异构集成推理—盘级最早告警—阈值判定”顺序，具体步骤与上文衔接说明一致。预警生成流程如图 5.3 所示，其中预处理、特征构造、模型推理与阈值判定由算法服务层完成，日志拉取与预警写入分别由调度器与预警数据管理服务负责。

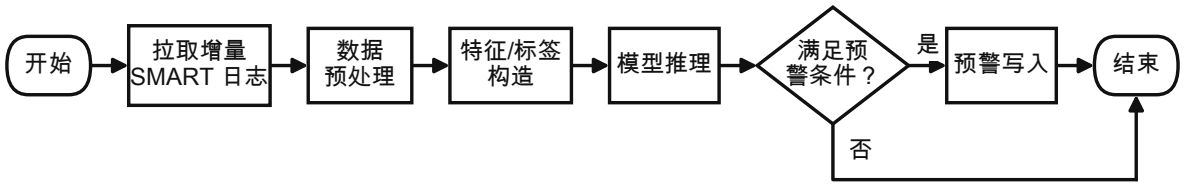


图 5.3 预警生成流程

5.3.3 预警处置流程设计

预警处置由在线服务完成。运维人员在故障处理页面查看预警评分与关联日志快照后，可执行“确认故障”或“忽略预警”：确认操作将预警状态更新为 confirmed，并同步写入故障记录表；忽略操作将状态更新为 ignored，且不产生新的故障事件。两类终态均不允许重复处置，以保证审计链路清晰。预警处置的交互顺序如图 5.4 所示。

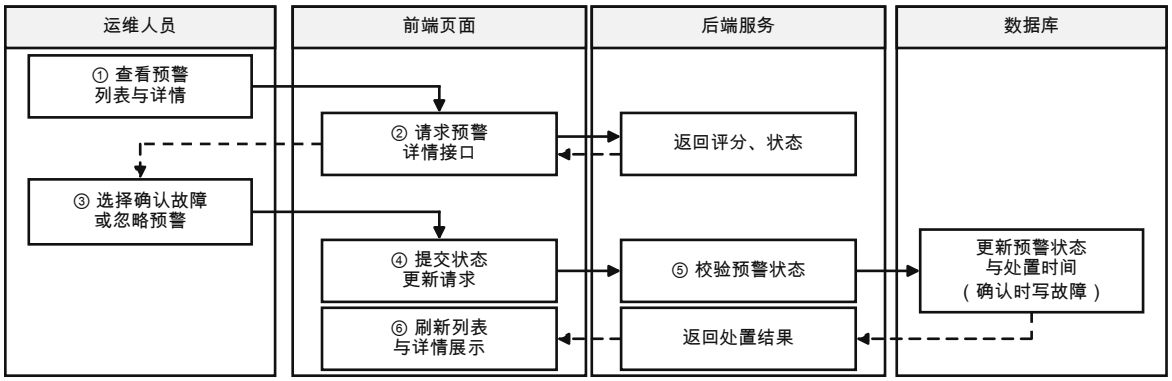


图 5.4 预警处置交互流程

5.3.4 预警状态设计

预警记录在生命周期内具有三种状态：pending 表示待处置，confirmed 表示已确认故障，ignored 表示已忽略。状态转换规则如表 5.6 所示。

表 5.6 预警状态转换规则

当前状态	触发事件	目标状态	系统动作
pending	确认故障	confirmed	更新预警状态，写入故障记录
pending	忽略预警	ignored	更新预警状态，不写入故障记录
confirmed	—	confirmed	终态，不允许重复处置
ignored	—	ignored	终态，不允许重复处置

5.3.5 接口设计

系统对外提供 REST 风格接口，按资源类型划分为 SSD 盘、日志、预警与故障四类，采用统一的 JSON 数据格式进行交互。各资源均支持列表查询与单条操作；预警资源另提供确认与忽略处置接口；预测任务可通过手动触发接口调用。接口分层汇总如表 5.7 所示，完整路径与方法定义见附表 D.6。

表 5.7 系统 REST 接口分层汇总

资源类型	主要能力	典型 HTTP 方法
SSD 盘	资产列表查询、单盘增删改查	GET、POST、PUT、DELETE
日志	按序列号与日期检索、导入维护	GET、POST
预警	分页查询、详情查看、确认/忽略处置	GET、POST
故障	故障事件登记与回溯查询	GET、POST

5.4 数据库设计

为支撑上述功能，系统围绕“资产管理—日志采集—预警生成—故障沉淀”的业务链路设计了四类核心数据表。整体设计遵循结构清晰、关系可追溯和查询高效的原则，

在保证数据一致性的同时兼顾后续扩展性。其中，SSD 盘信息表用于维护资产主数据，SMART 日志表用于沉淀运行时序信息，预警记录表用于保存模型输出与处置状态，故障记录表用于沉淀已确认事件并支撑评估分析。本节先从概念层梳理实体及其联系，再给出各数据表的逻辑结构设计。

5.4.1 数据库概念设计

从概念层看，系统涉及 SSD 盘信息、SMART 日志、预警记录与故障记录四类核心实体。SSD 盘信息作为资产主实体，与其余实体之间均为一对多联系；预警记录与故障记录之间还存在“确认后生成”的可选业务关联。各实体主要属性及其联系如图 5.5 所示，图中矩形表示实体、椭圆表示属性、菱形表示联系。实体间主要关系如表 5.8 所示。

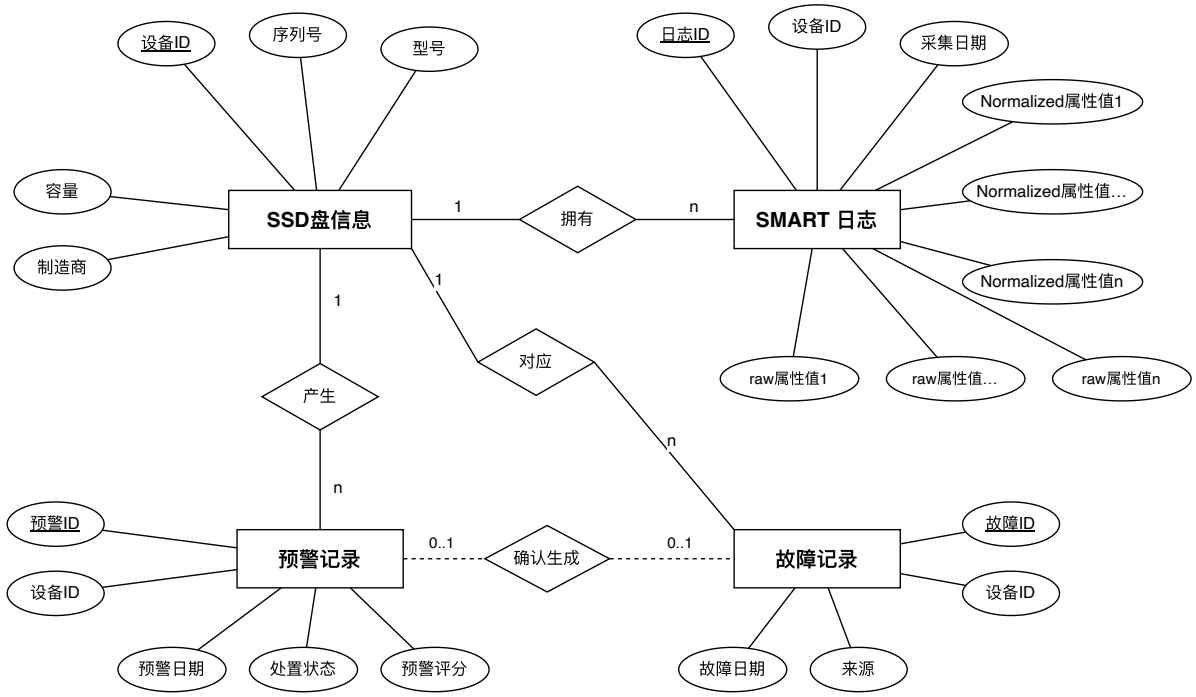


图 5.5 智慧 SSD 运维系统 E-R 图

在关联实现上，其余三表通过 disk_id 外键引用 SSD 盘信息表主键 id 建立一对多联系；serial_number 仅作为 SSD 盘资产的业务标识字段保留在 SSD 盘信息表中。日志表与预警表还可按时间窗口进行关联查询，以支持预警溯源与详情展示。预警记录与故障记录之间的“确认生成”联系属于业务流转关系，仅当运维人员确认故障时才会写入故障记录，手工登记的故障事件则不经过预警表。

表 5.8 数据库实体关系说明

主实体	关系类型	从实体	关联说明
SSD 盘信息表	一对多	SMART 日志表	通过 disk_id 外键关联 SSD 盘主键
SSD 盘信息表	一对多	预警记录表	通过 disk_id 外键关联 SSD 盘主键
SSD 盘信息表	一对多	故障记录表	通过 disk_id 外键关联 SSD 盘主键
预警记录表	可选生成	故障记录表	预警确认后写入对应故障记录

5.4.2 逻辑结构设计

四类核心数据表的用途与关键字段汇总如表 5.9 所示。SSD 盘信息表维护序列号、型号、容量等资产主数据；SMART 日志表按日历日存储原始属性读数，支撑特征构造与模型推理；预警记录表保存模型评分、关联日志快照及处置状态；故障记录表沉淀已确认事件及其来源。各表完整字段类型与约束定义见附表 D.2–D.5；该结构在保证实体边界清晰的同时，可满足当前系统的一致性约束与关联查询需求。

表 5.9 系统核心数据表汇总

数据表	主要用途	主键	外键
SSD 盘信息表	SSD 资产主数据维护与检索	id	—
SMART 日志表	按日存储运行日志，支撑预测分析	id	disk_id
预警记录表	保存模型输出、日志快照与处置状态	id	disk_id
故障记录表	沉淀已确认故障事件及来源	id	disk_id

5.5 系统实现与功能落地

基于上述设计，本文完成了智慧 SSD 运维软件原型系统实现。系统采用前后端分离架构：前端基于 Vue3 与 TypeScript 实现页面组织与交互逻辑，后端基于 Java 分层接口服务实现数据读写、任务调度与预警状态流转。整体实现围绕“数据管理—预测预警—人工处置—结果沉淀”的闭环目标展开，实现过程遵循“先打通主链路、再完善管理功能”的顺序。

5.5.1 管理员模块实现

在后台管理模块中，系统按业务对象划分为 SSD 盘管理、日志管理与故障管理三个核心单元。SSD 盘管理模块负责维护 SSD 基础信息，支持列表查询、新增、编辑与删除；日志管理模块负责维护 SMART 日志记录，支持按序列号与日期检索并进行增删改查；故障管理模块负责维护已确认故障事件，支持故障日期登记、回溯查询与记录管理。三类页面均采用“列表检索—表单编辑—详情确认”的统一交互模式，将运维高频操作纳入标准化流程，各页面完整截图见附录 E。

5.5.2 预警生成与处置流程实现

预警功能由算法服务层与后端服务层协同完成。定时调度器周期触发故障预测算法服务，对增量 SMART 日志依次执行预处理、Lag 与 $r_k|\Delta|$ 突变特征构造、异构集成推理及盘级阈值判定，并将结果交由预警数据管理服务写入预警表；算法服务内部复用第三章离线训练得到的模型、稀有权重与阈值配置。后端服务层根据页面请求返回预警列表、关联日志明细与当前处置状态。运维人员可在故障处理页面同时查看评分与日志快照，并执行确认或忽略操作；系统在更新预警状态的同时，于确认路径下自动写入故障记录，形成从模型输出到运维动作的闭环链路。图 5.6 给出了故障处理页面的交互效果。

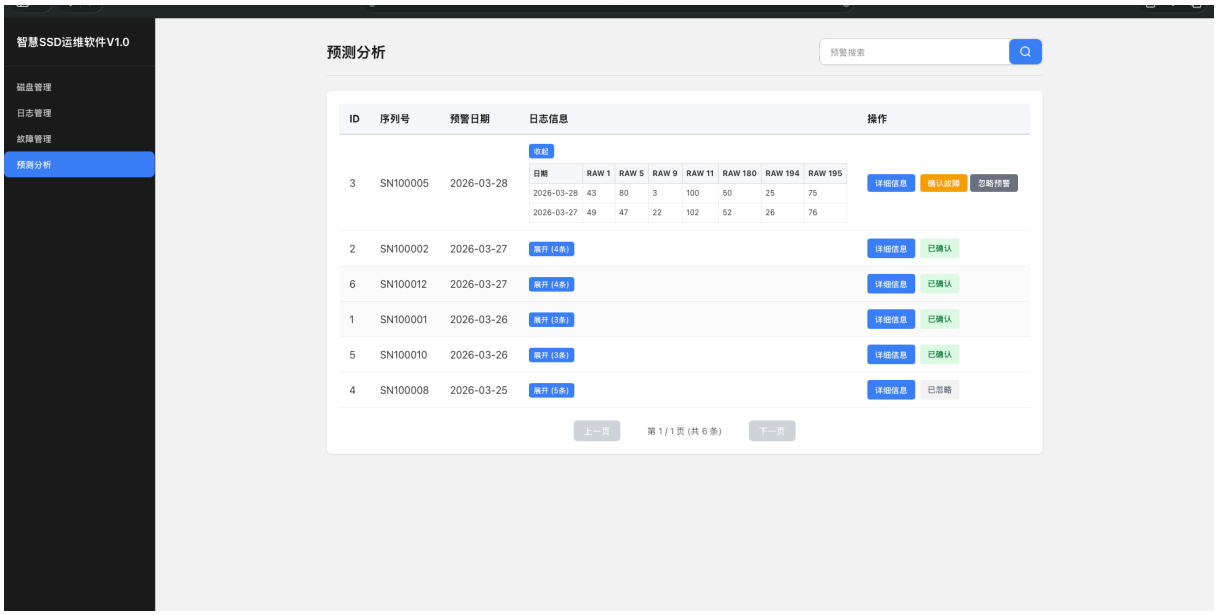


图 5.6 故障处理页面实现效果

5.5.3 功能落地效果分析

从工程落地效果看，系统已实现以下关键能力：第一，完成 SSD 资产与运行日志的结构化管理，满足日常数据治理需求；第二，实现预警记录与关联日志的联动展示，提升故障定位效率；第三，打通预警状态流转与故障沉淀流程，使模型输出可直接转化为可执行运维动作；第四，为后续模型重训练、阈值优化与策略迭代提供持续数据闭环。与此同时，系统在功能组织与数据链路上保持了较好的模块解耦性，便于后续按业务需求逐步扩展模型服务、规则引擎与可视化能力。除正文图 5.6 所示故障处理页外，磁盘管理、日志管理与故障管理页面截图统一收录于附录 E。

5.6 系统测试

5.6.1 测试环境与方法

系统测试在本地部署环境中进行：前端运行于 Edge 浏览器，后端服务与 MySQL 8.0 数据库部署于同一主机，预测任务通过内置定时调度模块触发，整体拓扑与第 5.2.3 节部署设计一致。测试以功能测试为主，覆盖附表 D.1 所列核心用例及表 5.7 汇总的主要 REST 能力，验证需求项能否通过系统操作正确实现。测试方法采用黑盒测试，从运维使用视角沿“资产维护—日志导入—预警生成—预警处置—故障回溯”主路径设计用例，执行操作后核对页面展示与数据库状态变化；逐步操作说明见附表 D.7。

5.6.2 功能测试用例与结果

功能测试覆盖资产管理、日志维护、预警生成、预警处置、故障登记及接口调用六类场景，共 12 项用例，测试结果汇总如表 5.10 所示。资产管理与日志维护用例验证了主数据治理与检索能力；预警生成用例确认定时任务能够正确写入 pending 记录；预警处置用例进一步检验详情展示、确认/忽略状态流转及故障表联动写入；接口调用用例则核对预警列表返回的分页数据与状态字段。全部用例均通过测试，表明系统在本地环境下能够稳定支撑从模型推理到人工确认的完整流程。

表 5.10 系统功能测试结果汇总

测试模块	用例数	测试结论
SSD 设备资产管理	3	全部通过
SMART 日志管理	2	全部通过
预警生成	1	全部通过
预警处置	4	全部通过
故障管理	1	全部通过
接口调用	1	全部通过
合计	12	全部通过

5.7 本章小结

本章围绕智慧 SSD 运维软件的工程落地展开，按照软件工程基本流程完成了需求分析、概要设计、详细设计、数据库设计、系统实现与系统测试。需求分析部分明确了功能需求、非功能需求与核心用例；概要设计部分给出了总体架构、模块划分、服务层职责、部署方式与技术选型；详细设计部分补充了预警生成与处置流程、状态转换规则、REST 接口设计及与第三章预测方法的衔接；数据库设计部分完成了概念层 E-R 建模与核心数据表汇总；实现与测试部分验证了各管理模块与预警闭环功能。整体上，系统将“数据采集—模型推理—人工处置—结果沉淀”串联为可追踪流程，为后续在真实生产环境中开展策略迭代、指标评估与跨版本对比提供了统一的平台支撑。

6 总结与展望

6.1 全文工作总结

本文围绕规模化数据中心 SSD 运维中“故障预警误报成本高”与“闪存块耐久差异未充分利用”两大核心痛点，以提升运维可靠性和资源利用率为目标，开展了系统性的研究工作。主要结论与贡献如下:

首先，针对现有盘级故障预测方法误报率偏高、难以适应近端突变前兆的问题，本文提出了一种面向低误报约束的预测方法。该方法通过混合标注策略与短期时序突变特征，将监督信号与故障前兆的时间尺度对齐，在抑制标签噪声的同时有效放大微弱的故障信号。实验表明，在阿里云 MB1 数据集上该方法取得了 0.919 的 $F_{0.5}$，与最强基线并列最优，并在更低误报与更高精确率上保持优势，能够在极低误报约束下对故障盘给出有效检出。这为数据中心降低因误报导致的非必要换盘成本提供了技术手段。

其次，针对传统统一 PE 阈值策略浪费强块寿命的问题，本文设计了一套基于块级 FBC 的差异化寿命提升策略。该策略将块寿命预测转化为“强/弱块”二分类问题，并据此实施差异化的 PE 擦写上限管控，在不突破可靠性边界的前提下充分挖掘强块的剩余寿命。测试结果表明，该策略可带来约 17% 的累计可写入量提升。轻量化采集实验进一步验证了该策略在控制器端部署的可行性。

最后，为验证上述算法的工程实用性，本文设计并实现了一套智慧 SSD 运维原型软件。该系统打通了从数据采集、模型推理到预警处置的完整业务闭环，并通过功能测试覆盖采集—推理—预警处置链路，表明所提方法具备落地应用的潜力。

综上所述，本文形成了一条从“盘级精准预警”到“块级寿命优化”再到“系统闭环落地”的完整技术链路。研究工作表明，在盘级侧落实运维误报成本约束、在块级侧落实可靠性边界约束，并辅以原型系统闭环验证，可以在保障数据中心存储可靠性的同时，显著提升存储资源的利用效率，为 SSD 的智能化运维提供了有价值的参考。

6.2 后续工作展望

尽管本文取得了一定成果，但受限于实验条件与研究周期，仍有以下几个方面值得在未来进行深入探索：

第一，验证方法在 QLC/PLC 等新型闪存上的有效性。随着存储密度提升，新型闪存的 P/E 耐受度更低，寿命管理的安全裕量被进一步压缩。未来工作需要在更接近实际场景的 QLC/PLC 颗粒上，验证本文预测模型与寿命策略的鲁棒性，并探索针对其特有失效模式的优化方案。

第二，探索跨硬件平台的模型泛化能力。本文模型基于特定型号的 SSD 数据训练，而不同厂商、工艺的闪存存在显著异质性。未来可研究迁移学习（Transfer Learning）等技术，旨在利用已有模型的知识，降低在新硬件平台上的数据标注与模型重训成本，提升方案的通用性。

第三，优化控制器端的部署效率。面向在线应用场景，算法的实时性与计算开销是关键约束。未来需在特征计算、模型推理的精度与效率之间寻求更精细的平衡，例如探索模型剪枝、量化或设计更轻量级的特征集，以满足控制器端严苛的资源限制。

第四，增强面向运维的故障归因能力。当前集成模型对单次告警的细粒度解释仍有限。后续可结合树模型特征重要性、注意力融合权重与基于规则的归因方法，定位对预警贡献较大的 SMART 属性与突变通道，便于运维人员核对告警依据。

第五，补充面向坏块与弱块的极限仿真测试。现有块级实验样本有限，难以覆盖更多失效形态。后续可在健康 SSD 上仿真植入特定坏块或弱块，系统考察相关算法在更多情形下的误报与漏报表现。

参考文献

[1] SHANKAR S. Challenging trends in energy of computing for data centers[J]. Computer, 2024, 57(12): 134-142.

[2] 华为技术有限公司. 数据存储 2030(2024 版)[R/OL]. 白皮书. 深圳: 华为技术有限公司, 2024 [2026-03-02]. https://www-file.huawei.com/-/media/corp2020/pdf/giv/2024/data_storage_whitepaper_2030_cn.pdf.

[3] XU E, ZHENG M, QIN F, et al. Lessons and actions: What we learned from 10k SSD-related storage system failures[C]//2019 USENIX Annual Technical Conference. 2019: 961-976.

[4] XU F, HAN S, LEE P P, et al. General feature selection for failure prediction in large-scale SSD deployment[C]//2021 51st Annual IEEE/IFIP International Conference on Dependable Systems and Networks. 2021: 263-270.

[5] JAFFER S, MANEAS S, HWANG A, et al. The reliability of modern file systems in the face of SSD errors[J]. ACM Transactions on Storage, 2020, 16(1): 1-28.

[6] HUANG P, SUBEDI P, HE X, et al. FlexECC: Partially relaxing ECC of MLC SSD for better cache performance[C]//2014 USENIX Annual Technical Conference. 2014: 489-500.

[7] PINHEIRO E, WEBER W D, BARROSO L A. Failure Trends in a Large Disk Drive Population.[C]//5th USENIX Conference on File and Storage Technologies: vol. 7: 1. 2007: 17-23.

[8] ALTER J, XUE J, DIMNAKU A, et al. SSD failures in the field: symptoms, causes, and prediction models[C/OL]//Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis. New York, NY, USA, 2019. DOI: 10.1145/3295500.3356172.

[9] HAN S, LEE P P, XU F, et al. An In-Depth Study of Correlated Failures in Production SSD-Based Data Centers[C]//19th USENIX Conference on File and Storage Technologies. 2021: 417-429.

[10] NG E. Topology-Aware SSD Health Risk Prediction with SMART Signals, Location Features, and LLM-Based Failure Explanation[J]. Journal of Advanced Computing Systems, 2026, 6(6): 56-73.

[11] MEZA J, WU Q, KUMAR S, et al. A large-scale study of flash memory failures in the field[J]. ACM SIGMETRICS Performance Evaluation Review, 2015, 43(1): 177-190.

[12] GU Y, WU C, HE X. Exploit both SMART Attributes and NAND Flash Wear Characteristics to Effectively Forecast SSD-based Storage Failures in Clusters[C]//2024 USENIX Annual Technical Conference. 2024: 1101-1117.

[13] 罗铮, 韩国军. 3D NAND 闪存 P/E 次数的快速测评与寿命预测[J]. 广东工业大学学报, 2024, 41(6): 52-59.

[14] MANEAS S, MAHDAVIANI K, EMAMI T, et al. A study of SSD reliability in large scale enterprise storage deployments[C]//18th USENIX Conference on File and Storage Technologies. 2020: 137-149.

[15] LU R, XU E, ZHANG Y, et al. NVMe SSD failures in the field: the fail-stop and the fail-slow[C]//2022 USENIX Annual Technical Conference. 2022: 1005-1020.

[16] CHAKRABORTTII C, TIWARI D. Failure Prediction in Cloud-based Storage Systems: A Survey[J]. ACM Transactions on Storage (Just Accepted), 2026.

[17] HUGHES G F, MURRAY J F, KREUTZ-DELGADO K, et al. Improved disk-drive failure warnings [J]. IEEE transactions on reliability, 2002, 51(3): 350-357.

[18] WANG Y, MIAO Q, PECHT M. Health monitoring of hard disk drive based on Mahalanobis distance [C]//2011 Prognostics and System Health Management Conferenece. 2011: 1-8.

[19] QUEIROZ L P, RODRIGUES F C M, GOMES J P P, et al. A fault detection method for hard disk drives based on mixture of Gaussians and nonparametric statistics[J]. IEEE Transactions on industrial informatics, 2016, 13(2): 542-550.

[20] LUKOVIĆ V, JOVANOVIĆ Ž, ĐURAŠEVIĆ PEŠOVIĆ S, et al. Solid-State Drive Failure Prediction Using Anomaly Detection[J]. Electronics, 2025, 14(7).

[21] LU R, XU E, ZHANG Y, et al. Perseus: A Fail-Slow detection framework for cloud storage systems [C]//21st USENIX Conference on File and Storage Technologies. 2023: 49-64.

[22] MURRAY J F, HUGHES G F, KREUTZ-DELGADO K, et al. Machine learning methods for predict-

ing failures in hard drives: A multiple-instance application.[J]. Journal of Machine Learning Research, 2005, 6(5).
[23] HAMERLY G, ELKAN C, et al. Bayesian approaches to failure prediction for disk drives[C]//ICML: vol. 1: 2001. 2001: 202-209.
[24] CHAVES I C, de PAULA M R P, LEITE L G, et al. Banhfap: A bayesian network based failure prediction approach for hard disk drives[C]//2016 5th Brazilian Conference on Intelligent Systems. 2016: 427-432.
[25] LI J, JI X, JIA Y, et al. Hard drive failure prediction using classification and regression trees[C]//2014 44th annual ieee/ifip international conference on dependable systems and networks. 2014: 383-394.
[26] ZHANG Y, HAO W, NIU B, et al. Multi-view feature-based SSD failure prediction: What, when, and why[C]//21st USENIX Conference on File and Storage Technologies. 2023: 409-424.
[27] WANG Z, XU J. SSD Failure Prediction Based on Classification Models and Data Engineering[C]//2022 IEEE Intl Conf on Dependable, Autonomic and Secure Computing, Intl Conf on Pervasive Intelligence and Computing, Intl Conf on Cloud and Big Data Computing, Intl Conf on Cyber Science and Technology Congress. 2022: 1-8.
[28] WANG S, ZHANG Y, LUO H, et al. FailureMiner: A Joint Key Decision Mining Scheme for Practical SSD Failure Prediction and Analysis[C]//24th USENIX Conference on File and Storage Technologies. 2026: 597-611.
[29] LU S, LUO B, PATEL T, et al. Making disk failure predictions SMARTer![C]//18th USENIX conference on file and storage technologies. 2020: 151-167.
[30] LUO C, ZHAO P, QIAO B, et al. NTAM: Neighborhood-temporal attention model for disk failure prediction in cloud platforms[C]//Proceedings of the Web Conference 2021. 2021: 1181-1191.
[31] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
[32] CHEN L, ZHU Z, LI A, et al. SSD drive failure prediction on Alibaba data center using machine learning[C]//2022 IEEE International Memory Workshop. 2022: 1-4.
[33] KOH C, KANG J, KIM T, et al. Temporal-Contextual Attention Network for Solid-State Drive Failure Prediction in Data Centers[J]. IEEE Access, 2024.
[34] ZHANG Y, ZHANG T, HAO W, et al. MSFRD: Mutation similarity based SSD failure rating and diagnosis for complex and volatile production environments[C]//2024 USENIX Annual Technical Conference. 2024: 869-884.
[35] ZHOU H, ZHANG S, PENG J, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 35: 12. 2021: 11106-11115.
[36] JIANG T, ZENG J, ZHOU K, et al. Lifelong disk failure prediction via GAN-based anomaly detection [C]//2019 IEEE 37th International Conference on Computer Design. 2019: 199-207.
[37] CHAKRABORTTII C, LITZ H. Improving the accuracy, adaptability, and interpretability of SSD failure prediction models[C]//Proceedings of the 11th acm symposium on cloud computing. 2020: 120-133.
[38] ZHOU H, NIU Z, WANG G, et al. Proactive drive failure prediction for cloud storage system through semi-supervised learning[J]. IEEE Transactions on Dependable and Secure Computing, 2023, 21(4): 1528-1543.
[39] MA R, WU F, ZHANG M, et al. RBER-aware lifetime prediction scheme for 3D-TLC NAND flash memory[J]. IEEE Access, 2019, 7: 44696-44708.
[40] TIAN X, LI L, ZHAO S, et al. Intelligent NAND Flash Memory for In-Situ Block Health Prediction with Machine Learning[C]//2024 International Conference on Microelectronics. 2024: 1-5.
[41] FANG X, ZHANG M, GUO Y, et al. Work-in-Progress: High-Precision Short-Term Lifetime Prediction in TLC 3D NAND Flash Memory as Hot-data Storage[C]//2022 International Conference on Compilers, Architecture, and Synthesis for Embedded Systems. 2022: 11-12.
[42] FANG X, ZHANG M, GUO Y, et al. High-precision short-term lifetime prediction in TLC 3-D NAND flash memory as hot-data storage[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2023, 42(10): 3224-3235.
[43] FITZGERALD B, RYAN C, SULLIVAN J. An early-life NAND flash endurance prediction system

[J]. IEEE Access, 2021, 9: 148635-148649.
[44] ZHANG H, WANG J, CHEN Z, et al. An SVM-based NAND flash endurance prediction method[J]. Micromachines, 2021, 12(7): 746.
[45] RAQUIBUZZAMAN M, MILENKOVIC A, RAY B. Intrablock wear leveling to counter layer-to-layer endurance variation of 3-D NAND flash memory[J]. IEEE Transactions on Electron Devices, 2022, 70(1): 70-75.
[46] ZHANG M, WU F, YU Q, et al. BeLDPC: Bit errors aware adaptive rate LDPC codes for 3D TLC NAND flash memory[C]//2020 Design, Automation & Test in Europe Conference & Exhibition. 2020: 302-305.
[47] SSDFans. 深入浅出 SSD[M]. 机械工业出版社, 2021.
[48] 王新梅, 肖国镇. 纠错码: 原理与方法[M]. 西安电子科技大学出版社, 1991.
[49] 周志华. 机器学习[M]. 清华大学出版社, 2016.
[50] 李航. 统计学习方法[M]. 北京: 清华大学出版社, 2012.
[51] GALLAGER R. Low-density parity-check codes[J]. IRE Transactions on Information Theory, 1962, 8(1): 21-28.
[52] BREIMAN L. Random forests[J]. Machine learning, 2001, 45(1): 5-32.
[53] CHEN T, GUESTRIN C. Xgboost: A scalable tree boosting system[C]//Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining. 2016: 785-794.
[54] KE G, MENG Q, FINLEY T, et al. Lightgbm: A highly efficient gradient boosting decision tree[J]. Advances in neural information processing systems, 2017, 30.
[55] NIE Y, NGUYEN N H, SINTHONG P, et al. A Time Series is Worth 64 Words: Long-term Forecasting with Transformers[EB/OL]. 2023. https://arxiv.org/abs/2211.14730. arXiv: 2211.14730 [cs.LG].
[56] LIU Y, HU T, ZHANG H, et al. iTransformer: Inverted Transformers Are Effective for Time Series Forecasting[Z/OL]. 2023. arXiv: 2310.06625 [cs.LG].
[57] LI G, JING Z, LI J, et al. MTMS: Age-Aware Multi-Task Multi-Layer Stacking for SSD Failure Prediction[C]//2025 IEEE European Test Symposium. 2025: 1-4.
[58] HE C, FENG M, LEE P, et al. Large-scale disk failure prediction[M]. Springer, 2020.
[59] CHANG L P, KUO T W. An adaptive striping architecture for flash memory storage systems of embedded systems[C]//Proceedings. Eighth IEEE Real-Time and Embedded Technology and Applications Symposium. 2002: 187-196.
[60] CHANG Y H, HSIEH J W, KUO T W. Endurance enhancement of flash-memory storage systems: An efficient static wear leveling design[C]//Proceedings of the 44th annual Design Automation Conference. 2007: 212-217.
[61] SARKAR J, SUN F B F. Reliability characterization and modeling of solid-state drives[C]//2015 Annual Reliability and Maintainability Symposium. 2015: 1-6.
[62] SEIF M, FARJALLAH E, BADETS F, et al. Refresh frequency reduction of data stored in SSDs based on A-timer and timestamps[C]//2017 22nd IEEE European Test Symposium. 2017: 1-6.
[63] LI P, LIU K, DANG W, et al. Reliability assessment of NAND SSD based on acceleration degradation test[C]//2017 IEEE International Conference on Industrial Engineering and Engineering Management. 2017: 1945-1949.

附录

A SMART 字段筛选剔除明细

附表 A.1 对应正文第3.2.2.1 节三步字段筛选流程，汇总各步骤剔除的读数列、剔除原因及 MB1/MB2 型号适配情况；读数列标记规则与正文保持一致，r_i 代表原始读数，n_i 代表归一化读数。

附表 A.1 SMART 字段筛选剔除明细

步骤	读数列	剔除原因	MB1	MB2
恒为空列剔除	r_2/n_2、r_3/n_3、r_4/n_4、r_6/n_6、r_7/n_7、r_8/n_8	全部盘-日样本均缺失，该属性在公开日志无上报记录	是	是
	r_{10}/n_{10}、r_{11}/n_{11}、r_{13}/n_{13}、r_{189}/n_{189}、r_{191}/n_{191}、r_{193}/n_{193}		是	是
	r_{200}/n_{200}、r_{204}/n_{205}、r_{207}/n_{207}、r_{240}/n_{240}		是	是
零方差列剔除	r_1/n_1、r_{170}/n_{171}、r_{172}/n_{173}	存在非空值，但全样本取值唯一，无区分能力	是	是
	r_{174}/n_{175}、r_{188}/n_{192}、r_{196}/n_{197}		是	是
	r_{198}/n_{206}、r_{211}/n_{232}、r_{233}/n_{245}		是	是
	r_{184}/n_{194}		—	是
	r_{244}		是	—
	n_{244}		—	是
冗余归一化列剔除	n_5、n_9、n_{177}、n_{181}、n_{182}、n_{183}、n_{187}、n_{190}、n_{195}、n_{199}	$\lvert\rho_s\rvert > 0.8$，归一化读数可由原始读数单调映射得到	是	是
	n_{184}、n_{194}		是	—

注：“是”代表该型号剔除此字段；“—”代表该型号未出现此字段。第三步相关 Spearman 系数见附表 B.1；MB2 数据集内 r_{184}、r_{194} 第二步已判定为零方差并剔除，故第三步不再处理对应 n_{184}、n_{194}。

B SMART 原始与归一化读数 Spearman 相关系数

附表 B.1 统计正文公式 (3-5) 所需的相关性指标，仅保留第一步、第二步筛选后的有效属性，分别对 MB1、MB2 全量盘日日志配对计算原始读数 r_i 与归一化读数 n_i 的 Spearman 相关系数 ρ_s。

附表 B.1 筛选后 SMART 原始/归一化读数 Spearman 相关系数

属性 ID	SMART 属性名称	MB1 ρ_s	MB2 ρ_s	最终保留字段
5	重映射扇区计数	-1.0000	-1.0000	r_5
9	通电时间累计	-0.9682	-0.9681	r_9
12	通电周期计数	-0.0183	-0.0472	r_{12}/n_{12}
177	磨损范围对比值	-0.9274	-0.8269	r_{177}
180	未用的备用块计数	0.0407	0.1512	r_{180}/n_{180}
181	编程失败计数	-1.0000	-1.0000	r_{181}
182	擦写失败计数	-1.0000	-1.0000	r_{182}
183	串口降速错误计数	-1.0000	-1.0000	r_{183}
184	点到点错误检测计数	-1.0000	—	r_{184}
187	无法校正的错误	-1.0000	-1.0000	r_{187}
190	气流温度	-1.0000	-1.0000	r_{190}
194	温度	-1.0000	—	r_{194}
195	编程错误块计数	-1.0000	-1.0000	r_{195}
199	Ultra ATA CRC 错误率	-0.9987	-0.9993	r_{199}
241	LBA 写入总数	-0.0842	-0.1709	r_{241}/n_{241}
242	LBA 读取总数	-0.0881	-0.0922	r_{242}/n_{242}

注：ρ_s 依据正文公式 (3-5) 在同 ID 原始、归一化读数配对计算；“—”代表该型号下此字段存在零方差，无有效相关样本。全文以 $|\rho_s| > 0.8$ 作为冗余判定阈值，超阈值仅保留原始读数 r_i，否则 r_i、n_i 全部保留。

C 盘级基线对比分轮明细

附表 C.1、C.2 对应正文第3.4.3 节基线对比实验，给出 MB1/MB2 各方法在 R1–R3 的盘级 TP、FP 与四项指标；正文表 3.10、3.11 与图 3.12 仅汇报三轮平均。加粗与下划线分别表示同列最优与次优；平均行中 TP、FP 为三轮检出/误报总数总和。

附表 C.1 MB1 盘级性能对比（分轮明细）

方法	轮次	TP	FP	TPR	FPR	Precision	$F_{0.5}$
本文方法	R1	36	**0**	0.783	**0**	**1.000**	**0.947**
	R2	46	2	0.708	5.41×10^{-5}	0.958	0.895
	R3	66	1	0.710	2.73×10^{-5}	**0.985**	0.914
	平均	148	3	0.733	2.71×10^{-5}	**0.981**	**0.919**
Mut-Rule	R1	**38**	38	**0.809**	1.03×10^{-3}	0.500	0.541
	R2	**50**	44	**0.769**	1.19×10^{-3}	0.532	0.567
	R3	70	36	0.753	9.83×10^{-4}	0.660	0.677
	平均	**158**	118	**0.777**	1.07×10^{-3}	0.564	0.595
RF	R1	37	1	0.804	2.71×10^{-5}	0.974	0.934
	R2	47	3	0.723	8.12×10^{-5}	0.940	0.887
	R3	**73**	9	**0.768**	2.46×10^{-4}	0.890	0.863
	平均	157	13	0.765	1.18×10^{-4}	0.935	0.895
AE	R1	1	54	0.022	1.46×10^{-3}	0.018	0.019
	R2	5	51	0.079	1.38×10^{-3}	0.089	0.087
	R3	1	43	0.011	1.17×10^{-3}	0.023	0.019
	平均	7	148	0.038	1.34×10^{-3}	0.043	0.042

续下表

续上表

方法	轮次	TP	FP	TPR	FPR	Precision	$F_{0.5}$
TCAN	R1	0	**0**	0.000	**0**	0.000	0.000
	R2	0	**0**	0.000	**0**	0.000	0.000
	R3	0	**0**	0.000	**0**	0.000	0.000
	平均	0	**0**	0.000	**0**	0.000	0.000
MVT-RF	R1	**37**	2	**0.804**	5.42×10^{-5}	0.949	0.916
	R2	**48**	1	**0.738**	2.71×10^{-5}	**0.980**	**0.920**
	R3	71	2	0.763	5.46×10^{-5}	0.973	**0.922**
	平均	156	5	**0.769**	4.53×10^{-5}	0.967	**0.919**
Mut-RF	R1	1	1	0.022	2.71×10^{-5}	0.500	0.094
	R2	1	1	0.016	2.70×10^{-5}	0.500	0.070
	R3	2	2	0.022	5.46×10^{-5}	0.500	0.094
	平均	4	4	0.020	3.63×10^{-5}	0.500	0.086

注：平均行中 TP、FP 为三轮实验检出/误报总数总和。

附表 C.2 MB2 盘级性能对比（分轮明细）

方法	轮次	TP	FP	TPR	FPR	Precision	$F_{0.5}$
本文方法	R1	**7**	**0**	**0.304**	**0**	**1.000**	**0.686**
	R2	**2**	**0**	**0.200**	**0**	**1.000**	**0.556**
	R3	**1**	**0**	**0.056**	**0**	**1.000**	**0.227**
	平均	**10**	**0**	**0.187**	**0**	**1.000**	**0.490**
Mut-Rule	R1	**8**	166	**0.348**	4.02×10^{-3}	0.046	0.056
	R2	**3**	130	**0.300**	3.15×10^{-3}	0.023	0.028
	R3	**3**	125	**0.167**	3.04×10^{-3}	0.023	0.028
	平均	**14**	421	**0.271**	3.40×10^{-3}	0.031	0.037
RF	R1	4	**0**	0.182	**0**	**1.000**	0.526
	R2	0	**0**	0.000	**0**	0.000	0.000
	R3	**1**	1	**0.056**	2.43×10^{-5}	0.500	0.192
	平均	5	1	0.079	8.14×10^{-6}	0.500	0.240

续下表

续上表

方法	轮次	TP	FP	TPR	FPR	Precision	$F_{0.5}$
AE	R1	4	111	0.182	2.69×10^{-3}	0.035	0.041
	R2	1	68	0.100	1.65×10^{-3}	0.014	0.017
	R3	**1**	56	**0.056**	1.36×10^{-3}	0.018	0.020
	平均	6	235	0.112	1.90×10^{-3}	0.022	0.026
TCAN	R1	0	**0**	0.000	**0**	0.000	0.000
	R2	0	**0**	0.000	**0**	0.000	0.000
	R3	0	**0**	0.000	**0**	0.000	0.000
	平均	0	**0**	0.000	**0**	0.000	0.000
MVT-RF	R1	6	**0**	0.273	**0**	**1.000**	0.652
	R2	1	**0**	0.100	**0**	**1.000**	0.357
	R3	**1**	**0**	**0.056**	**0**	**1.000**	**0.227**
	平均	8	**0**	0.143	**0**	**1.000**	0.412
Mut-RF	R1	0	**0**	0.000	**0**	0.000	0.000
	R2	0	**0**	0.000	**0**	0.000	0.000
	R3	0	**0**	0.000	**0**	0.000	0.000
	平均	0	**0**	0.000	**0**	0.000	0.000

注：平均行中 TP、FP 为三轮实验检出/误报总数总和。

D 智慧 SSD 运维系统设计明细表

本节汇总正文第五章用例分解、数据库字段设计、REST 接口定义与功能测试用例等工程明细，供查阅完整实现规范时使用。

附表 D.1 系统核心用例说明

用例名称	参与者	用例描述
维护 SSD 盘资产	运维用户	对 SSD 资产主数据进行统一管理
查询 SSD 盘列表	运维用户	按序列号、型号等条件检索 SSD 列表
新增 SSD 盘信息	运维用户	录入序列号、型号、容量、厂商等字段
编辑 SSD 盘信息	运维用户	修改已有 SSD 的基础属性
删除 SSD 盘记录	运维用户	删除无效或下线的 SSD 资产记录
管理 SMART 日志	运维用户	对 SSD 运行日志进行维护与检索
按条件检索日志	运维用户	按序列号与日期范围查询 SMART 日志
导入/维护日志	运维用户	导入或编辑 SMART 原始属性记录
生成故障预警	定时调度器	周期执行预测流程并写入预警表
手动触发故障预警	运维用户	在管理界面手动发起一次增量预测
拉取增量日志	系统	读取尚未参与推理的新增 SMART 日志
执行模型推理	系统	调用故障预测算法服务完成特征构造与模型推理
写入预警记录	系统	将预警日期、评分与日志快照写入数据库
处置预警记录	运维用户	查看预警详情并更新处置状态
确认故障	运维用户	将预警标记为 confirmed，并登记对应故障记录
忽略预警	运维用户	将预警标记为 ignored
维护故障记录	运维用户	对已确认或手工登记的故障事件进行统一管理
查询故障记录	运维用户	按序列号、日期等条件检索故障事件
登记故障记录	运维用户/系统	在故障管理页面手工登记，或由确认预警流程自动写入

附表 D.2 磁盘信息表字段设计

字段名	字段类型	字段表述	备注
id	BIGINT	记录主键	主键
serial_number	VARCHAR	磁盘序列号	
model_type	VARCHAR	磁盘型号	
capacity	BIGINT	容量（单位：KB）	
manufacturer	VARCHAR	制造商	
created_at	DATETIME	记录创建时间	

附表 D.3 SMART 日志表字段设计

字段名	字段类型	字段表述	备注
id	BIGINT	记录主键	主键
disk_id	BIGINT	关联磁盘 ID	外键
ds	DATE	日志采集日期	
raw_5	DECIMAL	重映射扇区计数	
raw_9	DECIMAL	通电时间	
raw_194	DECIMAL	温度	
raw_195	DECIMAL	硬件 ECC 恢复	
created_at	DATETIME	记录创建时间	

注：表中仅列出部分代表性 SMART 字段，其余属性可按原始计数字段的相同命名规范扩展。

附表 D.4 故障记录表字段设计

字段名	字段类型	字段表述	备注
id	BIGINT	记录主键	主键
disk_id	BIGINT	关联磁盘 ID	外键
fault_date	DATE	故障发生日期	
source	VARCHAR	来源（人工确认/自动写入）	
created_at	DATETIME	记录创建时间	

附表 D.5 预警记录表字段设计

字段名	字段类型	字段表述	备注
id	BIGINT	记录主键	主键
disk_id	BIGINT	关联磁盘 ID	外键
warning_date	DATE	预警生成日期	
status	VARCHAR	处置状态（pending/confirmed/ignored）	
score	DECIMAL	预警评分或概率	
logs_snapshot	JSON	关联日志快照	
handled_at	DATETIME	处置时间	
created_at	DATETIME	记录创建时间	

附表 D.6 系统主要 REST 接口设计

接口路径	方法	功能说明
/api/disks	GET/POST	查询磁盘列表或新增磁盘资产
/api/disks/{id}	GET/PUT/DELETE	查询、更新或删除指定磁盘
/api/logs	GET/POST	按序列号与日期查询或导入 SMART 日志
/api/warnings	GET	分页查询预警记录及处置状态
/api/warnings/{id}	GET	查询单条预警详情及关联日志快照
/api/warnings/{id}/confirm	POST	确认故障并写入故障记录
/api/warnings/{id}/ignore	POST	忽略当前预警
/api/faults	GET/POST	查询或登记故障记录
/api/predict/run	POST	手动触发一次增量预测任务

附表 D.7 系统功能测试用例及结果

测试模块	测试步骤与预期结果	结果
SSD 设备资产管理	新增 SSD 设备资产信息，列表可正常检索展示	通过
SSD 设备资产管理	修改 SSD 容量并保存，详情页数据同步更新	通过
SSD 设备资产管理	删除测试设备记录，列表不再展示该条目	通过
SMART 日志管理	按设备序列号导入 SMART 日志，支持日期检索	通过
SMART 日志管理	修改日志温度字段，保存后查询数据一致	通过
预警生成	执行预测任务，预警表自动新增 pending 待处置记录	通过
预警处置	查看预警详情，正常展示预测评分与日志快照	通过
预警处置	确认待处置预警，状态更新为 confirmed 已确认故障	通过
预警处置	确认预警后，故障表自动生成对应故障条目	通过
预警处置	忽略待处置预警，状态更新为 ignored 已忽略	通过
故障管理	手动录入故障记录，支持按日期回溯查询	通过
接口调用	调用预警列表接口，返回分页数据与状态字段	通过

E 智慧 SSD 运维系统界面截图集

本节汇总智慧 SSD 运维系统四类运维页面的前端界面截图，包括磁盘管理、日志管理、故障管理与预警处置；正文第 5.6 图已给出故障处理页作为闭环实现代表，此处收录全部页面供对照查阅。

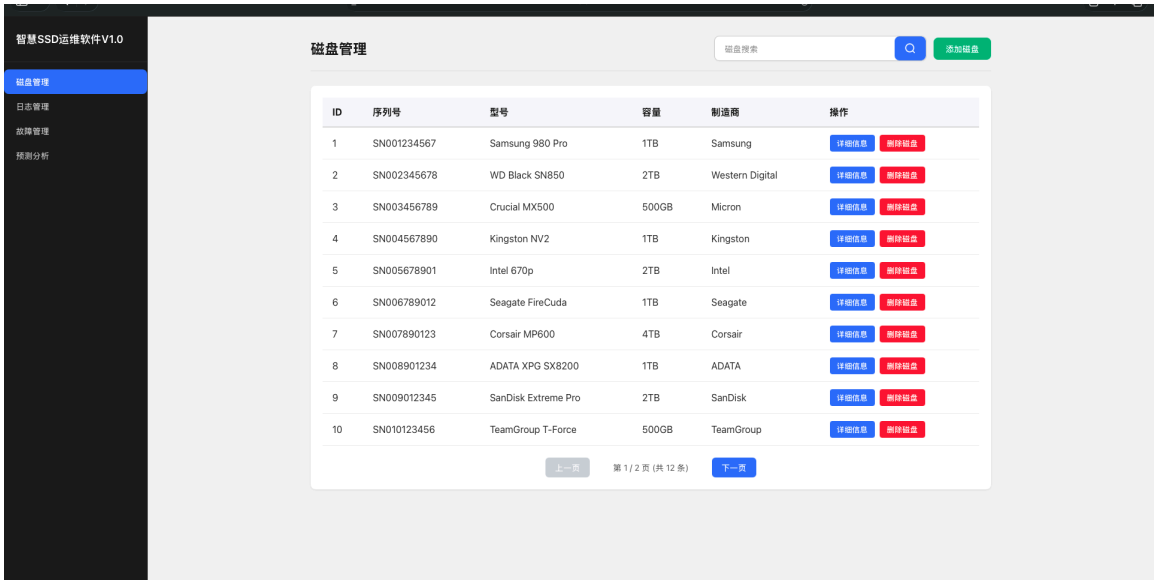


图 E.1 磁盘管理界面

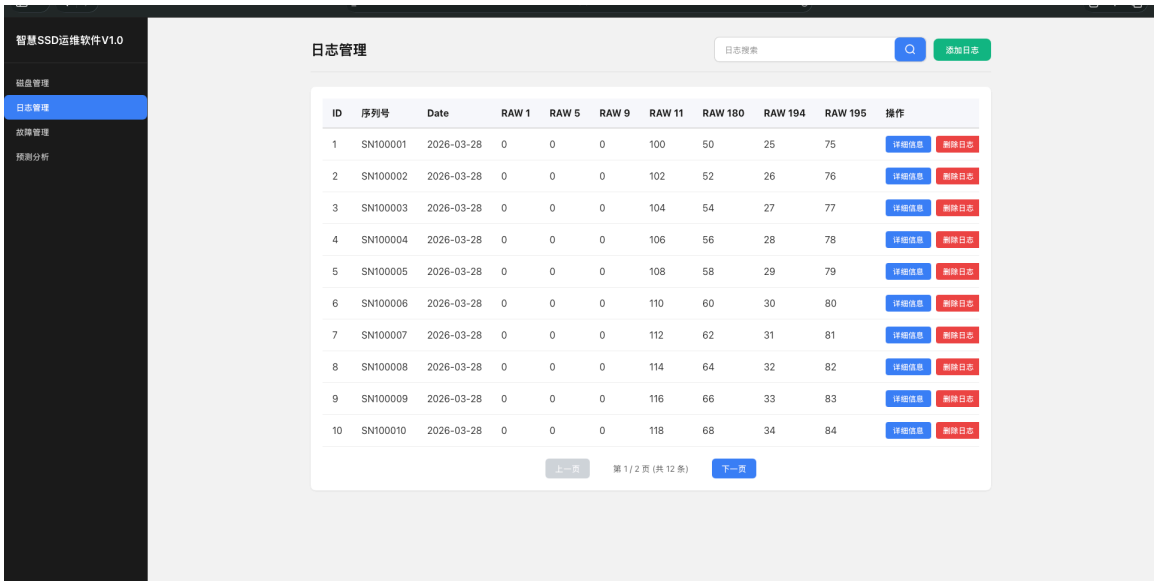


图 E.2 日志管理界面

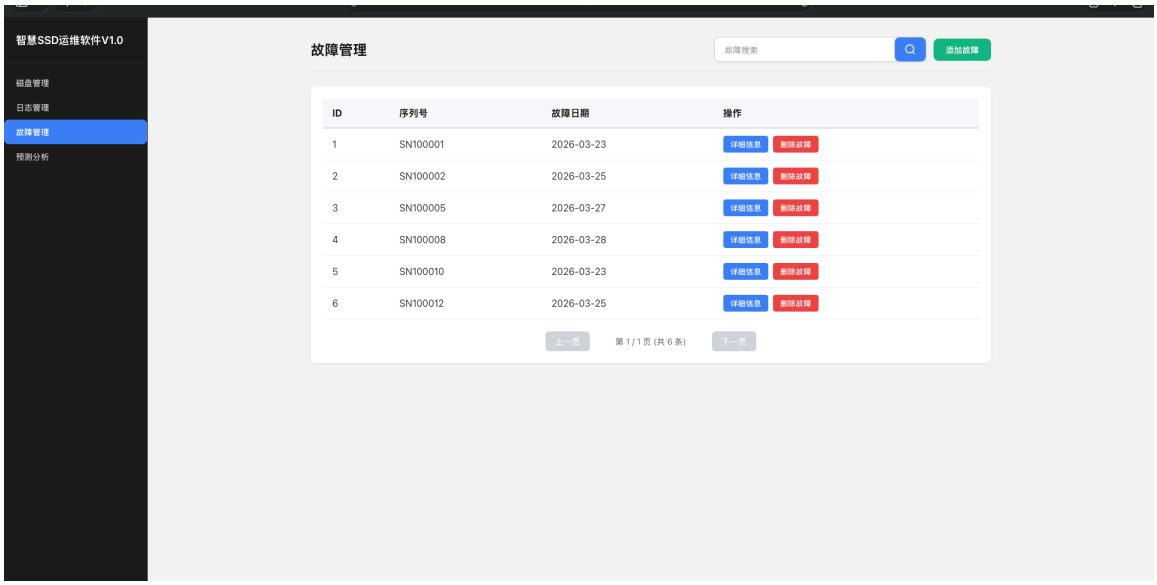


图 E.3 故障管理界面

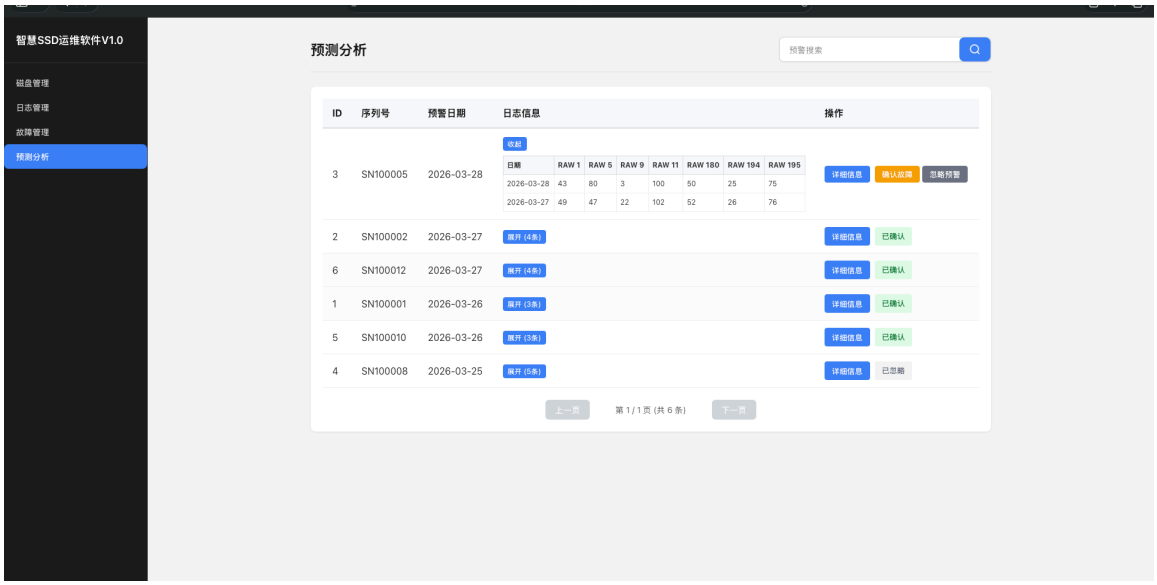


图 E.4 故障处理界面